



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

KATEDRA INFORMATYKI BIZNESOWEJ I INŻYNIERII ZARZĄDZANIA

Projekt dyplomowy / Praca dyplomowa

**Porównanie algorytmów rekomendacyjnych
(Filtrowanie Kolaboracyjne, Uczenie Głębokie, Grafowe
Sieci Neuronowe) na przykładzie portalu
streamingowego**

Comparison of recommendation algorithms (Collaborative Filtering,
Deep Learning, Graph Neural Networks) using a streaming platform as
an example

Autor: Jakub Sornat

Kierunek studiów: Informatyka i Ekonometria

Opiekun: dr hab. Iwona Skalna

Kraków, 2026

Spis treści

Wstęp	1
1 Wprowadzenie do problematyki systemów rekomendacyjnych	3
1.1 Zjawisko przeciążenia informacyjnego i specyfika rynku VOD	3
1.2 Definicje, formalizm matematyczny i struktura danych w personalizacji . .	4
1.3 Ewolucja technologiczna paradygmatów rekomendacyjnych	5
1.4 Przegląd literatury naukowej	6
1.5 Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych	9
2 Metodyka Badań	11
2.1 Środowisko wykonawcze	11
2.2 Opis i przygotowanie danych	12
2.2.1 Zjawisko rzadkości macierzy interakcji (Data Sparsity)	13
2.2.2 Rozkład popularności treści i zjawisko długiego ogona (Long-Tail) .	13
2.2.3 Transformacja ocen jawnych w sygnał dorozumiany (Implicit Feed-back)	14
2.2.4 Filtrowanie gęstości danych (k-core filtering) i aktywność użytkowników	15
2.2.5 Reprezentacja w postaci grafu dwudzielnego	15
2.2.6 Konwersja do formatu plików atomowych frameworka RecBole . . .	16
2.2.7 Protokół podziału danych i próbkowanie negatywne	16
2.2.8 Charakterystyka statystyczna przetworzonych zbiorów	16
2.3 Algorytmy filtrowania kolaboracyjnego	17
2.4 Algorytmy uczenia głębokiego	17
2.5 Algorytmy grafowych sieci neuronowych	17
2.6 Metryki oceny	17
3 Tytuł rozdziału 3	18
Podsumowanie	19
Bibliografia	20

Wstęp

Wyznaczanie spersonalizowanych rekomendacji w cyfrowych usługach rozrywkowych stanowi jedno z kluczowych wyzwań współczesnej informatyki stosowanej i ekonometrii. Dynamiczny rozwój metod uczenia maszynowego doprowadził do powstania odmiennych paradygmatów obliczeniowych – od klasycznej algebry macierzowej, przez głębokie sieci neuronowe, po algorytmy wykorzystujące osadzenia na strukturach grafowych. W literaturze naukowej brakuje jednak bezpośrednich, ujednoliconych badań porównawczych weryfikujących zarówno jakość porządkowania rankingowego, jak i czystą wydajność obliczeniową tych podejść w specyficznych warunkach konsumpcji mediów.

Powyższe uwarunkowania definiują **problem badawczy** niniejszej pracy magisterskiej, którym jest empiryczna ewaluacja relatywnej skuteczności personalizacji oraz narzutu serwerowego algorytmów reprezentujących trzy generacje technologiczne systemów rekomendacyjnych (faktoryzacji macierzy SVD/BPR, głębokiej architektury NCF oraz grafowych modeli LightGCN/KGCN) na zbiorze danych interakcji z dorozumianą informacją zwrotną (*implicit feedback*).

Jako cel główny pracy przyjęto zbudowanie ujednoliconego środowiska badawczego przy użyciu pakietu RecBole, przeprowadzenie kompleksowej optymalizacji hiperparametrów oraz ilościową ocenę porównawczą dokładności rankingowej i wydajności trzech reprezentatywnych klas modeli na zbiorze danych z obszaru VOD.

Dla realizacji celu głównego wyznaczono następujące **cele szczegółowe**:

1. Przygotowanie oraz analiza eksploracyjna (EDA) zbioru danych interakcji typu *implicit feedback*.
2. Skonfigurowanie powtarzalnego środowiska eksperymentalnego w języku Python z wykorzystaniem frameworka RecBole.
3. Przeprowadzenie procesu strojenia hiperparametrów (*hyperparameter tuning*) dla każdego z badanych modeli w celu wyznaczenia ich optymalnych konfiguracji.
4. Ilościowa ewaluacja wyników za pomocą metryk jakości rankingu (NDCG@k, Recall@k), miary błędu RMSE oraz pomiaru czasu uczenia i wnioskowania online.

W pracy sformułowano **hipotezę badawczą główną** (H_1):

Zastosowanie modeli Grafowych Sieci Neuronowych (LightGCN oraz KGCN) pozwala na osiągnięcie statystycznie istotnie wyższej trafności rekomendacji rankingowych Top-N (mierzonej wskaźnikami NDCG@k oraz Recall@k) na zbiorze danych VOD w porównaniu do klasycznej faktoryzacji macierzy SVD oraz głębokiej sieci NCF.

Sformułowano również **hipotezę pomocniczą** (H_2):

Wzrost dokładności rekomendacji uzyskiwany przez modele grafowe wiąże się z większym narzutem obliczeniowym w fazie treningu, jednak czas generowania predykcji w fazie wnioskowania online (*inference*) dla modeli LightGCN oraz KGCN mieści się w granicach akceptowalnych dla systemów czasu rzeczywistego VOD (poniżej 1 sekundy).

Podstawową **metodą badawczą** wykorzystaną w pracy jest eksperyment obliczeniowy przeprowadzony w środowisku Python 3.12 przy użyciu frameworka RecBole oraz bibliotek PyTorch i SciPy.

Układ pracy jest następujący: W **Rozdziale 1** omówiono uwarunkowania rynkowe VOD, formalizm matematyczny rekomendacji, ewolucję algorytmicznych oraz kompromisy wdrożeniowe. W **Rozdziale 2** przedstawiono przyjętą metodykę badań, ściśle sformułowania algorytmów (SVD, NCF, LightGCN/KGCN), zbiór danych oraz wskaźniki oceny. W **Rozdziale 3** zamieszczono przebieg eksperymentów obliczeniowych, zestawienie wyników ilościowych oraz dyskusję w kontekście wymagań produkcyjnych. Pracę zamyka **Podsumowanie**, zawierające syntezę wniosków oraz weryfikację postawionych hipotez badawczych.

1 Wprowadzenie do problematyki systemów rekomendacyjnych

Niniejszy rozdział wprowadza w ramy teoretyczne, formalizm matematyczny oraz uwarunkowania rynkowe systemów rekomendacyjnych, stanowiąc punkt wyjścia dla dalszych analiz algorytmicznych. Analiza obejmuje kognitywne aspekty przeciążenia informacyjnego na rynku VOD, formalną kategoryzację personalizacji, ewolucyjne ery technologiczne (od prostej algebry macierzy po złożone struktury grafowe) oraz kluczowe kompromisy wdrożeniowe.

1.1 Zjawisko przeciążenia informacyjnego i specyfika rynku VOD

Przejście od tradycyjnych form konsumpcji mediów do środowiska cyfrowego wywołało bezprecedensową transformację na rynku rozrywkowym. Widzowie systematycznie odchodzą od tradycyjnej telewizji, charakteryzującej się sztywną ramówką, na rzecz platform strumieniujących wideo na żądanie (VOD), które zapewniają asynchroniczny dostęp do materiałów. Serwisy takie jak Netflix, HBO Max, Amazon Prime Video oraz lokalne Player.pl i TVP VOD dysponują gigantycznymi bibliotekami, oferując natychmiastowy dostęp do setek tysięcy tytułów filmowych i serialowych.

Ta radykalna poprawa dostępności zrodziła jednak nowe wyzwanie. W czasach tak ogromnej różnorodności multimediiów użytkownicy konfrontowani są ze zjawiskiem zwanym cyfrową klęską urodzaju lub przeciążeniem informacyjnym [1]. Skalę tego problemu obrazują twarde statystyki: globalna baza filmowa IMDb zawiera ponad 30 milionów tytułów [2], platforma muzyczna Spotify oferuje ponad 100 milionów utworów [3], a serwis BookBeat udostępnia ponad milion pozycji [4].

Podaż setek tysięcy produkcji na pojedynczej platformie generuje efekt paradoksu wyboru. Obszerna baza treści przytłacza użytkownika, przez co fizyczne zapoznanie się z całą ofertą staje się niemożliwe, a podjęcie ostatecznej decyzji wymaga znacznego wysiłku poznawczego. Tego typu przeciążenie w skrajnych przypadkach prowadzi do frustracji widza i porzucenia usługi. Rozwiązania klasyczne, takie jak standardowe wyszukiwarki czy uniwersalne rankingi redakcyjne, są niewystarczające – wymagają inicjatywy lub promują treści nieznajdujące pokrycia w indywidualnym guście odbiorcy [5].

Z tego powodu zaawansowane systemy rekomendacyjne stały się kluczowym narzędziem personalizacji na rynku VOD [6]. Ich główną rolą jest filtrowanie gigantycznych zbiorów danych i drastyczne zmniejszenie przeciążenia informacyjnego poprzez automatyczne dostarczanie trafnych propozycji. Na platformach cyfrowych rekomendacje są podstawowym mechanizmem utrzymania uwagi widza. Zjawisko to ilustruje przykład serwisu Netflix, gdzie aż 80% całkowitej aktywności widzów jest napędzane przez spersonalizowane sugestie algorytmiczne [7].

1.2 Definicje, formalizm matematyczny i struktura danych w personalizacji

Historycznie pojęcie systemów rekomendacji ewoluowało wraz z rozwojem technologii sieciowych. Pierwsze rozwiązania miały charakter ściśle kooperacyjny. Klasycznym przykładem jest stworzony w 1992 roku przez Xerox Palo Alto Research system Tapestry, uznawany za pierwowzór filtrowania kolaboracyjnego do agregowania manualnych adnotacji grupy użytkowników.

Jedna z pierwszych oficjalnych definicji naukowych, zaproponowana w 1997 roku przez Resnicka i Variana, kładła nacisk na aspekt współpracy między ludźmi, opisując system rekomendacyjny jako narzędzie agregujące i kierujące rekomendacje do odpowiednich odbiorców [8]. Wraz z rozwojem zautomatyzowanych metod uczenia maszynowego definicja uległa rozszerzeniu. Według R. Burke'a (2002), systemem rekomendacji jest każdy program, który generuje zindywidualizowane sugestie lub ma za zadanie kierować użytkownika w spersonalizowany sposób do interesujących obiektów w dużej przestrzeni opcji [9].

W ujęciu formalnym, opartym na teorii mnogości i funkcji użyteczności [10], problem rekomendacji definiuje się następująco: niech C będzie zbiorem użytkowników, a O zbiorem wszystkich możliwych do zarekomendowania obiektów. Funkcja użyteczności:

$$u: C \times O \rightarrow W \quad (1)$$

mierzy przydatność danego obiektu $o \in O$ dla użytkownika $c \in C$, gdzie W jest uporządkowanym zbiorem (np. ocen). Zadaniem algorytmu jest znalezienie dla każdego użytkownika takiego podzbioru obiektów R_c^* , który maksymalizuje dla niego funkcję użyteczności:

$$R_c^* = \{r \in O: u(c, r) = \max_{o \in O} u(c, o)\} \quad (2)$$

Wyniki działania algorytmów prezentowane są użytkownikowi w dwóch głównych formach [11]:

1. **Przewidywanie ocen (Rating Prediction):** model prognozuje konkretną wartość liczbową oceny (np. 4,5/5 gwiazdek), co stanowiło fundament słynnego konkursu Netflix Prize (2006–2009) i algorytmu Cinematch.
2. **Prognoza rankingu (Top-N Ranking):** system generuje uporządkowaną listę N najlepszych pozycji specyficznie dopasowanych do użytkownika.

W systemach rozrywkowych VOD preferuje się prognozy rankingowe (Top-N). Jak wykazuje Harald Steck [12], dla biznesu kluczowe jest zaprezentowanie właściwych obiektów na górze listy, a nie przewidywanie dokładnych ocen liczbowych, których użytkownicy i tak rzadko udzielają.

Skuteczność personalizacji zależy bezpośrednio od dostępu do danych wejściowych, które dzielimy na trzy wymiary [1]:

- **Profil Użytkownika:** obejmuje parametry statyczne (dane demograficzne) oraz dynamiczne (historia interakcji).
- **Charakterystyka Przedmiotów (metadane):** atrybuty obiektów VOD (gatunki, obsada), a także zaawansowane cechy generowane automatycznie przez systemy rozpoznawania wideo (VCR – *Video Content Recognition*) – np. tempo montażu czy kolorystyka.
- **Logi Transakcyjne (*Clickstream*):** sekwencyjne zapisy zachowań użytkowników rejestrowane w czasie rzeczywistym.

Informację zwrotną o zachowaniach użytkowników dzielimy na jawne oceny (*explicit feedback*, np. gwiazdki), które są dokładne, ale skrajnie rzadkie (*data sparsity*), oraz doro-
zumiane ślady aktywności (*implicit feedback*, np. czas oglądania – *dwell time*, kliknięcia),
stanowiące obfite, lecz zaszumione źródło wiedzy.

1.3 Ewolucja technologiczna paradygmatów rekomendacyjnych

Ewolucję technologiczną systemów rekomendacyjnych można podzielić na trzy główne ery:

Era Tradycyjna (Foundational RS) Rozwój metodyczny zapoczątkowały trzy podejścia [13]:

- **Filtrowanie oparte na treści (Content-Based Filtering – CBF):** rekomenduje obiekty podobne do wybieranych w przeszłości na podstawie iloczynu skalarnego cech $\hat{r}_{ui} = \theta(u)^T \phi(i)$ (miary cosinusowe, Jaccarda). Główną wadą jest nadmierna specjalizacja (*overspecialization*) i bańka filtracyjna.
- **Filtrowanie kolaboracyjne (Collaborative Filtering – CF):** analizuje zachowania całej społeczności, uzupełniając rzadką macierz ocen. Dzieli się na metody oparte na pamięci (*Memory-Based*: UBCF, IBCF z algorytmem k -NN) oraz metody oparte na modelach (*Model-Based*: Faktoryzacja Macierzy SVD, ALS), redukujące wymiarowość do czynników ukrytych (*latent factors*).
- **Modele hybrydowe:** łączą podejścia kolaboracyjne i treściowe. R. Burke [9] wyróżnia 5 głównych technik hybrydyzacji: łączenie wyników (*weighted*), dodawanie cech (*feature addition*), podejście łańcuchowe (*cascading*), meta-model oraz przełączanie modeli (*switching*).

Era Uczenia Głębokiego (Deep Learning-Based RS) Wprowadzenie głębokich sieci neuronowych pozwoliło na automatyczną ekstrakcję cech oraz mapowanie nieliniowych interakcji [14]. W tej erze stosuje się wielowarstwowe perceptrony (MLP) zastępujące iloczyn skalarny w architekturze Neural Collaborative Filtering (NCF), autoenkodery (VAE), sieci splotowe (CNN) do analizy klatek wideo oraz sieci rekurencyjne (RNN/LSTM) do sekwencji.

Era Struktur Grafowych i Modelowania Sekwencyjnego Najbardziej zaawansowane współczesne modele odchodzą od statycznych tabel na rzecz dynamiki grafowej [15, 16]:

- **Systemy sekwencyjne i sesyjne (SBR):** modelują intencje użytkownika w ramach pojedynczej sesji (łańcuchy Markowa, reguły sekwencyjne).
- **Głębokie modele grafowe (GNN):** reprezentują system jako graf heterogeniczny. Modele oparte na propagacji osadzeń (LightGCN) oraz grafach wiedzy (KGCN) umożliwiają przechwytywanie relacji wyższego rzędu między użytkownikami, filmami i cechami semantycznymi.
- **Uczenie ze wzmocnieniem (Reinforcement Learning):** traktuje rekomendację jako dynamiczny proces decyzyjny z udziałem agenta w celu optymalizacji długoterminowej satysfakcji.

1.4 Przegląd literatury naukowej

W niniejszym podrozdziale dokonano szczegółowego i krytycznego przeglądu literatury naukowej z zakresu systemów rekomendacyjnych, ze szczególnym uwzględnieniem podejść opartych na filtrowaniu kolaboracyjnym, sztucznych sieciach neuronowych oraz grafowych strukturach wiedzy. Analiza obejmuje zarówno klasyczne metody faktoryzacji, jak i najnowsze osiągnięcia z obszaru głębokiego uczenia w odniesieniu do specyficznych warunkowań rynku wideo na żądanie (VOD). Przegląd literatury naukowej w kontekście usług streamingowych warto rozpocząć od analizy przełomowego konkursu Netflix Prize (2006–2009) omówionego przez Hallinana i Striphasa [17]. Autorzy wykazują, że publiczne udostępnienie zbioru obejmującego ponad 100 milionów ocen przypisanych przez 480 tysięcy użytkowników dla 17 tysięcy filmów zdefiniowało nowożytną erę kultury algorytmicznej (*algorithmic culture*). Rywalizacja o poprawę celności predykcji błędu RMSE o 10% względem algorytmu Cinematch udowodniła całkowitą niewystarczalność tradycyjnych metod opartych na sąsiedztwie (*neighborhood-based CF*), które wykazywały skrajną podatność na narzut pamięciowy i brak skalowalności. To właśnie Netflix Prize spopularyzował modele czynników ukrytych, w tym w szczególności faktoryzację macierzy (SVD).

Hallinan i Striphas zwracają również uwagę na skomplikowane zjawiska polaryzacyjne, określane jako wyzwanie *Napoleon Dynamite problem*, w którym przewidywanie gustów użytkowników dla niszowych i polaryzujących treści wymagało odrzucenia pojedynczych algorytmów na rzecz wielkich zespołów modeli hybrydowych (*ensemble learning*).

Kompleksowe i wieloaspektowe ujęcie podstaw teoretycznych oraz wyzwań wdrożeniowych przedstawia praca Krawczuka [5]. Autor przeprowadza szczegółową analizę poszczególnych paradygmatów rekomendacji, oceniając ich przydatność w warunkach produkcyjnych. W pierwszej kolejności analizuje techniki filtrowania opartego na treści (Content-Based Filtering – CBF), wykazując, że ich podstawową zaletą jest wysoka niezależność od aktywności reszty społeczności oraz odporność na rzadkość ocen innych użytkowników. Zauważa jednak przy tym istotne ograniczenia natury poznawczej i algebry czystych atrybutów: algorytmy CBF wykazują tendencję do nadmiernej specjalizacji (*overspecialization*), zamykając użytkownika w tzw. bańce filtracyjnej i uniemożliwiając odkrycie niespodziewanych, lecz trafnych pozycji (*serendipity*), a także zmagają się z problemem zimnego startu dla nowych obiektów bez uzupełnionych metadanych.

Przechodząc do filtrowania kolaboracyjnego (Collaborative Filtering – CF), Krawczuk akcentuje, że wykorzystywanie „mądrości tłumu” (*wisdom of the crowd*) pozwala na rekomendowanie treści o strukturze niezależnej od ich opisu semantycznego. Niemniej jednak metody te cierpią na krytyczną rzadkość ocen (*data sparsity*), gdzie wskaźnik wypełnienia macierzy ocen R często nie przekracza 1%, oraz na skrajny problem zimnego startu (*cold-start*) dla nowych uczestników systemu. Jako rozwiązanie kompromisowe autor omawia zaawansowane architektury hybrydowe, które poprzez strategie łączone (*weighted*), sekwencyjne (*cascading*) czy rozszerzanie cech (*feature augmentation*) skalają cechy treściowe z sygnałami interakcji. Niezwykle istotnym wkładem pracy Krawczuka jest również analiza wymogów architektonicznych: wskazuje on, że wdrożenie przemysłowe na platformach VOD wymaga utrzymania niskiego czasu odpowiedzi (*latency*) przy jednoczesnej skalowalności obliczeniowej. Podsumowując ewaluację, Krawczuk dowodzi, że w serwisach wideo nadrzędne znaczenie biznesowe ma porządek propozycji na ekranie, w związku z czym metryki rankingowe Top- K , takie jak MRR, NDCG oraz Precision@ k , stanowią jedyne adekwatne kryterium oceny modeli w tym środowisku.

Praca He i in. z 2017 roku skupia się na wykorzystaniu głębokich sieci neuronowych do tworzenia systemów rekomendacyjnych [18], wprowadzając architekturę Neural Collaborative Filtering (NCF). W pierwszej części publikacji autorzy uzasadniają potrzebę zastąpienia klasycznego iloczynu skalarnego (*inner product*) nieliniowymi warstwami neuronowymi, wykazując ograniczenia liniowych metod faktoryzacji macierzy oraz przedstawiając teoretyczne fundamenty stojące za proponowanym rozwiązaniem. Do przeprowadzania eksperymentów empirycznych wykorzystano zbiory danych MovieLens 1M oraz Pinterest. W przypadku MovieLens 1M oceny jawne (w skali 1–5) przekształcono na dane

ukryte (*implicit feedback*), traktując każdą ocenę jako obecność interakcji ($y_{ui} = 1$), zbiór Pinterest poddano natomiast filtracji typu *20-core* (odrzucając użytkowników z mniej niż 20 akcjami). W obu zbiorach zastosowano procedurę podziału *Leave-One-Out*, w której ostatnią interakcję odłożono do testów, przedostatnią do walidacji, a pozostałe do uczenia, łącząc w zestawie testowym każdy pozytywny obiekt z 99 losowymi próbkami negatywnymi (*negative sampling*). W celach porównawczych zestawiono architekturę NCF z szeregiem znanych metod referencyjnych: niepersonalizowanym baseline’em popularności ItemPop, modelem opartym na sąsiedztwie obiektów ItemKNN, faktoryzacją macierzy z optymalizacją błędu porządkowania par BPR (*Bayesian Personalized Ranking*) oraz zoptymalizowaną punktowo faktoryzacją dla danych dorozumianych eALS (*efficient Alternating Least Squares*). Ewaluację przeprowadzono na podstawie dwóch podstawowych metryk jakości rankingu Top-10: Hit Ratio ($HR@10$), mierzącą obecność poszukiwanego elementu testowego wśród pierwszych 10 propozycji, oraz Normalized Discounted Cumulative Gain ($NDCG@10$), uwzględniającą dokładną pozycję trafienia na liście. Wyniki badań jednoznacznie potwierdziły przewagę hybrydowej architektury NeuMF (łączącej liniowy wariant GMF z nieliniowym perceptronem MLP) nad wszystkimi modelami odniesienia, wykazując ponadto, że zwiększanie głębokości sieci MLP sukcesywnie podnosi celność rekomendacji, a wstępne uczenie (*pre-training*) parametrów składowych przed ich fuzją zapewnia optymalną zbieżność i najwyższą skuteczność algorytmu.

Kolejny przełomowy etap w rozwoju literatury to również praca He i in. tym razem z 2020 roku [19], wprowadzająca model LightGCN. Autorzy przeprowadzają w niej krytyczną dekonstrukcję dotychczasowych splotowych sieci grafowych (takich jak NGCF), wykazując, że przeniesienie skomplikowanych mechanizmów z klasycznych zastosowań uczenia maszynowego — takich jak nieliniowe transformacje macierzowe $\mathbf{W}$ czy nieliniowa funkcja aktywacji (np. ReLU) — jest w filtracji kolaboracyjnej zbędne i utrudnia proces uczenia. Tradycyjne sieci GCN projektowano z myślą o grafach z bogatymi opisami cech (np. sieciach cytowań z tekstami artykułów), podczas gdy w rekomendacjach obiekty i użytkownicy opisani są wyłącznie unikalnymi identyfikatorami ID. Poprzez szczegółowe eksperymenty ablacyjne autorzy udowodnili, że odrzucenie wag macierzowych oraz nieliniowości eliminuje trudności optymalizacyjne, pozwalając sieci na znacznie szybszą zbieżność i lepszą generalizację. W zamian zaproponowali architekturę LightGCN, która opiera się wyłącznie na liniowej agregacji osadzeń bezpośrednich sąsiadów na dwudzielnym grafie interakcji użytkownik-obiekt, stosując jedynie symetryczną normalizację stopni węzłów. Dodatkowo model zastępuje tradycyjne samopłączenia (*self-connections*) mechanizmem kombinacji warstw (*layer combination*), który uśrednia reprezentacje uzyskane ze wszystkich poziomów propagacji — od zerowej warstwy identyfikatorów po wyższe poziomy połączeń wyższego rzędu (*high-order connectivity*). W przeprowadzonych eksperymentach na zbiorach Gowalla, Yelp2018 oraz Amazon-Book model LightGCN bezapelacyjnie pokonał

dotychczasowe modele odniesienia — w tym klasyczną faktoryzację MF-BPR, głęboki perceptron NeuMF oraz bazowe sieci grafowe NGCF i GC-MC. Zastosowana uproszczona architektura pozwoliła na średni skok celności rekomendacji rankingowych o ponad 16,5% w metryce Recall@20 oraz o 16,9% w metryce NDCG@20 w porównaniu do pełnego modelu NGCF. Istotną obserwacją empiryczną było również zachowanie modelu przy głębszej propagacji: o ile w NGCF zwiększanie liczby warstw powyżej dwóch prowadziło do spadku celności z powodu trudności w zbieżności gradientowej, o tyle LightGCN pozwalał na stabilne wykorzystanie informacji z 3- i 4-stopniowego sąsiedztwa, stale poprawiając jakość rankingu. Ponadto całkowite odrzucenie operacji macierzowych przełożyło się na drastyczne obniżenie błędu treningowego (*training loss*) oraz ponad dwukrotne skrócenie czasu uczenia pojedynczej epoki.

Współczesnym wyzwaniem w metodologii badań nad systemami rekomendacyjnymi stał się tzw. kryzys odtwarzalności (*reproducibility crisis*). Znaczne rozproszenie środowisk programistycznych oraz brak standaryzowanych protokołów ewaluacji (np. stosowanie odmiennych wariantów próbkowania negatywnego czy ocenianie na ograniczonej próbie zamiast pełnego sortowania *full-sort ranking*) powodowały, że publikowane w literaturze przewagi nowych modeli bywały trudne do obiektywnej weryfikacji. Odpowiedzią na ten problem stała się przełomowa praca Zhao i in. [20], wprowadzająca zunifikowany szkielet badawczy RecBole. Autorzy stworzyli otwartą bibliotekę w środowisku PyTorch, która integruje ponad 70 uznanych algorytmów rekomendacyjnych (od tradycyjnych metod kolaboratywnych po zaawansowane głębokie sieci neuronowe i architektury grafowe) w oparciu o spójny format plików atomowych oraz jednolite pętle optymalizacyjne i ewaluacyjne. Stosując zaawansowane procedury akceleracji GPU dla predykcji rankingowych, RecBole zdefiniował nowy standard metodologiczny w dziedzinie RecSys, umożliwiając przeprowadzenie w pełni sprawiedliwego, powtarzalnego i porównywalnego benchmarku modeli wywodzących się z różnych paradygmatów technologicznych.

// TODO Rozdział do poprawy / przerobienia

1.5 Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych

Przeniesienie zaawansowanych koncepcji teoretycznych do komercyjnego środowiska VOD wiąże się z koniecznością ciągłego balansowania pomiędzy dwoma kluczowymi kompromisami badawczymi:

- **Dokładność predykcji ocen** (pointwise) **a jakość rankingu** (pairwise/listwise): Klasyczne algorytmy optymalizują błędy pointwise (RMSE, MAE). W serwisach VOD kluczowa jest jednak poprawność porządkowania listy (miary NDCG, Precision@k, Recall) [12], co premiuje modele optymalizujące funkcje strat zorientowane

na ranking.

- **Złożoność obliczeniowa i narzut serwerowy a czas odpowiedzi online** (Response Time): Głębokie modele neuronowe i grafowe generują duży narzut podczas uczenia. Tymczasem system produkcyjny online musi zwrócić spersonalizowaną odpowiedź w ułamkach sekund (poniżej 1 sekundy), aby nie zniechęcić widza.

Dodatkowo systemy personalizacji VOD mierzą się z wyzwaniami zimnego startu (*Cold-Start*), przeciwdziałaniem bańce filtracyjnej oraz monetyzacją treści z "długiego ogona" (*The long tail*), co pozwala na efektywne wykorzystanie całej posiadanej bazy licencyjnej. Wyzwania te stanowią bezpośrednie uzasadnienie celu naukowego niniejszej pracy magisterskiej, polegającego na empirycznym porównaniu tradycyjnej faktoryzacji SVD, głębokiego NCF oraz grafowego LightGCN/KGCN.

2 Metodyka Badań

W niniejszym rozdziale przedstawiono kompleksowy protokół badawczy oraz szczegółowy aparat matematyczny wykorzystanych algorytmów rekomendacyjnych. Omówiono również specyfikę środowiska wykonawczego, proces przygotowania i binarizacji zbioru danych oraz zastosowaną procedurę walidacji i ewaluacji jakości proponowanych propozycji rankingowych.

2.1 Środowisko wykonawcze

W celu standaryzacji protokołu ewaluacji wyników i przygotowania danych oraz dla zapewnienia maksymalnej powtarzalności wykorzystywanych algorytmów eksperymenty badawcze zdecydowano przeprowadzić z wykorzystaniem zunifikowanej biblioteki RecBole (wersja 1.1.1) [20]. Biblioteka ta, oparta na frameworku PyTorch, stanowi współcześnie standard badawczy w dziedzinie systemów rekomendacyjnych, łącząc w ramach jednolitej architektury modułowej cztery kluczowe komponenty: moduł konfiguracji, moduł danych, interfejsy modeli oraz zoptymalizowany moduł ewaluacji.

Sposób funkcjonowania ramki RecBole opiera się na ściśle zdematerializowanej i zorientowanej na obliczenia GPU architekturze potokowej (ang. *pipeline architecture*). Przepływ danych i wykonanie eksperymentu wewnątrz biblioteki realizowane jest w następujących etapach:

1. Moduł Konfiguracji (*Configuration Module*): Odpowiada za skalanie ustawień eksperymentalnych z hierarchicznie nakładanych źródeł: plików konfiguracyjnych YAML, parametrów przekazywanych z wiersza poleceń oraz bezpośrednich słowników języka Python. Moduł ten kontroluje rozmiar batcha, stopę uczenia, użyty optymalizator (np. Adam, SGD) oraz szczegółowe parametry poszczególnych modeli.
2. Moduł Danych i Struktura Interaction (*Data Module*): Surowe zbiory danych przekształcane są w uniwersalny format tzw. plików atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter` (zawierających relacje użytkownik-obiekt) oraz opcjonalnie `.user`, `.item` czy `.kg` (dla metadanych i grafów wiedzy). Wewnątrz środowiska dane są reprezentowane przez wyspecjalizowany obiekt `Interaction`, będący opakowaniem na słownik tensorów PyTorch (`torch.Tensor`). Zapewnia to bezpośrednie i bezkosztowe przenoszenie całych pakietów danych do pamięci VRAM karty graficznej (`.to(device)`), eliminując wąskie gardła transferu pamięci RAM-VRAM.
3. Moduł Modelu (*Model Module*): Wszystkie zaimplementowane algorytmy dziedziczą po zunifikowanych klasach bazowych (np. `GeneralRecommender` dla modeli filtracji kolaboracyjnej oraz `KnowledgeRecommender` dla modeli z grafami wiedzy). Wymaga to od każdego algorytmu zdefiniowania dwóch zunifikowanych interfejsów:

- `calculate_loss(interaction)` – wyliczanie wartości funkcji straty (np. BPR Loss lub Binary Cross-Entropy) w fazie propagacji wprzód podczas uczenia,
- `predict(interaction) / full_sort_predict(interaction)` – wyznaczanie punktacji relewancji (*scores*) dla par użytkownik-obiekt w fazie predykcji.

4. Moduł Wykonania i Akceleracji Ewaluacji (*Execution & Evaluation Module*): Pętla uczenia zarządzana jest przez obiekt `Trainer`, odpowiadający za automatyczny zapis punktów kontrolnych (*checkpoints*), wczesne zatrzymanie (*early stopping*) oraz optymalizację hiperparametrów.

Środowisko uruchomieniowe przygotowano na podstawie systemu operacyjnego Windows 11 oraz interpretera języka Python (wersja 3.12) działającego w odizolowanym środowisku wirtualnym. Wszystkie parametry modeli oraz ustawienia eksperymentalne zostały natomiast zdefiniowane w postaci deklaratywnych plików konfiguracji YAML. Rozwiązanie to gwarantuje pełną separację logiki eksperymentalnej od kodu źródłowego, ułatwiając rekonfigurowalność hiperparametrów, kontrolę wersji eksperymentów oraz bezproblemową powtarzalność uzyskanych wyników. Zastosowanie jednolitej ramki RecBole eliminuje ponadto tzw. błędy niespójności implementacyjnej (ang. *reproducibility crisis*), gwarantując, że obserwowane różnice w wynikach wynikają wyłącznie z właściwości samych algorytmów (SVD, NCF, LightGCN, KGCN), a nie z odmienności optymalizatorów czy funkcji próbkowania [20].

2.2 Opis i przygotowanie danych

W części empirycznej niniejszej pracy do ewaluacji modeli z grupy klasycznego filtrowania kolaboracyjnego (SVD/BPR), głębokiego uczenia (NCF) oraz grafowych sieci neuronowych (LightGCN, KGCN) wykorzystano zbiór danych MovieLens 1M, udostępniany przez grupę badawczą GroupLens Research z University of Minnesota. Wybór tego zbioru jest podyktowany jego powszechnym uznaniem w literaturze naukowej jako kanonicznego benchmarku w dziedzinie systemów rekomendacyjnych [18, 20].

Przestrzeń badawczą definiuje trójka uporządkowana obejmująca:

- zbiór wszystkich zarejestrowanych użytkowników, oznaczany symbolem $\mathcal{U}$,
- zbiór wszystkich dostępnych w katalogu obiektów (filmów), oznaczany symbolem $\mathcal{I}$,
- zbiór zaobserwowanych historycznych interakcji, oznaczany symbolem $\mathcal{E}$, będący podzbiorem iloczynu kartezjańskiego zbiorów użytkowników i obiektów ($\mathcal{E} \subseteq \mathcal{U} \times \mathcal{I}$).

Liczebności (moce) poszczególnych zbiorów oznaczamy odpowiednio jako $|\mathcal{U}|$ (łączna liczba użytkowników), $|\mathcal{I}|$ (łączna liczba filmów) oraz $|\mathcal{E}|$ (łączna liczba zaobserwowanych zdarzeń). W analizowanym zbiorze dane te przyjmują wartości: $|\mathcal{U}| = 6\,040$, $|\mathcal{I}| = 3\,706$

oraz $|\mathcal{E}| = 1\,000\,209$. Dokładne ustalenie tych wymiarów jest kluczowe z punktu widzenia uczenia maszynowego, gdyż determinują one bezpośrednio rozmiary warstw osadzeń (*embedding layers*) w architekturach neuronowych i grafowych.

2.2.1 Zjawisko rzadkości macierzy interakcji (Data Sparsity)

Tradycyjny model danych rekomendacyjnych reprezentuje się jako dwuwymiarową macierz $R \in \mathbb{R}^{|\mathcal{U}| \times |\mathcal{I}|}$, w której wiersze odpowiadają poszczególnym użytkownikom ($u \in \mathcal{U}$), a kolumny poszczególnym obiektom ($i \in \mathcal{I}$). Stopień braku wypełnienia tej macierzy opisuje wskaźnik rzadkości (*sparsity rate*), oznaczany symbolem S .

Przed przedstawieniem zależności matematycznej określmy znaczenie poszczególnych zmiennych występujących we wzorze:

- S — wskaźnik rzadkości macierzy interakcji (wyrażany jako ułamek z przedziału $[0, 1]$ lub w procentach),
- $|\mathcal{E}|$ — liczba faktycznie zaobserwowanych i zarejestrowanych interakcji w systemie,
- $|\mathcal{U}| \times |\mathcal{I}|$ — teoretyczna maksymalna liczba wszystkich możliwych relacji w macierzy przy założeniu, że każdy użytkownik wszedłby w interakcję z każdym filmem w katalogu.

Biorąc pod uwagę powyższe oznaczenia, wskaźnik rzadkości S definiuje się wzorem:

$$S = 1 - \frac{|\mathcal{E}|}{|\mathcal{U}| \times |\mathcal{I}|} \quad (3)$$


Dla wybranego zbioru danych stopień rzadkości wynosi $S = 95,53\%$, co oznacza, że jedynie $4,47\%$ komórek macierzy zawiera zaobserwowane wpisy. W środowisku VOD skrajna rzadkość jest zjawiskiem naturalnym — pojedynczy widz jest w stanie zapoznać się jedynie z ułamkiem procenta całkowitej oferty platformy. Skrajnie wysoki wskaźnik rzadkości stanowi podstawowe uzasadnienie metodologiczne dla odrzucenia prostych algorytmów pamięciowych (k -NN), które zmagają się z problemem braku wspólnych sąsiadów, na rzecz metod czynników ukrytych (SVD) oraz propagacji osadzeń w sieciach grafowych.

2.2.2 Rozkład popularności treści i zjawisko długiego ogona (Long-Tail)

Interakcje na platformach streamingowych podlegają silnej asymetrii popytu opisanej rozkładem potęgowym (*Power Law*). Badana przestrzeń danych jednoznacznie wykazuje zjawisko tzw. długiego ogona (*Long-Tail Distribution*), zaprezentowane na Rysunku 1.

Katalog filmowy dzieli się na dwie wyraźne strefy:

- **Głowę popytu (*Head*):** wąską grupę najpopularniejszych produkcji kinowych, które skupiają przeważającą część całkowitej liczby ocen w systemie.



Rysunek 1: Rozkład popularności filmów w zbiorze MovieLens 1M przedstawiający zjawisko długiego ogona (*Long-Tail Distribution*).

- **Długi ogon (*Tail*):** obszerną listę niszowych tytułów o niskiej częstotliwości odтворzeń.

Z biznesowego punktu widzenia spersonalizowany system rekomendacyjny na rynku VOD musi potrafić trafnie proponować pozycje z długiego ogona, zapobiegając zjawisku monopolizacji uwagi widza wyłącznie przez najpopularniejsze hity.

2.2.3 Transformacja ocen jawnych w sygnał dorozumiany (*Implicit Feedback*)

Oryginalny zbiór MovieLens zawiera oceny jawne (*explicit feedback*) wyrażone w 5-stopniowej skali dyskretnej (od 1 do 5 gwiazdek). W rzeczywistych systemach rekomendacyjnych platform wideo (VOD/OTT) oceny jawne występują jednak niezwykle rzadko — użytkownicy rzadko oceniają obejrzone materiały, a głównym źródłem informacji stają się ślady cyfrowe i interakcje dorozumiane (*implicit feedback*), takie jak odtworzenie filmu, czas oglądania czy kliknięcie [10, 1].

Ponadto analiza rozkładu ocen jawnych wykazuje silne skrzywienie pozytywne (*positivity bias*) — użytkownicy znacznie chętniej oceniają filmy, które im się podobały (oceny 3, 4 i 5 stanowią ponad 80% wszystkich wpisów).

Zgodnie z metodologią zaproponowaną przez He i in. [18], w celu dostosowania danych do realiów platform streamingowych dokonuje się przekształcenia binarnego oryginalnej macierzy ocen w macierz interakcji dorozumianych, oznaczaną jako $Y \in \mathbb{R}^{M \times N}$ (gdzie $M = |\mathcal{U}|$ oznacza liczbę użytkowników, a $N = |\mathcal{I}|$ liczbę filmów).

Przed przedstawieniem reguły dyskryminacyjnej zdefiniujmy elementy składowe wzoru:

- y_{ui} — wartość wskaźnikowa określająca obecność zaobserwowanej relacji pomiędzy użytkownikiem $u \in \mathcal{U}$ a obiektem $i \in \mathcal{I}$,

- $y_{ui} = 1$ — stan dodatni, oznaczający zarejestrowanie interakcji (np. wystawienie oceny lub obejrzenie filmu),
- $y_{ui} = 0$ — stan nieobserwowany, oznaczający brak zarejestrowanej akcji w logach.

Sformułowanie matematyczne funkcji binarnej przyjmuje postać:

$$y_{ui} = \begin{cases} 1, & \text{jeśli zaobserwowano interakcję (użytkownik } u \text{ ocenił/obejrzał film } i) \\ 0, & \text{w przeciwnym razie (brak obserwacji)} \end{cases} \quad (4)$$

Warto podkreślić, że wartość $y_{ui} = 0$ nie oznacza jawnej niechęci użytkownika do danego tytułu, lecz jedynie brak wiedzy o wchodzeniu w interakcję (efekt braku ekspozycji lub braku znajomości danego filmu w katalogu).

2.2.4 Filtrowanie gęstości danych (k-core filtering) i aktywność użytkowników

Rozkład aktywności użytkowników wykazuje duże zróżnicowanie — od profili okazjonalnych po użytkowników o skrajnie wysokiej liczbie obejrzanych pozycji. Aby wyeliminować zaburzenia wynikające ze skrajnie rzadkich profili oraz pozycji znikających z katalogu bez historii ocen, zastosowano procedurę filtrowania typu *k-core* ($k = 5$).

Odrzucono wszystkich użytkowników oraz filmy posiadające mniej niż 5 zarejestrowanych interakcji. Operacja ta zapobiega występowaniu niemożliwych do wyuczenia trywialnych wektorów zerowych w warstwach embeddingów oraz stabilizuje proces wyznaczania normalizacji macierzy sąsiedztwa grafu dwudzielnego w modelach GNN.

2.2.5 Reprezentacja w postaci grafu dwudzielnego

Na potrzeby modeli z grupy Grafowych Sieci Neuronowych (LightGCN oraz KGCN) zbiór interakcji zinterpretowano jako nieskierowany graf dwudzielny. Graf ten oznaczamy symbolem $G = (\mathcal{V}, \mathcal{E})$, w którym zbiór węzłów $\mathcal{V}$ oraz zbiór krawędzi $\mathcal{E}$ definiuje się następująco:

- $\mathcal{V} = \mathcal{U} \cup \mathcal{I}$ — zbiór wierzchołków stanowiący sumę dwóch rozłącznych podzbiorów: użytkowników $\mathcal{U}$ oraz filmów $\mathcal{I}$ ($\mathcal{U} \cap \mathcal{I} = \emptyset$),
- $\mathcal{E} = \{(u, i) \mid u \in \mathcal{U}, i \in \mathcal{I}, y_{ui} = 1\}$ — zbiór nieskierowanych krawędzi łączących węzeł użytkownika u z węzłem filmu i wtedy i tylko wtedy, gdy zaobserwowano dodatnią interakcję ($y_{ui} = 1$),
- $d(u)$ oraz $d(i)$ — stopień węzła (*node degree*), określający odpowiednio liczbę krawędzi incydentnych do użytkownika u (liczba obejrzanych filmów) oraz do filmu i (liczba widzów).

Struktura ta pozwala na jawne modelowanie połączeń wyższego rzędu (*high-order connectivity*). Informacja o preferencjach użytkownika propagowana jest przez sąsiednie węzły obiektów do innych użytkowników o podobnych gustach, co stanowi fundament działania algorytmu LightGCN omawianego w dalszej części pracy.

2.2.6 Konwersja do formatu plików atomowych frameworka RecBole

W celu zapewnienia ścisłej reprodukowalności eksperymentów i eliminacji błędów implementacyjnych, oczyszczone zbiory danych przekonwertowano do formatu Plików Atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter`, stanowiącego standard wejściowy biblioteki RecBole [20]. Plik `.inter` przechowuje relacje w strukturze tabularycznej ze zdefiniowanymi typami pól:

- `user_id:token` — unikalny identyfikator użytkownika (sekwencja dyskretna),
- `item_id:token` — unikalny identyfikator filmu (sekwencja dyskretna),
- `rating:float` — oryginalna ocena użytkownika (wykorzystywana pomocniczo),
- `timestamp:float` — znacznik czasu interakcji.

Przykładowa konfiguracja transformacji została zrealizowana przy użyciu autorskiego potoku w języku Python (`convert_to_recbole.py`).

2.2.7 Protokół podziału danych i próbkowanie negatywne

Ewaluację modeli przeprowadzono w oparciu o proporcjonalny losowy podział danych (*Ratio Splitting*) w stosunku 80% : 10% : 10% (odpowiednio: zbiór treningowy, walidacyjny i testowy).

Do trenowania modeli punktowych i parowych (Log Loss w NCF oraz BPR Loss w SVD/LightGCN) zastosowano procedurę próbkowania negatywnego (*negative sampling*). Dla każdej dodatniej pary $(u, i) \in \mathcal{Y}$ losowano jednostajnie ze zbioru nieobserwowane pozycje zestaw próbek negatywnych $(u, j) \in \mathcal{Y}^-$ (gdzie $y_{uj} = 0$), przy zachowaniu stosunku 1:4 (4 próbki negatywne na 1 pozycję dodatnią), co stanowi optymalny kompromis między stabilnością gradientu a czasem obliczeń [18].

2.2.8 Charakterystyka statystyczna przetworzonych zbiorów

Tabela 1 przedstawia zbiorcze zestawienie parametrów statystycznych przygotowanych zbiorów danych po przeprowadzeniu potoku przetwarzania.

Tabela 1: Podsumowanie statystyczne zbiorów danych wykorzystanych w eksperymentach

Parametr / Zbiór danych	MovieLens 100k (ml-100k)	MovieLens 1M (ml-1m)
Liczba użytkowników ($ U $)	943	6 040
Liczba filmów ($ I $)	1 682	3 706
Liczba interakcji ($ \mathcal{Y} $)	100 000	1 000 209
Średnia liczba ocen na użytkownika	106,04	165,60
Gęstość macierzy (Density)	6,30%	4,47%
Rzadkość macierzy (Sparsity)	93,70%	95,53%
Typ informacji zwrotnej	Implicit Feedback	Implicit Feedback

2.3 Algorytmy filtrowania kolaboracyjnego

2.4 Algorytmy uczenia głębokiego

2.5 Algorytmy grafowych sieci neuronowych

2.6 Metryki oceny

3 Tytuł rozdziału 3

Zwykle jest to problem badawczy składający się z podrozdziałów:

1. Eksperymenty obliczeniowe/symulacyjne/komputerowe
2. Rozwiązania/wyniki
3. Dyskusja wyników i wnioski

Analiza wyników ma być zaprojektowana i przeprowadza tak, aby móc zająć stanowisko względem tezy - potwierdzić ją lub odrzucić.

W dyskusji wyników należy podkreślić ważne obserwacje z wyników badań z punktu widzenia postawionej tezy. Należy też wspomnieć o wadach zaprojektowanego eksperymentu, jego niedociągnięciach wpływających na wyniki.

Podsumowanie

Należy nawiązać do problemu badawczego, tezy i celu pracy. Trzeba krótko podsumować najważniejsze wnioski z badań – nie w punktach; ma to być tekst ciągły. W oparciu o przywołane najważniejsze spostrzeżenia należy stwierdzić, czy tezę pracy można przyjąć, czy należy ją odrzucić. Na tej podstawie należy stwierdzić, czy cel pracy został zrealizowany. W przypadku prac opartych na konkretnych problemach przedsiębiorstw można ocenić znaczenie przeprowadzonych badań dla firmy w kontekście budowania przewagi konkurencyjnej na rynku (niższe koszty, większa prędkość produkcji, większa elastyczność produkcji itp.).

Bibliografia

- [1] K. Chęciński and R. Wawrzusiak, “Systemy rekomendacji. Remedium w cyfrowej kłęsce urodzaju,” *Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne*, vol. nr 2, 2023.
- [2] “Press Room - IMDb.” <https://www.imdb.com/pressroom/stats/>.
- [3] “Spotify — About Spotify.”
- [4] “O nas.” <https://www.bookbeat.com/pl/about>.
- [5] J. Krawczuk, *Systemy rekomendacyjne*. 2024.
- [6] T. Doligalski, M. Goliński, M. Bernardelli, W. Szpringer, G. Malgorzata, R. Szulc, K. Piech, A. Janowska, B. Koczetkow, L. Lech, N. Sarna, B. Mróz, A. Siejka, W. Szymkiewicz, J. Kowalczyk, W. Trzebiński, T. Niedziółka, W. Zdunkiewicz, M. Kowalczyk, and S. Sobolewska, *Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy (Książka Do Pobrania)*. Apr. 2024.
- [7] C. Gómez-Urbe and N. Hunt, “The Netflix Recommender System,” *ACM Transactions on Management Information Systems*, vol. 6, pp. 1–19, Dec. 2015.
- [8] P. Resnick and H. R. Varian, “Recommender systems,” *Communications of The ACM*, vol. 40, pp. 56–58, Mar. 1997.
- [9] R. Burke, “Hybrid Recommender Systems: Survey and Experiments,” *User Modeling and User-Adapted Interaction*, vol. 12, Nov. 2002.
- [10] G. Adomavicius and A. Tuzhilin, “Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 17, pp. 734–749, July 2005.
- [11] M. Malinowski, *Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce*. PhD thesis, Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, Warszawa, 2022.
- [12] H. Steck, *Evaluation of Recommendations: Rating-prediction and Ranking*. Oct. 2013.
- [13] X. Su and T. Khoshgoftaar, “A Survey of Collaborative Filtering Techniques,” *Adv. Artificial Intelligence*, vol. 2009, Oct. 2009.
- [14] S. Zhang, L. Yao, A. Sun, and Y. Tay, “Deep Learning Based Recommender System: A Survey and New Perspectives,” *ACM Computing Surveys*, vol. 52, pp. 1–38, Jan. 2020.

- [15] M. Malinowski, “Zastosowanie grafów i sieci w systemach rekomendacji,” pp. 77–96, Nov. 2021.
- [16] S. Raza, M. Rahman, S. Kamawal, A. Toroghi, A. Raval, F. Navah, and A. Kazemeini, *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. July 2024.
- [17] B. Hallinan and T. Striphas, “Recommended for you: The netflix prize and the production of algorithmic culture,” *New Media & Society*, vol. 18, no. 1, pp. 117–137, 2016.
- [18] X. He, L. Liao, H. Zhang, L. Nie, X. Hu, and C. Tat-Seng, “Neural collaborative filtering,” in *Proceedings of the 26th International Conference on World Wide Web*, pp. 173–182, 2017.
- [19] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, and M. Wang, “Lightgcn: Simplifying and powering graph convolution network for recommendation,” in *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 639–648, 2020.
- [20] W. X. Zhao, S. Mu, Y. Hou, Z. Lin, Y. Chen, X. Pan, K. Li, Y. Lu, H. Wang, C. Tian, Y. Min, K. Zhou, Z. Zhao, Z. Xu, Y. Ren, and J.-R. He, “Recbole: A unified, comprehensive and efficient recommendation library,” in *Proceedings of the 30th ACM International Conference on Information and Knowledge Management*, pp. 4653–4664, 2021.