



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

KATEDRA INFORMATYKI BIZNESOWEJ I INŻYNIERII ZARZĄDZANIA

Projekt dyplomowy / Praca dyplomowa

**Porównanie algorytmów rekomendacyjnych
(Filtrowanie Kolaboracyjne, Uczenie Głębokie, Grafowe
Sieci Neuronowe) na przykładzie portalu
streamingowego**

Comparison of recommendation algorithms (Collaborative Filtering,
Deep Learning, Graph Neural Networks) using a streaming platform as
an example

Autor: Jakub Sornat

Kierunek studiów: Informatyka i Ekonometria

Opiekun: dr hab. Iwona Skalna

Kraków, 2026

Spis treści

Wstęp	1
1 Wprowadzenie do problematyki systemów rekomendacyjnych	3
1.1 Zjawisko przeciążenia informacyjnego i specyfika rynku VOD	3
1.2 Definicje, formalizm matematyczny i struktura danych w personalizacji . .	4
1.3 Ewolucja technologiczna paradygmatów rekomendacyjnych	5
1.4 Przegląd literatury naukowej	7
1.5 Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych	10
2 Środowisko, dane i metodyka badań	12
2.1 Środowisko wykonawcze	12
2.2 Opis i przygotowanie danych	13
2.3 Algorytmy filtrowania kolaboracyjnego	20
2.3.1 Algorytm ItemKNN	21
2.3.2 Spersonalizowany ranking bayesowski	23
2.4 Algorytmy uczenia głębokiego	25
2.5 Algorytmy grafowych sieci neuronowych	25
2.6 Metryki oceny	25
3 Tytuł rozdziału 3	29
Podsumowanie	30
Bibliografia	31
Spis tabel	33
Spis rysunków	34

Wstęp

Wyznaczanie spersonalizowanych rekomendacji w cyfrowych usługach rozrywkowych stanowi jedno z kluczowych wyzwań współczesnej informatyki stosowanej i ekonometrii. Dynamiczny rozwój metod uczenia maszynowego doprowadził do powstania odmiennych paradygmatów obliczeniowych – od klasycznej algebry macierzowej, przez głębokie sieci neuronowe, po algorytmy wykorzystujące osadzenia na strukturach grafowych. W literaturze naukowej brakuje jednak bezpośrednich, ujednoliconych badań porównawczych weryfikujących zarówno jakość porządkowania rankingowego, jak i czystą wydajność obliczeniową tych podejść w specyficznych warunkach konsumpcji mediów.

Powyższe uwarunkowania definiują **problem badawczy** niniejszej pracy magisterskiej, którym jest empiryczna ewaluacja relatywnej skuteczności personalizacji oraz narzutu serwerowego algorytmów reprezentujących trzy generacje technologiczne systemów rekomendacyjnych (faktoryzacji macierzy SVD/BPR, głębokiej architektury NCF oraz grafowych modeli LightGCN/KGCN) na zbiorze danych interakcji z dorozumianą informacją zwrotną (*implicit feedback*).

Jako cel główny pracy przyjęto zbudowanie ujednoliconego środowiska badawczego przy użyciu pakietu RecBole, przeprowadzenie kompleksowej optymalizacji hiperparametrów oraz ilościową ocenę porównawczą dokładności rankingowej i wydajności trzech reprezentatywnych klas modeli na zbiorze danych z obszaru VOD.

Dla realizacji celu głównego wyznaczono następujące **cele szczegółowe**:

1. Przygotowanie oraz analiza eksploracyjna (EDA) zbioru danych interakcji typu *implicit feedback*.
2. Skonfigurowanie powtarzalnego środowiska eksperymentalnego w języku Python z wykorzystaniem frameworka RecBole.
3. Przeprowadzenie procesu strojenia hiperparametrów (*hyperparameter tuning*) dla każdego z badanych modeli w celu wyznaczenia ich optymalnych konfiguracji.
4. Ilościowa ewaluacja wyników za pomocą metryk jakości rankingu (NDCG@k, Recall@k), miary błędu RMSE oraz pomiaru czasu uczenia i wnioskowania online.

W pracy sformułowano **hipotezę badawczą główną** (H_1):

Zastosowanie modeli Grafowych Sieci Neuronowych (LightGCN oraz KGCN) pozwala na osiągnięcie statystycznie istotnie wyższej trafności rekomendacji rankingowych Top-N (mierzonej wskaźnikami NDCG@k oraz Recall@k) na zbiorze danych VOD w porównaniu do klasycznej faktoryzacji macierzy SVD oraz głębokiej sieci NCF.

Sformułowano również **hipotezę pomocniczą** (H_2):

Wzrost dokładności rekomendacji uzyskiwany przez modele grafowe wiąże się z większym narzutem obliczeniowym w fazie treningu, jednak czas generowania predykcji w fazie wnioskowania online (*inference*) dla modeli LightGCN oraz KGCN mieści się w granicach akceptowalnych dla systemów czasu rzeczywistego VOD (poniżej 1 sekundy).

Podstawową **metodą badawczą** wykorzystaną w pracy jest eksperyment obliczeniowy przeprowadzony w środowisku Python 3.12 przy użyciu frameworka RecBole oraz bibliotek PyTorch i SciPy.

Układ pracy jest następujący: W **Rozdziale 1** omówiono uwarunkowania rynkowe VOD, formalizm matematyczny rekomendacji, ewolucję er algorytmicznych oraz kompromisy wdrożeniowe. W **Rozdziale 2** przedstawiono przyjętą metodykę badań, ściśle sformułowania algorytmów (SVD, NCF, LightGCN/KGCN), zbiór danych oraz wskaźniki oceny. W **Rozdziale 3** zamieszczono przebieg eksperymentów obliczeniowych, zestawienie wyników ilościowych oraz dyskusję w kontekście wymagań produkcyjnych. Pracę zamyka **Podsumowanie**, zawierające syntezę wniosków oraz weryfikację postawionych hipotez badawczych.

1 Wprowadzenie do problematyki systemów rekomendacyjnych

Niniejszy rozdział wprowadza w ramy teoretyczne, formalizm matematyczny oraz uwarunkowania rynkowe systemów rekomendacyjnych, stanowiąc punkt wyjścia dla dalszych analiz algorytmicznych. Analiza obejmuje kognitywne aspekty przeciążenia informacyjnego na rynku VOD, formalną kategoryzację personalizacji, ewolucyjne ery technologiczne (od prostej algebry macierzy po złożone struktury grafowe) oraz kluczowe kompromisy wdrożeniowe.

1.1 Zjawisko przeciążenia informacyjnego i specyfika rynku VOD

Przejsie od tradycyjnych form konsumpcji mediów do środowiska cyfrowego wywołało bezprecedensową transformację na rynku rozrywkowym. Widzowie systematycznie odchodzą od tradycyjnej telewizji, charakteryzującej się sztywną ramówką, na rzecz platform strumieniujących wideo na żądanie (VOD), które zapewniają asynchroniczny dostęp do materiałów. Serwisy takie jak Netflix, HBO Max, Amazon Prime Video oraz lokalne Player.pl i TVP VOD dysponują gigantycznymi bibliotekami, oferując natychmiastowy dostęp do setek tysięcy tytułów filmowych i serialowych.

Ta radykalna poprawa dostępności zrodziła jednak nowe wyzwanie. W czasach tak ogromnej różnorodności multimediiów użytkownicy konfrontowani są ze zjawiskiem zwanym cyfrową klęską urodzaju lub przeciążeniem informacyjnym¹. Skalę tego problemu obrazują twarde statystyki: globalna baza filmowa IMDb zawiera ponad 30 milionów tytułów², platforma muzyczna Spotify oferuje ponad 100 milionów utworów³, a serwis BookBeat udostępnia ponad milion pozycji⁴.

Podaż setek tysięcy produkcji na pojedynczej platformie generuje efekt paradoksu wyboru. Obszerna baza treści przytłacza użytkownika, przez co fizyczne zapoznanie się z całą ofertą staje się niemożliwe, a podjęcie ostatecznej decyzji wymaga znacznego wysiłku poznawczego. Tego typu przeciążenie w skrajnych przypadkach prowadzi do frustracji widza i porzucenia usługi. Rozwiązania klasyczne, takie jak standardowe wyszukiwarki czy uniwersalne rankingi redakcyjne, są niewystarczające – wymagają inicjatywy lub promują treści niezajdujące pokrycia w indywidualnym guście odbiorcy⁵.

Z tego powodu zaawansowane systemy rekomendacyjne stały się kluczowym narzędziem

¹ K. Chęciński i R. Wawrzusiak. Systemy rekomendacji. Remedium w cyfrowej klęsce urodzaju. W: „Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne” nr 2 (2023).

² IMDb. *Press Room - IMDb*. <https://www.imdb.com/pressroom/stats/>.

³ Spotify. *Spotify — About Spotify*. <https://newsroom.spotify.com/company-info/>.

⁴ BookBeat. *O nas – BookBeat*. <https://www.bookbeat.com/pl/about>.

⁵ J. Krawczuk. Systemy rekomendacyjne. W: (w:) Wybrane zagadnienia symulacji komputerowej. 2024.

dziem personalizacji na rynku VOD⁶. Ich główną rolą jest filtrowanie gigantycznych zbiorów danych i drastyczne zmniejszenie przeciążenia informacyjnego poprzez automatyczne dostarczanie trafnych propozycji. Na platformach cyfrowych rekomendacje są podstawowym mechanizmem utrzymania uwagi widza. Zjawisko to ilustruje przykład serwisu Netflix, gdzie aż 80% całkowitej aktywności widzów jest napędzane przez spersonalizowane sugestie algorytmiczne⁷.

1.2 Definicje, formalizm matematyczny i struktura danych w personalizacji

Historycznie pojęcie systemów rekomendacji ewoluowało wraz z rozwojem technologii sieciowych. Pierwsze rozwiązania miały charakter ściśle kooperacyjny. Klasycznym przykładem jest stworzony w 1992 roku przez Xerox Palo Alto Research system Tapestry, uznawany za pierwowzór filtrowania kolaboracyjnego do agregowania manualnych adnotacji grupy użytkowników.

Jedna z pierwszych oficjalnych definicji naukowych, zaproponowana w 1997 roku przez Resnicka i Variana, kładła nacisk na aspekt współpracy między ludźmi, opisując system rekomendacyjny jako narzędzie agregujące i kierujące rekomendacje do odpowiednich odbiorców⁸. Wraz z rozwojem zautomatyzowanych metod uczenia maszynowego definicja uległa rozszerzeniu. Według R. Burke'a (2002), systemem rekomendacji jest każdy program, który generuje zindywidualizowane sugestie lub ma za zadanie kierować użytkownika w spersonalizowany sposób do interesujących obiektów w dużej przestrzeni opcji⁹.

W ujęciu formalnym, opartym na teorii mnogości i funkcji użyteczności¹⁰, problem rekomendacji definiuje się następująco: niech C będzie zbiorem użytkowników, a O zbiorem wszystkich możliwych do zarekomendowania obiektów. Funkcja użyteczności:

$$u: C \times O \rightarrow W \quad (1)$$

mierzy przydatność danego obiektu $o \in O$ dla użytkownika $c \in C$, gdzie W jest uporządkowanym zbiorem (np. ocen). Zadaniem algorytmu jest znalezienie dla każdego użytkownika takiego podzbioru obiektów R_c^* , który maksymalizuje dla niego funkcję użyteczności:

$$R_c^* = \{r \in O: u(c, r) = \max_{o \in O} u(c, o)\} \quad (2)$$

⁶ T. Doligalski i in. *Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy*. 2024.

⁷ C. Gómez-Urbe i N. Hunt. The Netflix Recommender System. W: „ACM Transactions on Management Information Systems” 6 (2015).

⁸ P. Resnick i H. R. Varian. Recommender Systems. W: „Communications of The ACM” 40.Nr 3 (1997).

⁹ R. Burke. Hybrid Recommender Systems: Survey and Experiments. W: „User Modeling and User-Adapted Interaction” 12 (2002).

¹⁰ G. Adomavicius i A. Tuzhilin. Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. W: „IEEE Transactions on Knowledge and Data Engineering” 17 (2005).

Wyniki działania algorytmów prezentowane są użytkownikowi w dwóch głównych formach¹¹:

1. **Przewidywanie ocen (Rating Prediction):** model prognozuje konkretną wartość liczbową oceny (np. 4,5/5 gwiazdek), co stanowiło fundament słynnego konkursu Netflix Prize (2006–2009) i algorytmu Cinematch.
2. **Prognoza rankingu (Top-N Ranking):** system generuje uporządkowaną listę N najlepszych pozycji specyficznie dopasowanych do użytkownika.

W systemach rozrywkowych VOD preferuje się prognozy rankingowe (Top-N). Jak wykazuje Harald Steck¹², dla biznesu kluczowe jest zaprezentowanie właściwych obiektów na górze listy, a nie przewidywanie dokładnych ocen liczbowych, których użytkownicy i tak rzadko udzielają.

Skuteczność personalizacji zależy bezpośrednio od dostępu do danych wejściowych, które dzielimy na trzy wymiary¹³:

- **Profil Użytkownika:** obejmuje parametry statyczne (dane demograficzne) oraz dynamiczne (historia interakcji).
- **Charakterystyka Przedmiotów (metadane):** atrybuty obiektów VOD (gatunki, obsada), a także zaawansowane cechy generowane automatycznie przez systemy rozpoznawania wideo (VCR – *Video Content Recognition*) – np. tempo montażu czy kolorystyka.
- **Logi Transakcyjne (Clickstream):** sekwencyjne zapisy zachowań użytkowników rejestrowane w czasie rzeczywistym.

Informację zwrotną o zachowaniach użytkowników dzielimy na jawne oceny (*explicit feedback*, np. gwiazdki), które są dokładne, ale skrajnie rzadkie (*data sparsity*), oraz dorozumiane ślady aktywności (*implicit feedback*, np. czas oglądania – *dwell time*, kliknięcia), stanowiące obfite, lecz zaszumione źródło wiedzy.

1.3 Ewolucja technologiczna paradygmatów rekomendacyjnych

Ewolucję technologiczną systemów rekomendacyjnych można podzielić na trzy główne ery:

¹¹ M. Malinowski. „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”. Rozprawa doktorska. Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022.

¹² H. Steck. *Evaluation of Recommendations: Rating-prediction and Ranking*. 2013.

¹³ Chęciński i Wawrzusiak, dz. cyt.

Era Tradycyjna (Foundational RS) Rozwój metodyczny zapoczątkowały trzy podejścia¹⁴:

- **Filtrowanie oparte na treści (Content-Based Filtering – CBF)**: rekomenduje obiekty podobne do wybieranych w przeszłości na podstawie iloczynu skalarnego cech $\hat{r}_{ui} = \theta(u)^T \phi(i)$ (miary cosinusowe, Jaccarda). Główną wadą jest nadmierna specjalizacja (*overspecialization*) i bańka filtracyjna.
- **Filtrowanie kolaboracyjne (Collaborative Filtering – CF)**: analizuje zachowania całej społeczności, uzupełniając rzadką macierz ocen. Dzieli się na metody oparte na pamięci (*Memory-Based*: UBCF, IBCF z algorytmem k -NN) oraz metody oparte na modelach (*Model-Based*: Faktoryzacja Macierzy SVD, ALS), redukujące wymiarowość do czynników ukrytych (*latent factors*).
- **Modele hybrydowe**: łączą podejścia kolaboracyjne i treściowe. R. Burke¹⁵ wyróżnia 5 głównych technik hybrydyzacji: łączenie wyników (*weighted*), dodawanie cech (*feature addition*), podejście łańcuchowe (*cascading*), meta-model oraz przełączanie modeli (*switching*).

Era Uczenia Głębokiego (Deep Learning-Based RS) Wprowadzenie głębokich sieci neuronowych pozwoliło na automatyczną ekstrakcję cech oraz mapowanie nieliniowych interakcji¹⁶. W tej erze stosuje się wielowarstwowe perceptrony (MLP) zastępujące iloczyn skalarny w architekturze Neural Collaborative Filtering (NCF), autoenkodery (VAE), sieci splotowe (CNN) do analizy klatek wideo oraz sieci rekurencyjne (RNN/LSTM) do sekwencji.

Era Struktur Grafowych i Modelowania Sekwencyjnego Najbardziej zaawansowane współczesne modele odchodzą od statycznych tabel na rzecz dynamiki grafowej¹⁷:

- **Systemy sekwencyjne i sesyjne (SBR)**: modelują intencje użytkownika w ramach pojedynczej sesji (łańcuchy Markowa, reguły sekwencyjne).
- **Głębokie modele grafowe (GNN)**: reprezentują system jako graf heterogeniczny. Modele oparte na propagacji osadzeń (LightGCN) oraz grafach wiedzy (KGCN)

¹⁴X. Su i T. Khoshgoftaar. A Survey of Collaborative Filtering Techniques. W: „Adv. Artificial Intelligence” 2009 (2009).

¹⁵Burke, dz. cyt.

¹⁶S. Zhang i in. Deep Learning Based Recommender System: A Survey and New Perspectives. W: „ACM Computing Surveys” 52.Nr 1 (2020).

¹⁷M. Malinowski. Zastosowanie Grafów i Sieci w Systemach Rekomendacji. W: 2021; S. Raza i in. *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. 2024.

umożliwiają przechwytywanie relacji wyższego rzędu między użytkownikami, filmami i cechami semantycznymi.

- **Uczenie ze wzmocnieniem (Reinforcement Learning):** traktuje rekomendację jako dynamiczny proces decyzyjny z udziałem agenta w celu optymalizacji długoterminowej satysfakcji.

1.4 Przegląd literatury naukowej

W niniejszym podrozdziale dokonano szczegółowego i krytycznego przeglądu literatury naukowej z zakresu systemów rekomendacyjnych, ze szczególnym uwzględnieniem podejść opartych na filtrowaniu kolaboracyjnym, sztucznych sieciach neuronowych oraz grafowych strukturach wiedzy. Analiza obejmuje zarówno klasyczne metody faktoryzacji, jak i najnowsze osiągnięcia z obszaru głębokiego uczenia w odniesieniu do specyficznych uwarunkowań rynku wideo na żądanie (VOD). Przegląd literatury naukowej w kontekście usług streamingowych warto rozpocząć od analizy przełomowego konkursu Netflix Prize (2006–2009) omówionego przez Hallinana i Striphasa¹⁸. Autorzy wykazują, że publiczne udostępnienie zbioru obejmującego ponad 100 milionów ocen przypisanych przez 480 tysięcy użytkowników dla 17 tysięcy filmów zdefiniowało nowożytną erę kultury algorytmicznej (*algorithmic culture*). Rywalizacja o poprawę celności predykcji błędu RMSE o 10% względem algorytmu Cinematch udowodniła całkowitą niewystarczalność tradycyjnych metod opartych na sąsiedztwie (*neighborhood-based CF*), które wykazywały skrajną podatność na narzut pamięciowy i brak skalowalności. To właśnie Netflix Prize spopularyzował modele czynników ukrytych, w tym w szczególności faktoryzację macierzy (SVD). Hallinan i Striphas zwracają również uwagę na skomplikowane zjawiska polaryzacyjne, określane jako wyzwanie *Napoleon Dynamite problem*, w którym przewidywanie gustów użytkowników dla niszowych i polaryzujących treści wymagało odrzucenia pojedynczych algorytmów na rzecz wielkich zespołów modeli hybrydowych (*ensemble learning*).

Kompleksowe i wieloaspektowe ujęcie podstaw teoretycznych oraz wyzwań wdrożeniowych przedstawia praca Krawczuka¹⁹. Autor przeprowadza szczegółową analizę poszczególnych paradygmatów rekomendacji, oceniając ich przydatność w warunkach produkcyjnych. W pierwszej kolejności analizuje techniki filtrowania opartego na treści (Content-Based Filtering – CBF), wykazując, że ich podstawową zaletą jest wysoka niezależność od aktywności reszty społeczności oraz odporność na rzadkość ocen innych użytkowników. Zauważa jednak przy tym istotne ograniczenia natury poznawczej i algebry czystych atrybutów: algorytmy CBF wykazują tendencję do nadmiernej specjalizacji (*overspecial-*

¹⁸B. Hallinan i T. Striphas. Recommended for You: The Netflix Prize and the Production of Algorithmic Culture. W: „New Media & Society” 18 (2016).

¹⁹Krawczuk, dz. cyt.

ization), zamykając użytkownika w tzw. bańce filtracyjnej i uniemożliwiając odkrycie niespodziewanych, lecz trafnych pozycji (*serendipity*), a także zmagają się z problemem zimnego startu dla nowych obiektów bez uzupełnionych metadanych.

Przechodząc do filtrowania kolaboracyjnego (Collaborative Filtering – CF), Krawczuk akcentuje, że wykorzystywanie „mądrości tłumu” (*wisdom of the crowd*) pozwala na rekomendowanie treści o strukturze niezależnej od ich opisu semantycznego. Niemniej jednak metody te cierpią na krytyczną rzadkość ocen (*data sparsity*), gdzie wskaźnik wypełnienia macierzy ocen R często nie przekracza 1%, oraz na skrajny problem zimnego startu (*cold-start*) dla nowych uczestników systemu. Jako rozwiązanie kompromisowe autor omawia zaawansowane architektury hybrydowe, które poprzez strategie łączone (*weighted*), sekwencyjne (*cascading*) czy rozszerzanie cech (*feature augmentation*) skalają cechy treściowe z sygnałami interakcji. Niezwykle istotnym wkładem pracy Krawczuka jest również analiza wymogów architektonicznych: wskazuje on, że wdrożenie przemysłowe na platformach VOD wymaga utrzymania niskiego czasu odpowiedzi (*latency*) przy jednoczesnej skalowalności obliczeniowej. Podsumowując ewaluację, Krawczuk dowodzi, że w serwisach wideo nadrzędne znaczenie biznesowe ma porządek propozycji na ekranie, w związku z czym metryki rankingowe Top- K , takie jak MRR, NDCG oraz Precision@ k , stanowią jedyne adekwatne kryterium oceny modeli w tym środowisku.

Praca He i in. z 2017 roku skupia się na wykorzystaniu głębokich sieci neuronowych do tworzenia systemów rekomendacyjnych²⁰, wprowadzając architekturę Neural Collaborative Filtering (NCF). W pierwszej części publikacji autorzy uzasadniają potrzebę zastąpienia klasycznego iloczynu skalarnego (*inner product*) nieliniowymi warstwami neuronowymi, wykazując ograniczenia liniowych metod faktoryzacji macierzy oraz przedstawiając teoretyczne fundamenty stojące za proponowanym rozwiązaniem. Do przeprowadzania eksperymentów empirycznych wykorzystano zbiory danych MovieLens 1M oraz Pinterest. W przypadku MovieLens 1M oceny jawne (w skali 1–5) przekształcono na dane ukryte (*implicit feedback*), traktując każdą ocenę jako obecność interakcji ($y_{ui} = 1$), zbiór Pinterest poddano natomiast filtracji typu 20-*core* (odrzucając użytkowników z mniej niż 20 akcjami). W obu zbiorach zastosowano procedurę podziału *Leave-One-Out*, w której ostatnią interakcję odłożono do testów, przedostatnią do walidacji, a pozostałe do uczenia, łącząc w zestawie testowym każdy pozytywny obiekt z 99 losowymi próbkami negatywnymi (*negative sampling*). W celach porównawczych zestawiono architekturę NCF z szeregiem znanych metod referencyjnych: niepersonalizowanym baseline’em popularności ItemPop, modelem opartym na sąsiedztwie obiektów ItemKNN, faktoryzacją macierzy z optymalizacją błędu porządkowania par BPR (*Bayesian Personalized Ranking*) oraz

²⁰ X. He i in. „Neural Collaborative Filtering”. W: *Proceedings of the 26th International Conference on World Wide Web*. WWW ’17. Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017.

zoptymalizowaną punktowo faktoryzacją dla danych dorozumianych eALS (*efficient Alternating Least Squares*). Ewaluację przeprowadzono na podstawie dwóch podstawowych metryk jakości rankingu Top-10: Hit Ratio ($HR@10$), mierzącą obecność poszukiwanego elementu testowego wśród pierwszych 10 propozycji, oraz Normalized Discounted Cumulative Gain ($NDCG@10$), uwzględniającą dokładną pozycję trafienia na liście. Wyniki badań jednoznacznie potwierdziły przewagę hybrydowej architektury NeuMF (łączącej liniowy wariant GMF z nieliniowym perceptronem MLP) nad wszystkimi modelami odniesienia, wykazując ponadto, że zwiększanie głębokości sieci MLP sukcesywnie podnosi celność rekomendacji, a wstępne uczenie (*pre-training*) parametrów składowych przed ich fuzją zapewnia optymalną zbieżność i najwyższą skuteczność algorytmu.

Kolejny przełomowy etap w rozwoju literatury to również praca He i in. tym razem z 2020 roku²¹, wprowadzająca model LightGCN. Autorzy przeprowadzają w niej krytyczną dekonstrukcję dotychczasowych splotowych sieci grafowych (takich jak NGCF), wykazując, że przeniesienie skomplikowanych mechanizmów z klasycznych zastosowań uczenia maszynowego — takich jak nieliniowe transformacje macierzowe $\mathbf{W}$ czy nieliniowa funkcja aktywacji (np. ReLU) — jest w filtracji kolaboracyjnej zbędne i utrudnia proces uczenia. Tradycyjne sieci GCN projektowano z myślą o grafach z bogatymi opisami cech (np. sieciach cytowań z tekstami artykułów), podczas gdy w rekomendacjach obiekty i użytkownicy opisani są wyłącznie unikalnymi identyfikatorami ID. Poprzez szczegółowe eksperymenty ablacyjne autorzy udowodnili, że odrzucenie wag macierzowych oraz nieliniowości eliminuje trudności optymalizacyjne, pozwalając sieci na znacznie szybszą zbieżność i lepszą generalizację. W zamian zaproponowali architekturę LightGCN, która opiera się wyłącznie na liniowej agregacji osadzeń bezpośrednich sąsiadów na dwudzielnym grafie interakcji użytkownik-obiekt, stosując jedynie symetryczną normalizację stopni węzłów. Dodatkowo model zastępuje tradycyjne samopłączenia (*self-connections*) mechanizmem kombinacji warstw (*layer combination*), który uśrednia reprezentacje uzyskane ze wszystkich poziomów propagacji — od zerowej warstwy identyfikatorów po wyższe poziomy połączeń wyższego rzędu (*high-order connectivity*). W przeprowadzonych eksperymentach na zbiorach Gowalla, Yelp2018 oraz Amazon-Book model LightGCN bezapelacyjnie pokonał dotychczasowe modele odniesienia — w tym klasyczną faktoryzację MF-BPR, głęboki perceptron NeuMF oraz bazowe sieci grafowe NGCF i GC-MC. Zastosowana uproszczona architektura pozwoliła na średni skok celności rekomendacji rankingowych o ponad 16,5% w metryce Recall@20 oraz o 16,9% w metryce NDCG@20 w porównaniu do pełnego modelu NGCF. Istotną obserwacją empiryczną było również zachowanie modelu przy głębszej propagacji: o ile w NGCF zwiększanie liczby warstw powyżej dwóch prowadziło do spadku celności z powodu trudności w zbieżności gradientowej, o tyle LightGCN pozwalał

²¹ X. He i in. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. W: (2020).

na stabilne wykorzystanie informacji z 3- i 4-stopniowego sąsiedztwa, stale poprawiając jakość rankingu. Ponadto całkowite odrzucenie operacji macierzowych przełożyło się na drastyczne obniżenie błędu treningowego (*training loss*) oraz ponad dwukrotne skrócenie czasu uczenia pojedynczej epoki.

Współczesnym wyzwaniem w metodologii badań nad systemami rekomendacyjnymi stał się tzw. kryzys odtwarzalności (*reproducibility crisis*). Znaczne rozproszenie środowisk programistycznych oraz brak standaryzowanych protokołów ewaluacji (np. stosowanie odmiennych wariantów próbkowania negatywnego czy ocenianie na ograniczonej próbie zamiast pełnego sortowania *full-sort ranking*) powodowały, że publikowane w literaturze przewagi nowych modeli bywały trudne do obiektywnej weryfikacji. Odpowiedzią na ten problem stała się przełomowa praca Zhao i in.²², wprowadzająca zunifikowany szkielet badawczy RecBole. Autorzy stworzyli otwartą bibliotekę w środowisku PyTorch, która integruje ponad 70 uznanych algorytmów rekomendacyjnych (od tradycyjnych metod kolaboratywnych po zaawansowane głębokie sieci neuronowe i architektury grafowe) w oparciu o spójny format plików atomowych oraz jednolite pętle optymalizacyjne i ewaluacyjne. Stosując zaawansowane procedury akceleracji GPU dla predykcji rankingowych, RecBole zdefiniował nowy standard metodologiczny w dziedzinie RecSys, umożliwiając przeprowadzenie w pełni sprawiedliwego, powtarzalnego i porównywalnego benchmarku modeli wywodzących się z różnych paradygmatów technologicznych.

// TODO Rozdział do poprawy / przerobienia

1.5 Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych

Przeniesienie zaawansowanych koncepcji teoretycznych do komercyjnego środowiska VOD wiąże się z koniecznością ciągłego balansowania pomiędzy dwoma kluczowymi kompromisami badawczymi:

- **Dokładność predykcji ocen (pointwise) a jakość rankingu (pairwise/listwise):** Klasyczne algorytmy optymalizują błędy pointwise (RMSE, MAE). W serwisach VOD kluczowa jest jednak poprawność porządkowania listy (miary NDCG, Precision@k, Recall)²³, co premiuje modele optymalizujące funkcje strat zorientowane na ranking.
- **Złożoność obliczeniowa i narzut serwerowy a czas odpowiedzi online (Response Time):** Głębokie modele neuronowe i grafowe generują duży narzut podczas

²²W. X. Zhao i in. „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”. W: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*. CIKM '21. New York, NY, USA: Association for Computing Machinery, 2021.

²³Steck, dz. cyt.

uczenia. Tymczasem system produkcyjny online musi zwrócić spersonalizowaną odpowiedź w ułamkach sekund (poniżej 1 sekundy), aby nie zniechęcić widza.

Dodatkowo systemy personalizacji VOD mierzą się z wyzwaniami zimnego startu (*Cold-Start*), przeciwdziałaniem bańce filtracyjnej oraz monetyzacją treści z "długiego ogona" (*The long tail*), co pozwala na efektywne wykorzystanie całej posiadanej bazy licencyjnej. Wyzwania te stanowią bezpośrednie uzasadnienie celu naukowego niniejszej pracy magisterskiej, polegającego na empirycznym porównaniu tradycyjnej faktoryzacji SVD, głębokiego NCF oraz grafowego LightGCN/KGCN.

2 Środowisko, dane i metodyka badań

W niniejszym rozdziale przedstawiono kompleksowy protokół badawczy oraz szczegółowy aparat matematyczny wykorzystanych algorytmów rekomendacyjnych. Omówiono również specyfikę środowiska wykonawczego, proces przygotowania i binarizacji zbioru danych oraz zastosowaną procedurę walidacji i ewaluacji jakości proponowanych propozycji rankingowych.

2.1 Środowisko wykonawcze

W celu standaryzacji protokołu ewaluacji wyników i przygotowania danych oraz dla zapewnienia maksymalnej powtarzalności wykorzystywanych algorytmów eksperymenty badawcze zdecydowano przeprowadzić z wykorzystaniem zunifikowanej biblioteki RecBole (wersja 1.1.1)²⁴. Biblioteka ta, oparta na frameworku PyTorch, stanowi współcześnie standard badawczy w dziedzinie systemów rekomendacyjnych, łącząc w ramach jednolitej architektury modułowej cztery kluczowe komponenty: moduł konfiguracji, moduł danych, interfejsy modeli oraz zoptymalizowany moduł ewaluacji.

Sposób funkcjonowania ramki RecBole opiera się na ściśle zdematerializowanej i zorientowanej na obliczenia GPU architekturze potokowej (ang. *pipeline architecture*). Przepływ danych i wykonanie eksperymentu wewnątrz biblioteki realizowane jest w następujących etapach:

1. Moduł Konfiguracji (*Configuration Module*): Odpowiada za skalanie ustawień eksperymentalnych z hierarchicznie nakładanych źródeł: plików konfiguracyjnych YAML, parametrów przekazywanych z wiersza poleceń oraz bezpośrednich słowników języka Python. Moduł ten kontroluje rozmiar batcha, stopę uczenia, użyty optymalizator (np. Adam, SGD) oraz szczegółowe parametry poszczególnych modeli.
2. Moduł Danych i Struktura Interaction (*Data Module*): Surowe zbiory danych przekształcane są w uniwersalny format tzw. plików atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter` (zawierających relacje użytkownik-obiekt) oraz opcjonalnie `.user`, `.item` czy `.kg` (dla metadanych i grafów wiedzy). Wewnątrz środowiska dane są reprezentowane przez wyspecjalizowany obiekt Interaction, będący opakowaniem na słownik tensorów PyTorch (`torch.Tensor`). Zapewnia to bezpośrednie i bezkosztowe przenoszenie całych pakietów danych do pamięci VRAM karty graficznej (`.to(device)`), eliminując wąskie gardła transferu pamięci RAM-VRAM.
3. Moduł Modelu (*Model Module*): Wszystkie zaimplementowane algorytmy dziedziczą po zunifikowanych klasach bazowych (np. GeneralRecommender dla modeli filtracji

²⁴Zhao i in., dz. cyt.

kolaboracyjnej oraz KnowledgeRecommender dla modeli z grafami wiedzy). Wymaga to od każdego algorytmu zdefiniowania dwóch zunifikowanych interfejsów:

- `calculate_loss(interaction)` – wyliczanie wartości funkcji straty (np. BPR Loss lub Binary Cross-Entropy) w fazie propagacji wprzód podczas uczenia,
- `predict(interaction) / full_sort_predict(interaction)` – wyznaczanie punktacji relewancji (*scores*) dla par użytkownik-obiekt w fazie predykcji.

4. Moduł Wykonania i Akceleracji Ewaluacji (*Execution & Evaluation Module*): Pętla uczenia zarządzana jest przez obiekt Trainer, odpowiadający za automatyczny zapis punktów kontrolnych (*checkpoints*), wczesne zatrzymanie (*early stopping*) oraz optymalizację hiperparametrów.

Środowisko uruchomieniowe przygotowano na podstawie systemu operacyjnego Windows 11 oraz interpretera języka Python (wersja 3.12) działającego w odizolowanym środowisku wirtualnym. Wszystkie parametry modeli oraz ustawienia eksperymentalne zostały natomiast zdefiniowane w postaci deklaratywnych plików konfiguracji YAML. Rozwiązanie to gwarantuje pełną separację logiki eksperymentalnej od kodu źródłowego, ułatwiając rekonfigurowalność hiperparametrów, kontrolę wersji eksperymentów oraz bezproblemową powtarzalność uzyskanych wyników. Zastosowanie jednolitej ramki RecBole eliminuje ponadto tzw. błędy niespójności implementacyjnej (ang. *reproducibility crisis*), gwarantując, że obserwowane różnice w wynikach wynikają wyłącznie z właściwości samych algorytmów.

2.2 Opis i przygotowanie danych

W części empirycznej niniejszej pracy do ewaluacji modeli rekomendacyjnych wykorzystano zbiór danych MovieLens 1M, udostępniany przez grupę badawczą GroupLens Research z University of Minnesota. Wybór tego zbioru jest podyktowany jego powszechnym uznaniem w literaturze naukowej jako kanonicznego benchmarku w dziedzinie systemów rekomendacyjnych²⁵.

Przestrzeń badawczą definiuje trójka uporządkowana obejmująca:

- zbiór wszystkich zarejestrowanych użytkowników, oznaczany symbolem $\mathcal{U}$ (gdzie $M = |\mathcal{U}|$ stanowi łączną liczbę użytkowników),
- zbiór wszystkich dostępnych w katalogu obiektów (filmów), oznaczany symbolem $\mathcal{I}$ (gdzie $N = |\mathcal{I}|$ stanowi łączną liczbę obiektów),

²⁵F. M. Harper i J. A. Konstan. The MovieLens Datasets: History and Context. W: „ACM Transactions on Interactive Intelligent Systems” 5.Nr 4 (2016); He i in., „Neural Collaborative Filtering”; Zhao i in., dz. cyt.

- zbiór zaobserwowanych historycznych interakcji, oznaczany symbolem $\mathcal{E}$ ($\mathcal{E} \subseteq \mathcal{U} \times \mathcal{I}$), reprezentujący zaobserwowane zdarzenia o liczebności $|\mathcal{E}|$.

W analizowanym zbiorze dane te przyjmują wartości: $M = 6\,040$, $N = 3\,706$ oraz $|\mathcal{E}| = 1\,000\,209$. Dokładne ustalenie wymiarów M i N jest kluczowe z punktu widzenia uczenia maszynowego, gdyż determinują one bezpośrednio rozmiary wejściowych słowników dla warstw osadzeń (*embedding layers*) w architekturach neuronowych i grafowych²⁶. W klasycznym ujęciu rzadkie wektory identyfikatorów użytkowników $\mathbf{v}_u \in \{0, 1\}^M$ (typu *one-hot*) oraz obiektów $\mathbf{v}_i \in \{0, 1\}^N$ są mapowane na gęste reprezentacje wektorowe $\mathbf{p}_u \in \mathbb{R}^k$ i $\mathbf{q}_i \in \mathbb{R}^k$ (gdzie $k \ll \min(M, N)$) poprzez mnożenie przez macierze wag osadzeń odpowiednio $\mathbf{P} \in \mathbb{R}^{M \times k}$ oraz $\mathbf{Q} \in \mathbb{R}^{N \times k}$.

Tradycyjny model danych rekomendacyjnych reprezentuje się jako dwuwymiarową macierz interakcji $\mathbf{R} \in \mathbb{R}^{M \times N}$, w której wiersze odpowiadają poszczególnym użytkownikom ($u \in \mathcal{U}$), a kolumny poszczególnym obiektom ($i \in \mathcal{I}$)²⁷. Stopień braku wypełnienia tej struktury opisuje wskaźnik rzadkości (*sparsity rate*), oznaczany symbolem $S \in [0, 1]$. Definiuje się go jako dopełnienie stosunku liczby faktycznie zaobserwowanych interakcji do teoretycznej maksymalnej liczby wszystkich możliwych powiązań w macierzy:

$$S = 1 - \frac{|\mathcal{E}|}{M \times N} \quad (3)$$

Dla wybranego zbioru danych stopień rzadkości wynosi $S = 95,53\%$, co oznacza, że jedynie 4,47% komórek macierzy zawiera zaobserwowane wpisy. W środowisku VOD skrajna rzadkość jest zjawiskiem naturalnym — pojedynczy widz jest w stanie zapoznać się jedynie z ułamkiem procenta całkowitej oferty platformy²⁸. Skrajnie wysoki wskaźnik rzadkości stanowi podstawowe uzasadnienie metodologiczne dla odrzucenia prostych algorytmów pamięciowych (k -NN), które zmagają się z problemem braku wspólnych sąsiadów, na rzecz metod czynników ukrytych (SVD)²⁹ oraz propagacji osadzeń w sieciach grafowych³⁰.

Interakcje na platformach streamingowych podlegają silnej asymetrii popytu opisanej rozkładem potęgowym (*Power Law*)³¹. Charakterystyczną cechą tej asymetrii w systemach dystrybucji cyfrowej jest fakt, że skrajnie nieliczna, uprzywilejowana grupa najpopularniejszych pozycji skupia wokół siebie zdecydowaną większość całej aktywności w

²⁶ Zhang i in., dz. cyt., s. sekcje 2.1, 3.2 oraz 3.4.

²⁷ Su i Khoshgoftaar, dz. cyt., s. 2.


²⁸ Chęciński i Wawrzusiak, dz. cyt., s. 19, 23.

²⁹ Su i Khoshgoftaar, dz. cyt.; Y. Koren, R. Bell i C. Volinsky. *Matrix Factorization Techniques for Recommender Systems*. W: „Computer” 42 (2009), s. 2, 3.

³⁰ Zhang i in., dz. cyt., s. sekcja 3.4.

³¹ O. Celma. *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*. 2010, s. 14–15, 105.

systemie, podczas gdy olbrzymia większość pozostałych obiektów odnotowuje znikome zainteresowanie ze strony odbiorców³². Badana przestrzeń danych jednoznacznie wykazuje zjawisko tzw. długiego ogona (*Long-Tail Distribution*), zaprezentowane na Rysunku 1.



Rysunek 1: Rozkład popularności filmów w zbiorze MovieLens 1M przedstawiający zjawisko długiego ogona (*Long-Tail Distribution*).

Źródło: opracowanie własne.

Katalog filmowy dzieli się na dwie wyraźne strefy³³:

- **Głowę popytu (*Head*):** wąską grupę najpopularniejszych produkcji kinowych (tzw. hitów), które skupiają przeważającą część całkowitej liczby ocen w systemie. Tradycyjnie to ta część oferty była faworyzowana w erze analogowej ze względu na ograniczenia fizycznej przestrzeni sklepowej i wysokie koszty dystrybucji, które wymuszały na dystrybutorach selekcję wyłącznie pozycji o masowej popularności³⁴.
- **Długi ogon (*Tail*):** obszerną listę niszowych, mniej znanych lub starszych tytułów o niskiej częstotliwości odtworzeń. W dobie cyfrowej, po wyeliminowaniu fizycznych ograniczeń magazynowych i półkowych, cała ta niszowa oferta może pozostawać stale dostępna dla użytkowników, tworząc ogromną sumę małych rynków o bardzo wysokim potencjale zaspokajania specyficznych i zróżnicowanych gustów³⁵.

Z biznesowego i funkcjonalnego punktu widzenia spersonalizowany system rekomendacyjny na rynku VOD musi potrafić trafnie proponować pozycje z długiego ogona, zapobiegając zjawisku monopolizacji uwagi widza wyłącznie przez najpopularniejsze hity³⁶. W

³²Ibidem, s. 93.

³³Ibidem, s. 100.

³⁴Ibidem, s. 14–15, 100.

³⁵Ibidem, s. 100.

³⁶Chęciński i Wawrzusiak, dz. cyt., s. 23.

dobie tzw. cyfrowej klęski urodzaju, gdy platformy streamingowe oferują tysiące filmów i seriali, użytkownicy stają w obliczu przeładowania informacyjnego, w którym samodzielne dotarcie do interesujących pozycji staje się wysoce utrudnione, a zapoznanie się z pełną ofertą katalogową jest fizycznie niemożliwe³⁷. Brak skutecznego mechanizmu personalizacji sprawia, że uwaga użytkowników koncentruje się wyłącznie na tytułach najgłośniejszych i powszechnie promowanych, co prowadzi do marnowania potencjału niszowej części biblioteki serwisu³⁸. Wdrożenie algorytmów zdolnych do eksploracji długiego ogona i kierowania uwagi widzów z obszaru głowy popytu ku pozycjom niszowym pozwala na pełniejsze wykorzystanie zasobów, zwiększa satysfakcję i lojalność odbiorców oraz maksymalizuje zaangażowanie w korzystanie z platformy³⁹.

Oryginalny zbiór MovieLens zawiera oceny jawne (*explicit feedback*) wyrażone w 5-stopniowej skali dyskretnej (od 1 do 5 gwiazdek). Choć oceny te dostarczają bardzo precyzyjnej i jednoznacznej informacji o stopniu satysfakcji użytkownika, w rzeczywistych systemach rekomendacyjnych współczesnych platform wideo występują one niezwykle rzadko. Wynika to z faktu, że czynność ta nakłada na odbiorcę dodatkowe obciążenie poznawcze i wymaga intencjonalnego działania po seansie, co zakłóca naturalną, bezwysiłkową konsumpcję treści — większość widzów chce po prostu oglądać kolejne materiały, a nie dokonywać ich ewaluacji⁴⁰.

W konsekwencji głównym źródłem informacji dla algorytmów stają się ślady cyfrowe i interakcje dorozumiane (*implicit feedback*), takie jak odtworzenie filmu, czas jego oglądania, kliknięcie w miniaturę czy historia wyszukiwania⁴¹. Dane te są gromadzone przez platformy całkowicie pasywnie, bez wysiłku ze strony widza, co pozwala na budowę znacznie większych i bardziej aktualnych zbiorów uczących, choć są one trudniejsze w interpretacji z uwagi na brak bezpośredniej deklaracji zadowolenia⁴². Rozkład ocen jawnych w analizowanym zbiorze zaprezentowano na Rysunku 2.

³⁷Ibidem, s. 19.


³⁸Ibidem, s. 19.

³⁹Celma, dz. cyt.; Chęciński i Wawrzusiak, dz. cyt., s. 14–15, 23.

⁴⁰S. Rendle i in. „BPR: Bayesian Personalized Ranking from Implicit Feedback.” W: 2009, s. 452.

⁴¹Su i Khoshgoftaar, dz. cyt.; Chęciński i Wawrzusiak, dz. cyt., s. 2.

⁴²Rendle i in., dz. cyt., s. 452–453.



Rysunek 2: Rozkład ocen jawnych w zbiorze MovieLens 1M obrazujący efekt zjawiska *positivity bias*

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 1M.

Analiza histogramu wykazuje silne skrzywienie pozytywne (*positivity bias*) – użytkownicy znacznie chętniej oceniają filmy, które im się podobały, podczas gdy produkcje ocenione negatywnie są w logach niemal nieobecne (oceny 3, 4 i 5 stanowią ponad 80% wszystkich wpisów). Zjawisko to jest bezpośrednią konsekwencją błędu selekcji; widzowie intuicyjnie wybierają do obejrzenia te tytuły, wobec których żywią już uprzednie pozytywne oczekiwania (np. ze względu na ulubiony gatunek czy obsadę), co wtórnie drastycznie ogranicza szansę na wystawienie niskiej noty⁴³. W rezultacie obserwowany zbiór ocen jawnych nie odzwierciedla reprezentatywnego profilu gustu użytkownika wobec całego katalogu, a jedynie wobec jego wyselekcjonowanego ułamka⁴⁴.

Zgodnie z metodologią zaproponowaną przez He i in.⁴⁵, w celu dostosowania danych do realiów platform streamingowych dokonuje się przekształcenia binarnego oryginalnej macierzy ocen w macierz interakcji dorozumianych, oznaczaną jako $\mathbf{Y} \in \mathbb{R}^{M \times N}$ (gdzie $M = |\mathcal{U}|$ oznacza liczbę użytkowników, a $N = |\mathcal{I}|$ liczbę filmów). Zabieg ten pozwala na przekształcenie subiektywnego problemu regresji ocen w zadanie klasyfikacji binarnej (rekomendacji góry listy), co znacznie lepiej oddaje rzeczywiste zachowanie i procesy decyzyjne użytkowników w serwisach OTT, gdzie kluczowym wyborem jest decyzja o kliknięciu i rozpoczęciu odtwarzania danego tytułu⁴⁶.

Przed przedstawieniem reguły dyskryminacyjnej zdefiniujmy elementy składowe wzoru:

⁴³ Celma, dz. cyt., s. 28.

⁴⁴ Ibidem, s. 28.

⁴⁵ He i in., dz. cyt., s. 7.

⁴⁶ Ibidem, s. 7.

- y_{ui} — wartość wskaźnikowa określająca obecność zaobserwowanej relacji pomiędzy użytkownikiem $u \in \mathcal{U}$ a obiektem $i \in \mathcal{I}$,
- $y_{ui} = 1$ — stan dodatni, oznaczający zarejestrowanie interakcji (np. wystawienie jakiegokolwiek oceny lub obejrzenie filmu),
- $y_{ui} = 0$ — stan nieobserwowany, oznaczający brak zarejestrowanej akcji w logach systemowych.

Sformułowanie matematyczne funkcji binarnej przyjmuje postać:

$$y_{ui} = \begin{cases} 1, & \text{jeśli zaobserwowano interakcję (użytkownik } u \text{ ocenił/obejrzał film } i) \\ 0, & \text{w przeciwnym razie (brak obserwacji)} \end{cases} \quad (4)$$

Warto podkreślić, że wartość $y_{ui} = 0$ ma charakter wysoce niejednoznaczny semantycznie. Nie oznacza ona bowiem jawnej niechęci użytkownika do danego tytułu, lecz jedynie brak wiedzy o wchodzeniu w interakcję⁴⁷. Użytkownik mógł nie obejrzeć filmu z powodów zupełnie niezależnych od jego gustu: mógł go nie zauważyć w katalogu, nie zostać na niego wyeksponowany przez interfejs platformy, bądź po prostu jeszcze na niego nie trafić⁴⁸. Struktura ta stanowi fundamentalne wyzwanie w uczeniu maszynowym, gdyż zbiór danych nieobserwowanych ($y_{ui} = 0$) de facto reprezentuje jednocześnie rzeczywiste negatywne preferencje (użytkownik zna film, ale nie chce go obejrzeć), jak i potencjalne przyszłe interakcje dodatnie (użytkownik chętnie obejrzałby film, gdyby tylko dowiedział się o jego istnieniu), które model powinien poprawnie zidentyfikować i wybić na górę listy rekomendacji⁴⁹.

Rozkład aktywności użytkowników wykazuje duże zróżnicowanie – od profili okazjonalnych po użytkowników o skrajnie wysokiej liczbie obejrzanych pozycji. Rozkład liczby ocen przypadających na pojedynczego użytkownika w analizowanym zbiorze zaprezentowano na Rysunku 3. Aby wyeliminować zaburzenia wynikające ze skrajnie rzadkich profili oraz pozycji znikających z katalogu bez historii ocen, zastosowano procedurę filtrowania typu k -core ($k = 5$)⁵⁰. Odrzucono wszystkich użytkowników oraz filmy posiadające mniej niż 5 zarejestrowanych interakcji. Operacja ta zapobiega występowaniu niemożliwych do wyuczenia trywialnych wektorów zerowych w warstwach embeddingów oraz stabilizuje proces wyznaczania normalizacji macierzy sąsiedztwa grafu dwudzielnego w modelach GNN⁵¹.


⁴⁷Ibidem, s. 2.

⁴⁸Tenże, „Neural Collaborative Filtering”; Rendle i in., dz. cyt., s. 2.

⁴⁹Tenże, „BPR”, s. 453.

⁵⁰He i in., dz. cyt., s. 7, sekcja 4.1.1.

⁵¹Zhao i in., dz. cyt., s. 6, sekcja 2.1.1.



Rysunek 3: Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 1M

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 1M.

W celu zapewnienia ścisłej reprodukowalności eksperymentów i eliminacji błędów implementacyjnych oczyszczone zbiory danych przekonwertowano do formatu Plików Atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter`, stanowiącego standard wejściowy biblioteki RecBole⁵². Plik `.inter` przechowuje relacje w strukturze tabularycznej ze zdefiniowanymi typami pól⁵³:

- `user_id:token` – unikalny identyfikator użytkownika (sekwencja dyskretna),
- `item_id:token` – unikalny identyfikator filmu (sekwencja dyskretna),
- `rating:float` – oryginalna ocena użytkownika (wykorzystywana pomocniczo),
- `timestamp:float` – znacznik czasu interakcji.

Ewaluację modeli przeprowadzono w oparciu o proporcjonalny losowy podział danych (*Ratio Splitting*) w stosunku 80% : 10% : 10% (odpowiednio: zbiór treningowy, walidacyjny i testowy), co stanowi standardowy protokół podziału danych typu *ratio-based splitting* obsługiwany przez bibliotekę RecBole⁵⁴.

Do trenowania modeli punktowych i parowych (Log Loss w NCF oraz BPR Loss w SVD/LightGCN) zastosowano procedurę próbkowania negatywnego (*negative sampling*). Dla każdej dodatniej pary $(u, i) \in \mathcal{E}$ losowano jednostajnie ze zbioru pozycji nieobserwowanych zestaw próbek negatywnych $(u, j) \in \mathcal{E}^-$ (gdzie $y_{uj} = 0$), przy zachowaniu

⁵²Ibidem, s. 6, sekcja 2.1.2.

⁵³Ibidem, s. 6, Tabela 3.

⁵⁴Ibidem, s. 6, sekcja 2.1.1 oraz s. 7, sekcja 2.3.4.

stosunku 1 : 4 (4 próbki negatywne na 1 pozycję dodatnią), co stanowi optymalny kompromis między stabilnością gradientu a czasem obliczeń⁵⁵. Zastosowanie elastycznej liczby próbek negatywnych (w optymalnym przedziale od 3 do 6) pozwala modelom optymalizowanym punktową stratą logarytmicznej na znaczące przełamanie ograniczeń klasycznych strat parowych typu BPR, które z natury parują wyłącznie jedną próbkę negatywną z dodatnią⁵⁶.

Tabela 1 przedstawia zbiorcze zestawienie parametrów statystycznych przygotowanego zbioru danych MovieLens 1M po przeprowadzeniu potoku przetwarzania.

Tabela 1: Podsumowanie statystyczne zbioru danych MovieLens 1M wykorzystanego w eksperymentach

Parametr statystyczny	Wartość dla zbioru MovieLens 1M (ml-1m)
Liczba użytkowników ($ \mathcal{U} $)	6 040
Liczba filmów ($ \mathcal{I} $)	3 706
Liczba interakcji ($ \mathcal{E} $)	1 000 209
Średnia liczba ocen na użytkownika	165,60
Gęstość macierzy (<i>Density</i>)	4,47%
Rzadkość macierzy (<i>Sparsity</i>)	95,53%
Typ informacji zwrotnej	Interakcje dorożumiane (<i>Implicit Feedback</i>)

Źródło: opracowanie własne.

2.3 Algorytmy filtrowania kolaboracyjnego

Filtrowanie kolaboracyjne stanowi jeden z najważniejszych i najbardziej ugruntowanych paradygmatów w dziedzinie systemów rekomendacyjnych⁵⁷. Jego podstawowym założeniem jest hipoteza, że użytkownicy o zbliżonych wzorcach zachowań w przeszłości będą przejawiać podobne preferencje w przyszłości. W przeciwieństwie do metod opartych na treści, filtrowanie kolaboracyjne nie wymaga analizy semantycznej obiektów ani dostępu do ich szczegółowych metadanych, opierając proces wnioskowania wyłącznie na macierzy interakcji użytkownik-obiekt $R \in \mathbb{R}^{M \times N}$, gdzie M oznacza liczbę użytkowników, natomiast N liczbę filmów w katalogu platformy.

Techniki filtrowania kolaboracyjnego dzielą się na trzy główne nurty: metody oparte na pamięci (ang. *memory-based CF*), metody oparte na modelach (ang. *model-based CF*) oraz systemy hybrydowe. Pierwsza z wymienionych grup polega na bezpośrednim wykorzystaniu historycznych interakcji do poszukiwania podobieństw i działa w dwóch podstawowych wariantach. Z jednej strony wyróżnia się podejście zorientowane na użytkownika

⁵⁵He i in., dz. cyt., s. 7, sekcja 4.1.2.

⁵⁶Ibidem, s. 8, sekcja 4.3.

⁵⁷Su i Khoshgoftaar, dz. cyt.; Koren, Bell i Volinsky, dz. cyt.; Krawczuk, dz. cyt.

(ang. *User-Based CF*), które opiera się na poszukiwaniu profili o gustach historycznie zbliżonych do aktywnego odbiorcy. Z drugiej strony stosuje się podejście zorientowane na obiekty (ang. *Item-Based CF*), w którym oblicza się analityczne podobieństwo pomiędzy samymi pozycjami w katalogu na podstawie tego, czy wchodziła z nimi w interakcję ta sama grupa odbiorców. W przypadku serwisów VOD znacznie powszechniej wykorzystuje się podejście oparte na obiektach. Wynika to z faktu, że zbiór filmów tworzy strukturę znacznie bardziej stabilną w czasie – charakterystyki ich grup docelowych rzadko ulegają zmianie, podczas gdy gusta użytkowników są zmienne, a ich całkowita liczba nieustannie fluktuuje.

Ogromnym krokiem naprzód w ewolucji systemów rekomendacyjnych okazało się odejście od surowej pamięci na rzecz wprowadzania uczących się metod analitycznych (nurt oparty na modelach), a dokładniej modeli czynników ukrytych (ang. *latent factor models*), realizowanych za pomocą technik faktoryzacji macierzy. Idea faktoryzacji polega na odwzorowaniu zarówno użytkowników u , jak i obiektów i we wspólnej, k -wymiarowej przestrzeni ukrytej $\mathbb{R}^k$, gdzie $k \ll \min(M, N)$ oznacza wyznaczoną liczbę wymiarów ukrytych. W architekturze tej preferencje pojedynczego użytkownika reprezentowane są przez wektor $\mathbf{p}_u \in \mathbb{R}^k$, natomiast właściwości samego filmu oddaje wektor $\mathbf{q}_i \in \mathbb{R}^k$. Stopień potencjalnego dopasowania danego tytułu do gustu widza obliczany jest na podstawie klasycznej operacji iloczynu skalarnego wyznaczonych wektorów.

W niniejszej pracy jako wiodących reprezentantów tradycyjnego filtrowania kolaboracyjnego wybrano dwa algorytmy odniesienia (tzw. *baseline*), z których każdy reprezentuje całkowicie odmienne podejście analityczne: ItemKNN (stanowiący klasyczną metodę opartą na obiektowej pamięci) oraz BPR-MF, będący fundamentalnym przykładem wariantu opartego na uczeniu parametrów przy użyciu faktoryzacji macierzy z optymalizacją porządkową.

2.3.1 Algorytm ItemKNN

Jedną z najpopularniejszych i najbardziej uznanych metod bazujących na pamięci jest technika oparta na analizie podobieństwa obiektów (ang. *Item-Based Collaborative Filtering*), powszechnie implementowana jako algorytm ItemKNN. Geneza tej metody, wprowadzona i spopularyzowana na przełomie wieków w systemach e-commerce przez B. Sarwara i in.⁵⁸, opiera się na intuicyjnym założeniu, że z większym prawdopodobieństwem będziemy preferować te filmy, które są w dużym stopniu powiązane z produkcjami pozytywnie ocenionymi przez nas w przeszłości. Matematyczne podstawy algorytmu ItemKNN oraz koncepcja budowania sąsiedztwa, przedstawione w niniejszym podrozdziale, opierają

⁵⁸B. Sarwar i in. Item-Based Collaborative Filtering Recommendation Algorithms. W: „Proceedings of ACM World Wide Web Conference” 1 (2001).

się w głównej mierze na metodologii syntetyzowanej w pracy Bałchanowskiego⁵⁹.

W przeciwieństwie do metod zorientowanych na użytkownika (*User-Based CF*), ItemKNN wyszukuje podobieństwa na poziomie kolumn macierzy interakcji (filmów). Ogranicza to znacząco problemy wynikające ze zmienności gustów ludzkich oraz nieustannego rotowania bazy aktywnych kont. Z biznesowego punktu widzenia na platformach VOD liczba filmów rośnie wolniej niż liczba nowych subskrybentów, co stabilizuje proces obliczania sąsiedztwa i zwiększa jakość rekomendacji w ujęciu długoterminowym.

Procedura generowania rekomendacji przy użyciu algorytmu ItemKNN przedstawia się następująco:

1. W pierwszej kolejności, dla każdego z analizowanych elementów, system precyzyjnie ustala sąsiedztwo. Proces ten rozpoczyna się od wyliczenia funkcji podobieństwa $s(i, j)$ pomiędzy dowolnymi dwoma filmami i oraz j z katalogu $\mathcal{I}$. Ze względu na to, że badana w niniejszej pracy przestrzeń danych opiera się na interakcjach dorozumianych (*implicit feedback*), klasyczne miary uwzględniające średnie wariancje ocen (np. korelacja Pearsona) nie znajdują tu matematycznego zastosowania. Standardową techniką służącą do pomiaru bliskości w środowisku binarnym jest odległość kosinusowa (ang. *Cosine Similarity*), operująca w przestrzeni wektorowej. Stopień powiązania dwóch filmów wyznacza się za jej pomocą ze wzoru⁶⁰:

$$s(i, j) = \frac{\mathbf{y}_i \cdot \mathbf{y}_j}{\|\mathbf{y}_i\|_2 \|\mathbf{y}_j\|_2} = \frac{\sum_u y_{ui} y_{uj}}{\sqrt{\sum_u y_{ui}^2} \sqrt{\sum_u y_{uj}^2}} \quad (5)$$

Gdzie:

- $\mathbf{y}_i, \mathbf{y}_j$ – wektory binarne reprezentujące historię interakcji wszystkich użytkowników dla filmów i oraz j
 - y_{ui}, y_{uj} – obserwacje obecności interakcji (0 lub 1) dla użytkownika u z oboma filmami
 - $\|\mathbf{y}_i\|_2, \|\mathbf{y}_j\|_2$ – normy Euklidesowe (L2) badanych wektorów
2. Ponieważ obliczanie relacji dla każdej możliwej pary obiektów w skali milionów widzów wiąże się ze zjawiskiem ogromnego szumu informacyjnego, algorytm dokonuje redukcji macierzy podobieństw. Dla każdego filmu i zawęża się grono powiązań wyłącznie do zamkniętego zbioru K najbardziej zbliżonych filmów (tzw. zbiór najbliższych sąsiadów $\mathcal{N}_i$).

⁵⁹M. Bałchanowski. „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”. Rozprawa doktorska. 2023, s. 16-17.

⁶⁰Ibidem, s. 16.

3. W etapie predykcji, po zalogowaniu się użytkownika u , algorytm odczytuje zbiór wszystkich filmów, które ten użytkownik zdążył już obejrzeć (tzw. wejściowy profil użytkownika $\mathcal{I}_u^+$).
4. Ostateczny krok działania algorytmu polega na wyliczeniu estymowanego stopnia dopasowania $\hat{x}_{ui}$, jakim użytkownik u obdarzy dowolny, nieobejrzany jeszcze film i . Predykcję realizuje się poprzez obliczenie średniej ważonej z miar podobieństwa pomiędzy tym filmem i , a obejrzanymi już przez widza produkcjami j , które znalazły się w jego ograniczonym sąsiedztwie⁶¹:

$$\hat{x}_{ui} = \frac{\sum_j s(i, j) y_{uj}}{\sum_j |s(i, j)|}, \quad j \in \mathcal{N}_i \cap \mathcal{I}_u^+ \quad (6)$$

Gdzie:

- $\mathcal{N}_i$ – wyznaczony w etapie 2 statyczny zbiór zawierający K filmów najbliższych spokrewnionych z obiektem i
- $\mathcal{I}_u^+$ – zbiór wszystkich filmów, które użytkownik u już obejrzał
- y_{uj} – wystąpienie pozytywnej relacji pomiędzy użytkownikiem a sąsiadem badanego obiektu

Model ItemKNN, ze względu na swoją wysoką skuteczność w systemach pozbawionych zaawansowanych mechanizmów uczących oraz wysoką wyjaśnialność (wyniki można wprost zinterpretować w interfejsie jako klauzulę "Z uwagi na to, że obejrzałeś X, polecamy Ci Y"), na stałe wszedł do kanonu filtrowania kolaboracyjnego. W nowoczesnych zestawieniach naukowych odgrywa on rolę punktu odniesienia (*baseline*), służącego do weryfikacji celowości wdrażania cięższych obliczeniowo metod rekomendacji.

2.3.2 Spersonalizowany ranking bayesowski

Spersonalizowany ranking bayesowski (ang. *Bayesian Personalized Ranking, BPR*) jest to technika generująca rekomendacje na podstawie macierzy interakcji. Charakterystycznym elementem tego algorytmu jest sposób, w jaki traktuje sytuacje, w których użytkownik nie wszedł w interakcję z danym przedmiotem. Tradycyjnie brak interakcji jest traktowany w macierzy jako wartość 0, co interpretowane jest jako negatywna informacja zwrotna. Taki stan rzeczy może nieprecyzyjnie oddawać rzeczywistość. Filmami nieobejrzanymi mogą być zarówno te, które są dla użytkownika nieinteresujące, jak i te, których po prostu nie zna, bądź nie zdążył jeszcze obejrzeć.

⁶¹ Ibidem, s. 16.

Aby rozwiązać ten problem, algorytm BPR rezygnuje z klasycznego, punktowego podejścia do uczenia modelu (gdzie system estymuje konkretną wartość liczbową dla pary użytkownik-obiekt) na rzecz podejścia opartego na parach (ang. *pairwise learning*). Podstawowym założeniem metody jest to, że użytkownik zawsze preferuje obiekty, z którymi wszedł w interakcję, nad tymi, z którymi interakcji nie podjął. Jeżeli zdefiniujemy obiekty znane użytkownikowi u jako pozytywne (oznaczane jako i), a pozostałe pozycje w katalogu jako negatywne (j), BPR zakłada relację wyższości $i >_u j$ na liście rankingowej⁶².

W trakcie treningu optymalizator nie rozpatruje indywidualnych obiektów, lecz przetwarzając trójki uczące w postaci (u, i, j) . Celem algorytmu jest maksymalizacja prawdopodobieństwa, że estymowana ocena trafności filmu pozytywnego będzie zawsze przewyższać estymowaną ocenę filmu negatywnego. Podejście to prowadzi do sformułowania kryterium optymalizacyjnego BPR-OPT, które w oparciu o funkcję logistyczną minimalizuje stratę dla wszystkich trójek⁶³:

$$\text{BPR-OPT} = \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) - \lambda_{\Theta} \|\Theta\|^2 \quad (7)$$

Gdzie:

- D_S – zbiór wszystkich treningowych trójek (użytkownik, obiekt pozytywny, obiekt negatywny), formułowany na podstawie zbioru zaobserwowanych zdarzeń $\mathcal{E}$ i zdarzeń negatywnych z nim rozłącznych
- $\hat{x}_{ui}$ – estymowana preferencja użytkownika u względem obiektu i (pozytywnego)
- $\hat{x}_{uj}$ – estymowana preferencja użytkownika u względem obiektu j (negatywnego)
- Θ – wektory wag modelu podlegające wyuczeniu
- λ_{Θ} – hiperparametr terminu regularyzacyjnego L2, zapobiegającego zjawisku przeuczenia modelu (ang. *overfitting*)

Zastosowanie funkcji straty BPR samo w sobie nie określa architektury samej estymaty ($\hat{x}_{ui}$). W podejściu BPR-MF system integruje ową funkcję z modelem faktoryzacji macierzy. W tej konfiguracji przewidywana preferencja użytkownika względem danego obiektu jest obliczana jako standardowy iloczyn skalarny przypisanych do nich wektorów⁶⁴:

$$\hat{x}_{ui} = \mathbf{p}_u \cdot \mathbf{q}_i = \sum_{f=1}^k p_{uf} q_{if} \quad (8)$$

⁶² Rendle i in., dz. cyt., s. 453-454.

⁶³ Ibidem, s. 455.

⁶⁴ Ibidem, s. 456.

Gdzie:

- $\mathbf{p}_u$ – ukryty wektor cech reprezentujący użytkownika u
- $\mathbf{q}_i$ – ukryty wektor cech reprezentujący obiekt i
- k – wymiarowość przestrzeni ukrytej (z góry określona liczba cech w wektorze)
- p_{uf}, q_{if} – poszczególne (f -te) składowe wektorów ukrytych odpowiednio dla użytkownika u i obiektu i

W procesie optymalizacji – wykorzystującym zazwyczaj algorytm stochastycznego spadku wzdłuż gradientu (SGD) – system iteracyjnie przelicza parametry poszczególnych wektorów po jednej trójce, poszukując minimum funkcji błędu zdefiniowanej równaniem (7). Choć model BPR-MF opiera się na matematycznie prostym iloczynie skalarnym, przez lata dowiódł on swojej potężnej skuteczności w zadaniach wykorzystujących wyłącznie dane dorozumiane. Wynika to wprost z dopasowania samej definicji straty parowej do natury rankingu – algorytm uczy się bezpośrednio sortować obiekty, zamiast przewidywać ich wyizolowane oceny punktowe. Z tego powodu we współczesnej literaturze przedmiotu BPR stanowi fundamentalny model odniesienia, z którym obligatoryjnie zestawia się skuteczność nowszych, rozbudowanych architektur systemów rekomendacyjnych. Autorzy nowatorskich rozwiązań z rodziny głębokich sieci kolaboracyjnych⁶⁵ oraz sieci wykorzystujących propagację w strukturach grafowych⁶⁶ regularnie opierają ewaluację empiryczną na bazowym zestawieniu swoich wyników właśnie z klasycznym wariantem BPR-MF.

2.4 Algorytmy uczenia głębokiego

2.5 Algorytmy grafowych sieci neuronowych

2.6 Metryki oceny

Ewaluacja modeli rekomendacyjnych w warunkach interakcji dorozumianych (*implicit feedback*) różni się fundamentalnie od tradycyjnej oceny systemów ukierunkowanych na przewidywanie ocen jawnych. W klasycznym ujęciu regresyjnym celem algorytmu jest minimalizacja błędu predykcji wartości ciągłej, wyrażanej najczęściej za pomocą średniego błędu kwadratowego (ang. *Root Mean Squared Error*, *RMSE*) lub średniego błędu bezwzględnego (ang. *Mean Absolute Error*, *MAE*)⁶⁷.

⁶⁵He i in., dz. cyt., s. 178.

⁶⁶He i in., „LightGCN”, s. 5.

⁶⁷G. Shani i A. Gunawardana. Evaluating Recommendation Systems. W: (w:) Recommender Systems Handbook. T. 12. 2011, s. 15–16.

W rzeczywistych platformach VOD/OTT kluczowe znaczenie ma jednak zdolność systemu do wyselekcjonowania i trafnego uporządkowania spersonalizowanej listy K najwłaściwszych obiektów (tzw. rekomendacja góry listy, ang. *Top-K Recommendation*)⁶⁸. Skuteczność dopasowania listy do preferencji użytkownika mierzy się za pomocą metryk rangowych. W przeciwieństwie do miar regresyjnych uwzględniają one fakt, że w warunkach rzadkości danych oraz przytłaczającej liczby tytułów w katalogu, użytkownik zapoznaje się wyłącznie z czołowymi pozycjami rekomendowanej listy, ignorując pozostałą, nienadrzędną część asortymentu platformy⁶⁹.

W badaniach eksperymentalnych zastosowano zestaw czterech komplementarnych metryk rangowych poddawanych ewaluacji na zbiorze testowym dla progu $K = 10$: Czułość (*Recall@K*), Wskaźnik Trafień (*Hit Rate@K*), Znormalizowany Zdyskontowany Zysk Skumulowany (*Normalized Discounted Cumulative Gain, NDCG@K*) oraz Średnią Odwrotność Rangi (*Mean Reciprocal Rank, MRR@K*)⁷⁰.

Niech $\mathcal{U}$ oznacza zbiór użytkowników poddawanych ewaluacji, $\mathcal{R}_u(K)$ uporządkowany zbiór K obiektów rekomendowanych użytkownikowi $u \in \mathcal{U}$ przez analizowany model, natomiast $\mathcal{T}_u$ zbiór obiektów faktycznie zaobserwowanych (relevantnych) w zbiorze testowym dla tego użytkownika. Każda z wymienionych metryk mierzy odmienny aspekt jakości dopasowania listy rekomendacyjnej:

- **Czułość (ang. *Recall at K, Recall@K*):** określa, jaki ułamek wszystkich relevantnych dla użytkownika obiektów ze zbioru testowego znalazł się na wygenerowanej liście rekomendacji, ignorując kolejność ich ułożenia⁷¹. Obliczany jako iloraz trafnych wskazań algorytmu (wyrażonych jako przecięcie zbioru rekomendacji ze zbiorem testowym) i łącznej liczby pożądaných przez użytkownika elementów:

$$\text{Recall@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{|\mathcal{R}_u(K) \cap \mathcal{T}_u|}{|\mathcal{T}_u|} \quad (9)$$

- **Wskaźnik Trafień (ang. *Hit Rate at K, Hit Rate@K*):** reprezentuje prawdopodobieństwo, że na rekomendowanej liście o długości K znajdzie się co najmniej jeden obiekt poszukiwany przez użytkownika w zbiorze testowym⁷²:

$$\text{HR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbb{I}(\mathcal{R}_u(K) \cap \mathcal{T}_u \neq \emptyset) \quad (10)$$

gdzie $\mathbb{I}(\cdot)$ oznacza funkcję wskaźnikową, przyjmującą wartość 1, gdy warunek logiczny jest spełniony, oraz 0 w przeciwnym razie.

⁶⁸Steck, dz. cyt., s. 220.

⁶⁹Shani i Gunawardana, dz. cyt., s. 16–20.

⁷⁰Zhao i in., dz. cyt., s. zob. s. 6, sekcja 2.3.1.

⁷¹Shani i Gunawardana, dz. cyt., s. 264.

⁷²He i in., „Neural Collaborative Filtering”, s. 7, sekcja 4.1.1.

- **Znormalizowany Zdyskontowany Zysk Skumulowany (ang. *Normalized Discounted Cumulative Gain, NDCG@K*):** w przeciwieństwie do czułości i wskaźnika trafień, metryka NDCG@K uwzględnia dokładną pozycję (rangę) trafionych obiektów. Odzwierciedla to rzeczywiste zachowanie użytkowników platform streamingowych, których uwaga drastycznie maleje wraz z oddalaniem się od początku zestawienia. Dyskonto pozycyjne nakłada najwyższą wagę na trafienia na najwyższych miejscach (np. pozycje 1–3), stosując logarytmiczne osłabienie wag dla pozycji dalszych, co pozwala na precyzyjną ocenę zdolności modelu do pozycjonowania najlepszych propozycji na samym szczycie listy⁷³.

Zysk zdyskontowany (DCG@K) dla użytkownika u wyraża się wzorem⁷⁴:

$$\text{DCG@K}(u) = \sum_{i=1}^K \frac{rel_u(i)}{\log_2(i+1)} \quad (11)$$

gdzie $rel_u(i) \in \{0, 1\}$ oznacza wskaźnik trafienia obiektu znajdującego się na i -tej pozycji rekomendowanej listy $\mathcal{R}_u(K)$ (przyjmując wartość 1, jeśli obiekt należy do zbioru testowego $\mathcal{T}_u$, oraz 0 w przeciwnym razie). Idealny zysk zdyskontowany (IDCG@K) odpowiada hipotetycznemu, bezbłędnemu uszeregowaniu, w którym wszystkie rzeczywiste obiekty ze zbioru testowego umieszczono na najwyższych możliwych pozycjach listy rekomendacyjnej⁷⁵:

$$\text{IDCG@K}(u) = \sum_{i=1}^{\min(|\mathcal{T}_u|, K)} \frac{1}{\log_2(i+1)} \quad (12)$$

Znormalizowana wartość NDCG@K stanowi stosunek zysku rzeczywistego do idealnego, a jej uśrednienie po całym zbiorze użytkowników pozwala na uzyskanie syntetycznej oceny jakości rankingu generowanego przez model⁷⁶:

$$\text{NDCG@K}(u) = \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)} \implies \text{NDCG@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{NDCG@K}(u) \quad (13)$$

- **Średnia Odwrotność Rangi (ang. *Mean Reciprocal Rank, MRR@K*):** mierzy zdolność systemu do jak najszybszego dostarczenia pierwszej trafnej rekomendacji. Z punktu widzenia platform VOD wskaźnik ten ma fundamentalne znaczenie użytkowe, gdyż symuluje scenariusz, w którym widz poszukuje pojedynczego, satysfakcjonującego filmu na dany wieczór, a jego proces interakcji z interfejsem kończy się w momencie odnalezienia pierwszej interesującej pozycji. Jakość systemu ocenia

⁷³Krawczuk, dz. cyt., s. 35.

⁷⁴Shani i Gunawardana, dz. cyt., s. 270.

⁷⁵Krawczuk, Ibidem.

⁷⁶Shani i Gunawardana, dz. cyt.; Krawczuk, dz. cyt., s. 270–271.

się tu przez pryzmat odwrotności pozycji, na której pojawił się pierwszy obiekt ze zbioru testowego⁷⁷:

$$\text{MRR@K}(u) = \frac{1}{\text{rank}_u^*} \quad (14)$$

gdzie rank_u^* oznacza rangę pierwszej trafnej rekomendacji na liście $\mathcal{R}_u(K)$ (przyjmując $\text{MRR@K}(u) = 0$, jeśli w obrębie K pozycji nie wystąpiło żadne trafienie). Ostateczna wartość MRR@K stanowi średnią arytmetyczną odwrotności rang obliczoną dla wszystkich analizowanych użytkowników⁷⁸:

$$\text{MRR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{MRR@K}(u) \quad (15)$$

Wartość NDCG@10 przyjęto w badaniach jako główną metrykę walidacyjną (*target metric*), decydującą o zatrzymaniu procesu trenowania (procedura *early stopping*) oraz wyznaczaniu optymalnych zestawów hiperparametrów analizowanych modeli. Takie podejście jest w pełni spójne z powszechną praktyką eksperymentalną w dziedzinie głębokich systemów rekomendacyjnych, gdzie to właśnie jakość uporządkowania czołówki listy rekomendacji decyduje o finalnej użyteczności modelu dla widza⁷⁹.

⁷⁷ Tenże, „Systemy rekomendacyjne”, s. 34.

⁷⁸ Ibidem, s. 34.

⁷⁹ He i in., dz. cyt., s. zob. s. 7, sekcja 4.1.1.

3 Tytuł rozdziału 3

Zwykle jest to problem badawczy składający się z podrozdziałów:

1. Eksperymenty obliczeniowe/symulacyjne/komputerowe
2. Rozwiązania/wyniki
3. Dyskusja wyników i wnioski

Analiza wyników ma być zaprojektowana i przeprowadza tak, aby móc zająć stanowisko względem tezy - potwierdzić ją lub odrzucić.

W dyskusji wyników należy podkreślić ważne obserwacje z wyników badań z punktu widzenia postawionej tezy. Należy też wspomnieć o wadach zaprojektowanego eksperymentu, jego niedociągnięciach wpływających na wyniki.

Podsumowanie

Należy nawiązać do problemu badawczego, tezy i celu pracy. Trzeba krótko podsumować najważniejsze wnioski z badań – nie w punktach; ma to być tekst ciągły. W oparciu o przywołane najważniejsze spostrzeżenia należy stwierdzić, czy tezę pracy można przyjąć, czy należy ją odrzucić. Na tej podstawie należy stwierdzić, czy cel pracy został zrealizowany. W przypadku prac opartych na konkretnych problemach przedsiębiorstw można ocenić znaczenie przeprowadzonych badań dla firmy w kontekście budowania przewagi konkurencyjnej na rynku (niższe koszty, większa prędkość produkcji, większa elastyczność produkcji itp.).

Bibliografia

- G. Adomavicius i A. Tuzhilin. Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. W: „IEEE Transactions on Knowledge and Data Engineering” 17 (2005), s. 734–749.
- M. Bałchanowski. „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”. Rozprawa doktorska. 2023.
- BookBeat. *O nas – BookBeat*. <https://www.bookbeat.com/pl/about>.
- R. Burke. Hybrid Recommender Systems: Survey and Experiments. W: „User Modeling and User-Adapted Interaction” 12 (2002).
- O. Celma. *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*. 2010.
- K. Chęciński i R. Wawrzusiak. Systemy rekomendacji. Remedium w cyfrowej kłęsce urodzaju. W: „Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne” nr 2 (2023).
- T. Doligalski i in. *Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy*. 2024.
- C. Gómez-Urbe i N. Hunt. The Netflix Recommender System. W: „ACM Transactions on Management Information Systems” 6 (2015), s. 1–19.
- B. Hallinan i T. Striphas. Recommended for You: The Netflix Prize and the Production of Algorithmic Culture. W: „New Media & Society” 18 (2016), s. 117–137.
- F. M. Harper i J. A. Konstan. The MovieLens Datasets: History and Context. W: „ACM Transactions on Interactive Intelligent Systems” 5.Nr 4 (2016), s. 1–19.
- X. He i in. „Neural Collaborative Filtering”. W: *Proceedings of the 26th International Conference on World Wide Web*. WWW '17. Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017, s. 173–182.
- X. He i in. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. W: (2020).
- IMDb. *Press Room - IMDb*. <https://www.imdb.com/pressroom/stats/>.
- Y. Koren, R. Bell i C. Volinsky. Matrix Factorization Techniques for Recommender Systems. W: „Computer” 42 (2009), s. 30–37.
- J. Krawczuk. Systemy rekomendacyjne. W: (w:) *Wybrane zagadnienia symulacji komputerowej*. 2024, s. 24–38.
- M. Malinowski. Zastosowanie Grafów i Sieci w Systemach Rekomendacji. W: 2021, s. 77–96.
- „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”. Rozprawa doktorska. Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022.

- S. Raza i in. *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. 2024.
- S. Rendle i in. „BPR: Bayesian Personalized Ranking from Implicit Feedback.” W: 2009, s. 461.
- P. Resnick i H. R. Varian. Recommender Systems. W: „Communications of The ACM” 40.Nr 3 (1997), s. 56–58.
- B. Sarwar i in. Item-Based Collaborative Filtering Recommendation Algorithms. W: „Proceedings of ACM World Wide Web Conference” 1 (2001).
- G. Shani i A. Gunawardana. Evaluating Recommendation Systems. W: (w:) Recommender Systems Handbook. T. 12. 2011, s. 257–297.
- Spotify. *Spotify — About Spotify*. <https://newsroom.spotify.com/company-info/>.
- H. Steck. *Evaluation of Recommendations: Rating-prediction and Ranking*. 2013, s. 220.
- X. Su i T. Khoshgoftaar. A Survey of Collaborative Filtering Techniques. W: „Adv. Artificial Intelligence” 2009 (2009).
- S. Zhang i in. Deep Learning Based Recommender System: A Survey and New Perspectives. W: „ACM Computing Surveys” 52.Nr 1 (2020), s. 1–38.
- W. X. Zhao i in. „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”. W: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*. CIKM '21. New York, NY, USA: Association for Computing Machinery, 2021, s. 4653–4664.

Spis tabel

1	Podsumowanie statystyczne zbioru danych MovieLens 1M wykorzystanego w eksperymentach	20
---	---	----

Spis rysunków

1	Rozkład popularności filmów w zbiorze MovieLens 1M przedstawiający zjawisko długiego ogona (<i>Long-Tail Distribution</i>)	15
2	Rozkład ocen jawnych w zbiorze MovieLens 1M obrazujący efekt zjawiska <i>positivity bias</i>	17
3	Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 1M	19