



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

KATEDRA INFORMATYKI BIZNESOWEJ I INŻYNIERII ZARZĄDZANIA

Praca dyplomowa

**Porównanie algorytmów rekomendacyjnych
(Filtrowanie Kolaboracyjne, Uczenie Głębokie, Grafowe
Sieci Neuronowe) na przykładzie portalu
streamingowego**

Comparison of recommendation algorithms (Collaborative Filtering, Deep Learning, Graph Neural Networks) using a streaming platform as an example

Autor: Jakub Sornat

Kierunek studiów: Informatyka i Ekonometria

Opiekun: dr hab. Iwona Skalna

Kraków, 2026

Spis treści

Wstęp	1
1 Wprowadzenie do problematyki systemów rekomendacyjnych	3
1.1 Zjawisko przeciążenia poznawczego i specyfika rynku VOD	3
1.2 Definicje, formalizm matematyczny i struktura danych w personalizacji treści	4
1.2.1 Ewolucja pojęcia systemów rekomendacji	4
1.2.2 Formalizacja matematyczna problemu rekomendacji	6
1.2.3 Paradygmaty modelowania: przewidywanie ocen, a prognoza rankingu	7
1.2.4 Struktura danych i źródła informacji zwrotnej	8
1.3 Ewolucja technologiczna paradygmatów rekomendacyjnych	10
1.3.1 Tradycyjne systemy rekomendacyjne	10
1.3.2 Era Ucznia Głębokiego	12
1.3.3 Zaawansowane modele systemów rekomendacyjnych	13
1.4 Przegląd literatury naukowej	14
1.5 Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych	17
1.5.1 Kompromis dokładności i różnorodności: wyzwanie „Długiego Ogona”	17
1.5.2 Problem zimnego startu w dynamicznych katalogach	18
1.5.3 Wydajność obliczeniowa a wyzwanie czasu rzeczywistego	18
2 Środowisko, dane i metodyka badań	21
2.1 Środowisko wykonawcze	21
2.2 Opis i przygotowanie danych	22
2.2.1 Charakterystyka zbioru MovieLens 100K	22
2.2.2 Zjawisko rzadkości macierzy i asymetria popytu	23
2.2.3 Problem skrzywienia pozytywnego i binaryzacja danych	26
2.2.4 Filtrowanie i technika próbkowania negatywnego	28
2.3 Filtrowanie kolaboracyjne	30
2.3.1 Algorytm ItemKNN	31
2.3.2 Spersonalizowany ranking bayesowski	34
2.4 Uczenie głębokie i Neural Collaborative Filtering	35
2.5 Grafowe sieci neuronowe i architektura LightGCN	38

2.6	Metryki oceny	40
2.6.1	Czułość (ang. <i>Recall@K</i>)	41
2.6.2	Wskaźnik Trafień (HR@K)	42
2.6.3	Średnia Odwrotność Rangi (MRR@K)	42
2.6.4	Znormalizowany Zdyskontowany Zysk Skumulowany	43
3	Porównanie algorytmów rekomendacyjnych	45
3.1	Proces strojenia hiperparametrów	45
3.1.1	Analiza wrażliwości	46
3.1.2	Przeszukiwanie siatki parametrów — Grid Search	48
3.2	Wyniki badań	51
3.2.1	Krzywe zbieżności i stabilność procesu uczenia	52
3.2.2	Koszty obliczeniowe a skuteczność algorytmów	53
3.3	Dyskusja wyników i wnioski	54
	Zakończenie	55
	Bibliografia	57
	Źródła internetowe	59
	Spis tabel	60
	Spis rysunków	61

Wstęp

W dobie dynamicznego rozwoju platform cyfrowych, a w szczególności serwisów oferujących wideo na żądanie (VOD), użytkownicy coraz częściej stykają się ze zjawiskiem przeciążenia poznawczego. Ilość dostępnych treści znacznie przekracza ludzkie możliwości poznawcze i analityczne, a proces wyboru interesujących treści staje się dla użytkownika czasochłonny i mało efektywny. W takich warunkach systemy rekomendacyjne stają się nie tylko udogodnieniem, ale wręcz kluczowym narzędziem nawigacyjnym oraz podstawowym mechanizmem budowania zaangażowania i satysfakcji klienta. Dynamiczny rozwój metod sztucznej inteligencji doprowadził do powstania wielu zaawansowanych algorytmów rekomendacyjnych. Główną motywacją do podjęcia niniejszej tematyki jest chęć sprawdzenia, który z analizowanych sposobów generowania rekomendacji najlepiej sprawdzi się w przyjętym środowisku badawczym i przy określonych kryteriach oceny.

W pracy przeanalizowano cztery modele rekomendacyjne: algorytm oparty na sąsiedztwie obiektów (ItemKNN), klasyczną faktoryzację macierzy optymalizowaną za pomocą spersonalizowanego rankingu bayesowskiego (ang. *Bayesian Personalized Ranking* – BPR-MF), neuronowe filtrowanie kolaboracyjne (ang. *Neural Collaborative Filtering* – NCF) oraz algorytm LightGCN, reprezentujący grafowe sieci neuronowe (ang. *Graph Neural Networks*). Zostały one dobrane w taki sposób, aby zilustrować kluczowe kierunki rozwoju systemów tego typu. ItemKNN oraz BPR-MF to klasyczne techniki filtrowania kolaboracyjnego, stanowiące główny punkt odniesienia. Z kolei NCF opiera się na architekturach uczenia głębokiego (ang. *Deep Learning*). LightGCN natomiast bada potencjał wspomnianych wcześniej struktur grafowych. Takie zestawienie umożliwia bezpośrednie porównanie tradycyjnych fundamentów z nowocześniejszymi rozwiązaniami. Zakres badań obejmuje opis teoretyczny, implementację w środowisku eksperymentalnym oraz ocenę skuteczności poszczególnych podejść.

Celem badawczym jest ocena przewagi metod rekomendacyjnych opartych na głębokich sieciach neuronowych i strukturach grafowych nad klasycznymi metodami filtrowania kolaboracyjnego oraz analiza relacji pomiędzy jakością predykcji a złożonością obliczeniową tych metod.

W realizacji pracy wykorzystano zróżnicowane źródła informacji. Warstwa teoretyczna opiera się głównie na anglojęzycznej i polskiej literaturze przedmiotu. Podstawę stanowiły recenzowane artykuły naukowe oraz publikacje z wiodących konferencji poświęconych sztucznej inteligencji. Materiał badawczy stanowił powszechnie uznawany zbiór danych MovieLens¹, który dobrze odzwierciedla charakterystykę preferencji użyt-

¹ <https://grouplens.org/datasets/movielens/> (dostęp 7.09.2026).

kowników platform filmowych. Dokumentacja techniczna dedykowanych bibliotek (w tym frameworku RecBole) stanowiła bazę informacyjną do implementacji badanych architektur.

W przeprowadzonych badaniach oparto się na praktycznej implementacji modeli oraz ilościowej ocenie ich skuteczności. Zastosowano zaawansowane strojenie hiperparametrów algorytmów z użyciem techniki przeszukiwania siatki (ang. *Grid Search*) oraz eksperymenty analizujące zbieżność funkcji straty w procesie uczenia. Do oceny jakości generowanych rekomendacji zastosowano ugruntowane w dziedzinie metryki ewaluacyjne, takie jak znormalizowany zdyskontowany zysk skumulowany (ang. *Normalized Discounted Cumulative Gain* – NDCG) czy wskaźnik trafień (ang. *Hit Rate* – HR). Modele zaimplementowano i przetrenowano w środowisku języka Python. Realizacja założonego celu podyktowała podział pracy na trzy rozdziały.

Rozdział pierwszy stanowi wprowadzenie w problematykę systemów rekomendacyjnych. Omówiono w nim specyfikę serwisów VOD, zdefiniowano niezbędne pojęcia, przedstawiono formalizm matematyczny, a także zarysowano ewolucję paradygmatów personalizacji treści. Przedstawiono również kluczowy dla rozważanej tematyki przegląd dotychczasowej literatury oraz zdefiniowano główne wyzwania badawcze.

Rozdział drugi poświęcono metodyce badawczej oraz szczegółowemu opisowi testowanych algorytmów. Scharakteryzowano w nim wykorzystane środowisko wykonawcze i sposób przygotowania danych. Kolejna część rozdziału przybliży teoretyczne podstawy badanych modeli. Przedstawiono zasady ich działania oraz architekturę: od klasycznego filtrowania kolaboracyjnego, przez uczenie głębokie, aż po grafowe sieci neuronowe. Rozdział ten zamyka formalna definicja zastosowanych metryk oceny.

W rozdziale trzecim zaprezentowano właściwe rezultaty przeprowadzonych eksperymentów numerycznych i ich szczegółową analizę. Udokumentowano proces strojenia hiperparametrów, zestawiono algorytmy pod kątem jakości predykcji, zbadano koszty obliczeniowe i stabilność treningu. Praca kończy się dyskusją nad osiągniętymi wynikami i sformułowaniem wniosków płynących z badań.

1. Wprowadzenie do problematyki systemów rekomendacyjnych

Rozdział pierwszy przedstawia teoretyczne oraz rynkowe podstawy systemów rekomendacyjnych. Omówiono w nim zjawisko przeciążenia poznawczego na rynku platform VOD, formalny podział metod personalizacji treści oraz technologiczną ewolucję algorytmów – od klasycznych podejść opartych na algebrze macierzy po zaawansowane struktury grafowe. Rozdział kończy analiza kluczowych wyzwań wdrożeniowych związanych z projektowaniem tego typu systemów.

1.1. Zjawisko przeciążenia poznawczego i specyfika rynku VOD

Rozwój technologii internetowych w pierwszych dekadach XXI wieku doprowadził do cyfryzacji głównych segmentów rynku rozrywkowego. W sektorze wideo obserwuje się stopniowe odchodzenie od tradycyjnej telewizji na rzecz platform VOD. Rynek ten zdominowały serwisy globalne (np. Netflix, Max, Amazon Prime Video) oraz dostawcy lokalni (np. Player.pl, TVP VOD). Analogiczne zmiany nastąpiły w branży muzycznej, gdzie czołową pozycję zajmują platformy takie jak Spotify i Apple Music. Model subskrypcyjny wprowadzono także na rynku wydawniczym, umożliwiając stały dostęp do e-booków oraz audiobooków. W rezultacie użytkownicy mogą korzystać z obszernych baz multimedialnych z poziomu pojedynczej aplikacji.

Rosnąca objętość udostępnianych katalogów stanowi jednak istotny problem z perspektywy użytkownika. Ze względu na znaczną liczbę dostępnych materiałów, odbiorcy często doświadczają zjawiska przeciążenia poznawczego (ang. *cognitive overload*)². Zjawisko to występuje powszechnie w całym sektorze cyfrowej rozrywki, co potwierdzają dane rynkowe. Baza IMDb indeksuje ponad 30 milionów tytułów filmowych i telewizyjnych³. Katalog platformy Spotify obejmuje ponad 100 milionów utworów⁴, natomiast serwis BookBeat oferuje subskrybentom dostęp do ponad miliona pozycji literackich⁵.

Setki tysięcy produkcji w ramach pojedynczego serwisu wywołują u odbiorcy efekt tzw. paradoksu wyboru⁶. Nadmierna ekspozycja na treści przytłacza użytkownika, sprawiając, że całościowa eksploracja katalogu staje się fizycznie niemożliwa, a podjęcie decyzji o wyborze seansu wiąże się ze znacznym wysiłkiem poznawczym. Takie przeciążenie w wielu przypadkach prowadzi do zniechęcenia, frustracji widza, a ostatecznie do rezygnacji

² Dirk Bollen i in., *Understanding Choice Overload in Recommender Systems*, 2010, s. 70.

³ <https://www.imdb.com/pressroom/stats/> (dostęp 13.07.2026).

⁴ <https://newsroom.spotify.com/company-info/> (dostęp 13.07.2026).

⁵ <https://www.bookbeat.com/pl/about> (dostęp 13.07.2026).

⁶ Barry Schwartz, *The Paradox of Choice: Why More is Less*, Harper Perennial, 2004.

z subskrypcji. Rozwiązania tradycyjne, takie jak wyszukiwanie frazowe czy statyczne, redakcyjne zestawienia popularności, okazują się niewystarczające, ponieważ wymagają one aktywnej inicjatywy ze strony odbiorcy lub promują pozycje najpopularniejsze, nieuwzględniające jego indywidualnych preferencji⁷.

W konsekwencji zaawansowane systemy rekomendacyjne przestały być jedynie opcjonalnym dodatkiem funkcjonalnym, stając się integralnym i kluczowym elementem architektury współczesnych platform cyfrowych⁸. Ich nadrzędnym zadaniem jest ciągłe, zautomatyzowane analizowanie ogromnych katalogów treści i filtrowanie ich w taki sposób, aby skutecznie chronić widza przed zjawiskiem paraliżu decyzyjnego. Zamiast zmuszać odbiorcę do samodzielnego przeszukiwania tysięcy tytułów, algorytmy te dostarczają spersonalizowane propozycje, ściśle dopasowane do jego profilu, historii oglądania oraz preferencji. W cyfrowym modelu biznesowym, opartym na miesięcznych subskrypcjach, to właśnie trafność tych podpowiedzi stanowi podstawowe narzędzie budujące lojalność i długoterminowe zaangażowanie użytkowników. Skuteczność takiego podejścia najlepiej obrazują wewnętrzne dane platformy Netflix, z których wynika, że precyzyjne sugestie algorytmiczne odpowiadają za wygenerowanie aż 80% całkowitego czasu, jaki widzowie spędzają na odtwarzaniu materiałów w serwisie⁹.

1.2. Definicje, formalizm matematyczny i struktura danych w personalizacji treści

W niniejszym podrozdziale wprowadzono podstawowe pojęcia pozwalające zrozumieć działanie systemów personalizacji treści. Przedstawiono rozwój oraz matematyczny zapis problemu rekomendacji, a także omówiono specyfikę danych wykorzystywanych przez współczesne algorytmy uczenia maszynowego.

1.2.1. Ewolucja pojęcia systemów rekomendacji

Historycznie pojęcie systemów rekomendacji ewoluowało wraz z postępującą cyfryzacją oraz narastającym problemem przeciążenia poznawczego. Pierwsze rozwiązania badawcze miały charakter ściśle kooperacyjny i opierały się na świadomej współpracy odbiorców. Pionierskim przykładem jest stworzony w 1992 roku przez badaczy z Xerox

⁷ Jerzy Krawczuk, *Systemy rekomendacyjne, Wybrane zagadnienia symulacji komputerowej*, 2024, s. 24–38.

⁸ Michał Bernardelli, *Wpływ Algorytmów Rekomendacyjnych Na Stopień Usieciowienia Platform Cyfrowych, Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy*, 2024, s. 23–24.

⁹ Carlos Gómez-Urbe i Neil Hunt, „The Netflix Recommender System”, *ACM Transactions on Management Information Systems*, 2015, t. 6, s. 1–19.

Palo Alto Research Center (PARC) system Tapestry¹⁰. Powstał on w odpowiedzi na dynamicznie rosnącą liczbę wiadomości w sieciach korporacyjnych i na grupach dyskusyjnych, proponując nowatorskie podejście do selekcji strumieni danych. Tapestry umożliwiał użytkownikom filtrowanie przychodzących dokumentów na podstawie jawnych, manualnych adnotacji i ocen wprowadzonych wcześniej przez innych czytelników (np. żądanie wyświetlenia wyłącznie tych wiadomości, które konkretny współpracownik oznaczył jako wartościowe). To właśnie w publikacji opisującej ten system po raz pierwszy w literaturze sformułowano termin "filtrowanie kolaboracyjne", kładąc podwaliny pod cały współczesny nurt badań nad personalizacją treści. Chociaż system Tapestry działał zadowalająco, to jednak ze względu na wymóg budowania skomplikowanych zapytań i ograniczenie do małych, zamkniętych społeczności, w których użytkownicy znali się nawzajem, jego koncepcja szybko ewoluowała w stronę w pełni zautomatyzowanych, bezobsługowych algorytmów na dużą skalę.

Przełomowym momentem dla rozwoju pojęć w tej dziedzinie była praca opublikowana w 1997 roku przez P. Resnicka i H. Variana¹¹. Badacze ci zaproponowali, aby wąskie pojęcie "filtrowania kolaboracyjnego" zastąpić szerszym i bardziej uniwersalnym terminem "systemy rekomendacyjne". Argumentowali oni, że nowa generacja algorytmów nie wymaga już celowej współpracy między użytkownikami, którzy w środowisku sieciowym mogą pozostawać dla siebie całkowicie anonimowi. Zgodnie z ich ujęciem, system rekomendacyjny to dowolne zautomatyzowane narzędzie, które agreguje oceny – zarówno te wprowadzane jawnie, jak i te pozyskane w sposób niejawny z zachowania odbiorców (ang. *implicit feedback*), a następnie kieruje trafne sugestie do odpowiednich osób.

Wraz z dynamicznym rozwojem metod uczenia maszynowego na początku XXI wieku, definicja ta uległa dalszemu rozszerzeniu i abstrakcji. Klasyczne już dziś ujęcie zaproponował w 2002 roku R. Burke, definiując system rekomendacji jako każdy program, którego nadrzędnym zadaniem jest generowanie zindywidualizowanych sugestii lub aktywne kierowanie użytkownika do interesujących go obiektów w obrębie bardzo rozległej przestrzeni opcji¹². To pojemne ujęcie usankcjonowało rozwój kolejnych architektur, w tym filtrowania opartego na treści (ang. *Content-Based Filtering* – CBF) oraz wysoce złożonych modeli hybrydowych. Współcześnie, za sprawą algorytmów głębokiego uczenia, zadanie to uległo radykalnej automatyzacji. W ekosystemach cyfrowych platform VOD systemy rekomendacyjne przestały być jedynie narzędziem pomocniczym wspo-

¹⁰ David Goldberg i in., „Using Collaborative Filtering to Weave an Information TAPESTRY”, *Commun. ACM*, 1992, t. 35, s. 61–70.

¹¹ Paul Resnick i Hal R Varian, „Recommender Systems”, *Communications of The ACM*, 1997, t. 40, nr 3, s. 56–58.

¹² Robin Burke, „Hybrid Recommender Systems: Survey and Experiments”, *User Modeling and User-Adapted Interaction*, 2002, t. 12, nr 4, s. 331–370.

magającym wybór, stając się ich centralnym elementem i kształtując codzienne decyzje użytkowników w znacznie większym stopniu niż tradycyjne wyszukiwanie czy statyczne rankingi popularności.

1.2.2. Formalizacja matematyczna problemu rekomendacji

Systemy rekomendacyjne są nierozzerwalnie związane z problemem badawczym, który można sformalizować jako problem optymalizacyjny z wykorzystaniem funkcji użyteczności¹³:

$$u: C \times O \rightarrow W, \quad (1)$$

gdzie:

- $C = \{c_1, c_2, \dots, c_m\}$ – skończony zbiór użytkowników wykorzystujących system rekomendacyjny,
- $O = \{o_1, o_2, \dots, o_n\}$ – skończony zbiór wszystkich możliwych obiektów podlegających rekomendacji,
- u – funkcja użyteczności mierząca przydatność obiektu dla użytkownika,
- W – uporządkowany zbiór wartości (np. zbiór nieujemnych liczb całkowitych).

Głównym zadaniem algorytmów rekomendacyjnych jest znalezienie obiektów o najwyższej użyteczności dla danego odbiorcy. Matematycznie sprowadza się to do wyznaczenia dla każdego użytkownika optymalnego zbioru rekomendacji¹⁴:

$$R_c^* = \arg \max_{o \in O} u(c, o), \quad (2)$$

gdzie:

- R_c^* – zbiór elementów z przestrzeni O maksymalizujących funkcję użyteczności,
- $u(c, o)$ – użyteczność obiektu o dla konkretnego użytkownika c .

Jednym z głównych wyzwań związanych z działaniem systemów personalizacji treści jest zjawisko rzadkości danych (*data sparsity*), wynikające z dysponowania nielicznymi

¹³ Michał Malinowski, „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”, rozprawa doktorska, Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022, s. 36–37.

¹⁴ G. Adomavicius i Alexander Tuzhilin, „Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions”, *IEEE Transactions on Knowledge and Data Engineering*, 2005, t. 17, s. 734–749.

informacjami o użytkownikach lub z ich całkowitego braku¹⁵. Taka sytuacja ma miejsce w przypadku, gdy użytkownik po raz pierwszy ma kontakt z systemem (tzw. problem zimnego startu) lub gdy system celowo nie gromadzi danych historycznych w związku z wymogami ochrony prywatności. Z tego powodu klasyczna postać problemu rekomendacji bywa często modyfikowana w taki sposób, aby algorytm opierał się bezpośrednio na podobieństwie obiektów, a nie na złożonym profilu użytkownika. Wymaga to zastąpienia funkcji użyteczności odwzorowaniem w ¹⁶:

$$w: O \times O \rightarrow W, \quad (3)$$

gdzie:

- w – nowa funkcja określająca siłę powiązania między dwoma obiektami.

Dzięki temu pierwotny problem wyznaczenia rekomendacji dla użytkownika transformuje się w optymalizację zbioru dla konkretnego elementu. W konsekwencji zbiór polecanych przedmiotów definiuje się następująco¹⁷:

$$R_{o^*}^* = \arg \max_{o \in O} w(o^*, o), \quad (4)$$

gdzie:

- $R_{o^*}^*$ – optymalny zbiór rekomendowanych przedmiotów powiązanych z obiektem startowym,
- o^* – ustalony przez użytkownika obiekt bazowy (np. film, w którego miniaturę właśnie kliknął),
- $w(o^*, o)$ – siła powiązania (matematyczne podobieństwo) między ocenianym obiektem $o \in O$ a obiektem bazowym o^* .

1.2.3. Paradygmaty modelowania: przewidywanie ocen, a prognoza rankingu

Wyniki działania algorytmów rekomendacyjnych prezentowane są użytkownikowi na podstawie dwóch głównych paradygmatów¹⁸:

¹⁵ Julian McAuley i Jure Leskovec, „Hidden Factors and Hidden Topics: Understanding Rating Dimensions with Review Text”, *Proceedings of the 7th ACM Conference on Recommender Systems*, RecSys '13, New York, NY, USA: Association for Computing Machinery, 2013, s. 165–172.

¹⁶ Michał Malinowski, *Zastosowanie Grafów i Sieci w Systemach Rekomendacji*, Przedsiębiorstwo w Nowej Rzeczywistości Gospodarczej. Relacje – Zmiany – Strategie, 1, Częstochowa: Wydawnictwo Politechniki Częstochowskiej, 2021, s. 77–96.

¹⁷ Ibidem.

¹⁸ Ibidem.

1. Przewidywanie ocen: model prognozuje konkretną wartość liczbową oceny (np. 4,5/5 gwiazdek). Celem jest tutaj minimalizacja błędu bezwzględnego estymacji (np. RMSE) między przewidywaną oceną a rzeczywistą. Taki paradygmat stanowił fundament historycznego konkursu *Netflix Prize* (2006–2009) i algorytmu *Cinematch*.
2. Prognoza rankingu: system ignoruje absolutną wartość oceny na rzecz wygenerowania uporządkowanej listy N najlepszych pozycji, dopasowanych specyficznie do użytkownika. Optymalizacji podlega względna kolejność proponowanych elementów. Podejście to zostało pierwotnie spopularyzowane przez wyszukiwarki internetowe oraz pionierskie platformy e-commerce (np. Amazon), dla których znacznie cenniejsze od predykcji bezwzględnej oceny produktu było zaprezentowanie klientowi zoptymalizowanej listy najbardziej trafnych propozycji zakupowych. Z czasem algorytmy te stały się nieodzownym elementem platform internetowych, w tym serwisów streamingowych¹⁹.

W nowoczesnych systemach rozrywkowych VOD zdecydowanie preferuje się prognozy rankingowe (Top-N). Jak wykazuje Harald Steck²⁰, z perspektywy biznesowej oraz doświadczeń użytkownika, kluczowe jest zaprezentowanie najtrafniejszych obiektów na samym szczycie listy, a nie przewidywanie dokładnych ocen liczbowych. Odejście od klasycznej predykcji ocen wynika również z masowego przejścia platform na gromadzenie danych niejawnych. Współcześni odbiorcy rzadko udzielają bezpośrednich ocen punktowych, co wymusza na algorytmach analizę behawioralną (np. mierzenie czasu odtwarzania materiału). Dane tego typu nie przekładają się wprost na bezwzględną ocenę liczbową, jednak idealnie wpisują się w zadanie optymalizacji względnego rankingu proponowanych treści.

1.2.4. Struktura danych i źródła informacji zwrotnej

Systemy rekomendacyjne to w swej istocie systemy przetwarzania informacji, których skuteczność i architektura zależą bezpośrednio od wolumenu, jakości oraz wielowymiarowości gromadzonych danych wejściowych. Dane te mogą mieć różną formę i pochodzenie, a stopień ich wykorzystania determinuje wybór odpowiedniej techniki rekomendacji. W literaturze przedmiotu strukturę danych zasilających systemy rekomendacyjne dzieli się najczęściej na trzy główne obiekty: przedmioty, użytkowników oraz transakcje²¹:

¹⁹ Mukund Deshpande i George Karypis, „Item-Based Top-N Recommendation Algorithms”, *ACM Transactions on Information Systems (TOIS)*, 2004, t. 22, nr 1, s. 143–177.

²⁰ Harald Steck, „Evaluation of Recommendations: Rating-prediction and Ranking”, *RecSys 2013 - Proceedings of the 7th ACM Conference on Recommender Systems*, 2013, s. 220.

²¹ Francesco Ricci, Lior Rokach i Bracha Shapira, *Introduction to Recommender Systems Handbook*, *Recommender Systems Handbook*, 2010, s. 1–35.

- **Przedmioty:** obiekty podlegające rekomendacji charakteryzują się różnym stopniem złożoności oraz określoną wartością (użytecznością) dla odbiorcy, z którą wiąże się koszt poznawczy lub finansowy. W kontekście portali streamingowych (VOD) pozycje mogą być reprezentowane w sposób minimalistyczny (wyłącznie jako unikalny identyfikator) lub za pomocą bogatych zbiorów metadanych. Obejmują one atrybuty katalogowe (np. gatunki, reżyserzy, obsada), a także zaawansowane cechy generowane automatycznie przez systemy analizy obrazu i dźwięku (np. VCR – ang. *Video Content Recognition*), takie jak tempo montażu czy tonacja kolorystyczna.
- **Użytkownicy:** model użytkownika gromadzi informacje pozwalające na personalizację rekomendacji, kodując jego preferencje i potrzeby. W zależności od wybranego algorytmu reprezentacja ta może przyjmować różną formę. W systemach demograficznych profil opiera się na statycznych parametrach (np. wiek, płeć), podczas gdy w filtrowaniu kolaboracyjnym użytkownik modelowany jest najczęściej poprzez wektor ukrytych cech lub bezpośrednio przez historię ocen. Profil uzupełniany jest często o kontekst dynamiczny (np. używane urządzenie, pora dnia, geolokalizacja) oraz dane behawioralne odzwierciedlające wzorce nawigacji w systemie.
- **Transakcje:** zapisy interakcji pomiędzy użytkownikiem a systemem rekomendacyjnym. Stanowią one sekwencyjne logi zachowań, które obok samego faktu wyboru przedmiotu mogą zawierać informacje o kontekście zapytania oraz ewentualnej informacji zwrotnej. To właśnie na podstawie danych transakcyjnych algorytmy uczą się wzorców preferencji.

Z punktu widzenia optymalizacji matematycznej modelu i budowy funkcji celu, kluczowy jest podział informacji zwrotnej (reprezentującej historyczne transakcje) na dwie główne kategorie:

- **Jawne oceny (ang. *explicit feedback*):** bezpośrednie wyrażenie preferencji przez użytkownika. Przyjmują one najczęściej formę ocen numerycznych (np. skala 1–5 gwiazdek), ocen porządkowych, czy też wartości binarnych (np. pozytywny/negatywny). Choć dostarczają precyzyjnych i jednoznacznych informacji o upodobaniach, ich główną wadą jest wysoki koszt poznawczy wymagany od użytkownika, co sprawia, że występują w systemie skrajnie rzadko, prowadząc do silnego problemu rzadkości macierzy danych.
- **Dorozumiane ślady aktywności (ang. *implicit feedback*):** zachowania wywnioskowane w sposób pośredni z akcji użytkownika (np. czas oglądania, historia odtworzeń, przewijanie wideo, liczba kliknięć). Są to dane łatwe do masowego gromadzenia,

jednak charakteryzują się sporym zaszumieniem. Modelowanie informacji dorozumianych wiąże się z problematyką jednoklasowego filtrowania kolaboracyjnego²². Główne wyzwanie polega na interpretacji braku interakcji: w przeciwieństwie do ocen jawnych, brak interakcji z filmem nie musi oznaczać niechęci do niego, lecz bardzo często wynika z faktu, że użytkownik nie był świadomy jego istnienia.

Współczesne środowiska wielkoskalowych systemów VOD, z uwagi na marginalny odsetek ocen jawnych, opierają się w głównej mierze na wykorzystaniu dorozumianych śladów aktywności. Zdolność algorytmów do skutecznego wyciągania użytecznych informacji z tych obfitych, lecz przepelnionych zbędnymi informacjami zbiorów danych, przy jednoczesnym uwzględnieniu dostępnych metadanych, jest kluczowa dla jakości działania całego systemu.

1.3. Ewolucja technologiczna paradygmatów rekomendacyjnych

Systemy rekomendacyjne funkcjonują i są rozwijane na rynku od ponad trzydziestu lat. Na przestrzeni tego czasu środowiska informatyczne przeszły całkowitą transformację, z czym wiązała się również dynamiczna zmiana preferencji, przyzwyczajeń i oczekiwań samych użytkowników. Te głębokie przemiany technologiczne i behawioralne wymusiły ciągłą ewolucję w sposobie projektowania algorytmów. Opierając się na współczesnym przeglądzie literatury przeprowadzonym przez Razę i in.²³, historyczny rozwój paradygmatów rekomendacyjnych można podzielić na trzy główne ery. Odzwierciedlają one rosnącą złożoność w modelowaniu preferencji użytkowników oraz postęp w dziedzinie sztucznej inteligencji, przy czym każda z er charakteryzuje się odmiennym podejściem do analizy danych i reprezentacji wiedzy:


1.3.1. Tradycyjne systemy rekomendacyjne

Historyczny rozwój systemów rekomendacyjnych ukształtowały trzy klasyczne paradygmaty, które do dziś odgrywają rolę standardowych modeli referencyjnych w badaniach naukowych²⁴:

²² Steffen Rendle i in., „BPR: Bayesian Personalized Ranking from Implicit Feedback.”, *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, Montreal, Quebec, Canada, 2009, s. 452–461.

²³ Shaina Raza i in., *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*, 2024.

²⁴ Xiaoyuan Su i Taghi Khoshgoftaar, „A Survey of Collaborative Filtering Techniques”, *Adv. Artificial Intelligence*, 2009, t. 2009.



Rysunek 1: Taksonomia i historyczny podział algorytmów rekomendacyjnych uwzględnionych w badaniach.

Źródło: opracowanie własne.

- Filtrowanie oparte na treści:** rekomenduje obiekty na podstawie ich podobieństwa do tych wybieranych w przeszłości (często obliczając iloczyn skalarny wektorów). Metoda ta jest stosunkowo odporna na problem „zimnego startu” w przypadku wprowadzania do katalogu nowych premier filmowych. Wynika to z faktu, że algorytm do działania nie wymaga zgromadzenia początkowej masy interakcji od społeczności. Wystarczy sama obecność metadanych opisujących nowy film (np. gatunek, obsada, reżyser), by móc od razu dopasować go do profili widzów. Z drugiej strony, ścisłe uzależnienie predykcji od dotychczasowej historii oglądania prowadzi do zjawiska nadmiernej specjalizacji. System nie posiada mechanizmu eksploracji i promuje wyłącznie pozycje podobne do tych już obejrzanych. W efekcie zamyka to użytkownika w bańce filtracyjnej, pozbawiając go możliwości odkrywania nowych gatunków i tytułów. Produkcje te, choć mogłyby okazać się dla niego atrakcyjne, przez swoje niewystarczające podobieństwo do dotychczasowej historii oglądania są całkowicie pomijane przez algorytm.
- Filtrowanie kolaboracyjne:** opiera się na analizie opinii i zachowań całej społeczności. Główne założenie tego podejścia mówi, że użytkownicy o podobnej historii interakcji (np. oglądający te same filmy) będą mieli zbliżone preferencje w przyszłości. Klasycznie algorytmy te dzieli się na metody oparte na pamięci wykorzystujące m.in. algorytm k -najbliższych sąsiadów oraz znacznie wydajniejsze metody oparte na modelach. Podejścia pamięciowe, choć intuicyjne, wykazują poważne problemy ze skalowalnością i drastycznie tracą na skuteczności przy bardzo rzadkich danych. Odpowiedzią na te ograniczenia stała się technika faktoryzacji macierzy (m.in. roz-

kład według wartości osobliwych, ang. *Singular Value Decomposition* – SVD, oraz ALS), która zrewolucjonizowała uczenie modeli bazowych. Pozwala ona na rzutowanie rzadkiej macierzy interakcji do gęstej przestrzeni tzw. czynników ukrytych (*latent factors*), dzięki czemu system potrafi uczyć się nieoczywistych wzorców. Należy jednak zaznaczyć, że w przeciwieństwie do metod opartych na treści, czyste filtrowanie kolaboracyjne jest całkowicie podatne na problem „zimnego startu” – nie potrafi trafnie polecić nowo dodanego filmu, dopóki ten nie zbierze krytycznej masy odtworzeń od początkowych widzów.

- **Modele hybrydowe:** stanowią pragmatyczny kompromis łączący podejścia kolaboracyjne i treściowe, zaprojektowany z myślą o niwelowaniu słabości pojedynczych paradygmatów. Poprzez połączenie obu technik system potrafi jednocześnie przełamać bańkę filtracyjną (wykorzystując eksploracyjny potencjał CF) oraz skutecznie rekomendować nowości kinowe nieposiadające historii odtworzeń (wykorzystując metadane z CBF). Klasyczną taksonomię takich rozwiązań przedstawił R. Burke²⁵, wyróżniając kluczowe strategie ich integracji. Należą do nich m.in.: łączenie wyników poprzez ważone sumowanie predykcji niezależnych modeli, wykorzystywanie wyników jednego algorytmu jako atrybutów dla drugiego, wieloetapowe kaskadowanie predykcji oraz dynamiczne przełączanie (*switching*). Ta ostatnia strategia pozwala systemowi np. zastosować model oparty na treści dla najnowszych premier, a płynnie przejść na model kolaboracyjny w przypadku filmów posiadających już bogatą, historyczną reprezentację w bazie danych.

1.3.2. Era Uczenia Głębokiego

Adaptacja głębokich sieci neuronowych w systemach rekomendacyjnych pozwoliła na rozwiązanie części ograniczeń metod klasycznych. Nowe modele wprowadziły przede wszystkim mechanizmy automatycznego uczenia się reprezentacji (ang. *representation learning*) oraz modelowania nieliniowych zależności między użytkownikiem a przedmiotem²⁶. Rozwój tej dziedziny opierał się na zastosowaniu kilku głównych architektur:

- **Wielowarstwowe perceptrony (ang. *Multi-Layer Perceptron* – MLP):** uogólniły metody oparte na faktoryzacji macierzy. W modelu *Neural Collaborative Filtering* (NCF) klasyczny iloczyn skalarny zastąpiono siecią neuronową, co pozwoliło na aproksymację funkcji nieliniowych i zwiększyło pojemność predykcyjną algorytmu.

²⁵ Burke, dz. cyt.

²⁶ Shuai Zhang i in., „Deep Learning Based Recommender System: A Survey and New Perspectives”, *ACM Computing Surveys*, 2020, t. 52, nr 1, s. 1–38.

- **Autoenkodery i sieci splotowe (VAE / CNN):** wariacyjne autoenkodery (ang. *Variational Autoencoders* – VAE) znalazły zastosowanie w redukcji wymiarowości przy dużej rzadkości danych. Sieci splotowe (ang. *Convolutional Neural Networks* – CNN) posłużyły natomiast do analizy multimediów (np. miniatur lub klatek wideo), pozwalając na bezpośrednie włączenie cech wizualnych do modelu.
- **Modele sekwencyjne i Transformery:** do analizy chronologicznej historii utworzeń początkowo wykorzystywano sieci rekurencyjne (ang. *Recurrent Neural Networks* – RNN). Z czasem zastąpiono je mechanizmami uwagi i architekturą Transformer (np. modele SASRec czy BERT4Rec), które lepiej radzą sobie z modelem zarówno krótko-, jak i długoterminowych preferencji użytkownika.

1.3.3. Zaawansowane modele systemów rekomendacyjnych

Współczesne modele rekomendacyjne odchodzą od płaskich, tabelarycznych reprezentacji użytkownika na rzecz struktur opartych na grafach i relacjach²⁷:

- **Systemy oparte na sesjach (ang. *Session-Based Recommendation* – SBR):** modelują krótkoterminowe preferencje użytkownika w ramach pojedynczej, często anonimowej sesji, wykorzystując łańcuchy Markowa lub analizę sekwencyjną.
- **Grafowe sieci neuronowe (ang. *Graph Neural Networks* – GNN):** reprezentują system VOD jako graf dwudzielny lub heterogeniczny. Modele oparte na propagacji osadzeń (takie jak architektura LightGCN) pozwalają na wydajne modelowanie relacji wyższego rzędu pomiędzy użytkownikami a przedmiotami. Z kolei sieci splotowe na grafach wiedzy (ang. *Knowledge Graph Convolutional Networks* – KGCN) uwzględniają bogaty kontekst semantyczny. Wspiera to koncepcję wyjaśnialnej sztucznej inteligencji (ang. *Explainable AI* – XAI), pozwalając generować komunikaty typu: „Polecamy ten film, ponieważ polubiłeś reżysera X, który pracował także przy produkcji Y”.
- **Uczenie ze wzmocnieniem (ang. *Reinforcement Learning* – RL):** traktuje problem rekomendacji jako sekwencyjny proces decyzyjny agenta. Algorytm optymalizuje kompromis między eksploatacją znanych treści a eksploracją nowości, maksymalizując długoterminową satysfakcję użytkownika, zamiast skupiać się wyłącznie na natychmiastowej nagrodzie (np. pojedynczym kliknięciu).

Przedstawiona taksonomia obrazuje ewolucję algorytmów rekomendacyjnych: od prostych heurystyk, przez gęste modele nieliniowe, aż po paradygmaty oparte na grafach. Wybór

²⁷ Malinowski, dz. cyt.

reprezentatywnych algorytmów z różnych gałęzi tej klasyfikacji pozwoli w dalszej części pracy na empiryczne porównanie skuteczności modeli pochodzących z różnych generacji. Zanim jednak zdefiniowana zostanie metodyka eksperymentów, niezbędne jest przyjrzenie się najnowszemu dorobkowi naukowemu w badanej dziedzinie.

1.4. Przegląd literatury naukowej

W niniejszym podrozdziale dokonano przeglądu literatury naukowej z zakresu systemów rekomendacyjnych, ze szczególnym uwzględnieniem podejść opartych na filtrowaniu kolaboracyjnym, sztucznych sieciach neuronowych oraz grafowych strukturach wiedzy. Analiza obejmuje zarówno klasyczne metody faktoryzacji, jak i najnowsze osiągnięcia z obszaru głębokiego uczenia w odniesieniu do specyficznych uwarunkowań rynku VOD.

Przegląd literatury naukowej w kontekście usług streamingowych warto rozpocząć od analizy konkursu Netflix Prize (2006–2009) omówionego przez Hallinana i Striphasa²⁸. Autorzy wykazują, że publiczne udostępnienie zbioru obejmującego ponad 100 milionów ocen przypisanych przez 480 tysięcy użytkowników dla 17 tysięcy filmów stanowiło punkt zwrotny w rozwoju algorytmów rekomendacyjnych. Rywalizacja o poprawę predykcji błędu RMSE o 10% względem algorytmu Cinematch udowodniła, że tradycyjne metody oparte na sąsiedztwie są niewystarczające w środowisku o takiej skali, głównie ze względu na wysoki narzut pamięciowy i brak skalowalności obliczeniowej. To właśnie konkurs Netflix'a spopularyzował modele czynników ukrytych, w tym rozkład SVD. Hallinan i Striphas zwracają również uwagę na skomplikowane zjawiska polaryzacyjne, określane jako wyzwanie *Napoleon Dynamite problem*, w którym przewidywanie gustów użytkowników dla niszowych treści wymagało odrzucenia pojedynczych algorytmów na rzecz złożonych zespołów modeli hybrydowych.

Szczegółowe omówienie podstaw teoretycznych oraz wyzwań wdrożeniowych przedstawia praca Krawczuka²⁹. Autor przeprowadza analizę poszczególnych paradygmatów rekomendacji, oceniając ich przydatność w warunkach produkcyjnych. W pierwszej kolejności analizuje techniki CBF, wykazując, że ich podstawową zaletą jest niezależność od aktywności reszty społeczności oraz odporność na rzadkość ocen innych użytkowników. Zauważa jednak ograniczenia natury poznawczej: algorytmy CBF wykazują tendencję do nadmiernej specjalizacji, zamykając użytkownika w tzw. bańce filtracyjnej i utrudniając odkrywanie nieoczywistych, lecz trafnych pozycji, a także zmagają się z problemem zimnego startu dla nowych obiektów bez uzupełnionych metadanych. Przechodząc do podejść

²⁸ Blake Hallinan i Ted Striphas, „Recommended for You: The Netflix Prize and the Production of Algorithmic Culture”, *New Media & Society*, 2016, t. 18, s. 117–137.

²⁹ Krawczuk, dz. cyt.

typu CF, Krawczuk akcentuje, że wykorzystywanie zbiorowych zachowań użytkowników pozwala na rekomendowanie treści niezależnie od ich opisu semantycznego. Metody te charakteryzują się jednak wysoką wrażliwością na rzadkość ocen, gdzie wskaźnik wypełnienia macierzy interakcji R często nie przekracza 1%, oraz na problem zimnego startu dla nowych uczestników systemu. Jako rozwiązanie kompromisowe autor omawia architektury hybrydowe, które poprzez strategie łączone, sekwencyjne czy rozszerzanie cech scalają sygnały treściowe z relacjami interakcji. Ważnym wnioskiem z pracy Krawczuka jest również identyfikacja wymogów architektonicznych: wdrożenie przemysłowe na platformach VOD wymaga utrzymania niskiego czasu odpowiedzi przy jednoczesnej skalowalności. Podsumowując ewaluację, autor dowodzi, że w serwisach wideo kluczowe znaczenie ma kolejność prezentowanych propozycji na ekranie, w związku z czym metryki rankingowe Top- K , takie jak średnia odwrotność rangi (MRR), NDCG oraz Precision@ k , stanowią jedyne adekwatne kryterium oceny modeli w tym środowisku.

Praca He i in. z 2017 roku skupia się na wykorzystaniu głębokich sieci neuronowych do tworzenia systemów rekomendacyjnych³⁰, wprowadzając architekturę NCF. W pierwszej części publikacji autorzy uzasadniają potrzebę zastąpienia klasycznego iloczynu skalarnego nieliniowymi warstwami neuronowymi, wykazując ograniczenia liniowych metod faktoryzacji macierzy oraz przedstawiając teoretyczne fundamenty proponowanego rozwiązania. Do przeprowadzania eksperymentów empirycznych wykorzystano zbiory danych MovieLens 1M oraz Pinterest. W przypadku MovieLens 1M oceny jawne przekształcono na dane niejawne, traktując każdą ocenę jako obecność interakcji ($y_{ui} = 1$), zbiór Pinterest poddano natomiast filtracji typu 20-core (odrzucając użytkowników posiadających mniej niż 20 wykonanych akcji). W obu zbiorach zastosowano procedurę podziału *Leave-One-Out*, w której ostatnią interakcję odłożono do testów, przedostatnią do walidacji, a pozostałe do uczenia, łącząc w zestawie testowym każdy pozytywny obiekt z 99 losowymi próbkami negatywnymi. W celach porównawczych zestawiono architekturę NCF z szeregiem znanych metod referencyjnych: niepersonalizowanym modelem bazowym popularności ItemPop, modelem opartym na sąsiedztwie obiektów ItemKNN, faktoryzacją macierzy z optymalizacją błędu BPR oraz zoptymalizowaną punktowo faktoryzacją eALS (*efficient Alternating Least Squares*). Ewaluację przeprowadzono na podstawie dwóch metryk jakości rankingu Top-10: wskaźnika trafień ($HR@10$), mierzącego obecność elementu testowego wśród pierwszych 10 propozycji, oraz wskaźnika $NDCG@10$, uwzględniającego dokładną pozycję trafienia na liście. Wyniki jednoznacznie potwierdziły wyższą skuteczność hybrydowej architektury NeuMF (łączącej liniowy wariant uogólnionej fakto-

³⁰ Xiangnan He i in., „Neural Collaborative Filtering”, *Proceedings of the 26th International Conference on World Wide Web*, WWW '17, Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017, s. 173–182.

ryzacji macierzy, ang. *Generalized Matrix Factorization* – GMF, z nieliniową siecią MLP) w stosunku do badanych modeli odniesienia. Wykazano ponadto, że zwiększanie głębokości sieci MLP poprawia celność predykcji, a wstępne uczenie parametrów składowych przed ich fuzją pozytywnie wpływa na zbieżność i końcową skuteczność algorytmu.

Kolejny przełomowy etap w rozwoju literatury to również praca He i in., tym razem z 2020 roku³¹, wprowadzająca model LightGCN. Autorzy przeprowadzają w niej krytyczną dekonstrukcję dotychczasowych splotowych sieci grafowych (takich jak NGCF), wykazując, że przeniesienie skomplikowanych mechanizmów z klasycznych zastosowań uczenia maszynowego — takich jak nieliniowe transformacje macierzowe $\mathbf{W}$ czy nieliniowa funkcja aktywacji (np. ReLU) — jest w filtracji kolaboracyjnej zbędne i utrudnia proces uczenia. Tradycyjne sieci GCN projektowano z myślą o grafach z bogatymi opisami cech (np. sieciach cytowań z tekstami artykułów), podczas gdy w rekomendacjach obiekty i użytkownicy opisani są wyłącznie unikalnymi identyfikatorami ID. Poprzez szczegółowe eksperymenty ablacyjne autorzy udowodnili, że odrzucenie wag macierzowych oraz nieliniowości eliminuje trudności optymalizacyjne, pozwalając sieci na znacznie szybszą zbieżność i lepszą generalizację. W zamian zaproponowali architekturę LightGCN, która opiera się wyłącznie na liniowej agregacji osadzeń bezpośrednich sąsiadów na dwudzielnym grafie interakcji użytkownik-obiekt, stosując jedynie symetryczną normalizację stopni węzłów. Dodatkowo model zastępuje tradycyjne samopłączenia mechanizmem kombinacji warstw, który uśrednia reprezentacje uzyskane ze wszystkich poziomów propagacji — od zerowej warstwy identyfikatorów po wyższe poziomy połączeń wyższego rzędu. W przeprowadzonych eksperymentach na zbiorach Gowalla, Yelp2018 oraz Amazon-Book model LightGCN bezapelacyjnie pokonał dotychczasowe modele odniesienia — w tym klasyczną faktoryzację MF-BPR, głęboki perceptron NeuMF oraz bazowe sieci grafowe NGCF i GC-MC. Zastosowana uproszczona architektura pozwoliła na średni skok celności rekomendacji rankingowych o ponad 16,5% w metryce Recall@20 oraz o 16,9% w metryce NDCG@20 w porównaniu do pełnego modelu NGCF. Istotną obserwacją empiryczną było również zachowanie modelu przy głębszej propagacji: o ile w NGCF zwiększanie liczby warstw powyżej dwóch prowadziło do spadku celności z powodu trudności w zbieżności gradientowej, o tyle LightGCN pozwalał na stabilne wykorzystanie informacji z 3- i 4-stopniowego sąsiedztwa, stale poprawiając jakość rankingu. Ponadto całkowite odrzucenie operacji macierzowych przełożyło się na drastyczne obniżenie błędu treningowego oraz ponad dwukrotne skrócenie czasu uczenia pojedynczej epoki.

Współczesnym wyzwaniem w metodologii badań nad systemami rekomendacyjnymi stał się tzw. kryzys odtwarzalności. Znaczne rozproszenie środowisk programistycznych

³¹ Xiangnan He i in., „LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation”, 2020.

oraz brak standaryzowanych protokołów ewaluacji (np. stosowanie odmiennych wariantów próbkowania negatywnego czy ocenianie na ograniczonej próbie zamiast pełnego sortowania całego katalogu) powodowały, że publikowane w literaturze przewagi nowych modeli bywały trudne do obiektywnej weryfikacji. Odpowiedzią na ten problem stała się przełomowa praca Zhao i in.³², wprowadzająca zunifikowany szkielet badawczy RecBole. Autorzy stworzyli otwartą bibliotekę w środowisku PyTorch, która integruje ponad 70 uznanych algorytmów rekomendacyjnych (od tradycyjnych metod kolaboratywnych po zaawansowane głębokie sieci neuronowe i architektury grafowe) na podstawie spójnego formatu plików atomowych oraz jednolite pętle optymalizacyjne i ewaluacyjne. Stosując zaawansowane procedury akceleracji GPU dla predykcji rankingowych, RecBole zdefiniował nowy standard metodologiczny w dziedzinie RecSys, umożliwiając przeprowadzenie w pełni sprawiedliwego, powtarzalnego i porównywalnego benchmarku modeli wywodzących się z różnych paradygmatów technologicznych. Wpisując się w ten nurt badawczy, w niniejszej pracy wykorzystano właśnie środowisko RecBole do przeprowadzenia autorskich eksperymentów. Pozwolą one na obiektywne zestawienie opisanych modeli klasycznych (BPR), głębokich (NCF) oraz grafowych (LightGCN) na rzeczywistych danych z domeny serwisów VOD.

1.5. Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych

Przeniesienie zaawansowanych koncepcji teoretycznych, omówionych w poprzednich podrozdziałach, do komercyjnego środowiska platform VOD wiąże się z koniecznością ciągłego balansowania między czystą dokładnością matematyczną a operacyjnymi uwarunkowaniami biznesowymi i technicznymi. Projektowanie takich systemów wymaga mierzenia się z kilkoma fundamentalnymi kompromisami.

1.5.1. Kompromis dokładności i różnorodności: wyzwanie „Długiego Ogona”

Pierwszym kluczowym wyzwaniem jest zjawisko asymetrii popularności katalogu treści, określane w literaturze jako krzywa długiego ogona (ang. *Long Tail*)³³. Większość interakcji użytkowników skupia się wokół wąskiej grupy najpopularniejszych hitów kinowych i serialowych, podczas gdy ogromna część katalogu platformy streamingowej

³² Wayne Xin Zhao i in., „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”, *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*, 2021, s. 4653–4664.

³³ Oscar Celma, *Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*, Music Recommendation, Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, s. 43–85.

generuje znikomą liczbę wyświetleń.

Klasyczne algorytmy oparte na filtrowaniu kolaboracyjnym wykazują silną tendencję do rekomendowania wyłącznie pozycji najpopularniejszych (ang. *popularity bias*). Zjawisko to prowadzi do efektu „bogaty, którzy stają się jeszcze bogatsi” (*rich-get-richer*)³⁴. Choć faworyzowanie powszechnie znanych hitów gwarantuje modelowi wysokie wyniki w standardowych metrykach dokładności offline, z punktu widzenia biznesowego platformy jest to wysoce nieefektywne. Tworzy to tzw. bańki filtracyjne i ogranicza widoczność niszowych produkcji, uniemożliwiając pełną monetyzację nabytej bazy filmowej³⁵. Wybór i parametryzacja modelu muszą więc stanowić świadomy kompromis między maksymalną dokładnością rankingową a zdolnością systemu do wspierania odkrywania nowych treści.

1.5.2. Problem zimnego startu w dynamicznych katalogach

W przeciwieństwie do tradycyjnego rynku e-commerce ze stałym asortymentem, środowisko platform strumieniowych charakteryzuje się ciągłą rotacją katalogu. Serwisy VOD regularnie nabywają nowe licencje i publikują własne produkcje. Sytuacja ta rodzi krytyczny wdrożeniowy kompromis związany z tzw. problemem zimnego startu dla nowych obiektów.

Algorytmy kolaboracyjne, w tym modele oparte na uczeniu głębokim (NCF) oraz sieci grafowe (LightGCN), funkcjonują wyłącznie na podstawie macierzy historycznych interakcji. W momencie dodania nowego filmu nie posiada on jeszcze ocen ani historii odtworzeń. W strukturze grafu dwudzielnego staje się węzłem izolowanym (pozbawionym krawędzi), przez co model nie jest w stanie wyznaczyć dla niego odpowiedniego wektora cech (ang. *embedding*)³⁶. Oparcie systemu wdrożeniowego wyłącznie na metodach CF skutkuje całkowitym pomijaniem nowości w generowanych rekomendacjach. W praktyce inżynierskiej problem ten rozwiązuje się poprzez stosowanie architektur hybrydowych (uwzględniających metadane obiektów, takie jak reżyser czy gatunek) lub wprowadzanie reguł heurystycznych promujących nowe pozycje, dopóki nie zgromadzą one liczby interakcji niezbędnej do poprawnego działania modeli kolaboracyjnych.

1.5.3. Wydajność obliczeniowa a wyzwanie czasu rzeczywistego

Z punktu widzenia inżynierii systemów oprogramowania, zaawansowane modele matematyczne podlegają ograniczeniom wydajnościowym. Czas wygenerowania rekomendacji warunkuje czas odpowiedzi serwera i w warunkach komercyjnych nie powinien

³⁴ Ibidem.

³⁵ Vito Walter Anelli i in., *Top-N Recommendation Algorithms: A Quest for the State-of-the-Art*, 2022.

³⁶ Ibidem.

przekraczać ułamka sekundy (tzw. *latency* na poziomie pojedynczych milisekund), aby zachować bezstratną płynność działania aplikacji³⁷.

Złożoność strukturalna współczesnych modeli uczenia maszynowego rodzi tu poważne wyzwania wdrożeniowe:

- **Modele głębokie (NeuMF/NCF):** Charakteryzują się bardzo dużą liczbą parametrów treningowych ze względu na jednoczesne uczenie gęstych osadzeń dla warstw MLP oraz GMF³⁸. Choć faza inferencji dla pojedynczego zapytania może być silnie zoptymalizowana, to dynamiczne przeliczanie nieliniowych transformacji dla milionów kombinacji bywa wysoce kosztowne w czasie rzeczywistym.
- **Modele grafowe (LightGCN):** Paradoksalnie, pomimo rezygnacji z nieliniowych funkcji aktywacji oraz wag, sieci GNN cechują się potężnym kosztem operacyjnym ze względu na mechanizm wieloskokowej propagacji (agregacji) informacji po całym grafie dwudzielnym³⁹. Skompletowanie rekomendacji dla użytkownika wymaga pobrania cech z jego głębokiego sąsiedztwa (sieci powiązań), co stanowi potężne wąskie gardło wydajnościowe.

Rozwiązaniem tego problemu w architekturach przemysłowych jest najczęściej zastosowanie asynchronicznej dystrybucji obliczeń. Złożone algorytmy sztucznej inteligencji trenowane są okresowo w trybie wsadowym (ang. *batch processing*) na gigantycznych klastrach danych, gdzie z wyprzedzeniem wyliczają statyczne wektory cech. Następnie gotowe parametry są propagowane do szybkich baz klucz-wartość w środowisku online, gdzie błyskawiczna warstwa heurystyczna odpowiada wyłącznie za ostateczne filtrowanie biznesowe (np. odrzucenie z rekomendacji filmów, na które wygasła licencja) i proste sortowanie gotowych wyników predykcji.

Opisane powyżej wyzwania, związane ze specyfiką platform VOD, problemem rzadkości macierzy ocen, zjawiskiem baniek filtracyjnych oraz narzutem obliczeniowym głębokich architektur, stanowią bezpośrednie uzasadnienie celu naukowego niniejszej pracy. Wymagają one empirycznego porównania i ewaluacji modeli o różnym stopniu skomplikowania: od klasycznego filtrowania kolaboracyjnego, poprzez architektury głębokiego uczenia, aż po grafowe sieci neuronowe. Badanie to ma na celu weryfikację skuteczności wybranych algorytmów na wysoce rozrzedzonych, rzeczywistych danych, reprezentatywnych dla współczesnej branży rozrywkowej. Cel ten został zrealizowany w kolejnych

³⁷ Malinowski, „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”.

³⁸ He i in., „Neural Collaborative Filtering”.

³⁹ He i in., „LightGCN”.

rozdziałach pracy, w których przedstawiono metodologię eksperymentu oraz analizę uzyskanych wyników.

2. Środowisko, dane i metodyka badań

W niniejszym rozdziale przedstawiono metodykę badań oraz podstawy matematyczne wybranych algorytmów rekomendacyjnych. Omówiono również specyfikę środowiska wykonawczego, proces przygotowania i binarizacji zbioru danych oraz zastosowaną procedurę walidacji i ewaluacji jakości proponowanych propozycji rankingowych.

2.1. Środowisko wykonawcze

Aby ujednolicić proces przygotowania danych i oceny algorytmów, a także zapewnić pełną powtarzalność eksperymentów, badania przeprowadzono przy użyciu biblioteki RecBole (wersja 1.1.1)⁴⁰. Narzędzie to, bazujące na frameworku PyTorch, jest obecnie uznany standardem w badaniach nad systemami rekomendacyjnymi. Jego główną zaletą jest czytelna, modułowa budowa, która dzieli proces badawczy na cztery powiązane ze sobą części: konfigurację, przetwarzanie danych, implementację modeli oraz zoptymalizowaną ewaluację wyników.

Sposób funkcjonowania frameworku RecBole opiera się na wysoce zmodularyzowanej i zorientowanej na obliczenia GPU architekturze potokowej (ang. *pipeline architecture*). Przepływ danych i wykonanie eksperymentu wewnątrz biblioteki realizowane jest w następujących etapach:

1. **Moduł Konfiguracji:** Odpowiada za scalanie ustawień eksperymentalnych z hierarchicznie nakładanymi źródłami: plikami konfiguracyjnymi YAML, parametrami przekazywanymi z wiersza poleceń oraz bezpośrednimi słownikami języka Python. Moduł ten kontroluje rozmiar partii danych (ang. *batch size*), stopę uczenia, użyty optymalizator (np. Adam, SGD) oraz szczegółowe parametry poszczególnych modeli.
2. **Moduł Danych:** Surowe zbiory danych przekształcane są w uniwersalny format tzw. plików atomowych z rozszerzeniem `.inter` (zawierających relacje użytkownik-obiekt) oraz opcjonalnie `.user`, `.item` czy `.kg` (dla metadanych i grafów wiedzy). Wewnątrz środowiska dane są reprezentowane przez wyspecjalizowany obiekt `Interaction`, będący opakowaniem na słownik tensorów (`torch.Tensor`). Zapewnia to bezpośrednie i wysoce zoptymalizowane przenoszenie całych pakietów danych do pamięci VRAM karty graficznej, minimalizując narzuty i wąskie gardła transferu pomiędzy pamięcią RAM a VRAM.

⁴⁰ Zhao i in., dz. cyt.

3. **Moduł Modelu:** Wszystkie zaimplementowane algorytmy dziedziczą po zunifikowanych klasach bazowych (np. `GeneralRecommender` dla modeli filtracji kolaboracyjnej oraz `KnowledgeRecommender` dla modeli z grafami wiedzy). Wymaga to od każdego algorytmu zdefiniowania dwóch ustandaryzowanych interfejsów:
- `calculate_loss(interaction)` – metoda wykorzystywana na etapie trenowania modelu. Odpowiada za obliczenie wielkości błędu algorytmu (tzw. funkcji straty, np. *BPR Loss*). Na podstawie tego błędu model koryguje swoje parametry i uczy się wzorców preferencji użytkowników.
 - `predict(interaction)` oraz `full_sort_predict(interaction)` – metody wykorzystywane już po wytrenowaniu sieci, w fazie ewaluacji. Służą one do liczbowego określenia stopnia dopasowania (ang. *relevance scores*) poszczególnych filmów do danego użytkownika, co pozwala na ułożenie ostatecznego rankingu rekomendacji.
4. **Moduł Wykonania i Ewaluacji:** Pętlą uczenia zarządza gotowy obiekt `Trainer`. Odpowiada on za automatyczny zapis punktów kontrolnych (ang. *checkpoints*), wczesne zatrzymywanie oraz strojenie hiperparametrów.

2.2. Opis i przygotowanie danych

W niniejszym podrozdziale zaprezentowano profil i parametry statystyczne wykorzystanego zbioru danych, a także omówiono proces jego wstępnego przetwarzania. Przedstawiono w nim charakterystykę zjawiska długiego ogona oraz asymetrii popytu na podstawie badanego zbioru. Ponadto wyjaśniono mechanizm binarizacji ocen jawnych do postaci interakcji dorozumianych i opisano procedury filtrowania oraz próbkowania, które były niezbędne do prawidłowego wytrenowania algorytmów.

2.2.1. Charakterystyka zbioru MovieLens 100K

W części empirycznej niniejszej pracy do ewaluacji modeli rekomendacyjnych wykorzystano zbiór danych MovieLens 100K, udostępniany przez grupę badawczą GroupLens Research z Uniwersytetu Minnesoty w 1998 roku. Proces zbierania danych odbył się poprzez stronę internetową, działającą jako spersonalizowany system rekomendacyjny. Internauci na początku byli zobowiązani do założenia konta i uzupełnienia podstawowych informacji osobowych. Następnie mogli oceniać filmy w skali od 1 do 5. System rozwijał się i ewoluował na przestrzeni lat poprzez dodawanie kolejnych funkcjonalności takich jak dodatkowe tagi czy słowa kluczowe opisujące wrażenia po obejrzeniu danego tytułu.

Dane ze zbioru MovieLens 100k były kolekcjonowane między 19 września 1997 roku a 22 kwietnia 1998 roku⁴¹. Autorzy przed opublikowaniem danych oczyścili je jeszcze z rekordów niosących stosunkowo małą wartość informacyjną tj. użytkownicy, którzy ocenili mniej niż 20 filmów lub nie wprowadzili pełnych informacji demograficznych, zostali usunięci.

Wybór tego zbioru podyktowany jest jego powszechnym uznaniem w literaturze przedmiotu jako kanonicznego benchmarku w dziedzinie systemów rekomendacyjnych⁴². Należy zaznaczyć, że zastosowanie mniejszego wariantu (wobec alternatywnych zbiorów o rozmiarach rzędu 1 mln czy 25 mln, udostępnianych przez grupę GroupLens) nie obniża wartości naukowej prowadzonych eksperymentów, co znajduje potwierdzenie w dotychczasowych badaniach⁴³. Istotnym czynnikiem determinującym ten wybór jest również problem optymalizacji hiperparametrów oraz związane z nim zapotrzebowanie na moc obliczeniową. Jak podkreślają autorzy publikacji⁴⁴, współczesne algorytmy rekomendacyjne charakteryzują się znaczną złożonością, przez co proces poszukiwania optymalnych parametrów ulega drastycznemu wydłużeniu. Stanowi to silny argument za wykorzystaniem mniejszych zbiorów danych, w szczególności w obliczu ograniczonych zasobów sprzętowych i braku dostępu do zaawansowanej infrastruktury obliczeniowej.

2.2.2. Zjawisko rzadkości macierzy i asymetria popytu

W ujęciu formalnym strukturę danych modelu rekomendacyjnego definiują trzy fundamentalne zbiory:

- zbiór wszystkich zarejestrowanych użytkowników, oznaczany symbolem $\mathcal{U}$ (a $M = |\mathcal{U}|$ to liczba użytkowników),
- zbiór wszystkich dostępnych w katalogu obiektów (filmów), oznaczany symbolem $\mathcal{I}$ (a $N = |\mathcal{I}|$ to liczba obiektów),
- zbiór zaobserwowanych historycznych interakcji, oznaczany symbolem $\mathcal{E}$ ($\mathcal{E} \subseteq \mathcal{U} \times \mathcal{I}$), reprezentujący zaobserwowane zdarzenia o liczebności $|\mathcal{E}|$.

⁴¹ Michał Bałchanowski, „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”, rozprawa doktorska, 2023.

⁴² F. Maxwell Harper i Joseph A. Konstan, „The MovieLens Datasets: History and Context”, *ACM Transactions on Interactive Intelligent Systems*, 2016, t. 5, nr 4, s. 1–19; He i in., „Neural Collaborative Filtering”; Zhao i in., dz. cyt.

⁴³ Zhu Sun i in., „Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison”, *Proceedings of the 14th ACM Conference on Recommender Systems*, RecSys '20, New York, NY, USA: Association for Computing Machinery, 2020, s. 23–32.

⁴⁴ Anelli i in., dz. cyt.

W analizowanym zbiorze dane te przyjmują odpowiednio wartości: $M = 943$, $N = 1\,682$ oraz $|\mathcal{E}| = 100\,000$. Dokładne ustalenie wymiarów M i N jest kluczowe z punktu widzenia uczenia maszynowego, gdyż determinują one bezpośrednio rozmiary wejściowych słowników dla warstw osadzeń w architekturach neuronowych i grafowych⁴⁵. W klasycznym ujęciu, identyfikator konkretnego użytkownika $u \in \mathcal{U}$ oraz obiektu $i \in \mathcal{I}$ zapisuje się początkowo jako rzadkie wektory (wypełnione zerami z wyjątkiem pojedynczej wartości 1), odpowiednio $\mathbf{x}_u \in \{0, 1\}^M$ oraz $\mathbf{y}_i \in \{0, 1\}^N$ (zapis typu *one-hot*). Następnie są one mapowane na gęste reprezentacje wektorowe $\mathbf{p}_u \in \mathbb{R}^k$ i $\mathbf{q}_i \in \mathbb{R}^k$ (gdzie $k \ll \min(M, N)$) poprzez mnożenie przez macierze wag osadzeń odpowiednio $\mathbf{P} \in \mathbb{R}^{M \times k}$ oraz $\mathbf{Q} \in \mathbb{R}^{N \times k}$.

Tradycyjny model danych rekomendacyjnych reprezentuje się jako dwuwymiarową macierz interakcji $\mathbf{R} \in \mathbb{R}^{M \times N}$, w której wiersze odpowiadają poszczególnym użytkownikom ($u \in \mathcal{U}$), a kolumny poszczególnym obiektom ($i \in \mathcal{I}$). Stopień braku wypełnienia tej struktury opisuje wskaźnik rzadkości (*sparsity rate*), oznaczany symbolem $S \in [0, 1]$. Definiuje się go jako dopełnienie stosunku liczby faktycznie zaobserwowanych interakcji do teoretycznej maksymalnej liczby wszystkich możliwych powiązań w macierzy⁴⁶:

$$S = 1 - \frac{|\mathcal{E}|}{M \times N}. \quad (5)$$

Dla wybranego zbioru danych stopień rzadkości wynosi $S = 93,70\%$, co oznacza, że jedynie 6,30% komórek macierzy zawiera zaobserwowane wpisy. W środowisku VOD wysoka rzadkość macierzy jest zjawiskiem naturalnym — pojedynczy widz jest w stanie zapoznać się jedynie z ułamkiem procenta całkowitej oferty platformy⁴⁷. Skrajnie wysoki wskaźnik rzadkości stanowi podstawowe uzasadnienie metodologiczne dla odrzucenia prostych algorytmów pamięciowych (k -NN), które zmagają się z problemem braku wspólnych sąsiadów, na rzecz metod czynników ukrytych (SVD)⁴⁸ oraz propagacji osadzeń w sieciach grafowych⁴⁹.

Interakcje na platformach streamingowych podlegają silnej asymetrii popytu opisanej rozkładem potęgowym. Charakterystyczną cechą tej asymetrii w systemach dystrybucji cyfrowej jest fakt, że bardzo nieliczna, uprzywilejowana grupa najpopularniejszych pozycji skupia wokół siebie zdecydowaną większość całej aktywności w systemie, podczas gdy olbrzymia większość pozostałych obiektów odnotowuje znikome zainteresowanie ze strony odbiorców⁵⁰. Badana przestrzeń danych jednoznacznie wykazuje zjawisko tzw. długiego

⁴⁵ Zhang i in., dz. cyt., s. sekcje 2.1, 3.2 oraz 3.4.

⁴⁶ Su i Khoshgoftaar, dz. cyt.


⁴⁷ Karol Chęciński i Radosław Wawrzusiak, „Systemy rekomendacji. Remedium w cyfrowej klęsce urodzaju”, *Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne*, 2023, t. nr 2, s. 19, 23.

⁴⁸ Yehuda Koren, Robert Bell i Chris Volinsky, „Matrix Factorization Techniques for Recommender Systems”, *Computer*, 2009, t. 42, s. 30–37.

⁴⁹ Zhang i in., dz. cyt.

⁵⁰ Celma, dz. cyt., s. 93.

ogona, zaprezentowane na Rysunku 2.



Rysunek 2: Rozkład popularności filmów w zbiorze MovieLens 100K przedstawiający zjawisko długiego ogona (*Long-Tail Distribution*)

Źródło: opracowanie własne.

Katalog filmowy dzieli się na dwie wyraźne strefy⁵¹:

- **Głowę popytu:** wąską grupę najpopularniejszych produkcji kinowych (tzw. hitów), które skupiają przeważającą część całkowitej liczby ocen w systemie. Tradycyjnie to ta część oferty była faworyzowana w erze analogowej ze względu na ograniczenia fizycznej przestrzeni sklepowej i wysokie koszty dystrybucji, które wymuszały na dystrybutorach selekcję wyłącznie pozycji o masowej popularności.
- **Długi ogon:** obszerną listę niszowych, mniej znanych lub starszych tytułów o niskiej częstotliwości odtworzeń. W dobie cyfrowej, po wyeliminowaniu fizycznych ograniczeń magazynowych i półkowych, cała ta niszowa oferta może pozostawać stale dostępna dla użytkowników, tworząc rozległą sieć małych rynków o bardzo wysokim potencjale zaspokajania specyficznych i zróżnicowanych gustów.

Z biznesowego i funkcjonalnego punktu widzenia spersonalizowany system rekomendacyjny na rynku VOD musi potrafić trafnie proponować pozycje z długiego ogona, zapobiegając zjawisku monopolizacji uwagi widza wyłącznie przez najpopularniejsze hity⁵². Ze względu na stale rosnące objętości katalogów VOD, użytkownicy stają w obliczu zjawiska przeciążenia poznawczego, w którym samodzielne dotarcie do interesujących

⁵¹ Ibidem, s. 100.

⁵² Chęciński i Wawrzusiak, dz. cyt.


pozycji staje się utrudnione, a zapoznanie się z pełną ofertą katalogową jest fizycznie niemożliwe. Brak skutecznego mechanizmu personalizacji sprawia, że uwaga użytkowników koncentruje się wyłącznie na tytułach najgłośniejszych i powszechnie promowanych, co prowadzi do marnowania potencjału niszowej części biblioteki serwisu. Wdrożenie algorytmów zdolnych do eksploracji długiego ogona i kierowania uwagi widzów z obszaru głowy popytu ku pozycjom niszowym pozwala na pełniejsze wykorzystanie zasobów, zwiększa satysfakcję i lojalność odbiorców oraz maksymalizuje zaangażowanie w korzystanie z platformy.

2.2.3. Problem skrzywienia pozytywnego i binarizacja danych

Oryginalny zbiór MovieLens zawiera oceny jawne wyrażone w 5-stopniowej skali (od 1 do 5 gwiazdek). Choć dostarczają one bezpośredniej informacji o preferencjach użytkownika, w rzeczywistych systemach VOD oceny tego typu wpływają stosunkowo rzadko. Wynika to z faktu, że wystawienie noty wymaga od widza dodatkowego wysiłku i intencjonalnego działania po zakończeniu seansu. W praktyce platform streamingowych użytkownicy znacznie częściej konsumują treści pasywnie, nie pozostawiając systemowi jawnej informacji zwrotnej o swoim stopniu satysfakcji⁵³.

W konsekwencji głównym źródłem informacji dla algorytmów stają się ślady cyfrowe i interakcje dorozumiane, takie jak odtworzenie filmu, czas jego oglądania, kliknięcie w miniaturę czy historia wyszukiwania. Dane te są gromadzone przez platformy całkowicie pasywnie, bez wysiłku ze strony widza, co pozwala na budowę znacznie większych i bardziej aktualnych zbiorów uczących, choć są one trudniejsze w interpretacji z uwagi na brak bezpośredniej deklaracji zadowolenia. Rozkład ocen jawnych w analizowanym zbiorze zaprezentowano na Rysunku 3.

⁵³ Rendle i in., dz. cyt.



Rysunek 3: Rozkład ocen jawnych w zbiorze MovieLens 100K obrazujący efekt zjawiska *positivity bias*

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 100K.

Analiza histogramu wykazuje silną asymetrię lewostronną. Użytkownicy znacznie chętniej oceniają filmy, które im się podobały, podczas gdy produkcje ocenione negatywnie są w logach niemal nieobecne (oceny 3, 4 i 5 stanowią ponad 80% wszystkich wpisów). Zjawisko to jest bezpośrednią konsekwencją błędu selekcji; widzowie intuicyjnie wybierają do obejrzenia te tytuły, wobec których żywią już uprzednie pozytywne oczekiwania (np. ze względu na ulubiony gatunek czy obsadę), co wtórnie znacząco zmniejsza prawdopodobieństwo wystawienia niskiej noty. W rezultacie obserwowany zbiór ocen jawnych nie odzwierciedla reprezentatywnego profilu gustu użytkownika wobec całego katalogu, a jedynie wobec jego wyselekcjonowanego ułamka⁵⁴.

Zgodnie z metodologią zaproponowaną przez He i in.⁵⁵, w celu dostosowania danych do realiów platform streamingowych dokonuje się przekształcenia binarnego oryginalnej macierzy ocen w macierz interakcji dorozumianych, oznaczaną jako $\mathbf{Y} \in \mathbb{R}^{M \times N}$ (gdzie $M = |\mathcal{U}|$ oznacza liczbę użytkowników, a $N = |\mathcal{I}|$ liczbę filmów). Zabieg ten pozwala na przekształcenie subiektywnego problemu regresji ocen w zadanie klasyfikacji binarnej (rekomendacji góry listy), co znacznie lepiej oddaje rzeczywiste zachowanie i procesy decyzyjne użytkowników w serwisach VOD, gdzie kluczowym wyborem jest decyzja o kliknięciu i rozpoczęciu odtwarzania danego tytułu.

Przed przedstawieniem reguły dyskryminacyjnej zdefiniujmy elementy składowe wzoru:

⁵⁴ Celma, dz. cyt.

⁵⁵ He i in., dz. cyt.

- y_{ui} — wartość wskaźnikowa określająca obecność zaobserwowanej relacji pomiędzy użytkownikiem $u \in \mathcal{U}$ a obiektem $i \in \mathcal{I}$,
- $y_{ui} = 1$ — stan dodatni, oznaczający zarejestrowanie interakcji (np. wystawienie jakiegokolwiek oceny lub obejrzenie filmu),
- $y_{ui} = 0$ — stan nieobserwowany, oznaczający brak zarejestrowanej akcji w logach systemowych.

Sformułowanie matematyczne funkcji binarnej przyjmuje postać:

$$y_{ui} = \begin{cases} 1, & \text{jeśli zaobserwowano interakcję} \\ 0, & \text{w przeciwnym razie} \end{cases}, \quad (6)$$

gdzie stan 1 oznacza zarejestrowanie dowolnej oceny przez użytkownika u dla filmu i , a 0 oznacza jej brak.

Warto podkreślić, że wartość $y_{ui} = 0$ ma charakter niejednoznaczny semantycznie. Nie oznacza ona bowiem jawnej niechęci użytkownika do danego tytułu, lecz jedynie brak zaobserwowanej interakcji w systemie⁵⁶. Użytkownik mógł nie obejrzeć filmu z powodów zupełnie niezależnych od jego gustu: film mógł nie zostać wyeksponowany przez interfejs platformy, użytkownik mógł go nie zauważyć w katalogu bądź po prostu jeszcze na niego nie trafić. Struktura ta stanowi fundamentalne wyzwanie w uczeniu maszynowym, gdyż zbiór danych nieobserwowanych ($y_{ui} = 0$) de facto reprezentuje jednocześnie rzeczywiste negatywne preferencje (użytkownik zna film, ale nie chce go obejrzeć) oraz potencjalne przyszłe interakcje dodatnie (użytkownik chętnie obejrzałby film, gdyby tylko dowiedział się o jego istnieniu), które model powinien poprawnie zidentyfikować i wybić na górę listy rekomendacji⁵⁷.


2.2.4. Filtrowanie i technika próbkowania negatywnego

Rozkład aktywności użytkowników wykazuje duże zróżnicowanie – od profili okazjonalnych po użytkowników o bardzo dużej liczbie obejrzanych pozycji (rozkład liczby ocen przypadających na pojedynczego użytkownika zaprezentowano na Rysunku 4).

Chociaż natywny zbiór MovieLens gwarantuje, że każdy użytkownik posiada co najmniej 20 zarejestrowanych interakcji, warunek ten nie dotyczy katalogu filmów. Wiele niszowych pozycji posiada zaledwie pojedyncze oceny, co w architekturach uczenia głębokiego uniemożliwia prawidłową aktualizację wag. Z tego względu zastosowano

⁵⁶ Ibidem.

⁵⁷ Rendle i in., dz. cyt.



Rysunek 4: Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 100K

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 100K.

rygorystyczną procedurę filtrowania typu k -core ($k = 5$)⁵⁸. Usunięto z katalogu wszystkie filmy posiadające mniej niż 5 zarejestrowanych interakcji (co kaskadowo mogło odrzucić również ułamek profili użytkowników). Operacja ta zapobiega występowaniu wektorów zerowych w warstwach osadzeń oraz stabilizuje proces wyznaczania znormalizowanej macierzy sąsiedztwa grafu dwudzielnego w modelach opartych na sieciach GNN.

W celu zapewnienia reprodukowalności eksperymentów i eliminacji błędów implementacyjnych oczyszczone zbiory danych przekonwertowano do formatu Plików Atomowych z rozszerzeniem `.inter`, stanowiącego standard wejściowy biblioteki RecBole. Plik `.inter` przechowuje relacje w strukturze tabularycznej ze zdefiniowanymi typami pól⁵⁹:

- `user_id:token` – unikalny identyfikator użytkownika (sekwencja dyskretna),
- `item_id:token` – unikalny identyfikator filmu (sekwencja dyskretna),
- `rating:float` – oryginalna ocena użytkownika (wykorzystywana pomocniczo),
- `timestamp:float` – znacznik czasu interakcji.

Ewaluację modeli przeprowadzono z wykorzystaniem klasycznej procedury losowego, proporcjonalnego podziału danych (ang. *ratio-based splitting*). Cały dostępny zbiór został

⁵⁸ He i in., dz. cyt.

⁵⁹ Zhao i in., dz. cyt.

podzielony w stosunku 80% : 10% : 10%, co pozwoliło na wydzielenie odpowiednio: zbioru treningowego, walidacyjnego oraz testowego.

Do trenowania modeli punktowych i parowych (Log Loss w NCF oraz BPR Loss w SVD/LightGCN) zastosowano procedurę próbkowania negatywnego (*negative sampling*). Dla każdej dodatniej pary $(u, i) \in \mathcal{E}$ losowano jednostajnie ze zbioru pozycji nieobserwowanych zestaw próbek negatywnych $(u, j) \in \mathcal{E}^-$ (gdzie $y_{uj} = 0$), przy zachowaniu stosunku 1 : 4 (4 próbki negatywne na 1 pozycję dodatnią), co stanowi optymalny kompromis między stabilnością gradientu a czasem obliczeń. Wykorzystanie większej liczby próbek negatywnych jest szczególnie korzystne dla modeli optymalizowanych punktowo (za pomocą funkcji Log Loss). Pozwala im to na ominięcie ograniczeń metody BPR, która z założenia porównuje interakcję pozytywną z tylko jedną losową próbką negatywną⁶⁰.

Tabela 1 przedstawia zbiorcze zestawienie parametrów statystycznych przygotowanego zbioru danych MovieLens 100K po przeprowadzeniu potoku przetwarzania.

Tabela 1: Podsumowanie statystyczne zbioru danych MovieLens 100K wykorzystanego w eksperymentach

Parametr statystyczny	Wartość dla zbioru MovieLens 100K (m1–100k)
Liczba użytkowników ($ \mathcal{U} $)	943
Liczba filmów ($ \mathcal{I} $)	1 682
Liczba interakcji ($ \mathcal{E} $)	100 000
Średnia liczba ocen na użytkownika	106,04
Gęstość macierzy (<i>Density</i>)	6,30%
Rzadkość macierzy (<i>Sparsity</i>)	93,70%
Typ informacji zwrotnej	Interakcje dorozumiane (<i>Implicit Feedback</i>)

Źródło: opracowanie własne.

2.3. Filtrowanie kolaboracyjne

Filtrowanie kolaboracyjne stanowi jeden z najważniejszych i najbardziej ugruntowanych paradygmatów w dziedzinie systemów rekomendacyjnych⁶¹. Jego podstawowym założeniem jest hipoteza, że użytkownicy o zbliżonych wzorcach zachowań w przeszłości będą przejawiać podobne preferencje w przyszłości. W przeciwieństwie do metod opartych na treści, filtrowanie kolaboracyjne nie wymaga analizy semantycznej obiektów ani dostępu do ich szczegółowych metadanych, opierając proces wnioskowania wyłącznie na macierzy interakcji użytkownik-obiekt $R \in \mathbb{R}^{M \times N}$, gdzie M oznacza liczbę użytkowników,

⁶⁰ He i in., dz. cyt.

⁶¹ Koren, Bell i Volinsky, dz. cyt.; Krawczuk, dz. cyt.

natomiast N liczbę filmów w katalogu platformy.

Techniki filtrowania kolaboracyjnego dzielą się na trzy główne nurty⁶²: metody oparte na pamięci, metody oparte na modelach oraz systemy hybrydowe. Pierwsza z wymienionych grup polega na bezpośrednim wykorzystaniu historycznych interakcji do poszukiwania podobieństw i działa w dwóch podstawowych wariantach. Z jednej strony wyróżnia się podejście zorientowane na użytkownika, które opiera się na poszukiwaniu profili o gustach historycznie zbliżonych do aktywnego odbiorcy. Z drugiej strony stosuje się podejście zorientowane na obiekty, w którym oblicza się analityczne podobieństwo pomiędzy samymi pozycjami w katalogu na podstawie tego, czy wchodziła z nimi w interakcję ta sama grupa odbiorców. W przypadku serwisów VOD znacznie powszechniej wykorzystuje się podejście oparte na obiektach. Wynika to z faktu, że zbiór filmów tworzy strukturę znacznie bardziej stabilną w czasie – charakterystyki ich grup docelowych rzadko ulegają zmianie, podczas gdy gusta użytkowników są zmienne, a ich całkowita liczba nieustannie fluktuuje.

Istotnym etapem w ewolucji systemów rekomendacyjnych okazało się odejście od surowej pamięci na rzecz wprowadzania uczących się metod analitycznych (nurt oparty na modelach), a dokładniej modeli czynników ukrytych, realizowanych za pomocą technik faktoryzacji macierzy. Idea faktoryzacji polega na odwzorowaniu zarówno użytkowników u , jak i obiektów i we wspólnej, k -wymiarowej przestrzeni ukrytej $\mathbb{R}^k$, gdzie $k \ll \min(M, N)$ oznacza wyznaczoną liczbę wymiarów ukrytych⁶³. W architekturze tej preferencje pojedynczego użytkownika reprezentowane są przez wektor $\mathbf{p}_u \in \mathbb{R}^k$, natomiast właściwości samego filmu oddaje wektor $\mathbf{q}_i \in \mathbb{R}^k$. Stopień potencjalnego dopasowania danego tytułu do gustu widza obliczany jest na podstawie iloczynu skalarnego wyznaczonych wektorów.

W niniejszej pracy jako wiodących reprezentantów tradycyjnego filtrowania kolaboracyjnego wybrano dwa algorytmy, z których każdy reprezentuje całkowicie odmienne podejście analityczne: ItemKNN (stanowiący klasyczną metodę opartą na obiektowej pamięci) oraz BPR-MF, będący przykładem wariantu opartego na uczeniu parametrów przy użyciu faktoryzacji macierzy z optymalizacją porządkową. Te dwie techniki będą stanowić punkt odniesienia dla wyników nowszych.

2.3.1. Algorytm ItemKNN

Jedną z najpopularniejszych i najbardziej uznanych metod bazujących na pamięci jest technika oparta na analizie podobieństwa obiektów, powszechnie implementowana jako algorytm ItemKNN. Geneza tej metody, wprowadzona i spopularyzowana na przełomie

⁶² Su i Khoshgoftaar, dz. cyt.

⁶³ Rendle i in., dz. cyt.

wieków w systemach e-commerce przez B. Sarwara i in.⁶⁴, opiera się na intuicyjnym założeniu, że użytkownicy z większym prawdopodobieństwem preferują filmy powiązane z produkcjami, które pozytywnie ocenili w przeszłości. Matematyczne podstawy algorytmu ItemKNN oraz koncepcja budowania sąsiedztwa, przedstawione w niniejszym podrozdziale, opierają się w głównej mierze na metodologii syntetyzowanej w pracy Bałchanowskiego⁶⁵.

W przeciwieństwie do metod zorientowanych na użytkownika ItemKNN wyszukuje podobieństwa na poziomie kolumn macierzy interakcji (tj. pomiędzy poszczególnymi filmami). Ogranicza to znacząco problemy wynikające ze zmienności gustów oraz nieustannego rotowania bazy aktywnych kont. Z biznesowego punktu widzenia na platformach VOD liczba filmów rośnie wolniej niż liczba nowych subskrybentów, co stabilizuje proces obliczania sąsiedztwa i zwiększa jakość rekomendacji w ujęciu długoterminowym.

Procedura generowania rekomendacji przy użyciu algorytmu ItemKNN przedstawia się następująco:

1. W pierwszej kolejności, dla każdego z analizowanych elementów, system precyzyjnie ustala sąsiedztwo. Proces ten rozpoczyna się od wyliczenia funkcji podobieństwa $s(i, j)$ pomiędzy dowolnymi dwoma filmami i oraz j z katalogu $\mathcal{I}$. Ze względu na to, że badana w niniejszej pracy przestrzeń danych opiera się na interakcjach dorozumianych, klasyczne miary uwzględniające średnie wariancje ocen (np. korelacja Pearsona) nie znajdują tu matematycznego zastosowania. Standardową techniką służącą do pomiaru bliskości w środowisku binarnym jest odległość kosinusowa, operująca w przestrzeni wektorowej. Stopień powiązania dwóch filmów wyznacza się za jej pomocą ze wzoru⁶⁶:

$$s(i, j) = \frac{\mathbf{y}_i \cdot \mathbf{y}_j}{\|\mathbf{y}_i\|_2 \|\mathbf{y}_j\|_2} = \frac{\sum_u y_{ui} y_{uj}}{\sqrt{\sum_u y_{ui}^2} \sqrt{\sum_u y_{uj}^2}}, \quad (7)$$

gdzie:

- $\mathbf{y}_i, \mathbf{y}_j$ – wektory binarne reprezentujące historię interakcji wszystkich użytkowników dla filmów i oraz j
- y_{ui}, y_{uj} – obserwacje obecności interakcji (0 lub 1) dla użytkownika u z oboma filmami
- $\|\mathbf{y}_i\|_2, \|\mathbf{y}_j\|_2$ – normy Euklidesowe (L2) badanych wektorów

⁶⁴ Badrul Sarwar i in., „Item-Based Collaborative Filtering Recommendation Algorithms”, *Proceedings of ACM World Wide Web Conference*, 2001, t. 1, s. 285–295.

⁶⁵ Bałchanowski, dz. cyt., s. 16-17.

⁶⁶ Ibidem, s. 16.

2. Ponieważ obliczanie relacji dla każdej możliwej pary obiektów w skali milionów widzów generuje znaczny szum informacyjny, algorytm dokonuje redukcji macierzy podobieństw. Dla każdego filmu i zawęża się grono powiązań wyłącznie do zamkniętego zbioru K najbardziej zbliżonych filmów (tzw. zbiór najbliższych sąsiadów $\mathcal{N}_i$). Wynik predykcji $\hat{y}_{ui}$ (zainteresowania użytkownika u filmem i) jest następnie estymowany jako zagregowana i uśredniona statystyka historycznych ocen, jakie widz u wystawił bezpośrednim sąsiadom filmu i (odrzucając całkowicie te interakcje użytkownika, które dotyczyły obiektów leżących poza zdefiniowanym sąsiedztwem $\mathcal{N}_i$). Podejście to pozwala modelowi w sposób intuicyjny wnioskować, że „skoro obiekty w zbiorze $\mathcal{N}_i$ wykazują silną korelację profilu publiczności z analizowanym filmem i , a użytkownik u oglądał wcześniej obiekty z tego zbioru, istnieje wysokie prawdopodobieństwo, że film i również spotka się z jego aprobatą”.
3. W etapie predykcji, po zalogowaniu się użytkownika u , algorytm odczytuje zbiór wszystkich filmów, które ten użytkownik zdążył już obejrzeć (tzw. wejściowy profil użytkownika $\mathcal{I}_u^+$).
4. Ostateczny krok działania algorytmu polega na wyliczeniu estymowanego stopnia dopasowania $\hat{x}_{ui}$, jakim użytkownik u obdarzy dowolny, nieobejrzany jeszcze film i . Predykcję realizuje się poprzez obliczenie średniej ważonej z miar podobieństwa pomiędzy tym filmem i , a obejrzanymi już przez widza produkcjami j , które znalazły się w jego ograniczonym sąsiedztwie⁶⁷:

$$\hat{x}_{ui} = \frac{\sum_j s(i, j) y_{uj}}{\sum_j |s(i, j)|}, \quad j \in \mathcal{N}_i \cap \mathcal{I}_u^+, \quad (8)$$

gdzie:

- $\mathcal{N}_i$ – wyznaczony w etapie 2 statyczny zbiór zawierający K filmów najbliżej spokrewnionych z obiektem i
- $\mathcal{I}_u^+$ – zbiór wszystkich filmów, które użytkownik u już obejrzał
- y_{uj} – wystąpienie pozytywnej relacji pomiędzy użytkownikiem a sąsiadem badanego obiektu

Model ItemKNN, ze względu na swoją wysoką skuteczność w systemach pozbawionych zaawansowanych mechanizmów uczących oraz wysoką wyjaśnialność (wyniki można wprost zinterpretować w interfejsie jako klauzulę "Z uwagi na to, że obejrzałeś

⁶⁷ Ibidem, s. 16.

X, polecamy Ci Y"), na stałe wszedł do kanonu filtrowania kolaboracyjnego. W nowoczesnych zestawieniach naukowych odgrywa on rolę punktu odniesienia, służącego do weryfikacji celowości wdrażania cięższych obliczeniowo metod rekomendacji.

2.3.2. Spersonalizowany ranking bayesowski

Algorytm BPR to technika generująca rekomendacje na podstawie macierzy interakcji. Całokształt teorii oraz formalizm matematyczny tego algorytmu, opisany w niniejszym podrozdziale, bazuje na fundamentalnej pracy Rendle'a i in.⁶⁸. Charakterystycznym elementem algorytmu jest sposób, w jaki traktuje sytuacje, w których użytkownik nie wszedł w interakcję z danym przedmiotem. Tradycyjnie brak interakcji jest traktowany w macierzy jako wartość 0, co interpretowane jest jako negatywna informacja zwrotna. Taki stan rzeczy może nieprecyzyjnie oddawać rzeczywistość. Filmami nieobejrzanymi mogą być zarówno te, które są dla użytkownika nieinteresujące, jak i te, których po prostu nie zna, bądź nie zdążył jeszcze obejrzeć.

Aby rozwiązać ten problem, algorytm BPR rezygnuje z klasycznego, punktowego podejścia do uczenia modelu (gdzie system estymuje konkretną wartość liczbową dla pary użytkownik-obiekt) na rzecz podejścia opartego na parach. Podstawowym założeniem metody jest to, że użytkownik zawsze preferuje obiekty, z którymi wszedł w interakcję, nad tymi, z którymi interakcji nie podjął. Jeżeli zdefiniujemy obiekty znane użytkownikowi u jako pozytywne (oznaczane jako i), a pozostałe pozycje w katalogu jako negatywne (j), BPR zakłada relację wyższości $i >_u j$ na liście rankingowej.

W trakcie treningu optymalizator nie rozpatruje indywidualnych obiektów, lecz przetwarza trójki uczące w postaci (u, i, j) . Celem algorytmu jest maksymalizacja prawdopodobieństwa, że estymowana ocena trafności filmu pozytywnego zawsze będzie przewyższać estymowaną ocenę filmu negatywnego. Podejście to prowadzi do sformułowania parowej funkcji straty BPR (*BPR Loss*), która poprzez znak ujemności odwraca oryginalne kryterium BPR-OPT i minimalizuje błąd dla wszystkich badanych trójek⁶⁹:

$$\text{BPR Loss} = - \sum_{(u,i,j) \in D_{\mathcal{E}}} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) + \lambda_{\Theta} \|\Theta\|^2, \quad (9)$$

gdzie:

- $D_{\mathcal{S}}$ – zbiór wszystkich treningowych trójek (użytkownik, obiekt pozytywny, obiekt negatywny), formułowany na podstawie zbioru zaobserwowanych zdarzeń $\mathcal{E}$ i zdarzeń negatywnych z nim rozłącznych

⁶⁸ Rendle i in., dz. cyt.

⁶⁹ Ibidem.

- $\hat{x}_{ui}$ – estymowana preferencja użytkownika u względem obiektu i (pozytywnego)
- $\hat{x}_{uj}$ – estymowana preferencja użytkownika u względem obiektu j (negatywnego)
- Θ – wektory wag modelu podlegające wyuczeniu
- λ_{Θ} – hiperparametr terminu regularyzacyjnego L2, zapobiegającego zjawisku przeuczenia modelu

Zastosowanie funkcji straty BPR samo w sobie nie określa architektury samej estymaty ($\hat{x}_{ui}$). W podejściu BPR-MF system integruje ową funkcję z modelem faktoryzacji macierzy. W tej konfiguracji przewidywana preferencja użytkownika względem danego obiektu jest obliczana jako standardowy iloczyn skalarny przypisanych do nich wektorów⁷⁰:

$$\hat{x}_{ui} = \mathbf{p}_u \cdot \mathbf{q}_i = \sum_{f=1}^k p_{uf} q_{if}, \quad (10)$$

gdzie:

- $\mathbf{p}_u$ – ukryty wektor cech reprezentujący użytkownika u
- $\mathbf{q}_i$ – ukryty wektor cech reprezentujący obiekt i
- k – wymiarowość przestrzeni ukrytej (z góry określona liczba cech w wektorze)
- p_{uf}, q_{if} – poszczególne (f -te) składowe wektorów ukrytych odpowiednio dla użytkownika i obiektu

2.4. Uczenie głębokie i Neural Collaborative Filtering

Uczenie głębokie w systemach rekomendacyjnych stanowi bezpośrednią odpowiedź na ograniczenia klasycznej faktoryzacji macierzy. W tradycyjnych modelach, takich jak opisany wcześniej BPR-MF, estymowana preferencja użytkownika względem obiektu obliczana jest za pomocą prostego iloczynu skalarnego przypisanych do nich wektorów ukrytych. Z matematycznego punktu widzenia jest to operacja ściśle liniowa. Taki stan rzeczy znacząco ogranicza elastyczność algorytmu i uniemożliwia uchwycenie złożonych, nieliniowych wzorców ukrytych w wielkoskalowych zbiorach interakcji użytkowników platform VOD.

Aby rozwiązać ten problem, architektura Neural Collaborative Filtering (NCF) całkowicie rezygnuje ze sztywnego iloczynu skalarnego na rzecz wielowarstwowych sieci neuronowych. Koncepcja tej architektury oraz przedstawiony w niniejszym podrozdziale

⁷⁰ Ibidem.

formalizm matematyczny bazują na przełomowej pracy badawczej autorstwa He i in.⁷¹. Podstawowym założeniem metody jest to, że sieć neuronowa potrafi samodzielnie wyuczyć się optymalnej, nieliniowej funkcji interakcji bezpośrednio z danych historycznych.

Najskuteczniejszym wariantem z rodziny NCF jest hybrydowy model Neural Matrix Factorization (NeuMF). Łączy on w sobie dwie niezależne ścieżki przetwarzania informacji: GMF oraz MLP. Przetwarzanie danych i generowanie predykcji w tej architekturze realizowane są w następujących krokach⁷²:

1. W pierwszej kolejności identyfikatory użytkownika u oraz obiektu i rzutowane są na gęstą przestrzeń wektorową w postaci macierzy osadzeń. Ponieważ obie ścieżki uczą się odmiennych cech, NeuMF inicjuje dla nich dwa niezależne zestawy wektorów – jeden dla ścieżki liniowej ($\mathbf{p}_u^G, \mathbf{q}_i^G$) i drugi dla nieliniowej ($\mathbf{p}_u^M, \mathbf{q}_i^M$).
2. Równolegle system przetwarza wektory w dwóch odrębnych modułach:
 - Ścieżka GMF: wykonuje iloczyn Hadamarda (mnożenie po współrzędnych) pomiędzy wektorem użytkownika i obiektu, służąc do modelowania prostych, liniowych zależności.
 - Ścieżka MLP (Multi-Layer Perceptron): dokonuje konkatencji (połączenia) wektorów użytkownika i obiektu, a następnie przepuszcza je przez kaskadę ukrytych warstw gęstych z nieliniowymi funkcjami aktywacji (zazwyczaj ReLU), realizując ekstrakcję głębokich relacji.
3. Na przedostatnim poziomie architektury (tzw. warstwie NeuMF) następuje fuzja. Ostateczna preferencja użytkownika obliczana jest poprzez połączenie wyników GMF i MLP w jeden wektor wyjściowy i przepuszczenie go przez sigmoidalną funkcję aktywacji:

$$\hat{y}_{ui} = \sigma \left(\mathbf{h}^T \begin{bmatrix} \mathbf{p}_u^G \odot \mathbf{q}_i^G \\ \phi^{MLP}(\mathbf{p}_u^M, \mathbf{q}_i^M) \end{bmatrix} \right), \quad (11)$$

gdzie:

- $\hat{y}_{ui}$ – estymowane prawdopodobieństwo interakcji użytkownika u z obiektem i
- σ – sigmoidalna funkcja aktywacji, transformująca wynik do przedziału $[0, 1]$
- $\mathbf{h}$ – wektor wag warstwy wyjściowej modelu, łączący wyniki obu ścieżek
- $\odot$ – iloczyn Hadamarda wektorów osadzeń ścieżki GMF

⁷¹ He i in., dz. cyt.

⁷² Ibidem.


- ϕ^{MLP} – wynik przetwarzania połączonych wektorów przez sieć MLP
4. Ze względu na operowanie na danych dorozumianych (1 – obecność interakcji, 0 – brak interakcji), proces optymalizacji (uczenia modelu) traktowany jest jako zadanie binarnej klasyfikacji. Algorytm spadku gradientu dąży iteracyjnie do minimalizacji funkcji binarnej entropii krzyżowej (tzw. *Binary Cross-Entropy* lub *Log Loss*):

$$\mathcal{L}_{NeuMF} = - \sum_{(u,i) \in \mathcal{Y}^+} \log(\hat{y}_{ui}) - \sum_{(u,j) \in \mathcal{Y}^-} \log(1 - \hat{y}_{uj}), \quad (12)$$

gdzie:

- $\mathcal{Y}^+$ – zbiór zaobserwowanych, pozytywnych interakcji w danych treningowych,
- $\mathcal{Y}^-$ – zbiór interakcji negatywnych, wygenerowanych sztucznie poprzez losowe próbkowanie niezaobserwowanych par.

Graficzny schemat modelu NeuMF zaprezentowano na Rysunku 5.



Rysunek 5: Architektura hybrydowego modelu Neural Matrix Factorization (NeuMF)

Źródło: opracowanie własne na podstawie ⁷³.

⁷³ Ibidem

Na przestrzeni lat architektura NeuMF stała się kanonicznym przykładem zastosowania głębokich sieci neuronowych w filtracji kolaboracyjnej. Stanowi ona obecnie kluczowy, uniwersalny punkt odniesienia, względem którego weryfikuje się skuteczność nowszych algorytmów – w tym metod adresujących problem izolacji węzłów, takich jak grafowe sieci neuronowe⁷⁴.

2.5. Grafowe sieci neuronowe i architektura LightGCN

Uczenie głębokie, reprezentowane przez architekturę NeuMF, znacząco zwiększyło zdolność systemów rekomendacyjnych do modelowania nieliniowych interakcji. Modele te posiadają jednak fundamentalne ograniczenie – traktują każdą parę użytkownik-obiekt jako wyizolowany rekord danych. W rzeczywistości interakcje na platformach VOD tworzą rozbudowany graf dwudzielny, w którym użytkownicy są połączeni z oglądanymi filmami. Ignorowanie topologii tego grafu uniemożliwia uchwycenie tzw. relacji wyższych rzędów, czyli wiedzy płynącej z faktu, że użytkownicy o podobnym guście tworzą ukryte klastry powiązań.

Odpowiedzią na ten problem są sieci GNN. Początkowo adaptowano w tym celu klasyczne konwolucje grafowe (GCN), jednak ze względu na ich ciężar obliczeniowy (transformacje cech i nieliniowe funkcje aktywacji), okazały się one nieoptymalne dla zadania filtrowania kolaboracyjnego. Przełomem w tej dziedzinie stał się algorytm LightGCN, zaproponowany w 2020 roku przez He i in.⁷⁵, na którego pracy opiera się niniejszy podrzdział. Badacze ci udowodnili, że w systemach rekomendacyjnych opartych wyłącznie na identyfikatorach (ID) operacje nieliniowe są szkodliwe, a kluczem do sukcesu jest samo wygładzanie wektorów po strukturze grafu. Architekturę algorytmu zilustrowano na rysunku 6.

Działanie algorytmu LightGCN można podzielić na następujące etapy przetwarzania:

1. **Inicjalizacja (Warstwa Osadzeń):** Podobnie jak w standardowej faktoryzacji macierzy, każdemu węzłowi w grafie (użytkownikowi u oraz obiektowi i) przypisywany jest unikalny wektor cech. Stanowią one początkowe reprezentacje informacyjne w tzw. warstwie zerowej: $\mathbf{e}_u^{(0)}$ oraz $\mathbf{e}_i^{(0)}$.
2. **Lekka Konwolucja Grafowa (Propagacja):** Wektory reprezentacji aktualizowane są iteracyjnie poprzez agregację informacji od bezpośrednich sąsiadów w grafie dwudzielnym. Zgodnie z głównym postulatem LightGCN, z procesu tego całkowicie

⁷⁴ He i in., „LightGCN”, s. 5.

⁷⁵ Ibidem.

usunięto parametryzowane macierze wag i aktywacje nieliniowe. Wartość wektora użytkownika w kolejnej warstwie $k + 1$ wyliczana jest ze wzoru⁷⁶:

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}} \mathbf{e}_i^{(k)}, \quad (13)$$

gdzie:

- $\mathbf{e}_u^{(k+1)}$ – zaktualizowany wektor cech użytkownika u po $k + 1$ krokach propagacji grafowej,
- $\mathbf{e}_i^{(k)}$ – wektor cech obiektu i (sąsiada) pochodzący z poprzedniej warstwy k ,
- $\mathcal{N}_u, \mathcal{N}_i$ – zbiór bezpośrednich sąsiadów w grafie (dla użytkownika są to obejrzane przez niego filmy, a dla filmu – użytkownicy, którzy weszli z nim w interakcję),
- $\frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}}$ – symetryczny czynnik normalizujący dyskontujący wpływ bardzo popularnych filmów lub wybitnie aktywnych użytkowników.

Analogiczny proces propagacji zachodzi w drugą stronę – wektory filmów aktualizowane są na podstawie połączonych z nimi wektorów użytkowników.

3. **Fuzja Warstw (Kombinacja Wektorów):** Ponieważ każda warstwa k koduje informacje o topologii z innej odległości (np. $k = 1$ to bezpośrednie interakcje, $k = 2$ to znajomi o podobnym guście), LightGCN nie odrzuca warstw pośrednich. Ostateczna reprezentacja węzła jest wyliczana jako średnia ważona jego stanów z poszczególnych warstw⁷⁷:

$$\mathbf{e}_u = \sum_{k=0}^K \alpha_k \mathbf{e}_u^{(k)}, \quad (14)$$


gdzie K to łączna liczba wykorzystanych warstw konwolucyjnych (zazwyczaj od 2 do 4), a α_k to waga przypisana danej warstwie (domyślnie przyjmuje się stałą wartość $\alpha_k = \frac{1}{K+1}$, traktując wszystkie kroki propagacji równorzędnie).

4. **Predykcja i Optymalizacja:** Ostateczna predykcja prawdopodobieństwa interakcji wyliczana jest poprzez standardowy iloczyn skalarny finalnych, wzbogaconych strukturalnie wektorów: $\hat{y}_{ui} = \mathbf{e}_u^T \mathbf{e}_i$. Tak zaprojektowany model trenowany jest z wykorzystaniem znanej z klasycznych podejść parowej funkcji straty BPR (zdefiniowanej wcześniej wzorem (9)). Pozwala to na bezpośrednią optymalizację algorytmu pod kątem poprawnego sortowania spersonalizowanej listy rekomendacji.

⁷⁶ Ibidem, s. 3.

⁷⁷ Ibidem, s. 4.

Usunięcie zbędnych operacji matematycznych uczyniło z LightGCN model nie tylko skuteczniejszy od wcześniejszych architektur GNN, ale także znacznie szybszy obliczeniowo i łatwiejszy w procesie strojenia. Algorytm ten redefiniuje podejście do filtrowania kolaboracyjnego, udowadniając wprost, że ukryta struktura powiązań pomiędzy użytkownikami a multimediami jest równie kluczowa, co głęboka ekstrakcja nieliniowych wzorców preferencji. Graficzną reprezentację architektury przedstawiono na rysunku 6.



Rysunek 6: Architektura algorytmu LightGCN z uwzględnieniem propagacji warstwowej

Źródło: opracowanie własne na podstawie ⁷⁸.

2.6. Metryki oceny

Ewaluacja modeli rekomendacyjnych w warunkach interakcji dorozumianych różni się od tradycyjnej oceny systemów ukierunkowanych na przewidywanie ocen jawnych. W klasycznym ujęciu regresyjnym celem algorytmu jest minimalizacja błędu predykcji wartości ciągłej, wyrażanej najczęściej za pomocą średniego błędu kwadratowego (RMSE)

⁷⁸ Ibidem

lub średniego błędu bezwzględnego (MAE)⁷⁹.

W rzeczywistych platformach VOD kluczowe znaczenie ma jednak zdolność systemu do wyselekcjonowania i trafnego uporządkowania spersonalizowanej listy K najważniejszych obiektów (tzw. rekomendacja góry listy)⁸⁰. Skuteczność dopasowania listy do preferencji użytkownika mierzy się za pomocą metryk rangowych. W przeciwieństwie do miar regresyjnych uwzględniają one fakt, że w warunkach rzadkości danych oraz wysokiej liczby tytułów w katalogu, użytkownik zapoznaje się wyłącznie z czołowymi pozycjami rekomendowanej listy, ignorując pozostałą, nienadrzędną część asortymentu platformy.

W badaniach eksperymentalnych zastosowano zestaw czterech komplementarnych metryk rangowych poddawanych ewaluacji na zbiorze testowym dla progu $K = 10$: Czułość ($Recall@K$), Wskaźnik Trafień ($HR@K$), Znormalizowany Zdyskontowany Zysk Skumulowany ($NDCG@K$) oraz Średnią Odwrotność Rangi ($MRR@K$).

Niech $\mathcal{U}$ oznacza zbiór użytkowników poddawanych ewaluacji, $\mathcal{R}_u(K)$ uporządkowany zbiór K obiektów rekomendowanych użytkownikowi $u \in \mathcal{U}$ przez analizowany model, natomiast $\mathcal{T}_u$ zbiór obiektów faktycznie zaobserwowanych (relevantnych) w zbiorze testowym dla tego użytkownika. Każda z wymienionych metryk mierzy odmienny aspekt jakości dopasowania listy rekomendacyjnej.

2.6.1. Czułość (ang. *Recall@K*)

Metryka ta określa, jaki ułamek wszystkich relevantnych dla użytkownika obiektów ze zbioru testowego znalazł się na wygenerowanej liście rekomendacji, ignorując kolejność ich ułożenia. Obliczana jest jako iloraz trafnych wskazań algorytmu (wyrażonych jako przecięcie zbioru rekomendacji ze zbiorem testowym) i łącznej liczby pożądaných przez użytkownika elementów. Wzór prezentuje się następująco⁸¹:

$$Recall@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{|\mathcal{R}_u(K) \cap \mathcal{T}_u|}{|\mathcal{T}_u|}. \quad (15)$$

Z perspektywy biznesowej wysoka wartość czułości oznacza, że system rzadko pomija pozycje interesujące dla użytkownika. Metryka ta sprawdza się szczególnie dobrze w scenariuszach, w których odbiorca posiada szerokie i zróżnicowane zainteresowania (np. śledzi wiele seriali jednocześnie), a zadaniem platformy jest zagwarantowanie, że jak najwięcej z nich zostanie wyeksponowanych w głównej sekcji interfejsu. Z racji swojej definicji, miara ta premiuje system za samo wytypowanie odpowiednich treści, niezależnie

⁷⁹ Guy Shani i Asela Gunawardana, Evaluating Recommendation Systems, Recommender Systems Handbook, t. 12, 2011, s. 257–297.

⁸⁰ Steck, dz. cyt.

⁸¹ Samuel Oliveira i in., „Is Rank Aggregation Effective in Recommender Systems? An Experimental Analysis”, *ACM Transactions on Intelligent Systems and Technology*, 2020, t. 11, s. 1–26.

od tego, czy trafny tytuł znalazł się na pierwszym, czy na dziesiątym miejscu zestawienia. W praktyce badań opartych na danych dorozumianych czułość wykazuje znaczną przewagę nad alternatywną precyzją (ang. *Precision*). Wynika to z faktu, że polecony film, który nie występuje w zbiorze testowym, nie musi być propozycją chybiałą – najczęściej jest to po prostu tytuł, którego widz nie miał jeszcze okazji odkryć. Precyzja potraktowałaby taką rekomendację jako jednoznaczny błąd, niesprawiedliwie zaniżając ocenę skuteczności modelu, podczas gdy czułość pozostaje na to zjawisko w pełni odporna.

2.6.2. Wskaźnik Trafień (HR@K)

Reprezentuje prawdopodobieństwo, że na rekomendowanej liście o długości K znajdzie się co najmniej jeden obiekt poszukiwany przez użytkownika w zbiorze testowym⁸²:

$$\text{HR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbb{I}(\mathcal{R}_u(K) \cap \mathcal{T}_u \neq \emptyset), \quad (16)$$

gdzie $\mathbb{I}(\cdot)$ oznacza funkcję wskaźnikową, przyjmującą wartość 1, gdy warunek logiczny jest spełniony, oraz 0 w przeciwnym razie.

Wskaźnik ten jest niezwykle intuicyjną miarą, binarną w swojej naturze z perspektywy pojedynczego użytkownika. W praktyce rynkowej wartość HR jest silnie skorelowana ze zjawiskiem satysfakcji i utrzymania uwagi widza. Użytkownik, który na pierwszej stronie rekomendacji odnajdzie choć jeden zachęcający go film, jest znacznie mniej skłonny do opuszczenia platformy. W odróżnieniu od Czułości Wskaźnik Trafień nie wymaga zidentyfikowania wszystkich interesujących obiektów, zadowalając się pojedynczym, wystarczająco dobrym poleceniem.

2.6.3. Średnia Odwrotność Rangi (MRR@K)

Metryka ta mierzy zdolność systemu do jak najszybszego dostarczenia pierwszej trafnej rekomendacji. Z punktu widzenia platform VOD wskaźnik ten ma fundamentalne znaczenie użytkowe, gdyż symuluje scenariusz, w którym widz poszukuje pojedynczego, satysfakcjonującego filmu na dany wieczór, a jego proces interakcji z interfejsem kończy się w momencie odnalezienia pierwszej interesującej pozycji. Jakość systemu ocenia się tu przez pryzmat odwrotności pozycji, na której pojawił się pierwszy obiekt ze zbioru testowego⁸³:

$$\text{MRR@K}(u) = \frac{1}{\text{rank}_u^*}, \quad (17)$$

⁸² He i in., „Neural Collaborative Filtering”.

⁸³ Krawczuk, dz. cyt., s. 34.

gdzie rank_u^* oznacza rangę pierwszej trafnej rekomendacji na liście $\mathcal{R}_u(K)$ (przyjmując $\text{MRR@K}(u) = 0$, jeśli w obrębie K pozycji nie wystąpiło żadne trafienie). Ostateczna wartość MRR@K stanowi średnią arytmetyczną odwrotności rang obliczoną dla wszystkich analizowanych użytkowników⁸⁴:

$$\text{MRR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{MRR@K}(u). \quad (18)$$

Wyróżnikiem metryki MRR jest jej wyłączenie skupienie na pozycji pierwszego sukcesu, przy całkowitym ignorowaniu ewentualnych kolejnych trafnych poleceń znajdujących się niżej na liście. Metryka ta idealnie odzwierciedla scenariusze, w których nadrzędnym celem systemu jest szybkie dostarczenie widzowi przynajmniej jednej, wysoce trafnej propozycji. Jeśli algorytm potrafi bezbłędnie wytypować taki obiekt i umieścić go na samym szczycie zestawienia, wartość MRR osiąga maksimum. Spadek oceny jest w tym przypadku bardzo gwałtowny – trafienie na pierwszym miejscu daje wynik 1.0, na drugim już tylko 0.5, a na trzecim 0.33, co silnie premiuje modele o najwyższej celności w pierwszej trójce rankingu.

2.6.4. Znormalizowany Zdyskontowany Zysk Skumulowany

W przeciwieństwie do czułości i wskaźnika trafień, metryka NDCG@K (ang. *Normalized Discounted Cumulative Gain*) uwzględnia dokładną pozycję (rangę) trafionych obiektów. Odzwierciedla to rzeczywiste zachowanie użytkowników platform streamingowych, których uwaga drastycznie maleje wraz z oddalaniem się od początku zestawienia. Dyskonto pozycjonalne nakłada najwyższą wagę na trafienia na najwyższych miejscach (np. pozycje 1–3), stosując logarytmiczne osłabienie wag dla pozycji dalszych, co pozwala na precyzyjną ocenę zdolności modelu do pozycjonowania najlepszych propozycji na samym szczycie listy⁸⁵.

Obecność logarytmu we wzorze odzwierciedla naturalny spadek uwagi widza – im dalej na liście znajduje się rekomendacja, tym mniejsza szansa, że użytkownik do niej dotrze. W przeciwieństwie do czułości, która ignoruje kolejność wyników, miara NDCG surowo ocenia jakość sortowania. Umieszczenie trafego filmu na dziesiątym zamiast na pierwszym miejscu skutkuje tu wyraźnym obniżeniem oceny modelu.

Zysk zdyskontowany (DCG@K) dla użytkownika u wyraża się wzorem⁸⁶:

$$\text{DCG@K}(u) = \sum_{v \in \mathcal{R}_u(K)} \frac{\text{rel}_u(v)}{\log_2(\text{rank}_u(v) + 1)}, \quad (19)$$

⁸⁴ Ibidem, s. 34.

⁸⁵ Ibidem.

⁸⁶ Oliveira i in., dz. cyt.

gdzie $rel_u(v) \in \{0, 1\}$ oznacza wskaźnik trafienia danego przedmiotu v (przyjmując wartość 1, jeśli obiekt należy do zbioru testowego $\mathcal{T}_u$, oraz 0 w przeciwnym razie), natomiast funkcja $rank_u(v)$ zwraca dokładną pozycję tego przedmiotu na rekomendowanej liście $\mathcal{R}_u(K)$. Idealny zysk zdyskontowany (IDCG@K) odpowiada hipotetycznemu, bezbłędnemu uszeregowaniu, w którym wszystkie rzeczywiste obiekty ze zbioru testowego umieszczono na najwyższych możliwych pozycjach listy rekomendacyjnej⁸⁷:

$$IDCG@K(u) = \sum_{i=1}^{\min(|\mathcal{T}_u|, K)} \frac{1}{\log_2(i+1)}. \quad (20)$$

Znormalizowana wartość NDCG@K stanowi stosunek zysku rzeczywistego do idealnego, a jej uśrednienie po całym zbiorze użytkowników pozwala na uzyskanie syntetycznej oceny jakości rankingu generowanego przez model⁸⁸:

$$NDCG@K(u) = \frac{DCG@K(u)}{IDCG@K(u)} \implies NDCG@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} NDCG@K(u). \quad (21)$$

Wartość NDCG@10 przyjęto w badaniach jako główną metrykę walidacyjną, decydującą o zatrzymaniu procesu trenowania oraz wyznaczaniu optymalnych zestawów hiperparametrów analizowanych modeli. Takie podejście jest spójne z powszechną praktyką eksperymentalną w dziedzinie głębokich systemów rekomendacyjnych, gdzie to właśnie jakość uporządkowania czołówki listy rekomendacji decyduje o finalnej użyteczności modelu dla widza⁸⁹.

⁸⁷ Krawczuk, dz. cyt., s. 35.

⁸⁸ Oliveira i in., dz. cyt.

⁸⁹ Anelli i in., dz. cyt.

3. Porównanie algorytmów rekomendacyjnych

W niniejszym rozdziale przeprowadzono ewaluację i porównanie skuteczności wybranych algorytmów rekomendacyjnych. Głównym celem badań było zestawienie ze sobą modeli reprezentujących trzy różne paradygmaty: klasyczną faktoryzację macierzy (BPR), głębokie sieci neuronowe (NCF) oraz grafowe sieci neuronowe (LightGCN).

Rozdział został podzielony na trzy główne sekcje. W pierwszej z nich szczegółowo opisano proces doboru i optymalizacji hiperparametrów, mający na celu maksymalizację zdolności predykcyjnych każdego z modeli. W kolejnej części zestawiono wyniki eksperymentów przeprowadzonych na zbiorze danych MovieLens i poddano je analizie pod kątem przyjętych metryk oceny (m.in. NDCG oraz Recall). Rozdział kończy dyskusja uzyskanych wyników oraz wnioski dotyczące skuteczności i ograniczeń badanych architektur w zadaniu rekomendacji Top-N.

3.1. Proces strojenia hiperparametrów

W celu uzyskania stosunkowo najlepszych możliwych wyników badanie poprzedzono procesem doboru odpowiednich hiperparametrów. Przyjęto następującą metodologię. W pierwszej kolejności zbadano poziom wrażliwości algorytmów na zmiany wartości określonych parametrów. Następnie bazując na wynikach zdefiniowano okrojoną siatkę hiperparametrów dla każdej z metod i przy pomocy metody Grid Search polegającej na zbadaniu wszystkich możliwych kombinacji określonych wcześniej wartości wyłoniono najlepsze zestawy parametrów będące podstawą późniejszej analizy porównawczej.


Dobór parametrów poddanych analizie wrażliwości wynikał z ich kluczowego wpływu na zdolności predykcyjne oraz charakterystyki architektonicznej każdego z badanych algorytmów:

- W modelu **ItemKNN** wybrano rozmiar sąsiedztwa (k) oraz współczynnik wygładzania (ang. *shrinkage*). Parametr k determinuje, na ilu najbardziej podobnych elementach bazuje predykcja, co jest kluczowe w filtrowaniu opartym na sąsiedztwie. Współczynnik wygładzania pozwala z kolei na redukcję szumu statystycznego przy obliczaniu podobieństwa dla rzadko ocenianych przedmiotów.
- Dla modelu **BPR** skupiono się na współczynniku uczenia (ang. *learning rate*) oraz rozmiarze wektora cech ukrytych (ang. *embedding size*). Współczynnik uczenia determinuje zbieżność optymalizacji. Z kolei złożoność faktoryzacji macierzy rośnie wraz z wymiarem przestrzeni latentnej, dlatego optymalizacja tego parametru jest kluczowa dla balansu pomiędzy niedouczeniem a przeuczeniem.

- W głębokim modelu **NeuMF** analizie poddano współczynnik uczenia oraz prawdopodobieństwo odrzucenia neuronów (ang. *dropout probability*). Głębokie sieci neuronowe są wysoce podatne na zapamiętywanie danych treningowych (ang. *overfitting*), dlatego właściwy dobór parametru dropout jest niezbędny do uzyskania dobrej zdolności do generalizacji.
- W przypadku grafowego modelu **LightGCN** wytypowano wagę regularyzacji (ang. *regularization weight*) oraz liczbę warstw propagacji (ang. *number of layers*). Regularyzacja L2 kontroluje wielkość wag wektorów zapobiegając nadmiernemu dopasowaniu, podczas gdy liczba warstw odpowiada za eksplorację sygnałów wyższego rzędu w grafie (np. odległości 2-skokowe).

3.1.1. Analiza wrażliwości

Poniżej przedstawiono graficzne zestawienie wpływu badanych hiperparametrów na metrykę NDCG@10 dla każdego z algorytmów. W przypadku modelu ItemKNN (Rysunek 7) można zaobserwować, że zwiększanie liczby uwzględnianych sąsiadów (k) konsekwentnie poprawia wyniki metryki NDCG@10 aż do wartości $k = 200$, po czym przyrost ten naturalnie zwalnia. Regularyzacja *shrinkage* z kolei nie przynosi w tym przypadku znaczących korzyści na zbiorze MovieLens 100K – najwyższy wynik odnotowano dla braku wygładzania (wartość 0.0), a dalsze zwiększanie tego parametru skutkuje delikatnym i marginalnym spadkiem trafności.




Rysunek 7: Wpływ hiperparametrów k oraz *shrinkage* na trafność modelu ItemKNN

Źródło: opracowanie własne.

Dla modelu faktoryzacji BPR (Rysunek 8) analiza ujawnia klasyczną zależność optymalizacyjną. Współczynnik uczenia osiąga jednoznaczne optimum dla wartości 0.0005, zapewniając najwyższą trafność na poziomie $\text{NDCG@10} \approx 0.2867$. Większe wartości


prowadzą do spadku trafności w wyniku niestabilności numerycznej. Z kolei rozmiar wektora cech wskazuje, że wartość 128 oferuje optymalną celność (niewielka przewaga nad 64), podczas gdy dalsze zwiększanie do wymiaru 256 skutkuje spadkiem skuteczności spowodowanym powolnym przeuczaniem się algorytmu na treningowej części zbioru.



Rysunek 8: Wpływ współczynnika uczenia oraz rozmiaru wektora zanurzeń na trafność modelu BPR

Źródło: opracowanie własne.


Ocena parametrów hybrydowego modelu NeuMF (Rysunek 9) potwierdza specyfikę głębokich sieci neuronowych. Widać jednoznacznie, że model zbiega do globalnego optimum przy $learning_rate$ na poziomie 0.0001 ($NDCG \approx 0.2810$). Parametr $dropout$ wykazuje z kolei wysoce czytelny punkt optymalny dla wartości 0.5. Pozwala to na odpowiednią, restrykcyjną regularyzację gęstych warstw, skutecznie hamując overfitting i zwiększając zdolność uogólniania wniosków.



Rysunek 9: Wpływ współczynnika uczenia oraz parametru dropout na trafność modelu NeuMF

Źródło: opracowanie własne.

Ostatnim etapem analizy była ocena grafowego modelu LightGCN (Rysunek 10). Architektura ta bazuje na propagacji informacji wzdłuż krawędzi, co ma swoje odzwierciedlenie na wykresie: zastosowanie dwóch warstw propagacji ($n_layers = 2$) okazało się optymalne. Zwiększanie liczby warstw do 3 lub 4 nieznacznie pogarsza wyniki, co jest klasycznym objawem problemu nadmiernego wygładzenia sygnałów (ang. *over-smoothing*). Zastosowanie odpowiedniej siły kary za wielkość wag również posiada ostry szczyt użyteczności: $reg_weight = 0.10$ maksymalizuje końcową precyzję predykcji tego algorytmu.



Rysunek 10: Wpływ wagi regularyzacji oraz liczby warstw propagacji na trafność modelu LightGCN

Źródło: opracowanie własne.

3.1.2. Przeszukiwanie siatki parametrów — Grid Search

Do ostatecznej optymalizacji hiperparametrów wykorzystano metodę przeszukiwania siatki (*Grid Search*). Jest to podejście deterministyczne, w którym dla każdego badanego parametru definiuje się dyskretny zbiór wartości, a następnie sprawdza każdą możliwą ich kombinację. Złożoność obliczeniowa tego procesu rośnie wykładniczo wraz z liczbą analizowanych wymiarów, co w naturalny sposób narzuca konieczność wcześniejszej redukcji przestrzeni wariantów.

Dzięki przeprowadzonej wcześniej, szczegółowej analizie wrażliwości (Sekcja 3.1.1) udało się odrzucić nieperspektywiczne przedziały wartości i drastycznie zawęzić ostateczną przestrzeń poszukiwań. Pozwoliło to na bezpieczne wykorzystanie metody *Grid Search*, która w przeciwieństwie do podejść stochastycznych (takich jak *Random Search*) gwarantuje bezwzględne odnalezienie globalnego optimum w obrębie zadanej siatki. Opierając się na wytycznych z analizy, dla każdego algorytmu zdefiniowano okrojoną przestrzeń hiperparametrów, którą zestawiono w Tabeli 2. Zgodnie z metodologią badawczą, dla każdej możliwej konfiguracji zdefiniowanej w siatce inicjowano całkowicie niezależny proces uczenia od podstaw. Ewaluacja poszczególnych wariantów odbywała się wyłącznie

na wyodrębnionym zbiorze walidacyjnym, co pozwalało na obiektywny wybór modelu i chroniło finalny zbiór testowy przed zjawiskiem przedwczesnego dopasowania. Za ostateczne kryterium wyboru najlepszego zestawu hiperparametrów przyjęto maksymalizację metryki NDCG@10.

Warto w tym miejscu zaznaczyć, że współczesne algorytmy rekomendacyjne – w szczególności te oparte na sieciach neuronowych – charakteryzują się rozbudowaną przestrzenią konfiguracyjną. Jednoczesna optymalizacja wszystkich dostępnych hiperparametrów przy użyciu metody *Grid Search* była niemożliwa ze względu na wykładniczy wzrost czasu trwania obliczeń. Z tego powodu proces strojenia świadomie ograniczono wyłącznie do kluczowych parametrów, zidentyfikowanych w analizie wrażliwości jako najbardziej wpływowe dla poszczególnych architektur.

Zdecydowana większość pozostałych ustawień procesu uczenia, niewyszczególnionych w Tabeli 2, została ustandaryzowana i zachowana na stałym poziomie dla badanych algorytmów. Do aktualizacji wag wykorzystano optymalizator Adam, będący powszechnie uznanym standardem w środowisku RecBole. Rozmiar partii danych ustalono na 4096, co zapewniło odpowiednią stabilność numeryczną gradientu. Maksymalną liczbę iteracji ograniczono do 100 epok, z włączonym mechanizmem wczesnego zatrzymywania – trening przerywano, gdy metryka NDCG@10 na zbiorze walidacyjnym nie uległa poprawie przez 10 kolejnych epok. Strategię negatywnego próbkowania uzależniono z kolei od specyfiki optymalizacji. Algorytmy bazujące na parowej funkcji straty BPR (klasyczny BPR oraz LightGCN) trenowano w schemacie 1:1, parując każdą interakcję pozytywną z jedną losową interakcją negatywną. Z kolei model NeuMF, zoptymalizowany pod kątem straty punktowej, trenowano stosując proporcję 1:4 (cztery próbki negatywne na jedną obserwowaną). Odpowiednie dostosowanie tego aspektu do natywnych mechanizmów poszczególnych architektur gwarantuje, że końcowa ewaluacja w pełni oddaje ich faktyczny potencjał.

Tabela 2: Zestawienie przestrzeni hiperparametrów (siatki) dla poszczególnych algorytmów

Model	Parametr	Przestrzeń poszukiwań (Grid)
ItemKNN	k	{100, 150, 200}
	$shrink$	{0.0, 2.5, 5.0, 7.5, 10.0}
BPR	$learning_rate$	{0.001, 0.0005, 0.0001}
	$embedding_size$	{64, 128}
NeuMF	$learning_rate$	{0.0005, 0.0001, 0.00005}
	$dropout_prob$	{0.4, 0.5, 0.6}
LightGCN	reg_weight	{0.01, 0.05, 0.1}
	n_layers	{2, 4}

Źródło: opracowanie własne.

Wyniki procesu optymalizacji pozwoliły na wyłonienie ostatecznych architektur, które posłużą do finalnego porównania skuteczności algorytmów w kolejnym podrozdziale. Zestawienie wyselekcjonowanych parametrów przedstawiono w Tabeli 3:

- **ItemKNN:** Najlepszą celność uzyskano dla sąsiedztwa $k = 100$ oraz wygładzania $shrinkage = 7.5$ ($NDCG@10 = 0.2734$).
- **BPR:** Wariant z optymalizacją bayesowską najlepiej operował w przestrzeni latentnej o rozmiarze 128 przy kroku uczenia równym 0.001 ($NDCG@10 = 0.2837$).
- **NeuMF:** Algorytm oparty na głębokich sieciach neuronowych osiągnął globalne optimum dla współczynnika odrzucenia (dropout) rzędu 0.5 oraz współczynnika uczenia 0.0005 ($NDCG@10 = 0.2895$). Pozostałe, stałe parametry architektoniczne (w tym rozmiary warstw ukrytych) zostały zachowane na podstawie wcześniejszej analizy.
- **LightGCN:** Model grafowy zdominował zestawienie testowe, uzyskując najwyższą bezwzględną trafność ($NDCG@10 = 0.3021$) dla 2 warstw propagacji wzdłuż krawędzi oraz wagi regularyzacji L2 na poziomie 0.1.

Powyższe zestawy parametrów gwarantują, że podczas ostatecznej ewaluacji każdy z modeli będzie operował na możliwie najlepiej dobranych wartościach i osiągał optymalne wyniki.

Tabela 3: Wyselekcjonowane, optymalne wartości hiperparametrów dla badanych modeli

Model	Parametr	Optymalna wartość
ItemKNN	k	100
	$shrink$	7.5
BPR	$learning_rate$	0.001
	$embedding_size$	128
NeuMF	$learning_rate$	0.0005
	$dropout_prob$	0.5
LightGCN	reg_weight	0.1
	n_layers	2

Źródło: opracowanie własne.

3.2. Wyniki badań

W niniejszym podrozdziale zaprezentowano ostateczne zestawienie skuteczności badanych algorytmów. Ocenę przeprowadzono na odseparowanym zbiorze testowym, gwarantując tym samym obiektywną miarę zdolności modeli do generalizacji. Zgodnie z wcześniej przyjętą metodologią, predykcje poszczególnych architektur oceniono z wykorzystaniem metryk NDCG@10, Recall@10, HR@10 oraz MRR@10. Pełne zestawienie wyników zaprezentowano w Tabeli 4.

Tabela 4: Porównanie wyników metryk oceny dla testowanych algorytmów rekomendacyjnych na zbiorze MovieLens 100K.

Model	NDCG@10	Recall@10	Hit@10	MRR@10
ItemKNN	0.2734	0.2336	0.7497	0.4392
BPR	0.2837	<u>0.2437</u>	0.7603	0.4525
NeuMF	<u>0.2895</u>	0.2435	0.7720	<u>0.4744</u>
LightGCN	0.3021	0.2529	<u>0.7678</u>	0.4835


Źródło: opracowanie własne.

Analiza powyższej tabeli pozwala na wyciągnięcie kilku kluczowych wniosków, które wpisują się w historyczną ewolucję systemów rekomendacyjnych. Punktem odniesienia w eksperymencie był najprostszy algorytm oparty na sąsiedztwie – ItemKNN, który uzyskał najniższe, bazowe wyniki. Wprowadzenie klasycznej faktoryzacji macierzy (BPR) znacząco poprawiło jakość rekomendacji (wzrost NDCG z 0.2734 na 0.2837), co dowodzi wyższości uczenia się cech ukrytych nad prostymi heurystykami podobieństwa.

Wykorzystanie głębokich sieci neuronowych w modelu NeuMF przyniosło dalszą poprawę w większości metryk, jednak na szczególną uwagę zasługuje relacja między wskaźnikami $HR@10$ a $NDCG@10$. Choć NeuMF wygrał w kategorii $HR@10$ (0.7720), co oznacza, że skuteczniej umieszczał przynajmniej jeden trafny element w pierwszej dziesiątce, to ustąpił w rankingu NDCG. Dowodzi to, że osiągający najwyższe wyniki w zestawieniu grafowy model LightGCN znacznie lepiej radzi sobie z precyzyjnym pozycjonowaniem trafnych rekomendacji na samym szczycie listy. Architektura grafowa, dzięki jawnej propagacji sygnałów między użytkownikami a przedmiotami, uzyskała najwyższe wartości $NDCG@10$ (0.3021) oraz $MRR@10$ (0.4835).

3.2.1. Krzywe zbieżności i stabilność procesu uczenia

Zestawienie końcowych wyników uzupełniono o analizę dynamiki procesu uczenia poszczególnych architektur. Na Rysunku 11 zaprezentowano krzywe zbieżności (ang. *learning curves*) rejestrujące zmianę metryki $NDCG@10$ na zbiorze walidacyjnym w trakcie trwania optymalizacji, aż do momentu aktywacji mechanizmu wczesnego zatrzymywania.



Rysunek 11: Krzywe zbieżności metryki $NDCG@10$ na zbiorze walidacyjnym dla algorytmów BPR, NeuMF oraz LightGCN.


Źródło: opracowanie własne.

Analiza krzywych ujawnia interesujące różnice w sposobie optymalizacji. Klasyczny model faktoryzacji macierzy (BPR) wykazuje najszybsze tempo zbieżności – jego trafność gwałtownie rośnie już w pierwszych iteracjach, osiągając lokalne optimum w okolicach 20. epoki. Następnie można zaobserwować delikatny spadek jakości, co świadczy o podatności

na przeuczenie na zbiorze treningowym. Z kolei model grafowy (LightGCN) startuje z niższego poziomu i uczy się znacznie wolniej, jednak jego krzywa jest wysoce stabilna. Ostatecznie, proces powolnego propagowania sygnałów w grafie pozwala na przekroczenie pułapu wyznaczonego przez BPR i NeuMF, a optymalna zbieżność osiągana jest znacznie później.

3.2.2. Koszty obliczeniowe a skuteczność algorytmów

Ostatnim elementem ewaluacji jest analiza relacji nakładów obliczeniowych (czasu optymalizacji modelu) do uzyskiwanej trafności predykcji. Jest to kluczowy wskaźnik inżynierski w środowiskach produkcyjnych, w których systemy rekomendacyjne muszą być regularnie i szybko dotrenowywane nowymi danymi. Zależność tę zilustrowano na Rysunku 12.



Rysunek 12: Zestawienie czasu uczenia względem ostatecznej skuteczności (NDCG@10) dla badanych modeli.

Źródło: opracowanie własne.

Wykres punktowy ukazuje bardzo wyraźny kompromis pomiędzy kosztem a jakością. Model bazowy ItemKNN, nie wymagający iteracyjnej optymalizacji stochastycznej, zapewnia bardzo krótki czas odpowiedzi przy relatywnie najniższej skuteczności. Klasyczny wariant BPR jawi się jako algorytm niezwykle efektywny kosztowo. Czas jego uczenia zamyka się w kilkudziesięciu sekundach, dostarczając bardzo zadowalające rezultaty.

Najważniejszym wnioskiem jest jednak ewaluacja grafowych sieci neuronowych. Choć LightGCN przewyższa pozostałe modele pod kątem metryki NDCG, to odbywa się to znacznym kosztem sprzętowym. Czas jego pełnego treningu okazał się niemal 10-krotnie wyższy niż w przypadku głębokiej sieci neuronowej (NeuMF) oraz rzędy wielkości wyższy

w porównaniu do klasycznej faktoryzacji macierzy. Wynik ten wskazuje na potencjalne ograniczenia wdrożeniowe algorytmu w czasie rzeczywistym.

3.3. Dyskusja wyników i wnioski

Przeprowadzone badania eksperymentalne na zbiorze MovieLens 100K dostarczyły dowodów na to, że ewolucja systemów rekomendacyjnych w kierunku architektur uwzględniających szerszy kontekst powiązań pomiędzy obiektami jest kierunkiem gwarantującym stosunkowo najlepsze wyniki. Metryki rangowe potwierdziły teoretyczną hierarchię modeli, układając się w czytelny ciąg rosnącej skuteczności: od najprostszych metod opartych na pamięci (ItemKNN), poprzez klasyczną faktoryzację macierzy (BPR), głębokie sieci neuronowe (NeuMF), aż po grafowe sieci neuronowe (LightGCN).

Zwycięstwo algorytmu LightGCN we wskaźnikach uwzględniających pozycje w rankingu (NDCG@10 na poziomie 0.3021 oraz MRR@10 wynoszące 0.4835) bezpośrednio udowadnia, że jawne włączenie struktury grafu dwudzielnego do procesu uczenia pozwala na najtrafniejsze ułożenie samej czołówki listy rekomendacji. Jest to zjawisko wysoce pożądane w systemach VOD, gdzie uwaga widza skupia się na pierwszych kilku propozycjach wyświetlanych na ekranie telewizora. Interesującą obserwacją okazał się jednak wynik wskaźnika HR@10, w którym to głęboka architektura NeuMF (0.7720) zdołała nieznacznie wyprzedzić wariant grafowy (0.7678). Sugeruje to, że nieliniowe sieci wielowarstwowe wykazują zdolność do odnajdywania jakiegokolwiek trafnego obiektu i wyprowadzania go do pierwszej dziesiątki, jednak brakuje im precyzji strukturalnej (którą posiada LightGCN), aby wywindować obiekt na wyższe miejsce w rankingu.

Z inżynierskiego i biznesowego punktu widzenia ostateczne wnioski z badań nie są jednak tak jednoznaczne, jak wskazywałyby na to same miary trafności. Analiza relacji kosztów do jakości (zob. Rysunek 12) pokazała, że zastosowanie najnowocześniejszych rozwiązań opartych na propagacji wiadomości w grafie powoduje znaczny wzrost czasu uczenia. Fakt, iż trening modelu LightGCN wymagał nieporównywalnie więcej nakładów niż optymalizacja wariantu NeuMF, a tym bardziej klasycznego BPR, stanowi zauważalną barierę wdrożeniową. Na wielkoskalowych platformach streamingowych generujących setki milionów logów dziennie proces ten może okazać się problematyczny.

Podsumowując, wybór algorytmu rekomendacyjnego w systemach VOD nie powinien opierać się wyłącznie na maksymalizacji metryki NDCG. Wyniki eksperymentu wskazują, że choć grafowe sieci neuronowe uzyskują najwyższą trafność, ich implementacja wiąże się ze znacznym kosztem obliczeniowym. Biorąc pod uwagę ograniczenia sprzętowe oraz wymóg niskiego opóźnienia w środowiskach produkcyjnych, zoptymalizowane metody oparte na faktoryzacji (BPR) lub architekturach hybrydowych (NeuMF) wciąż stanowią wysoce wydajną alternatywę.

Zakończenie

Głównym problemem badawczym podjętym w niniejszej pracy było zjawisko przeciążenia poznawczego na platformach VOD oraz konieczność doboru optymalnych metod zautomatyzowanej personalizacji treści. Celem pracy było kompleksowe porównanie skuteczności różnorodnych algorytmów rekomendacyjnych, wywodzących się z trzech odmiennych paradygmatów: klasycznego filtrowania kolaboracyjnego, architektur uczenia głębokiego oraz nowoczesnych grafowych sieci neuronowych. Główna hipoteza badawcza zakładała, że zaawansowane modele uwzględniające nieliniowość i grafową topologię powiązań (takie jak NeuMF i LightGCN) wykażą znaczącą przewagę predykcyjną nad tradycyjnymi metodami opartymi na faktoryzacji macierzy i sąsiedztwie (ItemKNN, BPR), jednak odbędzie się to kosztem wymiennie wyższego narzutu obliczeniowego.

Przeprowadzone eksperymenty numeryczne na zbiorze danych MovieLens w pełni potwierdziły słuszność przyjętych założeń. Wyniki analiz jednoznacznie wykazały, że ewolucja architektur w kierunku bezpośredniego modelowania struktury grafu dwudzielnego przynosi wymierne korzyści w jakości rekomendacji. Model LightGCN osiągnął najwyższe wyniki w zestawieniu testowym pod kątem kluczowych metryk rangowych (w tym NDCG oraz MRR), udowadniając swoją wysoką zdolność do pozycjonowania najbardziej relevantnych obiektów na samym szczycie listy rekomendacyjnej. Z kolei hybrydowa architektura głęboka NeuMF okazała się najskuteczniejsza w ogólnym odnajdywaniu pożądanых pozycji, osiągając najwyższą wartość wskaźnika trafień. Jednocześnie zidentyfikowano i udokumentowano wyraźny kompromis pomiędzy precyzją układania rankingu a wymaganym czasem uczenia algorytmów. Nowoczesne sieci grafowe wymagały rzędu wielkości dłuższej optymalizacji niż klasyczne metody bazowe.

Biorąc pod uwagę uzyskane wyniki, można stwierdzić, że teza badawcza postawiona we wstępie pracy została udowodniona. Zrealizowano również główny cel badawczy, którym było praktyczne przetestowanie i porównanie wybranych algorytmów pod kątem ich trafności oraz obciążenia sprzętowego w kontekście platform streamingowych.

Wnioski płynące z przeprowadzonych badań posiadają istotne znaczenie praktyczne dla współczesnych przedsiębiorstw działających na rynku. Z biznesowego punktu widzenia wdrożenie najbardziej zaawansowanych algorytmów grafowych bez rzetelnej analizy opłacalności wiązałoby się ze znacznymi kosztami infrastrukturalnymi, które mogą być nieopłacalne w środowiskach wymagających błyskawicznego odświeżania bazy modeli. Przeprowadzona dyskusja wykazała, że w realiach ograniczonych zasobów sprzętowych starsza klasyczna faktoryzacja macierzy (BPR) lub głęboki model NeuMF stanowią wysoce pożądaną równowagę pomiędzy satysfakcją końcowego odbiorcy a kosztami operacyjnymi utrzymania systemu.

Warto jednocześnie podkreślić pewne ograniczenia przeprowadzonych eksperymentów. Z uwagi na wysoką złożoność obliczeniową algorytmów opartych na grafowych sieciach neuronowych oraz ograniczone zasoby sprzętowe, analizę zrealizowano na podzbiorze MovieLens 100K. Wykorzystanie pełnoskalowych, komercyjnych zbiorów danych o znacznie większej rzadkości interakcji mogłoby dodatkowo uwydatnić różnice w precyzji pomiędzy architekturami, a jednocześnie wymusić zastosowanie bardziej wyrafinowanych strategii optymalizacyjnych niż klasyczne przeszukiwanie siatki. Kwestia ta stanowi naturalny kierunek dla przyszłych prac badawczych w tym obszarze.

Bibliografia

- G. Adomavicius i Alexander Tuzhilin, „Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions”, *IEEE Transactions on Knowledge and Data Engineering*, 2005, t. 17.
- Vito Walter Anelli i in., *Top-N Recommendation Algorithms: A Quest for the State-of-the-Art*, 2022.
- Michał Bałchanowski, „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”, rozprawa doktorska, 2023.
- Michał Bernardelli, Wpływ Algorytmów Rekomendacyjnych Na Stopień Usieciowienia Platform Cyfrowych, Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy, 2024.
- Dirk Bollen i in., *Understanding Choice Overload in Recommender Systems*, 2010.
- Robin Burke, „Hybrid Recommender Systems: Survey and Experiments”, *User Modeling and User-Adapted Interaction*, 2002, t. 12, nr 4.
- Oscar Celma, Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space, Music Recommendation, Berlin, Heidelberg: Springer Berlin Heidelberg, 2010.
- Karol Chęciński i Radosław Wawrzusiak, „Systemy rekomendacji. Remedium w cyfrowej kłęsce urodzaju”, *Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne*, 2023, t. nr 2.
- Mukund Deshpande i George Karypis, „Item-Based Top-N Recommendation Algorithms”, *ACM Transactions on Information Systems (TOIS)*, 2004, t. 22, nr 1.
- David Goldberg i in., „Using Collaborative Filtering to Weave an Information TAPESTRY”, *Commun. ACM*, 1992, t. 35.
- Carlos Gómez-Uribe i Neil Hunt, „The Netflix Recommender System”, *ACM Transactions on Management Information Systems*, 2015, t. 6.
- Blake Hallinan i Ted Striphas, „Recommended for You: The Netflix Prize and the Production of Algorithmic Culture”, *New Media & Society*, 2016, t. 18.
- F. Maxwell Harper i Joseph A. Konstan, „The MovieLens Datasets: History and Context”, *ACM Transactions on Interactive Intelligent Systems*, 2016, t. 5, nr 4.
- Xiangnan He i in., „Neural Collaborative Filtering”, *Proceedings of the 26th International Conference on World Wide Web, WWW '17*, Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017.
- Xiangnan He i in., „LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation”, 2020.

- Yehuda Koren, Robert Bell i Chris Volinsky, „Matrix Factorization Techniques for Recommender Systems”, *Computer*, 2009, t. 42.
- Jerzy Krawczuk, Systemy rekomendacyjne, Wybrane zagadnienia symulacji komputerowej, 2024.
- Michał Malinowski, Zastosowanie Grafów i Sieci w Systemach Rekomendacji, Przedsiębiorstwo w Nowej Rzeczywistości Gospodarczej. Relacje – Zmiany – Strategie, 1, Częstochowa: Wydawnictwo Politechniki Częstochowskiej, 2021.
- „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”, rozprawa doktorska, Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022.
- Julian McAuley i Jure Leskovec, „Hidden Factors and Hidden Topics: Understanding Rating Dimensions with Review Text”, *Proceedings of the 7th ACM Conference on Recommender Systems*, RecSys '13, New York, NY, USA: Association for Computing Machinery, 2013.
- Samuel Oliveira i in., „Is Rank Aggregation Effective in Recommender Systems? An Experimental Analysis”, *ACM Transactions on Intelligent Systems and Technology*, 2020, t. 11.
- Shaina Raza i in., *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*, 2024.
- Steffen Rendle i in., „BPR: Bayesian Personalized Ranking from Implicit Feedback.”, *Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence*, Montreal, Quebec, Canada, 2009.
- Paul Resnick i Hal R Varian, „Recommender Systems”, *Communications of The ACM*, 1997, t. 40, nr 3.
- Francesco Ricci, Lior Rokach i Bracha Shapira, Introduction to Recommender SystemsHandbook, Recommender Systems Handbook, 2010.
- Badrul Sarwar i in., „Item-Based Collaborative Filtering Recommendation Algorithms”, *Proceedings of ACM World Wide Web Conference*, 2001, t. 1.
- Barry Schwartz, *The Paradox of Choice: Why More is Less*, Harper Perennial, 2004.
- Guy Shani i Asela Gunawardana, Evaluating Recommendation Systems, Recommender Systems Handbook, t. 12, 2011.
- Harald Steck, „Evaluation of Recommendations: Rating-prediction and Ranking”, *RecSys 2013 - Proceedings of the 7th ACM Conference on Recommender Systems*, 2013.
- Xiaoyuan Su i Taghi Khoshgoftaar, „A Survey of Collaborative Filtering Techniques”, *Adv. Artificial Intelligence*, 2009, t. 2009.

- Zhu Sun i in., „Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison”, *Proceedings of the 14th ACM Conference on Recommender Systems*, RecSys '20, New York, NY, USA: Association for Computing Machinery, 2020.
- Shuai Zhang i in., „Deep Learning Based Recommender System: A Survey and New Perspectives”, *ACM Computing Surveys*, 2020, t. 52, nr 1.
- Wayne Xin Zhao i in., „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”, *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*, 2021.

Źródła internetowe

- <https://www.bookbeat.com/pl/about> (dostęp 13.07.2026).
- <https://grouplens.org/datasets/movielens/> (dostęp 7.09.2026).
- <https://www.imdb.com/pressroom/stats/> (dostęp 13.07.2026).
- <https://newsroom.spotify.com/company-info/> (dostęp 13.07.2026).

Spis tabel

1	Podsumowanie statystyczne zbioru danych MovieLens 100K wykorzystanego w eksperymentach	30
2	Zestawienie przestrzeni hiperparametrów (siatki) dla poszczególnych algorytmów	50
3	Wyselekcjonowane, optymalne wartości hiperparametrów dla badanych modeli	51
4	Porównanie wyników metryk oceny dla testowanych algorytmów rekomendacyjnych na zbiorze MovieLens 100K.	51

Spis rysunków

1	Taksonomia i historyczny podział algorytmów rekomendacyjnych uwzględnionych w badaniach.	11
2	Rozkład popularności filmów w zbiorze MovieLens 100K przedstawiający zjawisko długiego ogona (<i>Long-Tail Distribution</i>)	25
3	Rozkład ocen jawnych w zbiorze MovieLens 100K obrazujący efekt zjawiska <i>positivity bias</i>	27
4	Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 100K	29
5	Architektura hybrydowego modelu Neural Matrix Factorization (NeuMF)	37
6	Architektura algorytmu LightGCN z uwzględnieniem propagacji warstwowej	40
7	Wpływ hiperparametrów k oraz <i>shrinkage</i> na trafność modelu ItemKNN .	46
8	Wpływ współczynnika uczenia oraz rozmiaru wektora zanurzeń na trafność modelu BPR	47
9	Wpływ współczynnika uczenia oraz parametru dropout na trafność modelu NeuMF	47
10	Wpływ wagi regularyzacji oraz liczby warstw propagacji na trafność modelu LightGCN	48
11	Krzywe zbieżności metryki NDCG@10 na zbiorze walidacyjnym dla algorytmów BPR, NeuMF oraz LightGCN.	52
12	Zestawienie czasu uczenia względem ostatecznej skuteczności dla badanych modeli.	53