



AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE

WYDZIAŁ ZARZĄDZANIA

KATEDRA INFORMATYKI BIZNESOWEJ I INŻYNIERII ZARZĄDZANIA

Praca dyplomowa

**Porównanie algorytmów rekomendacyjnych
(Filtrowanie Kolaboracyjne, Uczenie Głębokie, Grafowe
Sieci Neuronowe) na przykładzie portalu
streamingowego**

Comparison of recommendation algorithms (Collaborative Filtering, Deep Learning, Graph Neural Networks) using a streaming platform as an example

Autor: Jakub Sornat

Kierunek studiów: Informatyka i Ekonometria

Opiekun: dr hab. Iwona Skalna

Kraków, 2026

Spis treści

1	Wstęp	1
2	Wprowadzenie do problematyki systemów rekomendacyjnych	3
2.1	Zjawisko przeciążenia informacyjnego i specyfika rynku VOD	3
2.2	Definicje, formalizm matematyczny i struktura danych w personalizacji .	4
2.2.1	Ewolucja pojęcia systemów rekomendacji	4
2.2.2	Formalizacja matematyczna problemu rekomendacji	6
2.2.3	Paradygmaty modelowania: przewidywanie ocen a prognoza rankingu	7
2.2.4	Struktura danych i źródła informacji zwrotnej	8
2.3	Ewolucja technologiczna paradygmatów rekomendacyjnych	9
2.3.1	Tradycyjne systemy rekomendacyjne	10
2.3.2	Era Uczenia Głębokiego	11
2.3.3	Zaawansowane modele systemów rekomendacyjnych	12
2.4	Przegląd literatury naukowej	13
2.5	Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych	17
2.5.1	Kompromis dokładności i różnorodności: wyzwanie „Długiego Ogona”	17
2.5.2	Problem zimnego startu w dynamicznych katalogach	17
2.5.3	Wydajność obliczeniowa a wyzwanie czasu rzeczywistego	18
3	Środowisko, dane i metodyka badań	20
3.1	Środowisko wykonawcze	20
3.2	Opis i przygotowanie danych	21
3.3	Filtrowanie kolaboracyjne	29
3.3.1	Algorytm ItemKNN	30
3.3.2	Spersonalizowany ranking bayesowski	32
3.4	Uczenie głębokie i Neural Collaborative Filtering	34
3.5	Grafowe sieci neuronowe i architektura LightGCN	36
3.6	Metryki oceny	39
4	Porównanie algorytmów rekomendacyjnych	43
4.1	Proces strojenia hiperparametrów	43
4.1.1	Analiza wrażliwości	44
4.1.2	Przeszukiwanie siatki parametrów — Grid Search	46

4.2	Wyniki badań	48
4.2.1	Krzywe zbieżności i stabilność procesu uczenia	49
4.2.2	Koszty obliczeniowe a skuteczność algorytmów	50
4.3	Dyskusja wyników i wnioski	51
	Podsumowanie	52
	Bibliografia	53
	Źródła internetowe	55
	Spis tabel	56
	Spis rysunków	57

1. Wstęp

W dobie dynamicznego rozwoju platform cyfrowych, a w szczególności serwisów oferujących wideo na żądanie (VOD), użytkownicy coraz częściej stykają się z bezprecedensowym zjawiskiem przeciążenia informacyjnego. Dostępny asortyment treści dalece przekracza ludzkie możliwości poznawcze i analityczne, czyniąc proces samodzielnego wyboru skrajnie nieefektywnym. W takich warunkach systemy rekomendacyjne stają się nie tylko wygodnym udogodnieniem, ale wręcz kluczowym narzędziem nawigacyjnym oraz podstawowym mechanizmem budowania zaangażowania i satysfakcji klienta. Dynamiczny rozwój metod sztucznej inteligencji doprowadził do powstania wielu zaawansowanych algorytmów rekomendacyjnych. Rodzi to naturalną potrzebę ich obiektywnego ewaluowania i porównywania pod kątem skuteczności predykcyjnej oraz koniecznych nakładów obliczeniowych, co stanowiło główną motywację do podjęcia niniejszej tematyki badawczej.

Przedmiotem rozważań i badań w niniejszej pracy są algorytmy rekomendacyjne wywodzące się z różnych paradygmatów nauczania maszynowego. Szczególną uwagę zwrócono na klasyczne techniki filtrowania kolaboracyjnego, zaawansowane architektury uczenia głębokiego (ang. *Deep Learning*) oraz nowoczesne podejścia oparte na grafowych sieciach neuronowych (ang. *Graph Neural Networks*). Zakres pracy obejmuje teoretyczny opis, praktyczną implementację oraz ewaluację wybranych, reprezentatywnych algorytmów (m.in. ItemKNN, BPR, NCF, LightGCN).

Celem pracy jest kompleksowe porównanie skuteczności działania wymienionych wyżej algorytmów rekomendacyjnych w specyficznym kontekście portali streamingowych. Założono weryfikację potencjalnej przewagi złożonych podejść opartych na głębokich sieciach neuronowych i strukturach grafowych nad klasycznymi metodami filtrowania kolaboracyjnego. Ważnym aspektem badawczym jest również analiza kompromisu pomiędzy uzyskiwanym zyskiem predykcyjnym a poniesionym narzutem obliczeniowym.

W realizacji pracy oparto się na zróżnicowanych źródłach informacji. W warstwie teoretycznej czerpano przede wszystkim z aktualnej literatury anglojęzycznej, uwzględniając recenzowane artykuły naukowe oraz publikacje z wiodących konferencji zajmujących się sztuczną inteligencją. Źródłem materiału badawczego był powszechnie uznany i wykorzystywany w nauce zbiór danych MovieLens, który dobrze oddaje charakterystykę preferencji użytkowników platform filmowych. Dokumentacja techniczna dedykowanych bibliotek (w tym frameworku RecBole) stanowiła bazę informacyjną do implementacji badanych architektur.

W przeprowadzonych badaniach posłużono się metodami o charakterze empirycznym i analitycznym. Zastosowano zaawansowane strojenie hiperparametrów algorytmów z

użyciem techniki przeszukiwania siatki (ang. *Grid Search*) oraz eksperymenty analizujące zbieżność funkcji straty w procesie uczenia. Do rzetelnej oceny jakości generowanych rekomendacji zastosowano ugruntowane w dziedzinie metryki ewaluacyjne, takie jak trafność rankingu (m.in. NDCG) czy wskaźnik trafień (ang. *Hit Rate*). Modele zaimplementowano i przetrenowano w środowisku języka Python. Realizacja założonych celów podyktowała podział pracy na trzy zasadnicze rozdziały.

W rozdziale pierwszym wprowadzono w ogólną problematykę systemów rekomendacyjnych. Omówiono specyfikę serwisów VOD, zdefiniowano niezbędne pojęcia i formalizm matematyczny, a także zarysowano ewolucję paradygmatów personalizacji treści. Przedstawiono również kluczowy dla tematyki przegląd dotychczasowej literatury oraz zdefiniowano główne wyzwania badawcze.

Rozdział drugi stanowi podbudowę metodyczną przeprowadzonych eksperymentów. Scharakteryzowano w nim wykorzystane środowisko wykonawcze i sposób przygotowania danych. Następnie szczegółowo opisano budowę matematyczną poddanych ewaluacji algorytmów: od klasycznego filtrowania kolaboracyjnego, przez uczenie głębokie, aż po grafowe sieci neuronowe. Rozdział ten zamyka formalna definicja zastosowanych metryk oceny.

W rozdziale trzecim zaprezentowano właściwe rezultaty przeprowadzonych eksperymentów numerycznych i ich szczegółową analizę. Udokumentowano proces strojenia hiperparametrów, zestawiono algorytmy pod kątem jakości predykcji, zbadano koszty obliczeniowe i stabilność treningu. Całość wieńczy dyskusja nad osiągniętymi wynikami i sformułowanie wniosków końcowych.

2. Wprowadzenie do problematyki systemów rekomendacyjnych

Niniejszy rozdział wprowadza w ramy teoretyczne, formalizm matematyczny oraz uwarunkowania rynkowe systemów rekomendacyjnych, stanowiąc punkt wyjścia dla dalszych badań. Przeprowadzona w nim analiza obejmuje kognitywne aspekty przeciążenia informacyjnego na rynku VOD, formalną kategoryzację metod personalizacji, a także ewolucję technologiczną algorytmów – od klasycznej algebry macierzy po złożone struktury grafowe. Całość zamyka omówienie kluczowych kompromisów wdrożeniowych, z jakimi wiąże się projektowanie tego typu systemów.

2.1. Zjawisko przeciążenia informacyjnego i specyfika rynku VOD

Przejście od tradycyjnych form konsumpcji mediów do środowiska cyfrowego wywołało bezprecedensową transformację na rynku rozrywkowym. Widzowie systematycznie odchodzą od tradycyjnej telewizji, charakteryzującej się sztywną ramówką, na rzecz platform strumieniujących wideo na żądanie (ang. *Video on Demand* – VOD), które zapewniają asynchroniczny i zindywidualizowany dostęp do materiałów. Współczesne serwisy globalne, takie jak Netflix, Max czy Amazon Prime Video, a także dostawcy lokalni pokroju Player.pl i TVP VOD, dysponują obszernymi bibliotekami cyfrowymi, oferując natychmiastowy dostęp do setek tysięcy tytułów filmowych oraz serialowych.

Ta radykalna poprawa dostępności zrodziła jednak nowe wyzwanie natury kognitywnej. W dobie tak gwałtownego rozrostu repozytoriów multimedialnych użytkownicy nieustannie konfrontowani są ze zjawiskiem przeciążenia informacyjnego (ang. *information overload*)¹. Skalę tego problemu obrazują dane rynkowe: globalna baza filmowa IMDb indeksuje ponad 30 milionów tytułów², platforma muzyczna Spotify udostępnia katalog przekraczający 100 milionów utworów³, natomiast serwis BookBeat oferuje dostęp do ponad miliona pozycji literackich⁴.

Obecność setek tysięcy produkcji w ramach pojedynczego serwisu wywołuje u odbiorcy efekt tzw. paradoksu wyboru⁵. Nadmierna ekspozycja na treści przytłacza użytkownika, sprawiając, że całościowa eksploracja katalogu staje się fizycznie niemożliwa, a podjęcie decyzji o wyborze seansu wiąże się ze znacznym wysiłkiem poznawczym.

¹ K. Chęciński i R. Wawrzusiak. Systemy rekomendacji. Remedium w cyfrowej kłęsce urodzaju. W: „Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne” nr 2 (2023), s. 18.

² <https://www.imdb.com/pressroom/stats/> (dostęp 13.07.2026).

³ <https://newsroom.spotify.com/company-info/> (dostęp 13.07.2026).

⁴ <https://www.bookbeat.com/pl/about> (dostęp 13.07.2026).

⁵ B. Schwartz. The Paradox of Choice: Why More Is Less. W: 82 (2005).

Tego typu przeciążenie kognitywne w skrajnych przypadkach prowadzi do zniechęcenia, frustracji widza, a ostatecznie do rezygnacji z subskrypcji. Rozwiązania tradycyjne, takie jak wyszukiwanie frazowe czy statyczne, redakcyjne zestawienia popularności, okazują się niewystarczające – wymagają one bowiem aktywnej inicjatywy ze strony odbiorcy lub promują pozycje najpopularniejsze, nieuwzględniając jego indywidualnych preferencji⁶.

W konsekwencji zaawansowane systemy rekomendacyjne przestały być jedynie opcjonalnym dodatkiem funkcjonalnym, stając się integralnym i kluczowym elementem architektury współczesnych platform cyfrowych⁷. Ich nadrzędnym zadaniem jest ciągłe, zautomatyzowane analizowanie ogromnych katalogów treści i filtrowanie ich w taki sposób, aby skutecznie chronić widza przed zjawiskiem paraliżu decyzyjnego. Zamiast zmuszać odbiorcę do samodzielnego przeszukiwania tysięcy tytułów, algorytmy te dostarczają spersonalizowane propozycje, ściśle dopasowane do jego unikalnego profilu, historii oglądania oraz preferencji. W cyfrowym modelu biznesowym, opartym na miesięcznych subskrypcjach, to właśnie trafność tych podpowiedzi stanowi podstawowe narzędzie budujące lojalność i długoterminowe zaangażowanie użytkowników. Skuteczność takiego podejścia najlepiej obrazują wewnętrzne dane platformy Netflix, z których wynika, że precyzyjne sugestie algorytmiczne odpowiadają za wygenerowanie aż 80% całkowitego czasu, jaki widzowie spędzają na odtwarzaniu materiałów w serwisie⁸.

2.2. Definicje, formalizm matematyczny i struktura danych w personalizacji

Niniejszy podrozdział przybliży aparat pojęciowy niezbędny do zrozumienia mechanizmów działania nowoczesnych systemów personalizacji treści. Zaprezentowano w nim ewolucję i matematyczną formalizację problemu rekomendacji, a także scharakteryzowano specyfikę struktury danych zasilających współczesne algorytmy uczenia maszynowego.

2.2.1. Ewolucja pojęcia systemów rekomendacji

Historycznie pojęcie systemów rekomendacji ewoluowało wraz z postępującą cyfryzacją oraz narastającym problemem przeciążenia informacyjnego. Pierwsze rozwiązania badawcze miały charakter ściśle kooperacyjny i opierały się na świadomej współpracy odbiorców. Pionierskim przykładem jest stworzony w 1992 roku przez badaczy z Xerox

⁶ J. Krawczuk. Systemy rekomendacyjne. W: (w:) Wybrane zagadnienia symulacji komputerowej. 2024, s. 24–25.

⁷ M. Bernardelli. Wpływ Algorytmów Rekomendacyjnych Na Stopień Usieciowienia Platform Cyfrowych. W: (w:) Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy. 2024, s. 23–24.

⁸ C. Gómez-Urbe i N. Hunt. The Netflix Recommender System. W: „ACM Transactions on Management Information Systems” 6 (2015), s. 6.

Palo Alto Research Center (PARC) system Tapestry⁹. Powstał on w odpowiedzi na dynamicznie rosnącą liczbę wiadomości w sieciach korporacyjnych i na grupach dyskusyjnych, proponując nowatorskie podejście do selekcji strumieni danych. Tapestry umożliwiał użytkownikom filtrowanie przychodzących dokumentów na podstawie jawnych, manualnych adnotacji i ocen wprowadzonych wcześniej przez innych czytelników (np. żądanie wyświetlenia wyłącznie tych wiadomości, które konkretny współpracownik oznaczył jako wartościowe). To właśnie w publikacji opisującej ten system po raz pierwszy w literaturze sformułowano termin, filtrowanie kolaboracyjne, kładąc podwaliny pod cały współczesny nurt badań nad personalizacją. Chociaż system Tapestry działał zadowalająco, to jednak ze względu na wymóg budowania skomplikowanych zapytań i ograniczenie do małych, zamkniętych społeczności, w których użytkownicy znali się nawzajem, jego koncepcja szybko ewoluowała w stronę w pełni zautomatyzowanych, bezobsługowych algorytmów na dużą skalę.

Przełomowym momentem dla rozwoju pojęć w tej dziedzinie była praca opublikowana w 1997 roku przez P. Resnicka i H. Variana¹⁰. Badacze ci zaproponowali, aby wąskie pojęcie "filtrowania kolaboracyjnego" zastąpić szerszym i bardziej uniwersalnym terminem "systemy rekomendacyjne". Argumentowali oni, że nowa generacja algorytmów nie wymaga już celowej współpracy między użytkownikami, którzy w środowisku sieciowym mogą pozostawać dla siebie całkowicie anonimowi. Zgodnie z ich ujęciem, system rekomendacyjny to dowolne zautomatyzowane narzędzie, które agreguje oceny – zarówno te wprowadzane jawnie, jak i te pozyskane w sposób niejawny z zachowania odbiorców (ang. *implicit feedback*) – a następnie kieruje trafne sugestie do odpowiednich osób.

Wraz z dynamicznym rozwojem metod uczenia maszynowego na początku XXI wieku, definicja ta uległa dalszemu rozszerzeniu i abstrakcji. Klasyczne już dziś ujęcie zaproponował w 2002 roku R. Burke, definiując system rekomendacji jako każdy program, którego nadrzędnym zadaniem jest generowanie zindywidualizowanych sugestii lub aktywne kierowanie użytkownika do interesujących go obiektów w obrębie bardzo rozległej przestrzeni opcji¹¹. To pojemne ujęcie usankcjonowało rozwój kolejnych architektur, w tym filtrowania opartego na zawartości (ang. *content-based filtering*) oraz wysoce złożonych modeli hybrydowych. Współcześnie, za sprawą algorytmów głębokiego uczenia, zadanie to uległo radykalnej automatyzacji. W ekosystemach cyfrowych platform VOD systemy rekomendacyjne przestały być jedynie narzędziem pomocniczym wspomagającym wybór, stając

⁹ D. Goldberg i in. Using Collaborative Filtering to Weave an Information TAPESTRY. W: „Commun. ACM” 35 (1992).

¹⁰ P. Resnick i H. R. Varian. Recommender Systems. W: „Communications of The ACM” 40.Nr 3 (1997).

¹¹ R. Burke. Hybrid Recommender Systems: Survey and Experiments. W: „User Modeling and User-Adapted Interaction” 12 (2002).

się ich centralnym elementem i kształtując codzienne decyzje użytkowników w znacznie większym stopniu niż tradycyjne wyszukiwanie czy statyczne rankingi popularności.

2.2.2. Formalizacja matematyczna problemu rekomendacji

Z obszarem systemów rekomendacyjnych nierozdzielnie związany jest problem badawczy, który można sformalizować w następujący sposób¹². Niech $C = \{c_1, c_2, \dots, c_m\}$ będzie skończonym zbiorem użytkowników wykorzystujących system rekomendacyjny, a $O = \{o_1, o_2, \dots, o_n\}$ – skończonym zbiorem wszystkich możliwych obiektów podlegających rekomendacji. Ponadto niech u będzie funkcją użyteczności mierzącą przydatność obiektu $o \in O$ dla użytkownika $c \in C$. Zależność tę można wyrazić jako odwzorowanie:

$$u: C \times O \rightarrow W \quad (1)$$

gdzie W jest uporządkowanym zbiorem (np. zbiorem nieujemnych liczb całkowitych). W takim ujęciu, dla każdego użytkownika $c \in C$ zostaje wybrany podzbiór $R_c^* \subset O$, który maksymalizuje użyteczność. Oznacza to, że dla ustalonego $c \in C$ wyznacza się zbiór rekomendowanych obiektów zgodnie ze wzorem¹³:

$$R_c^* = \left\{ r \in O : u(c, r) = \max_{o \in O} u(c, o) \right\} \quad (2)$$

W przypadku ogólnym podstawowym zadaniem algorytmów jest znalezienie powyższego podzbioru R_c^* , określanego jako zbiór rekomendowanych obiektów dla użytkownika c .

Jednym z głównych wyzwań związanych z działaniem systemów personalizacji jest zjawisko rzadkości danych (*data sparsity*), wynikające z dysponowania nielicznymi informacjami o użytkownikach lub ich całkowitego braku¹⁴. Sytuacja taka ma miejsce w przypadku, gdy użytkownik po raz pierwszy ma kontakt z systemem (tzw. problem zimnego startu) lub gdy system celowo nie gromadzi danych historycznych w związku z wymogami ochrony prywatności. Z tego względu model klasyczny ulega często modyfikacji, w której rekomendacja dokonuje się bezpośrednio względem wybranego obiektu m , bez bezpośredniego uwzględniania specyfiki użytkownika c . Po zastąpieniu funkcji

¹² M. Malinowski. „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”. Rozprawa doktorska. Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022, s. 36–37.

¹³ G. Adomavicius i A. Tuzhilin. Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. W: „IEEE Transactions on Knowledge and Data Engineering” 17 (2005).

¹⁴ J. McAuley i J. Leskovec. „Hidden Factors and Hidden Topics: Understanding Rating Dimensions with Review Text”. W: *Proceedings of the 7th ACM Conference on Recommender Systems*. RecSys '13. New York, NY, USA: Association for Computing Machinery, 2013.

użyteczności odwzorowaniem $w: O \times O \rightarrow W$, zadanie wyznaczenia zbioru rekomendacji dla użytkownika R_c^* transformowane jest w optymalizację zbioru R_m^* , czyli rekomendację na poziomie elementu (obiektu). W konsekwencji dla ustalonego $m \in O$ zbiór rekomendowanych obiektów definiuje się następująco¹⁵:

$$R_m^* = \left\{ r \in O : w(m, r) = \max_{o \in O} w(m, o) \right\} \quad (3)$$

W tym wariancie udział użytkownika c ogranicza się do faktu, że to on, świadomie kierując swoim zachowaniem (np. poprzez kliknięcie), dokonuje wyboru obiektu $m \in O$, względem którego konstruowana jest następnie rekomendacja R_m^* . Ponadto funkcja $w(m, o)$ określa w tym wypadku popularność obiektu $o \in O$ o użyteczności wykazującej największe podobieństwo do pierwotnego obiektu $m \in O$.

2.2.3. Paradygmaty modelowania: przewidywanie ocen a prognoza rankingu

Wyniki działania algorytmów rekomendacyjnych prezentowane są użytkownikowi na podstawie dwóch głównych paradygmatów¹⁶:

1. Przewidywanie ocen: model prognozuje konkretną wartość liczbową oceny (np. 4,5/5 gwiazdek). Podejście to stanowiło fundament historycznego konkursu *Netflix Prize* (2006–2009) i algorytmu *Cinematch*. Celem jest tutaj minimalizacja błędu bezwzględnego estymacji (np. RMSE) między przewidywaną oceną a rzeczywistą.
2. Prognoza rankingu: system ignoruje absolutną wartość oceny na rzecz wygenerowania uporządkowanej listy N najlepszych pozycji, dopasowanych specyficznie do użytkownika. Optymalizacji podlega względna kolejność proponowanych elementów.

W nowoczesnych systemach rozrywkowych VOD zdecydowanie preferuje się prognozy rankingowe (Top-N). Jak wykazuje Harald Steck¹⁷, z perspektywy biznesowej oraz doświadczeń użytkownika kluczowe jest zaprezentowanie najtrafniejszych obiektów na samym szczycie listy, a nie przewidywanie dokładnych ocen liczbowych. Odwrót od klasycznej predykcji ocen wynika również z masowego przejścia platform na gromadzenie danych niejawnych. Współcześni odbiorcy rzadko udzielają bezpośrednich ocen punktowych, co wymusza na algorytmach analizę behawioralną (np. mierzenie czasu odtwarzania materiału). Dane tego typu nie przekładają się wprost na bezwzględną ocenę liczbową, jednak idealnie wpisują się w zadanie optymalizacji względnego rankingu proponowanych treści.

¹⁵ M. Malinowski. Zastosowanie Grafów i Sieci w Systemach Rekomendacji. W: 2021, s. 80–81.

¹⁶ Ibidem, s. 78.

¹⁷ H. Steck. *Evaluation of Recommendations: Rating-prediction and Ranking*. 2013.

2.2.4. Struktura danych i źródła informacji zwrotnej

Systemy rekomendacyjne to w swej istocie systemy przetwarzania informacji, których skuteczność i architektura zależą bezpośrednio od wolumenu, jakości oraz wielowymiarowości gromadzonych danych wejściowych. Dane te mogą mieć różną formę i pochodzenie, a stopień ich wykorzystania determinuje wybór odpowiedniej techniki rekomendacji. W literaturze przedmiotu strukturę danych zasilających systemy rekomendacyjne dzieli się najczęściej na trzy główne obiekty: przedmioty, użytkowników oraz transakcje¹⁸:

- **Przedmioty:** obiekty podlegające rekomendacji charakteryzują się różnym stopniem złożoności oraz określoną wartością (użytecznością) dla odbiorcy, z którą wiąże się koszt poznawczy lub finansowy. W kontekście portali streamingowych (VOD) pozycje mogą być reprezentowane w sposób minimalistyczny (wyłącznie jako unikalny identyfikator) lub za pomocą bogatych zbiorów metadanych. Obejmują one atrybuty katalogowe (np. gatunki, reżyserzy, obsada), a także zaawansowane cechy generowane automatycznie przez systemy analizy obrazu i dźwięku (np. VCR – Video Content Recognition), takie jak tempo montażu czy tonacja kolorystyczna.
- **Użytkownicy:** model użytkownika gromadzi informacje pozwalające na personalizację rekomendacji, kodując jego preferencje i potrzeby. W zależności od wybranego algorytmu reprezentacja ta może przyjmować różną formę. W systemach demograficznych profil opiera się na statycznych parametrach (np. wiek, płeć), podczas gdy w filtrowaniu kolaboracyjnym użytkownik modelowany jest najczęściej poprzez wektor ukrytych cech lub bezpośrednio przez historię ocen. Profil uzupełniany jest często o kontekst dynamiczny (np. używane urządzenie, pora dnia, geolokalizacja) oraz dane behawioralne odzwierciedlające wzorce nawigacji w systemie.
- **Transakcje:** zapisy interakcji pomiędzy użytkownikiem a systemem rekomendacyjnym. Stanowią one sekwencyjne logi zachowań, które obok samego faktu wyboru przedmiotu mogą zawierać informacje o kontekście zapytania oraz ewentualnej informacji zwrotnej. To właśnie na podstawie danych transakcyjnych algorytmy uczą się wzorców preferencji.

Z punktu widzenia optymalizacji matematycznej modelu i budowy funkcji celu, kluczowy jest podział informacji zwrotnej (reprezentującej historyczne transakcje) na dwie główne kategorie:

¹⁸ F. Ricci, L. Rokach i B. Shapira. Recommender Systems Handbook. W: (w:) Recommender Systems Handbook. T. 1–35. 2010, s. 7–10.

- Jawne oceny (*explicit feedback*): bezpośrednie wyrażenie preferencji przez użytkownika. Przyjmują one najczęściej formę ocen numerycznych (np. skala 1–5 gwiazdek), ocen porządkowych, czy też wartości binarnych (np. pozytywny/negatywny). Choć dostarczają precyzyjnych i jednoznacznych informacji o upodobaniach, ich główną wadą jest wysoki koszt poznawczy wymagany od użytkownika, co sprawia, że występują w systemie skrajnie rzadko, prowadząc do silnego problemu rzadkości macierzy danych.
- Dorozumiane ślady aktywności (*implicit feedback*): zachowania wywnioskowane w sposób pośredni z akcji użytkownika (np. czas oglądania, historia odtworzeń, przewijanie wideo, liczba kliknięć). Stanowią one obfite, bezkosztowe w pozyskaniu, lecz zaszumione źródło wiedzy. Modelowanie informacji dorozumianych wiąże się z problematyką jednoklasowego filtrowania kolaboracyjnego¹⁹. Główne wyzwanie polega na interpretacji braku interakcji: w przeciwieństwie do ocen jawnych, brak interakcji z filmem nie musi oznaczać niechęci do niego, lecz bardzo często wynika z faktu, że użytkownik nie był świadomy jego istnienia.


Współczesne środowiska wielkoskalowych systemów VOD, z uwagi na marginalny odsetek ocen jawnych, opierają się w głównej mierze na wykorzystaniu dorozumianych śladów aktywności. Zdolność algorytmów do skutecznego wyciągania użytecznych informacji z tych obfitych, lecz przepelnionych zbędnymi informacjami zbiorów danych, przy jednoczesnym uwzględnieniu dostępnych metadanych, jest kluczowa dla jakości działania całego systemu.

2.3. Ewolucja technologiczna paradygmatów rekomendacyjnych

Systemy rekomendacyjne funkcjonują i są rozwijane na rynku od ponad trzydziestu lat. Na przestrzeni tego czasu środowiska informatyczne przeszły całkowitą transformację, z czym wiązała się również dynamiczna zmiana preferencji, przyzwyczajeń i oczekiwań samych użytkowników. Te głębokie przemiany technologiczne i behawioralne wymusiły ciągłą ewolucję w sposobie projektowania algorytmów. Opierając się na współczesnym przeglądzie literatury przeprowadzonym przez Razę i in.²⁰, historyczny rozwój paradygmatów rekomendacyjnych można podzielić na trzy główne ery. Odzwierciedlają one rosnącą złożoność w modelowaniu preferencji użytkowników oraz gwałtowny postęp w dziedzinie sztucznej inteligencji, przy czym każda z er charakteryzuje się odmiennym podejściem do analizy danych i reprezentacji wiedzy:

¹⁹ S. Rendle i in. „BPR: Bayesian Personalized Ranking from Implicit Feedback.” W: 2009.

²⁰ S. Raza i in. *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. 2024.



Rysunek 1: Taksonomia i historyczny podział algorytmów rekomendacyjnych uwzględnionych w badaniach.

Źródło: opracowanie własne.

2.3.1. Tradycyjne systemy rekomendacyjne

Historyczny rozwój systemów rekomendacyjnych ukształtowały trzy klasyczne paradygmaty, które do dziś odgrywają rolę standardowych modeli referencyjnych w badaniach naukowych²¹:

- **Filtrowanie oparte na treści:** rekomenduje obiekty na podstawie ich podobieństwa do tych wybieranych w przeszłości (często obliczając iloczyn skalarny wektorów). Metoda ta jest wysoce odporna na problem „zimnego startu” w przypadku wprowadzania do katalogu nowych premier filmowych. Wynika to z faktu, że algorytm do działania nie wymaga zgromadzenia początkowej masy interakcji od społeczności. Wystarczy sama obecność metadanych opisujących nowy film (np. gatunek, obsada, reżyser), by móc od razu dopasować go do profili widzów. Z drugiej strony, ścisłe uzależnienie predykcji od dotychczasowej historii oglądania prowadzi do zjawiska nadmiernej specjalizacji. System nie posiada mechanizmu eksploracji i promuje wyłącznie pozycje podobne do tych już obejrzanych. W efekcie zamyka to użytkownika w bańce filtracyjnej, pozbawiając go możliwości odkrywania nowych gatunków i tytułów. Produkcje te, choć mogłyby okazać się dla niego atrakcyjne, przez swoje niewystarczające podobieństwo do dotychczasowej historii oglądania są całkowicie pomijane przez algorytm.

²¹ X. Su i T. Khoshgoftaar. A Survey of Collaborative Filtering Techniques. W: „Adv. Artificial Intelligence” 2009 (2009).

- **Filtrowanie kolaboracyjne:** opiera się na analizie opinii i zachowań całej społeczności. Główne założenie tego podejścia mówi, że użytkownicy o podobnej historii interakcji (np. oglądający te same filmy) będą mieli zbliżone preferencje w przyszłości. Klasycznie algorytmy te dzieli się na metody oparte na pamięci wykorzystujące m.in. algorytm k -najbliższych sąsiadów oraz znacznie wydajniejsze metody oparte na modelach. Podejścia pamięciowe, choć intuicyjne, wykazują poważne problemy ze skalowalnością i drastycznie tracą na skuteczności przy bardzo rzadkich danych. Odpowiedzią na te ograniczenia stała się technika faktoryzacji macierzy (m.in. SVD, ALS), która zrewolucjonizowała uczenie modeli bazowych. Pozwala ona na rzutowanie niezwykle rzadkiej macierzy interakcji do gęstej przestrzeni tzw. czynników ukrytych (*latent factors*), dzięki czemu system potrafi uczyć się nieoczywistych wzorców. Należy jednak zaznaczyć, że w przeciwieństwie do metod opartych na treści, czyste filtrowanie kolaboracyjne jest całkowicie podatne na problem „zimnego startu” – nie potrafi trafnie polecić nowo dodanego filmu, dopóki ten nie zbierze krytycznej masy odtworzeń od początkowych widzów.
- **Modele hybrydowe:** stanowią pragmatyczny kompromis łączący podejścia kolaboracyjne i treściowe, zaprojektowany z myślą o niwelowaniu słabości pojedynczych paradygmatów. Poprzez fuzję obu technik system potrafi jednocześnie przełamać bańkę filtracyjną (wykorzystując eksploracyjny potencjał CF) oraz skutecznie rekomendować nowości kinowe nieposiadające historii odtworzeń (wykorzystując metadane z CBF). Klasyczną taksonomię takich rozwiązań przedstawił R. Burke²², wyróżniając kluczowe strategie ich integracji. Należą do nich m.in.: łączenie wyników poprzez ważone sumowanie predykcji niezależnych modeli, wykorzystywanie wyników jednego algorytmu jako atrybutów dla drugiego, wieloetapowe kaskadowanie predykcji oraz dynamiczne przełączanie (*switching*). Ta ostatnia strategia pozwala systemowi np. zastosować model oparty na treści dla najnowszych premier, a płynnie przejść na model kolaboracyjny w przypadku filmów posiadających już bogatą, historyczną reprezentację w bazie danych.

2.3.2. Era Uczenia Głębokiego

Około 2015 roku dokonał się technologiczny przełom związany z szeroką adaptacją głębokich sieci neuronowych. Wprowadziły one możliwość automatycznej ekstrakcji cech (*representation learning*) oraz elastycznego mapowania silnie nieliniowych interakcji, co

²² Burke, dz. cyt.

stanowiło wyraźne ograniczenie metod klasycznych²³. Rozwój modeli rekomendacyjnych w tej erze opierał się na wdrożeniu kilku kluczowych architektur:

- **Wielowarstwowe perceptrony (MLP):** zrewolucjonizowały modelowanie kolaboracyjne, czego sztandarowym przykładem jest architektura Neural Collaborative Filtering (NCF). Model ten uogólnił klasyczną faktoryzację macierzy, zastępując sztywny, liniowy iloczyn skalarny rozbudowaną siecią neuronową. Sieć ta zyskała zdolność do aproksymacji dowolnie złożonych funkcji, co drastycznie zwiększyło pojemność predykcyjną algorytmu.
- **Autoenkodery i sieci splotowe (VAE / CNN):** wariacyjne autoenkodery (VAE) znalazły zastosowanie jako potężne narzędzie do redukcji wymiarowości danych w obliczu ich wysokiej rzadkości. Z kolei sieci splotowe (CNN) otworzyły drogę do ekstrakcji cech bezpośrednio z multimediów (np. analiza miniatur, plakatów czy całych klatek wideo), łącząc cechy wizualne filmów bezpośrednio z algorytmem predykcyjnym.
- **Modele sekwencyjne i Transformery:** w celu analizowania historii oglądania w ujęciu chronologicznym początkowo zaprzęgnięto sieci rekurencyjne (RNN). Zostały one jednak szybko wyparte przez nowocześniejsze mechanizmy uwagi i architekturę Transformer (modele takie jak SASRec czy BERT4Rec), które pozwoliły na wysoce efektywną analizę zarówno krótko, jak i długoterminowych intencji widza.

2.3.3. Zaawansowane modele systemów rekomendacyjnych

Najbardziej zaawansowane modele współczesne odchodzą od płaskich, tabelarycznych reprezentacji użytkownika na rzecz rozbudowanej dynamiki relacyjnej i grafowej²⁴:

- **Systemy sekwencyjne i sesyjne (SBR):** modelują krótkoterminowe intencje użytkownika w ramach pojedynczej sesji anonimowej, posiłkując się łańcuchami Markowa lub zaawansowanymi regułami sekwencyjnymi.
- **Głębokie modele grafowe (GNN):** reprezentują cały system VOD jako graf dwudzielny lub heterogeniczny. Modele oparte na propagacji osadzeń, na czele z architekturą LightGCN, pozwalają na wysoce wydajne przechwytywanie relacji wyższego rzędu pomiędzy użytkownikami a przedmiotami. Z kolei zaawansowane Grafy Wiedzy (KGCN) osadzają system w głębokim kontekście semantycznym. Wspiera to

²³ S. Zhang i in. Deep Learning Based Recommender System: A Survey and New Perspectives. W: „ACM Computing Surveys” 52.Nr 1 (2020).

²⁴ Malinowski, dz. cyt.

konceptcję "Wyjaśnialnej Sztucznej Inteligencji"(XAI – Explainable AI), pozwalając wygenerować informację zwrotną: "Polecamy ten film, ponieważ polubiłeś reżysera X, który pracował także przy produkcji Y".

- **Uczenie ze wzmocnieniem:** traktuje problem rekomendacji jako sekwencyjny proces decyzyjny agenta. Algorytm na bieżąco optymalizuje kompromis między pokazywaniem znanych treści a sugerowaniem nowości, maksymalizując tym samym długoterminową satysfakcję użytkownika na platformie, a nie jedynie szansę na najbliższe kliknięcie.

Przedstawiona taksonomia obrazuje historyczny i strukturalny podział na trzy generacje algorytmów: od prostych heurystyk pamięciowych, przez gęste modele nieliniowe, aż po współczesne paradygmaty oparte na grafach. Wybór reprezentatywnych algorytmów z różnych gałęzi tego drzewa pozwoli w dalszej części pracy na empiryczne porównanie skuteczności predykcyjnej modeli pochodzących z odmiennych epok technologicznych. Zanim jednak zaprojektowane zostaną odpowiednie środowiska testowe, niezbędne jest przyjrzenie się najnowszemu dorobkowi naukowemu w badanej dziedzinie.

2.4. Przegląd literatury naukowej

W niniejszym podrozdziale dokonano szczegółowego i krytycznego przeglądu literatury naukowej z zakresu systemów rekomendacyjnych, ze szczególnym uwzględnieniem podejść opartych na filtrowaniu kolaboracyjnym, sztucznych sieciach neuronowych oraz grafowych strukturach wiedzy. Analiza obejmuje zarówno klasyczne metody faktoryzacji, jak i najnowsze osiągnięcia z obszaru głębokiego uczenia w odniesieniu do specyficznych uwarunkowań rynku wideo na żądanie (VOD).

Przegląd literatury naukowej w kontekście usług streamingowych warto rozpocząć od analizy przełomowego konkursu Netflix Prize (2006–2009) omówionego przez Hallinana i Striphasa²⁵. Autorzy wykazują, że publiczne udostępnienie zbioru obejmującego ponad 100 milionów ocen przypisanych przez 480 tysięcy użytkowników dla 17 tysięcy filmów zdefiniowało nowożytną erę kultury algorytmicznej. Rywalizacja o poprawę celności predykcji błędu RMSE o 10% względem algorytmu Cinematch udowodniła całkowitą niewystarczalność tradycyjnych metod opartych na sąsiedztwie, które wykazywały skrajną podatność na narzut pamięciowy i brak skalowalności. To właśnie Netflix Prize spopularyzował modele czynników ukrytych, w tym w szczególności faktoryzację macierzy (SVD). Hallinan i Striphas zwracają również uwagę na skomplikowane zjawiska polaryzacyjne,

²⁵ B. Hallinan i T. Striphase. Recommended for You: The Netflix Prize and the Production of Algorithmic Culture. W: „New Media & Society” 18 (2016).

określane jako wyzwanie *Napoleon Dynamite problem*, w którym przewidywanie gustów użytkowników dla niszowych i polaryzujących treści wymagało odrzucenia pojedynczych algorytmów na rzecz wielkich zespołów modeli hybrydowych.

Kompleksowe i wieloaspektowe ujęcie podstaw teoretycznych oraz wyzwań wdrożeniowych przedstawia praca Krawczuka²⁶. Autor przeprowadza szczegółową analizę poszczególnych paradygmatów rekomendacji, oceniając ich przydatność w warunkach produkcyjnych. W pierwszej kolejności analizuje techniki filtrowania opartego na treści (CBF), wykazując, że ich podstawową zaletą jest wysoka niezależność od aktywności reszty społeczności oraz odporność na rzadkość ocen innych użytkowników. Zauważa jednak przy tym istotne ograniczenia natury poznawczej i algebry czystych atrybutów: algorytmy CBF wykazują tendencję do nadmiernej specjalizacji, zamykając użytkownika w tzw. bańce filtracyjnej i uniemożliwiając odkrycie niespodziewanych, lecz trafnych pozycji, a także zmagają się z problemem zimnego startu dla nowych obiektów bez uzupełnionych metadanych. Przechodząc do filtrowania kolaboracyjnego (CF), Krawczuk akcentuje, że wykorzystywanie mądrości tłumu pozwala na rekomendowanie treści o strukturze niezależnej od ich opisu semantycznego. Niemniej jednak metody te cierpią na krytyczną rzadkość ocen, gdzie wskaźnik wypełnienia macierzy ocen R często nie przekracza 1%, oraz na skrajny problem zimnego startu dla nowych uczestników systemu. Jako rozwiązanie kompromisowe autor omawia zaawansowane architektury hybrydowe, które poprzez strategie łączone, sekwencyjne czy rozszerzanie cech skalają sygnały treściowe z relacjami interakcji. Niezwykle istotnym wkładem pracy Krawczuka jest również analiza wymogów architektonicznych: wskazuje on, że wdrożenie przemysłowe na platformach VOD wymaga utrzymania niskiego czasu odpowiedzi przy jednoczesnej skalowalności obliczeniowej. Podsumowując ewaluację, Krawczuk dowodzi, że w serwisach wideo nadrzędne znaczenie biznesowe ma porządek propozycji na ekranie, w związku z czym metryki rankingowe Top- K , takie jak MRR, NDCG oraz Precision@ k , stanowią jedyne adekwatne kryterium oceny modeli w tym środowisku.

Praca He i in. z 2017 roku skupia się na wykorzystaniu głębokich sieci neuronowych do tworzenia systemów rekomendacyjnych²⁷, wprowadzając architekturę Neural Collaborative Filtering (NCF). W pierwszej części publikacji autorzy uzasadniają potrzebę zastąpienia klasycznego iloczynu skalarnego nieliniowymi warstwami neuronowymi, wykazując ograniczenia liniowych metod faktoryzacji macierzy oraz przedstawiając teoretyczne fundamenty stojące za proponowanym rozwiązaniem. Do przeprowadzania eksperymentów

²⁶ Krawczuk, dz. cyt.

²⁷ X. He i in. „Neural Collaborative Filtering”. W: *Proceedings of the 26th International Conference on World Wide Web*. WWW '17. Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017.

empirycznych wykorzystano zbiory danych MovieLens 1M oraz Pinterest. W przypadku MovieLens 1M oceny jawne (w skali 1–5) przekształcono na dane ukryte, traktując każdą ocenę jako obecność interakcji ($y_{ui} = 1$), zbiór Pinterest poddano natomiast filtracji typu 20-core (odrzucając użytkowników z mniej niż 20 akcjami). W obu zbiorach zastosowano procedurę podziału *Leave-One-Out*, w której ostatnią interakcję odłożono do testów, przedostatnią do walidacji, a pozostałe do uczenia, łącząc w zestawie testowym każdy pozytywny obiekt z 99 losowymi próbkami negatywnymi. W celach porównawczych zestawiono architekturę NCF z szeregiem znanych metod referencyjnych: niepersonalizowanym baseline’em popularności ItemPop, modelem opartym na sąsiedztwie obiektów ItemKNN, faktoryzacją macierzy z optymalizacją błędu porządkowania par BPR (*Bayesian Personalized Ranking*) oraz zoptymalizowaną punktowo faktoryzacją dla danych dorozumianych eALS (*efficient Alternating Least Squares*). Ewaluację przeprowadzono na podstawie dwóch podstawowych metryk jakości rankingu Top-10: Hit Ratio ($HR@10$), mierzącą obecność poszukiwanego elementu testowego wśród pierwszych 10 propozycji, oraz Normalized Discounted Cumulative Gain ($NDCG@10$), uwzględniającą dokładną pozycję trafienia na liście. Wyniki badań jednoznacznie potwierdziły przewagę hybrydowej architektury NeuMF (łączącej liniowy wariant GMF z nieliniowym perceptronem MLP) nad wszystkimi modelami odniesienia, wykazując ponadto, że zwiększanie głębokości sieci MLP sukcesywnie podnosi celność rekomendacji, a wstępne uczenie parametrów składowych przed ich fuzją zapewnia optymalną zbieżność i najwyższą skuteczność algorytmu.

Kolejny przełomowy etap w rozwoju literatury to również praca He i in., tym razem z 2020 roku²⁸, wprowadzająca model LightGCN. Autorzy przeprowadzają w niej krytyczną dekonstrukcję dotychczasowych splotowych sieci grafowych (takich jak NGCF), wykazując, że przeniesienie skomplikowanych mechanizmów z klasycznych zastosowań uczenia maszynowego — takich jak nieliniowe transformacje macierzowe $\mathbf{W}$ czy nieliniowa funkcja aktywacji (np. ReLU) — jest w filtracji kolaboracyjnej zbędne i utrudnia proces uczenia. Tradycyjne sieci GCN projektowano z myślą o grafach z bogatymi opisami cech (np. sieciach cytowań z tekstami artykułów), podczas gdy w rekomendacjach obiekty i użytkownicy opisani są wyłącznie unikalnymi identyfikatorami ID. Poprzez szczegółowe eksperymenty ablacyjne autorzy udowodnili, że odrzucenie wag macierzowych oraz nieliniowości eliminuje trudności optymalizacyjne, pozwalając sieci na znacznie szybszą zbieżność i lepszą generalizację. W zamian zaproponowali architekturę LightGCN, która opiera się wyłącznie na liniowej agregacji osadzeń bezpośrednich sąsiadów na dwudzielnym grafie interakcji użytkownik-obiekt, stosując jedynie symetryczną normalizację stopni

²⁸ X. He i in. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. W: (2020).

węzłów. Dodatkowo model zastępuje tradycyjne samopłączenia mechanizmem kombinacji warstw, który uśrednia reprezentacje uzyskane ze wszystkich poziomów propagacji — od zerowej warstwy identyfikatorów po wyższe poziomy połączeń wyższego rzędu. W przeprowadzonych eksperymentach na zbiorach Gowalla, Yelp2018 oraz Amazon-Book model LightGCN bezapelacyjnie pokonał dotychczasowe modele odniesienia — w tym klasyczną faktoryzację MF-BPR, głęboki perceptron NeuMF oraz bazowe sieci grafowe NGCF i GC-MC. Zastosowana uproszczona architektura pozwoliła na średni skok celności rekomendacji rankingowych o ponad 16,5% w metryce Recall@20 oraz o 16,9% w metryce NDCG@20 w porównaniu do pełnego modelu NGCF. Istotną obserwacją empiryczną było również zachowanie modelu przy głębszej propagacji: o ile w NGCF zwiększanie liczby warstw powyżej dwóch prowadziło do spadku celności z powodu trudności w zbieżności gradientowej, o tyle LightGCN pozwalał na stabilne wykorzystanie informacji z 3- i 4-stopniowego sąsiedztwa, stale poprawiając jakość rankingu. Ponadto całkowite odrzucenie operacji macierzowych przełożyło się na drastyczne obniżenie błędu treningowego oraz ponad dwukrotne skrócenie czasu uczenia pojedynczej epoki.

Współczesnym wyzwaniem w metodologii badań nad systemami rekomendacyjnymi stał się tzw. kryzys odtwarzalności. Znaczne rozproszenie środowisk programistycznych oraz brak standaryzowanych protokołów ewaluacji (np. stosowanie odmiennych wariantów próbkowania negatywnego czy ocenianie na ograniczonej próbie zamiast pełnego sortowania całego katalogu) powodowały, że publikowane w literaturze przewagi nowych modeli bywały trudne do obiektywnej weryfikacji. Odpowiedzią na ten problem stała się przełomowa praca Zhao i in.²⁹, wprowadzająca zunifikowany szkielet badawczy RecBole. Autorzy stworzyli otwartą bibliotekę w środowisku PyTorch, która integruje ponad 70 uznanych algorytmów rekomendacyjnych (od tradycyjnych metod kolaboratywnych po zaawansowane głębokie sieci neuronowe i architektury grafowe) na podstawie spójnego formatu plików atomowych oraz jednolite pętle optymalizacyjne i ewaluacyjne. Stosując zaawansowane procedury akceleracji GPU dla predykcji rankingowych, RecBole zdefiniował nowy standard metodologiczny w dziedzinie RecSys, umożliwiając przeprowadzenie w pełni sprawiedliwego, powtarzalnego i porównywalnego benchmarku modeli wywodzących się z różnych paradygmatów technologicznych. Wpisując się w ten nurt badawczy, w niniejszej pracy wykorzystano właśnie środowisko RecBole do przeprowadzenia autorskich eksperymentów. Pozwolą one na obiektywne zestawienie opisanych modeli klasycznych (BPR), głębokich (NCF) oraz grafowych (LightGCN) na rzeczywistych danych z domeny serwisów VOD.

²⁹ W. X. Zhao i in. „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”. W: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*. CIKM '21. New York, NY, USA: Association for Computing Machinery, 2021.

2.5. Kompromisy badawcze i wyzwania wdrożeniowe w serwisach streamingowych

Przeniesienie zaawansowanych koncepcji teoretycznych, omówionych w poprzednich podrozdziałach, do komercyjnego środowiska platform VOD wiąże się z koniecznością ciągłego balansowania między czystą dokładnością matematyczną a operacyjnymi uwarunkowaniami biznesowymi i technicznymi. Projektowanie takich systemów wymaga mierzenia się z kilkoma fundamentalnymi kompromisami.

2.5.1. Kompromis dokładności i różnorodności: wyzwanie „Długiego Ogona”

Pierwszym kluczowym wyzwaniem jest zjawisko asymetrii popularności katalogu treści, określane w literaturze jako krzywa długiego ogona (ang. *Long Tail*)³⁰. Większość interakcji użytkowników skupia się wokół wąskiej grupy najpopularniejszych hitów kinowych i serialowych, podczas gdy ogromna część katalogu platformy streamingowej generuje znikomą liczbę wyświetleń.

Klasyczne algorytmy oparte na filtrowaniu kolaboracyjnym wykazują silną tendencję do rekomendowania wyłącznie pozycji najpopularniejszych (ang. *popularity bias*). Zjawisko to prowadzi do efektu „bogaty, którzy stają się jeszcze bogatsi” (*rich-get-richer*)³¹. Choć faworyzowanie powszechnie znanych hitów gwarantuje modelowi wysokie wyniki w standardowych metrykach dokładności offline, z punktu widzenia biznesowego platformy jest to wysoce nieefektywne. Tworzy to tzw. bańki filtracyjne i ogranicza widoczność niszowych produkcji, uniemożliwiając pełną monetyzację nabytej bazy filmowej³². Wybór i parametryzacja modelu muszą więc stanowić świadomy kompromis między maksymalną dokładnością rankingową a zdolnością systemu do wspierania odkrywania nowych treści.

2.5.2. Problem zimnego startu w dynamicznych katalogach

W przeciwieństwie do tradycyjnego rynku e-commerce ze stałym asortymentem, środowisko platform strumieniowych charakteryzuje się ciągłą rotacją katalogu. Serwisy VOD regularnie nabywają nowe licencje i publikują własne, głośne premiery. Sytuacja ta rodzi krytyczny wdrożeniowy kompromis związany z tzw. problemem zimnego startu dla nowych obiektów.

Algorytmy kolaboracyjne, w tym zaawansowane architektury głębokie (NCF) oraz sieci grafowe (LightGCN), opierają się wyłącznie na macrycy historycznych interakcji. W

³⁰ O. Celma. *Music Recommendation and Discovery: The Long Tail, Long Tail, and Long Play in the Digital Music Space*. 2010.

³¹ Ibidem.

³² V. W. Anelli i in. *Top-N Recommendation Algorithms: A Quest for the State-of-the-Art*. 2022.

momencie premiery nowego filmu nie posiada on jeszcze żadnych ocen ani kliknięć – w strukturze grafu dwudzielnego staje się wyizolowanym węzłem bez krawędzi, przez co model nie jest w stanie wyliczyć dla niego wiarygodnego wektora cech (*embedding*)³³. Wdrożenie czystych architektur CF na produkcję skutkowałoby całkowitym ignorowaniem przez algorytm nowych (często najdroższych w produkcji) filmów. Wyzwaniem inżynierskim jest więc sztuczna aktywizacja nowości poprzez stosowanie architektur hybrydowych (włączających metadane reżysera czy gatunku) lub heurystyczne wymuszanie ekspozycji premier na ekranie głównym, dopóki nie zbiorą one masy krytycznej interakcji od widzów.

2.5.3. Wydajność obliczeniowa a wyzwanie czasu rzeczywistego

Z punktu widzenia inżynierii systemów oprogramowania, zaawansowane modele matematyczne podlegają rygorystycznym ograniczeniom wydajnościowym. Czas wygenerowania rekomendacji warunkuje czas odpowiedzi serwera i w warunkach komercyjnych nie powinien przekraczać ułamka sekundy (tzw. *latency* na poziomie pojedynczych milisekund), aby zachować bezstratną płynność działania aplikacji³⁴.

Złożoność strukturalna współczesnych modeli uczenia maszynowego rodzi tu poważne wyzwania wdrożeniowe:

- **Modele głębokie (NeuMF/NCF):** Charakteryzują się bardzo dużą liczbą parametrów treningowych ze względu na jednoczesne uczenie gęstych osadzeń dla warstw wielowarstwowego perceptronu (MLP) oraz uogólnionej faktoryzacji (GMF)³⁵. Choć faza inferencji dla pojedynczego zapytania może być silnie zoptymalizowana, to dynamiczne przeliczanie nieliniowych transformacji dla milionów kombinacji bywa wysoce kosztowne w czasie rzeczywistym.
- **Modele grafowe (LightGCN):** Paradoksalnie, pomimo rezygnacji z nieliniowych funkcji aktywacji oraz wag, sieci GNN cechują się potężnym kosztem operacyjnym ze względu na mechanizm wieloskokowej propagacji (agregacji) informacji po całym grafie dwudzielnym³⁶. Skompletowanie rekomendacji dla użytkownika wymaga pobrania cech z jego głębokiego sąsiedztwa (sieci powiązań), co stanowi potężne wąskie gardło wydajnościowe.

Rozwiązaniem tego problemu w architekturach przemysłowych jest najczęściej zastosowanie asynchronicznej dystrybucji obliczeń. Złożone algorytmy sztucznej inteligencji

³³ Ibidem.

³⁴ Malinowski, „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”.

³⁵ He i in., „Neural Collaborative Filtering”.

³⁶ He i in., „LightGCN”.

trenowane są okresowo w trybie wsadowym (*batch processing*) na gigantycznych klastrach danych, gdzie z wyprzedzeniem wyliczają statyczne wektory cech. Następnie gotowe parametry są propagowane do szybkich baz klucz-wartość w środowisku online, gdzie błyskawiczna warstwa heurystyczna odpowiada wyłącznie za ostateczne filtrowanie biznesowe (np. odrzucenie z rekomendacji filmów, na które wygasła licencja) i proste sortowanie gotowych wyników predykcji.

Opisane powyżej wyzwania, związane ze specyfiką platform VOD, problemem rzadkości macierzy ocen, zjawiskiem baniek filtracyjnych oraz narzutem obliczeniowym głębokich architektur, stanowią bezpośrednie uzasadnienie celu naukowego niniejszej pracy. Wymagają one empirycznego porównania i ewaluacji modeli o różnym stopniu skomplikowania: od klasycznego filtrowania kolaboracyjnego, poprzez architektury głębokiego uczenia, aż po grafowe sieci neuronowe. Badanie to ma na celu weryfikację skuteczności wybranych algorytmów na wysoce rozrzedzonych, rzeczywistych danych, reprezentatywnych dla współczesnej branży rozrywkowej. Cel ten został zrealizowany w kolejnych rozdziałach pracy, w których przedstawiono metodologię eksperymentu oraz analizę uzyskanych wyników.

3. Środowisko, dane i metodyka badań

W niniejszym rozdziale przedstawiono protokół badawczy oraz szczegółowy aparat matematyczny wykorzystanych algorytmów rekomendacyjnych. Omówiono również specyfikę środowiska wykonawczego, proces przygotowania i binaryzacji zbioru danych oraz zastosowaną procedurę walidacji i ewaluacji jakości proponowanych propozycji rankingowych.

3.1. Środowisko wykonawcze

W celu standaryzacji protokołu ewaluacji wyników i przygotowania danych oraz dla zapewnienia maksymalnej powtarzalności wykorzystywanych algorytmów eksperymenty badawcze zdecydowano przeprowadzić z wykorzystaniem zuniifikowanej biblioteki RecBole (wersja 1.1.1)³⁷. Biblioteka ta, oparta na frameworku PyTorch, stanowi współcześnie standard badawczy w dziedzinie systemów rekomendacyjnych, łącząc w ramach jednolitej architektury modułowej cztery kluczowe komponenty: moduł konfiguracji, moduł danych, interfejsy modeli oraz zoptymalizowany moduł ewaluacji.

Sposób funkcjonowania ramki RecBole opiera się na ściśle zdematerializowanej i zorientowanej na obliczenia GPU architekturze potokowej (ang. *pipeline architecture*). Przepływ danych i wykonanie eksperymentu wewnątrz biblioteki realizowane jest w następujących etapach:

1. Moduł Konfiguracji (*Configuration Module*): Odpowiada za scalanie ustawień eksperymentalnych z hierarchicznie nakładanych źródeł: plików konfiguracyjnych YAML, parametrów przekazywanych z wiersza poleceń oraz bezpośrednich słowników języka Python. Moduł ten kontroluje rozmiar batcha, stopę uczenia, użyty optymalizator (np. Adam, SGD) oraz szczegółowe parametry poszczególnych modeli.
2. Moduł Danych i Struktura Interaction (*Data Module*): Surowe zbiory danych przekształcane są w uniwersalny format tzw. plików atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter` (zawierających relacje użytkownik-obiekt) oraz opcjonalnie `.user`, `.item` czy `.kg` (dla metadanych i grafów wiedzy). Wewnątrz środowiska dane są reprezentowane przez wyspecjalizowany obiekt `Interaction`, będący opakowaniem na słownik tensorów PyTorch (`torch.Tensor`). Zapewnia to bezpośrednie i bezkosztowe przenoszenie całych pakietów danych do pamięci VRAM karty graficznej (`.to(device)`), eliminując wąskie gardła transferu pamięci RAM-VRAM.

³⁷ Zhao i in., dz. cyt.

3. Moduł Modelu (*Model Module*): Wszystkie zaimplementowane algorytmy dziedziczą po zunifikowanych klasach bazowych (np. GeneralRecommender dla modeli filtracji kolaboracyjnej oraz KnowledgeRecommender dla modeli z grafami wiedzy). Wymaga to od każdego algorytmu zdefiniowania dwóch zunifikowanych interfejsów:

- `calculate_loss(interaction)` – wyliczanie wartości funkcji straty (np. BPR Loss lub Binary Cross-Entropy) w fazie propagacji wprzód podczas uczenia,
- `predict(interaction) / full_sort_predict(interaction)` – wyznaczanie punktacji relewancji (*scores*) dla par użytkownik-obiekt w fazie predykcji.

4. Moduł Wykonania i Akceleracji Ewaluacji (*Execution & Evaluation Module*): Pętla uczenia zarządzana jest przez obiekt Trainer, odpowiadający za automatyczny zapis punktów kontrolnych (*checkpoints*), wczesne zatrzymanie (*early stopping*) oraz optymalizację hiperparametrów.

Środowisko uruchomieniowe przygotowano na podstawie systemu operacyjnego Windows 11 oraz interpretera języka Python (wersja 3.12) działającego w odizolowanym środowisku wirtualnym. Wszystkie parametry modeli oraz ustawienia eksperymentalne zostały natomiast zdefiniowane w postaci deklaratywnych plików konfiguracji YAML. Rozwiązanie to gwarantuje pełną separację logiki eksperymentalnej od kodu źródłowego, ułatwiając rekonfigurowalność hiperparametrów, kontrolę wersji eksperymentów oraz bezproblemową powtarzalność uzyskanych wyników. Zastosowanie jednolitej ramki RecBole eliminuje ponadto tzw. błędy niespójności implementacyjnej (ang. *reproducibility crisis*), gwarantując, że obserwowane różnice w wynikach wynikają wyłącznie z właściwości samych algorytmów.

3.2. Opis i przygotowanie danych

W części empirycznej niniejszej pracy do ewaluacji modeli rekomendacyjnych wykorzystano zbiór danych MovieLens 100K, udostępniany przez grupę badawczą GroupLens Research z Uniwersytetu Minnesoty w 1998 rok. Proces zbierania danych odbył się poprzez stronę internetową, działającą jako spersonalizowany system rekomendacyjny. Internauci na początku byli zobowiązani do założenia konta i uzupełnienia podstawowych informacji osobowych. Następnie mogli oceniać filmy w skali od 1 do 5. System rozwijał i ewoluował na przestrzeni lat poprzez dodawanie kolejnych funkcjonalności takich jak dodatkowe tagi czy słowa kluczowe opisujące wrażenia po obejrzeniu danego tytułu.

Dane ze zbioru MovieLens 100k były kolekcjonowane między 19 września 1997 roku

a 22 kwietnia 1998 roku³⁸. Autorzy przed opublikowaniem danych oczyścili je jeszcze z rekordów niosących stosunkowo małą wartość informacyjną tj. użytkownicy, którzy ocenili mniej niż 20 filmów lub nie wprowadzili pełnych informacji demograficznych, zostali usunięci.

Wybór tego zbioru podyktowany jest jego powszechnym uznaniem w literaturze przedmiotu jako kanonicznego benchmarku w dziedzinie systemów rekomendacyjnych³⁹. Należy zaznaczyć, że zastosowanie mniejszego wariantu (wobec alternatywnych zbiorów o rozmiarach rzędu 1M czy 25M, udostępnianych przez grupę GroupLens) nie obniża wartości naukowej prowadzonych eksperymentów, co znajduje potwierdzenie w dotychczasowych badaniach⁴⁰. Istotnym czynnikiem determinującym ten wybór jest również problem optymalizacji hiperparametrów oraz związane z nim zapotrzebowanie na moc obliczeniową. Jak podkreślają autorzy publikacji⁴¹, współczesne algorytmy rekomendacyjne charakteryzują się znaczną złożonością, przez co proces poszukiwania optymalnych parametrów ulega drastycznemu wydłużeniu. Stanowi to silny argument za wykorzystaniem mniejszych zbiorów danych, w szczególności w obliczu ograniczonych zasobów sprzętowych i braku dostępu do zaawansowanej infrastruktury obliczeniowej.

Przestrzeń badawczą definiuje trójka uporządkowana obejmująca:

- zbiór wszystkich zarejestrowanych użytkowników, oznaczany symbolem $\mathcal{U}$ (gdzie $M = |\mathcal{U}|$ stanowi łączną liczbę użytkowników),
- zbiór wszystkich dostępnych w katalogu obiektów (filmów), oznaczany symbolem $\mathcal{I}$ (gdzie $N = |\mathcal{I}|$ stanowi łączną liczbę obiektów),
- zbiór zaobserwowanych historycznych interakcji, oznaczany symbolem $\mathcal{E}$ ($\mathcal{E} \subseteq \mathcal{U} \times \mathcal{I}$), reprezentujący zaobserwowane zdarzenia o liczebności $|\mathcal{E}|$.

W analizowanym zbiorze dane te przyjmują wartości: $M = 943$, $N = 1\,682$ oraz $|\mathcal{E}| = 100\,000$. Dokładne ustalenie wymiarów M i N jest kluczowe z punktu widzenia uczenia maszynowego, gdyż determinują one bezpośrednio rozmiary wejściowych słowników dla warstw osadzeń (*embedding layers*) w architekturach neuronowych i grafowych⁴². W

³⁸ M. Bałchanowski. „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”. Rozprawa doktorska. 2023, s. 62.

³⁹ F. M. Harper i J. A. Konstan. The MovieLens Datasets: History and Context. W: „ACM Transactions on Interactive Intelligent Systems” 5.Nr 4 (2016); He i in., „Neural Collaborative Filtering”; Zhao i in., dz. cyt.

⁴⁰ Z. Sun i in. „Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison”. W: *Proceedings of the 14th ACM Conference on Recommender Systems*. RecSys '20. New York, NY, USA: Association for Computing Machinery, 2020, s. 23–32.

⁴¹ Anelli i in., dz. cyt., s. 4.

⁴² Zhang i in., dz. cyt., s. sekcje 2.1, 3.2 oraz 3.4.

klasycznym ujęciu rzadkie wektory identyfikatorów użytkowników $\mathbf{v}_u \in \{0, 1\}^M$ (typu *one-hot*) oraz obiektów $\mathbf{v}_i \in \{0, 1\}^N$ są mapowane na gęste reprezentacje wektorowe $\mathbf{p}_u \in \mathbb{R}^k$ i $\mathbf{q}_i \in \mathbb{R}^k$ (gdzie $k \ll \min(M, N)$) poprzez mnożenie przez macierze wag osadzeń odpowiednio $\mathbf{P} \in \mathbb{R}^{M \times k}$ oraz $\mathbf{Q} \in \mathbb{R}^{N \times k}$.

Tradycyjny model danych rekomendacyjnych reprezentuje się jako dwuwymiarową macierz interakcji $\mathbf{R} \in \mathbb{R}^{M \times N}$, w której wiersze odpowiadają poszczególnym użytkownikom ($u \in \mathcal{U}$), a kolumny poszczególnym obiektom ($i \in \mathcal{I}$)⁴³. Stopień braku wypełnienia tej struktury opisuje wskaźnik rzadkości (*sparsity rate*), oznaczany symbolem $S \in [0, 1]$. Definiuje się go jako dopełnienie stosunku liczby faktycznie zaobserwowanych interakcji do teoretycznej maksymalnej liczby wszystkich możliwych powiązań w macierzy:

$$S = 1 - \frac{|\mathcal{E}|}{M \times N} \quad (4)$$

Dla wybranego zbioru danych stopień rzadkości wynosi $S = 93,70\%$, co oznacza, że jedynie 6,30% komórek macierzy zawiera zaobserwowane wpisy. W środowisku VOD skrajna rzadkość jest zjawiskiem naturalnym — pojedynczy widz jest w stanie zapoznać się jedynie z ułamkiem procenta całkowitej oferty platformy⁴⁴. Skrajnie wysoki wskaźnik rzadkości stanowi podstawowe uzasadnienie metodologiczne dla odrzucenia prostych algorytmów pamięciowych (k -NN), które zmagają się z problemem braku wspólnych sąsiadów, na rzecz metod czynników ukrytych (SVD)⁴⁵ oraz propagacji osadzeń w sieciach grafowych⁴⁶.

Interakcje na platformach streamingowych podlegają silnej asymetrii popytu opisanej rozkładem potęgowym (*Power Law*)⁴⁷. Charakterystyczną cechą tej asymetrii w systemach dystrybucji cyfrowej jest fakt, że skrajnie nieliczna, uprzywilejowana grupa najpopularniejszych pozycji skupia wokół siebie zdecydowaną większość całej aktywności w systemie, podczas gdy olbrzymia większość pozostałych obiektów odnotowuje znikome zainteresowanie ze strony odbiorców⁴⁸. Badana przestrzeń danych jednoznacznie wykazuje zjawisko tzw. długiego ogona (*Long-Tail Distribution*), zaprezentowane na Rysunku 2.

Katalog filmowy dzieli się na dwie wyraźne strefy⁴⁹:

- **Głowę popytu (*Head*):** wąską grupę najpopularniejszych produkcji kinowych (tzw. hitów), które skupiają przeważającą część całkowitej liczby ocen w systemie. Tradycyjnie to ta część oferty była faworyzowana w erze analogowej ze względu na

⁴³ Su i Khoshgoftaar, dz. cyt., s. 2.

⁴⁴ Chęciński i Wawrzusiak, dz. cyt., s. 19, 23.


⁴⁵ Su i Khoshgoftaar, dz. cyt.; Y. Koren, R. Bell i C. Volinsky. *Matrix Factorization Techniques for Recommender Systems*. W: „Computer” 42 (2009), s. 2, 3.

⁴⁶ Zhang i in., dz. cyt., s. sekcja 3.4.

⁴⁷ Celma, dz. cyt., s. 14–15, 105.

⁴⁸ Ibidem, s. 93.

⁴⁹ Ibidem, s. 100.



Rysunek 2: Rozkład popularności filmów w zbiorze MovieLens 100K przedstawiający zjawisko długiego ogona (*Long-Tail Distribution*).

Źródło: opracowanie własne.

ograniczenia fizycznej przestrzeni sklepowej i wysokie koszty dystrybucji, które wymuszały na dystrybutorach selekcję wyłącznie pozycji o masowej popularności⁵⁰.

- **Długi ogon (*Tail*):** obszerną listę niszowych, mniej znanych lub starszych tytułów o niskiej częstotliwości odtworzeń. W dobie cyfrowej, po wyeliminowaniu fizycznych ograniczeń magazynowych i półkowych, cała ta niszowa oferta może pozostawać stale dostępna dla użytkowników, tworząc ogromną sumę małych rynków o bardzo wysokim potencjale zaspokajania specyficznych i zróżnicowanych gustów⁵¹.

Z biznesowego i funkcjonalnego punktu widzenia spersonalizowany system rekomendacyjny na rynku VOD musi potrafić trafnie proponować pozycje z długiego ogona, zapobiegając zjawisku monopolizacji uwagi widza wyłącznie przez najpopularniejsze hity⁵². W dobie tzw. cyfrowej klęski urodzaju, gdy platformy streamingowe oferują tysiące filmów i seriali, użytkownicy stają w obliczu przeładowania informacyjnego, w którym samodzielne dotarcie do interesujących pozycji staje się wysoce utrudnione, a zapoznanie się z pełną ofertą katalogową jest fizycznie niemożliwe⁵³. Brak skutecznego mechanizmu personalizacji sprawia, że uwaga użytkowników koncentruje się wyłącznie na tytułach najgłośniejszych i powszechnie promowanych, co prowadzi do marnowania potencjału niszowej części biblioteki serwisu⁵⁴. Wdrożenie algorytmów zdolnych do eksploracji dłu-

⁵⁰ Ibidem, s. 14–15, 100.

⁵¹ Ibidem, s. 100.

⁵² Chęciński i Wawrzusiak, dz. cyt., s. 23.


⁵³ Ibidem, s. 19.

⁵⁴ Ibidem, s. 19.

giego ogona i kierowania uwagi widzów z obszaru głowy popytu ku pozycjom niszowym pozwala na pełniejsze wykorzystanie zasobów, zwiększa satysfakcję i lojalność odbiorców oraz maksymalizuje zaangażowanie w korzystanie z platformy⁵⁵.

Oryginalny zbiór MovieLens zawiera oceny jawne (*explicit feedback*) wyrażone w 5-stopniowej skali dyskretnej (od 1 do 5 gwiazdek). Choć oceny te dostarczają bardzo precyzyjnej i jednoznacznej informacji o stopniu satysfakcji użytkownika, w rzeczywistych systemach rekomendacyjnych współczesnych platform wideo występują one niezwykle rzadko. Wynika to z faktu, że czynność ta nakłada na odbiorcę dodatkowe obciążenie poznawcze i wymaga intencjonalnego działania po seansie, co zakłóca naturalną, bezwysiłkową konsumpcję treści — większość widzów chce po prostu oglądać kolejne materiały, a nie dokonywać ich ewaluacji⁵⁶.

W konsekwencji głównym źródłem informacji dla algorytmów stają się ślady cyfrowe i interakcje dorozumiane (*implicit feedback*), takie jak odtworzenie filmu, czas jego oglądania, kliknięcie w miniaturę czy historia wyszukiwania⁵⁷. Dane te są gromadzone przez platformy całkowicie pasywnie, bez wysiłku ze strony widza, co pozwala na budowę znacznie większych i bardziej aktualnych zbiorów uczących, choć są one trudniejsze w interpretacji z uwagi na brak bezpośredniej deklaracji zadowolenia⁵⁸. Rozkład ocen jawnych w analizowanym zbiorze zaprezentowano na Rysunku 3.



Rysunek 3: Rozkład ocen jawnych w zbiorze MovieLens 100K obrazujący efekt zjawiska *positivity bias*

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 100K.

⁵⁵ Celma, dz. cyt.; Chęciński i Wawrzusiak, dz. cyt., s. 14–15, 23.

⁵⁶ Rendle i in., dz. cyt., s. 452.

⁵⁷ Su i Khoshgoftaar, dz. cyt.; Chęciński i Wawrzusiak, dz. cyt., s. 2.

⁵⁸ Rendle i in., dz. cyt., s. 452–453.

Analiza histogramu wykazuje silne skrzywienie pozytywne (*positivity bias*) – użytkownicy znacznie chętniej oceniają filmy, które im się podobały, podczas gdy produkcje ocenione negatywnie są w logach niemal nieobecne (oceny 3, 4 i 5 stanowią ponad 80% wszystkich wpisów). Zjawisko to jest bezpośrednią konsekwencją błędu selekcji; widzowie intuicyjnie wybierają do obejrzenia te tytuły, wobec których żywią już uprzednie pozytywne oczekiwania (np. ze względu na ulubiony gatunek czy obsadę), co wtórnie drastycznie ogranicza szansę na wystawienie niskiej noty⁵⁹. W rezultacie obserwowany zbiór ocen jawnych nie odzwierciedla reprezentatywnego profilu gustu użytkownika wobec całego katalogu, a jedynie wobec jego wyselekcjonowanego ułamka⁶⁰.

Zgodnie z metodologią zaproponowaną przez He i in.⁶¹, w celu dostosowania danych do realiów platform streamingowych dokonuje się przekształcenia binarnego oryginalnej macierzy ocen w macierz interakcji dorozumianych, oznaczaną jako $\mathbf{Y} \in \mathbb{R}^{M \times N}$ (gdzie $M = |\mathcal{U}|$ oznacza liczbę użytkowników, a $N = |\mathcal{I}|$ liczbę filmów). Zabieg ten pozwala na przekształcenie subiektywnego problemu regresji ocen w zadanie klasyfikacji binarnej (rekomendacji góry listy), co znacznie lepiej oddaje rzeczywiste zachowanie i procesy decyzyjne użytkowników w serwisach OTT, gdzie kluczowym wyborem jest decyzja o kliknięciu i rozpoczęciu odtwarzania danego tytułu⁶².

Przed przedstawieniem reguły dyskryminacyjnej zdefiniujmy elementy składowe wzoru:

- y_{ui} — wartość wskaźnikowa określająca obecność zaobserwowanej relacji pomiędzy użytkownikiem $u \in \mathcal{U}$ a obiektem $i \in \mathcal{I}$,
- $y_{ui} = 1$ — stan dodatni, oznaczający zarejestrowanie interakcji (np. wystawienie jakiegokolwiek oceny lub obejrzenie filmu),
- $y_{ui} = 0$ — stan nieobserwowany, oznaczający brak zarejestrowanej akcji w logach systemowych.

Sformułowanie matematyczne funkcji binarnej przyjmuje postać:

$$y_{ui} = \begin{cases} 1, & \text{jeśli zaobserwowano interakcję (użytkownik } u \text{ ocenił/obejrzał film } i) \\ 0, & \text{w przeciwnym razie (brak obserwacji)} \end{cases} \quad (5)$$

Warto podkreślić, że wartość $y_{ui} = 0$ ma charakter wysoce niejednoznaczny semantycznie. Nie oznacza ona bowiem jawnej niechęci użytkownika do danego tytułu, lecz

⁵⁹ Celma, dz. cyt., s. 28.

⁶⁰ Ibidem, s. 28.

⁶¹ He i in., dz. cyt., s. 7.

⁶² Ibidem, s. 7.

jedynie brak wiedzy o wchodzeniu w interakcję⁶³. Użytkownik mógł nie obejrzeć filmu z powodów zupełnie niezależnych od jego gustu: mógł go nie zauważyć w katalogu, nie zostać na niego wyeksponowany przez interfejs platformy, bądź po prostu jeszcze na niego nie trafić⁶⁴. Struktura ta stanowi fundamentalne wyzwanie w uczeniu maszynowym, gdyż zbiór danych nieobserwowanych ($y_{ui} = 0$) de facto reprezentuje jednocześnie rzeczywiste negatywne preferencje (użytkownik zna film, ale nie chce go obejrzeć), jak i potencjalne przyszłe interakcje dodatnie (użytkownik chętnie obejrzałby film, gdyby tylko dowiedział się o jego istnieniu), które model powinien poprawnie zidentyfikować i wybić na górę listy rekomendacji⁶⁵.

Rozkład aktywności użytkowników wykazuje duże zróżnicowanie – od profili okazjonalnych po użytkowników o skrajnie wysokiej liczbie obejrzanych pozycji (rozkład liczby ocen przypadających na pojedynczego użytkownika zaprezentowano na Rysunku 4). Chociaż natywny zbiór MovieLens gwarantuje, że każdy użytkownik posiada co najmniej 20 zarejestrowanych interakcji, warunek ten nie dotyczy katalogu filmów. Wiele niszowych pozycji posiada zaledwie pojedyncze oceny, co w architekturach uczenia głębokiego uniemożliwia prawidłową aktualizację wag. Z tego względu zastosowano rygorystyczną procedurę filtrowania typu *k-core* ($k = 5$)⁶⁶. Usunięto z katalogu wszystkie filmy posiadające mniej niż 5 zarejestrowanych interakcji (co kaskadowo mogło odrzucić również ułamek profili użytkowników). Operacja ta zapobiega występowaniu trywialnych wektorów zerowych w warstwach osadzeń (ang. *embeddings*) oraz stabilizuje proces wyznaczania znormalizowanej macierzy sąsiedztwa grafu dwudzielnego w modelach opartych na grafowych sieciach neuronowych (GNN)⁶⁷.


⁶³ Ibidem, s. 2.

⁶⁴ Tenże, „Neural Collaborative Filtering”; Rendle i in., dz. cyt., s. 2.

⁶⁵ Tenże, „BPR”, s. 453.

⁶⁶ He i in., dz. cyt., s. 7, sekcja 4.1.1.

⁶⁷ Zhao i in., dz. cyt., s. 6, sekcja 2.1.1.



Rysunek 4: Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 100K

Źródło: opracowanie własne na podstawie danych z zestawu MovieLens 100K.

W celu zapewnienia ścisłej reprodukowalności eksperymentów i eliminacji błędów implementacyjnych oczyszczone zbiory danych przekonwertowano do formatu Plików Atomowych (ang. *Atomic Files*) z rozszerzeniem `.inter`, stanowiącego standard wejściowy biblioteki RecBole⁶⁸. Plik `.inter` przechowuje relacje w strukturze tabularycznej ze zdefiniowanymi typami pól⁶⁹:

- `user_id:token` – unikalny identyfikator użytkownika (sekwencja dyskretna),
- `item_id:token` – unikalny identyfikator filmu (sekwencja dyskretna),
- `rating:float` – oryginalna ocena użytkownika (wykorzystywana pomocniczo),
- `timestamp:float` – znacznik czasu interakcji.

Ewaluację modeli przeprowadzono w oparciu o proporcjonalny losowy podział danych (*Ratio Splitting*) w stosunku 80% : 10% : 10% (odpowiednio: zbiór treningowy, walidacyjny i testowy), co stanowi standardowy protokół podziału danych typu *ratio-based splitting* obsługiwany przez bibliotekę RecBole⁷⁰.

Do trenowania modeli punktowych i parowych (Log Loss w NCF oraz BPR Loss w SVD/LightGCN) zastosowano procedurę próbkowania negatywnego (*negative sampling*). Dla każdej dodatniej pary $(u, i) \in \mathcal{E}$ losowano jednostajnie ze zbioru pozycji nieobserwowanych zestaw próbek negatywnych $(u, j) \in \mathcal{E}^-$ (gdzie $y_{uj} = 0$), przy zachowaniu stosunku

⁶⁸ Ibidem, s. 6, sekcja 2.1.2.

⁶⁹ Ibidem, s. 6, Tabela 3.

⁷⁰ Ibidem, s. 6, sekcja 2.1.1 oraz s. 7, sekcja 2.3.4.

1 : 4 (4 próbki negatywne na 1 pozycję dodatnią), co stanowi optymalny kompromis między stabilnością gradientu a czasem obliczeń⁷¹. Zastosowanie elastycznej liczby próbek negatywnych (w optymalnym przedziale od 3 do 6) pozwala modelom optymalizowanym punktową stratą logarytmicznej na znaczące przełamanie ograniczeń klasycznych strat parowych typu BPR, które z natury parują wyłącznie jedną próbkę negatywną z dodatnią⁷².

Tabela 1 przedstawia zbiorcze zestawienie parametrów statystycznych przygotowanego zbioru danych MovieLens 100K po przeprowadzeniu potoku przetwarzania.

Tabela 1: Podsumowanie statystyczne zbioru danych MovieLens 100K wykorzystanego w eksperymentach

Parametr statystyczny	Wartość dla zbioru MovieLens 100K (m1–100k)
Liczba użytkowników ($ \mathcal{U} $)	943
Liczba filmów ($ \mathcal{I} $)	1 682
Liczba interakcji ($ \mathcal{E} $)	100 000
Średnia liczba ocen na użytkownika	106,04
Gęstość macierzy (<i>Density</i>)	6,30%
Rzadkość macierzy (<i>Sparsity</i>)	93,70%
Typ informacji zwrotnej	Interakcje dorozumiane (<i>Implicit Feedback</i>)

Źródło: opracowanie własne.

3.3. Filtrowanie kolaboracyjne

Filtrowanie kolaboracyjne stanowi jeden z najważniejszych i najbardziej ugruntowanych paradygmatów w dziedzinie systemów rekomendacyjnych⁷³. Jego podstawowym założeniem jest hipoteza, że użytkownicy o zbliżonych wzorcach zachowań w przeszłości będą przejawiać podobne preferencje w przyszłości. W przeciwieństwie do metod opartych na treści, filtrowanie kolaboracyjne nie wymaga analizy semantycznej obiektów ani dostępu do ich szczegółowych metadanych, opierając proces wnioskowania wyłącznie na macierzy interakcji użytkownik-obiekt $R \in \mathbb{R}^{M \times N}$, gdzie M oznacza liczbę użytkowników, natomiast N liczbę filmów w katalogu platformy.

Techniki filtrowania kolaboracyjnego dzielą się na trzy główne nurty: metody oparte na pamięci (ang. *memory-based CF*), metody oparte na modelach (ang. *model-based CF*) oraz systemy hybrydowe. Pierwsza z wymienionych grup polega na bezpośrednim wykorzystaniu historycznych interakcji do poszukiwania podobieństw i działa w dwóch podstawowych wariantach. Z jednej strony wyróżnia się podejście zorientowane na użytkownika (ang.

⁷¹ He i in., dz. cyt., s. 7, sekcja 4.1.2.

⁷² Ibidem, s. 8, sekcja 4.3.

⁷³ Su i Khoshgoftaar, dz. cyt.; Koren, Bell i Volinsky, dz. cyt.; Krawczuk, dz. cyt.

User-Based CF), które opiera się na poszukiwaniu profili o gustach historycznie zbliżonych do aktywnego odbiorcy. Z drugiej strony stosuje się podejście zorientowane na obiekty (ang. *Item-Based CF*), w którym oblicza się analityczne podobieństwo pomiędzy samymi pozycjami w katalogu na podstawie tego, czy wchodziła z nimi w interakcję ta sama grupa odbiorców. W przypadku serwisów VOD znacznie powszechniej wykorzystuje się podejście oparte na obiektach. Wynika to z faktu, że zbiór filmów tworzy strukturę znacznie bardziej stabilną w czasie – charakterystyki ich grup docelowych rzadko ulegają zmianie, podczas gdy gusta użytkowników są zmienne, a ich całkowita liczba nieustannie fluktuuje.

Ogromnym krokiem naprzód w ewolucji systemów rekomendacyjnych okazało się odejście od surowej pamięci na rzecz wprowadzania uczących się metod analitycznych (nurt oparty na modelach), a dokładniej modeli czynników ukrytych (ang. *latent factor models*), realizowanych za pomocą technik faktoryzacji macierzy. Idea faktoryzacji polega na odwzorowaniu zarówno użytkowników u , jak i obiektów i we wspólnej, k -wymiarowej przestrzeni ukrytej $\mathbb{R}^k$, gdzie $k \ll \min(M, N)$ oznacza wyznaczoną liczbę wymiarów ukrytych. W architekturze tej preferencje pojedynczego użytkownika reprezentowane są przez wektor $\mathbf{p}_u \in \mathbb{R}^k$, natomiast właściwości samego filmu oddaje wektor $\mathbf{q}_i \in \mathbb{R}^k$. Stopień potencjalnego dopasowania danego tytułu do gustu widza obliczany jest na podstawie klasycznej operacji iloczynu skalarnego wyznaczonych wektorów.

W niniejszej pracy jako wiodących reprezentantów tradycyjnego filtrowania kolaboracyjnego wybrano dwa algorytmy odniesienia (tzw. *baseline*), z których każdy reprezentuje całkowicie odmienne podejście analityczne: ItemKNN (stanowiący klasyczną metodę opartą na obiektowej pamięci) oraz BPR-MF, będący fundamentalnym przykładem wariantu opartego na uczeniu parametrów przy użyciu faktoryzacji macierzy z optymalizacją porządkową.

3.3.1. Algorytm ItemKNN

Jedną z najpopularniejszych i najbardziej uznanych metod bazujących na pamięci jest technika oparta na analizie podobieństwa obiektów (ang. *Item-Based Collaborative Filtering*), powszechnie implementowana jako algorytm ItemKNN. Geneza tej metody, wprowadzona i spopularyzowana na przełomie wieków w systemach e-commerce przez B. Sarwara i in.⁷⁴, opiera się na intuicyjnym założeniu, że z większym prawdopodobieństwem będziemy preferować te filmy, które są w dużym stopniu powiązane z produkcjami pozytywnie ocenionymi przez nas w przeszłości. Matematyczne podstawy algorytmu ItemKNN

⁷⁴ B. Sarwar i in. *Item-Based Collaborative Filtering Recommendation Algorithms*. W: „Proceedings of ACM World Wide Web Conference” 1 (2001).

oraz koncepcja budowania sąsiedztwa, przedstawione w niniejszym podrozdziale, opierają się w głównej mierze na metodologii syntetyzowanej w pracy Bałchanowskiego⁷⁵.

W przeciwieństwie do metod zorientowanych na użytkownika (*User-Based CF*), ItemKNN wyszukuje podobieństwa na poziomie kolumn macierzy interakcji (filmów). Ogranicza to znacząco problemy wynikające ze zmienności gustów ludzkich oraz nieustannego rotowania bazy aktywnych kont. Z biznesowego punktu widzenia na platformach VOD liczba filmów rośnie wolniej niż liczba nowych subskrybentów, co stabilizuje proces obliczania sąsiedztwa i zwiększa jakość rekomendacji w ujęciu długoterminowym.

Procedura generowania rekomendacji przy użyciu algorytmu ItemKNN przedstawia się następująco:

1. W pierwszej kolejności, dla każdego z analizowanych elementów, system precyzyjnie ustala sąsiedztwo. Proces ten rozpoczyna się od wyliczenia funkcji podobieństwa $s(i, j)$ pomiędzy dowolnymi dwoma filmami i oraz j z katalogu $\mathcal{I}$. Ze względu na to, że badana w niniejszej pracy przestrzeń danych opiera się na interakcjach dorozumianych (*implicit feedback*), klasyczne miary uwzględniające średnie wariancje ocen (np. korelacja Pearsona) nie znajdują tu matematycznego zastosowania. Standardową techniką służącą do pomiaru bliskości w środowisku binarnym jest odległość kosinusowa (ang. *Cosine Similarity*), operująca w przestrzeni wektorowej. Stopień powiązania dwóch filmów wyznacza się za jej pomocą ze wzoru⁷⁶:

$$s(i, j) = \frac{\mathbf{y}_i \cdot \mathbf{y}_j}{\|\mathbf{y}_i\|_2 \|\mathbf{y}_j\|_2} = \frac{\sum_u y_{ui} y_{uj}}{\sqrt{\sum_u y_{ui}^2} \sqrt{\sum_u y_{uj}^2}} \quad (6)$$

Gdzie:

- $\mathbf{y}_i, \mathbf{y}_j$ – wektory binarne reprezentujące historię interakcji wszystkich użytkowników dla filmów i oraz j
 - y_{ui}, y_{uj} – obserwacje obecności interakcji (0 lub 1) dla użytkownika u z oboma filmami
 - $\|\mathbf{y}_i\|_2, \|\mathbf{y}_j\|_2$ – normy Euklidesowe (L2) badanych wektorów
2. Ponieważ obliczanie relacji dla każdej możliwej pary obiektów w skali milionów widzów wiąże się ze zjawiskiem ogromnego szumu informacyjnego, algorytm dokonuje redukcji macierzy podobieństw. Dla każdego filmu i zawęża się grono powiązań wyłącznie do zamkniętego zbioru K najbardziej zbliżonych filmów (tzw. zbiór najbliższych sąsiadów $\mathcal{N}_i$).

⁷⁵ Bałchanowski, dz. cyt., s. 16-17.

⁷⁶ Ibidem, s. 16.

3. W etapie predykcji, po zalogowaniu się użytkownika u , algorytm odczytuje zbiór wszystkich filmów, które ten użytkownik zdążył już obejrzeć (tzw. wejściowy profil użytkownika $\mathcal{I}_u^+$).
4. Ostateczny krok działania algorytmu polega na wyliczeniu estymowanego stopnia dopasowania $\hat{x}_{ui}$, jakim użytkownik u obdarzy dowolny, nieobejrzany jeszcze film i . Predykcję realizuje się poprzez obliczenie średniej ważonej z miar podobieństwa pomiędzy tym filmem i , a obejrzanymi już przez widza produkcjami j , które znalazły się w jego ograniczonym sąsiedztwie⁷⁷:

$$\hat{x}_{ui} = \frac{\sum_j s(i, j) y_{uj}}{\sum_j |s(i, j)|}, \quad j \in \mathcal{N}_i \cap \mathcal{I}_u^+ \quad (7)$$

Gdzie:

- $\mathcal{N}_i$ – wyznaczony w etapie 2 statyczny zbiór zawierający K filmów najbliższych spokrewnionych z obiektem i
- $\mathcal{I}_u^+$ – zbiór wszystkich filmów, które użytkownik u już obejrzał
- y_{uj} – wystąpienie pozytywnej relacji pomiędzy użytkownikiem a sąsiadem badanego obiektu

Model ItemKNN, ze względu na swoją wysoką skuteczność w systemach pozbawionych zaawansowanych mechanizmów uczących oraz wysoką wyjaśnialność (wyniki można wprost zinterpretować w interfejsie jako klauzulę "Z uwagi na to, że obejrzałeś X, polecamy Ci Y"), na stałe wszedł do kanonu filtrowania kolaboracyjnego. W nowoczesnych zestawieniach naukowych odgrywa on rolę punktu odniesienia (*baseline*), służącego do weryfikacji celowości wdrażania cięższych obliczeniowo metod rekomendacji.

3.3.2. Spersonalizowany ranking bayesowski

Spersonalizowany ranking bayesowski (ang. *Bayesian Personalized Ranking, BPR*) jest to technika generująca rekomendacje na podstawie macierzy interakcji. Charakterystycznym elementem tego algorytmu jest sposób, w jaki traktuje sytuacje, w których użytkownik nie wszedł w interakcję z danym przedmiotem. Tradycyjnie brak interakcji jest traktowany w macierzy jako wartość 0, co interpretowane jest jako negatywna informacja zwrotna. Taki stan rzeczy może nieprecyzyjnie oddawać rzeczywistość. Filmami nieobejrzanymi mogą być zarówno te, które są dla użytkownika nieinteresujące, jak i te, których po prostu nie zna, bądź nie zdążył jeszcze obejrzeć.

⁷⁷ Ibidem, s. 16.

Aby rozwiązać ten problem, algorytm BPR rezygnuje z klasycznego, punktowego podejścia do uczenia modelu (gdzie system estymuje konkretną wartość liczbową dla pary użytkownik-obiekt) na rzecz podejścia opartego na parach (ang. *pairwise learning*). Podstawowym założeniem metody jest to, że użytkownik zawsze preferuje obiekty, z którymi wszedł w interakcję, nad tymi, z którymi interakcji nie podjął. Jeżeli zdefiniujemy obiekty znane użytkownikowi u jako pozytywne (oznaczane jako i), a pozostałe pozycje w katalogu jako negatywne (j), BPR zakłada relację wyższości $i >_u j$ na liście rankingowej⁷⁸.

W trakcie treningu optymalizator nie rozpatruje indywidualnych obiektów, lecz przetwarza trójki uczące w postaci (u, i, j) . Celem algorytmu jest maksymalizacja prawdopodobieństwa, że estymowana ocena trafności filmu pozytywnego będzie zawsze przewyższać estymowaną ocenę filmu negatywnego. Podejście to prowadzi do sformułowania kryterium optymalizacyjnego BPR-OPT, które w oparciu o funkcję logistyczną minimalizuje stratę dla wszystkich trójek⁷⁹:

$$\text{BPR-OPT} = \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{ui} - \hat{x}_{uj}) - \lambda_{\Theta} \|\Theta\|^2 \quad (8)$$

Gdzie:

- D_S – zbiór wszystkich treningowych trójek (użytkownik, obiekt pozytywny, obiekt negatywny), formułowany na podstawie zbioru zaobserwowanych zdarzeń $\mathcal{E}$ i zdarzeń negatywnych z nim rozłącznych
- $\hat{x}_{ui}$ – estymowana preferencja użytkownika u względem obiektu i (pozytywnego)
- $\hat{x}_{uj}$ – estymowana preferencja użytkownika u względem obiektu j (negatywnego)
- Θ – wektory wag modelu podlegające wyuczeniu
- λ_{Θ} – hiperparametr terminu regularyzacyjnego L2, zapobiegającego zjawisku przeuczenia modelu (ang. *overfitting*)

Zastosowanie funkcji straty BPR samo w sobie nie określa architektury samej estymaty ($\hat{x}_{ui}$). W podejściu BPR-MF system integruje ową funkcję z modelem faktoryzacji macierzy. W tej konfiguracji przewidywana preferencja użytkownika względem danego obiektu jest obliczana jako standardowy iloczyn skalarny przypisanych do nich wektorów⁸⁰:

$$\hat{x}_{ui} = \mathbf{p}_u \cdot \mathbf{q}_i = \sum_{f=1}^k p_{uf} q_{if} \quad (9)$$

⁷⁸ Rendle i in., dz. cyt., s. 453-454.

⁷⁹ Ibidem, s. 455.

⁸⁰ Ibidem, s. 456.

Gdzie:

- $\mathbf{p}_u$ – ukryty wektor cech reprezentujący użytkownika u
- $\mathbf{q}_i$ – ukryty wektor cech reprezentujący obiekt i
- k – wymiarowość przestrzeni ukrytej (z góry określona liczba cech w wektorze)
- p_{uf}, q_{if} – poszczególne (f -te) składowe wektorów ukrytych odpowiednio dla użytkownika u i obiektu i

W procesie optymalizacji – wykorzystującym zazwyczaj algorytm stochastycznego spadku wzdłuż gradientu (SGD) – system iteracyjnie przelicza parametry poszczególnych wektorów po jednej trójce, poszukując minimum funkcji błędu zdefiniowanej równaniem (8). Choć model BPR-MF opiera się na matematycznie prostym iloczynie skalarnym, przez lata dowiódł on swojej potężnej skuteczności w zadaniach wykorzystujących wyłącznie dane dorozumiane. Wynika to wprost z dopasowania samej definicji straty parowej do natury rankingu – algorytm uczy się bezpośrednio sortować obiekty, zamiast przewidywać ich wyizolowane oceny punktowe. Z tego powodu we współczesnej literaturze przedmiotu BPR stanowi fundamentalny model odniesienia, z którym obligatoryjnie zestawia się skuteczność nowszych, rozbudowanych architektur systemów rekomendacyjnych. Autorzy nowatorskich rozwiązań z rodziny głębokich sieci kolaboracyjnych⁸¹ oraz sieci wykorzystujących propagację w strukturach grafowych⁸² regularnie opierają ewaluację empiryczną na bazowym zestawieniu swoich wyników właśnie z klasycznym wariantem BPR-MF.

3.4. Uczenie głębokie i Neural Collaborative Filtering

Uczenie głębokie w systemach rekomendacyjnych stanowi bezpośrednią odpowiedź na ograniczenia klasycznej faktoryzacji macierzy. W tradycyjnych modelach, takich jak opisany wcześniej BPR-MF, estymowana preferencja użytkownika względem obiektu obliczana jest za pomocą prostego iloczynu skalarnego przypisanych do nich wektorów ukrytych. Z matematycznego punktu widzenia jest to operacja ściśle liniowa. Taki stan rzeczy znacząco ogranicza elastyczność algorytmu i uniemożliwia uchwycenie złożonych, nieliniowych wzorców ukrytych w gigantycznych zbiorach interakcji użytkowników platform VOD.

Aby rozwiązać ten problem, architektura Neural Collaborative Filtering (NCF) całkowicie rezygnuje ze sztywnego iloczynu skalarnego na rzecz wielowarstwowych sieci

⁸¹ He i in., dz. cyt., s. 178.

⁸² He i in., „LightGCN”, s. 5.

neuronowych. Podstawowym założeniem tej metody jest to, że sieć neuronowa potrafi samodzielnie wyuczyć się optymalnej, nieliniowej funkcji interakcji bezpośrednio z danych historycznych⁸³.

Najskuteczniejszym wariantem z rodziny NCF jest hybrydowy model Neural Matrix Factorization (NeuMF). Łączy on w sobie dwie niezależne ścieżki przetwarzania informacji: uogólnioną faktoryzację macierzy (GMF) oraz wielowarstwowy perceptron (MLP). Przetwarzanie danych i generowanie predykcji w tej architekturze realizowane są w następujących krokach:

1. W pierwszej kolejności identyfikatory użytkownika u oraz obiektu i rzutowane są na gęstą przestrzeń wektorową w postaci macierzy osadzeń (ang. *embeddings*). Ponieważ obie ścieżki uczą się odmiennych cech, NeuMF inicjuje dla nich dwa niezależne zestawy wektorów – jeden dla ścieżki liniowej ($\mathbf{p}_u^G, \mathbf{q}_i^G$) i drugi dla nieliniowej ($\mathbf{p}_u^M, \mathbf{q}_i^M$).
2. Równolegle system przetwarza wektory w dwóch odrębnych modułach:
 - Ścieżka GMF (Generalized Matrix Factorization): wykonuje iloczyn Hadamarda (mnożenie po współrzędnych) pomiędzy wektorem użytkownika i obiektu, służąc do modelowania prostych, liniowych zależności.
 - Ścieżka MLP (Multi-Layer Perceptron): dokonuje konkatenacji (połączenia) wektorów użytkownika i obiektu, a następnie przepuszcza je przez kaskadę ukrytych warstw gęstych z nieliniowymi funkcjami aktywacji (zazwyczaj ReLU), realizując ekstrakcję głębokich relacji.
3. Na przedostatnim poziomie architektury (tzw. warstwie NeuMF) następuje fuzja. Ostateczna preferencja użytkownika obliczana jest poprzez połączenie wyników GMF i MLP w jeden wektor wyjściowy i przepuszczenie go przez sigmoidalną funkcję aktywacji⁸⁴:

$$\hat{y}_{ui} = \sigma \left(\mathbf{h}^T \begin{bmatrix} \mathbf{p}_u^G \odot \mathbf{q}_i^G \\ \phi^{MLP}(\mathbf{p}_u^M, \mathbf{q}_i^M) \end{bmatrix} \right) \quad (10)$$

Gdzie:

- $\hat{y}_{ui}$ – estymowane prawdopodobieństwo interakcji użytkownika u z obiektem i
- σ – sigmoidalna funkcja aktywacji, transformująca wynik do przedziału $[0, 1]$

⁸³ He i in., „Neural Collaborative Filtering”, s. 174.

⁸⁴ Ibidem, s. 178.

- $\mathbf{h}$ – wektor wag warstwy wyjściowej modelu, łączący wyniki obu ścieżek
 - $\odot$ – iloczyn Hadamarda wektorów osadzeń ścieżki GMF
 - ϕ^{MLP} – wynik przetwarzania połączonych wektorów przez perceptron (MLP)
4. Ze względu na operowanie na danych dorozumianych (1 – obecność interakcji, 0 – brak interakcji), proces optymalizacji (uczenia modelu) traktowany jest jako zadanie binarnej klasyfikacji. Algorytm spadku gradientu dąży iteracyjnie do minimalizacji funkcji binarnej entropii krzyżowej (ang. *Binary Cross-Entropy*, Log Loss)⁸⁵:

$$\mathcal{L}_{NeuMF} = - \sum_{(u,i) \in \mathcal{Y}^+} \log(\hat{y}_{ui}) - \sum_{(u,j) \in \mathcal{Y}^-} \log(1 - \hat{y}_{uj}) \quad (11)$$

Gdzie:

- $\mathcal{Y}^+$ – zbiór zaobserwowanych, pozytywnych interakcji w danych treningowych
- $\mathcal{Y}^-$ – zbiór interakcji negatywnych, wygenerowanych sztucznie poprzez losowe próbkowanie niezaobserwowanych par (ang. *negative sampling*)

Dzięki takiej konstrukcji architektura NeuMF stała się kanonicznym przykładem zastosowania głębokich sieci neuronowych w filtracji kolaboracyjnej. Stanowi ona obecnie potężny, uniwersalny punkt odniesienia (ang. *benchmark*), względem którego weryfikuje się skuteczność nowszych algorytmów – w tym metod adresujących problem izolacji węzłów, takich jak grafowe sieci neuronowe⁸⁶.

3.5. Grafowe sieci neuronowe i architektura LightGCN


Uczenie głębokie, reprezentowane przez architekturę NeuMF, znacząco zwiększyło zdolność systemów rekomendacyjnych do modelowania nieliniowych interakcji. Modele te posiadają jednak fundamentalne ograniczenie – traktują każdą parę użytkownik-obiekt jako wyizolowany rekord danych. W rzeczywistości interakcje na platformach VOD tworzą rozbudowany graf dwudzielny, w którym użytkownicy są połączeni z oglądanymi filmami. Ignorowanie topologii tego grafu uniemożliwia uchwycenie tzw. relacji wyższych rzędów (ang. *high-order connectivity*), czyli wiedzy płynącej z faktu, że użytkownicy o podobnym guście tworzą ukryte klastry powiązań⁸⁸.

Odpowiedzią na ten problem są grafowe sieci neuronowe (GNN). Początkowo adaptowano w tym celu klasyczne konwolucje grafowe (GCN), jednak ze względu na ich

⁸⁵ Ibidem, s. 177.

⁸⁶ He i in., „LightGCN”, s. 5.

⁸⁸ Ibidem, s. 1.



Rysunek 5: Architektura hybrydowego modelu Neural Matrix Factorization (NeuMF). Opracowanie własne na podstawie⁸⁷.

ciężar obliczeniowy (transformacje cech i nieliniowe funkcje aktywacji), okazały się one nieoptymalne dla zadania filtrowania kolaboracyjnego. Przełomem w tej dziedzinie stał się algorytm *LightGCN*, zaproponowany w 2020 roku. Badacze udowodnili, że w systemach rekomendacyjnych opartych wyłącznie na identyfikatorach (ID) operacje nieliniowe są szkodliwe, a kluczem do sukcesu jest samo wygładzanie wektorów po strukturze grafu (ang. *neighborhood aggregation*)⁸⁹.

Architektura *LightGCN* składa się z następujących etapów przetwarzania:

1. **Inicjalizacja (Warstwa Osadzeń):** Podobnie jak w standardowej faktoryzacji macierzy, każdemu węzłowi w grafie (użytkownikowi u oraz obiektowi i) przypisywany jest unikalny wektor cech. Stanowią one początkowe reprezentacje informacyjne na tak zwanej warstwie zerowej: $\mathbf{e}_u^{(0)}$ oraz $\mathbf{e}_i^{(0)}$.
2. **Lekka Konwolucja Grafowa (Propagacja):** Wektory reprezentacji aktualizowane są iteracyjnie poprzez agregację informacji od bezpośrednich sąsiadów w grafie dwudzielnym. Zgodnie z głównym postulatem *LightGCN*, z procesu tego całkowicie usunięto parametryzowane macierze wag i aktywacje nieliniowe. Wartość wektora

⁸⁹ Ibidem, s. 2–3.

użytkownika w kolejnej warstwie $k + 1$ wyliczana jest ze wzoru⁹⁰:

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}} \mathbf{e}_i^{(k)} \quad (12)$$

Gdzie:

- $\mathbf{e}_u^{(k+1)}$ – zaktualizowany wektor cech użytkownika u po $k + 1$ krokach propagacji grafowej
- $\mathbf{e}_i^{(k)}$ – wektor cech obiektu i (sąsiada) pochodzący z poprzedniej warstwy k
- $\mathcal{N}_u, \mathcal{N}_i$ – zbiór bezpośrednich sąsiadów w grafie (dla użytkownika są to obejrzane przez niego filmy, a dla filmu – użytkownicy, którzy weszli z nim w interakcję)
- $\frac{1}{\sqrt{|\mathcal{N}_u|} \sqrt{|\mathcal{N}_i|}}$ – symetryczny czynnik normalizujący dyskontujący wpływ bardzo popularnych filmów lub wybitnie aktywnych użytkowników

Analogiczny proces propagacji zachodzi w drugą stronę – wektory filmów aktualizowane są na podstawie połączonych z nimi wektorów użytkowników.

3. **Fuzja Warstw (Kombinacja Wektorów):** Ponieważ każda warstwa k koduje informacje o topologii z innej odległości (np. $k = 1$ to bezpośrednie interakcje, $k = 2$ to znajomi o podobnym guście), LightGCN nie odrzuca warstw pośrednich. Ostateczna reprezentacja wężła jest wyliczana jako średnia ważona jego stanów z poszczególnych warstw⁹¹:

$$\mathbf{e}_u = \sum_{k=0}^K \alpha_k \mathbf{e}_u^{(k)} \quad (13)$$


Gdzie K to łączna liczba wykorzystanych warstw konwolucyjnych (zazwyczaj od 2 do 4), a α_k to waga przypisana danej warstwie (domyślnie przyjmuje się stałą wartość $\alpha_k = \frac{1}{K+1}$, traktując wszystkie kroki propagacji równorzędnie).

4. **Predykcja i Optymalizacja:** Ostateczna predykcja prawdopodobieństwa interakcji wyliczana jest poprzez standardowy iloczyn skalarny finalnych, wzbogaconych strukturalnie wektorów: $\hat{y}_{ui} = \mathbf{e}_u^T \mathbf{e}_i$. Tak zaprojektowany model trenowany jest z wykorzystaniem znanej z klasycznych podejść parowej funkcji straty BPR (zdefiniowanej wcześniej równaniem (8)). Pozwala to na bezpośrednią optymalizację algorytmu pod kątem poprawnego sortowania spersonalizowanej listy rekomendacji.

⁹⁰ Ibidem, s. 3.

⁹¹ Ibidem, s. 4.

Usunięcie zbędnych operacji matematycznych uczyniło z LightGCN model nie tylko skuteczniejszy od wcześniejszych architektur GNN, ale także znacznie szybszy obliczeniowo i łatwiejszy w procesie strojenia. Algorytm ten redefiniuje podejście do filtrowania kolaboracyjnego, udowadniając wprost, że ukryta struktura powiązań pomiędzy użytkownikami a multimediami jest równie kluczowa, co głęboka ekstrakcja nieliniowych wzorców preferencji.



Rysunek 6: Architektura algorytmu LightGCN z uwzględnieniem propagacji warstwowej. Opracowanie własne na podstawie⁹².

3.6. Metryki oceny

Ewaluacja modeli rekomendacyjnych w warunkach interakcji dorozumianych (*implicit feedback*) różni się fundamentalnie od tradycyjnej oceny systemów ukierunkowanych na przewidywanie ocen jawnych. W klasycznym ujęciu regresyjnym celem algorytmu jest minimalizacja błędu predykcji wartości ciągłej, wyrażanej najczęściej za pomocą średniego błędu kwadratowego (ang. *Root Mean Squared Error, RMSE*) lub średniego

błędu bezwzględnego (ang. *Mean Absolute Error, MAE*)⁹³.

W rzeczywistych platformach VOD/OTT kluczowe znaczenie ma jednak zdolność systemu do wyselekcjonowania i trafnego uporządkowania spersonalizowanej listy K najważniejszych obiektów (tzw. rekomendacja góry listy, ang. *Top-K Recommendation*)⁹⁴. Skuteczność dopasowania listy do preferencji użytkownika mierzy się za pomocą metryk rangowych. W przeciwieństwie do miar regresyjnych uwzględniają one fakt, że w warunkach rzadkości danych oraz przytłaczającej liczby tytułów w katalogu, użytkownik zapoznaje się wyłącznie z czołowymi pozycjami rekomendowanej listy, ignorując pozostałą, nienadrzędną część asortymentu platformy⁹⁵.

W badaniach eksperymentalnych zastosowano zestaw czterech komplementarnych metryk rangowych poddawanych ewaluacji na zbiorze testowym dla progu $K = 10$: Czułość (*Recall@K*), Wskaźnik Trafień (*Hit Rate@K*), Znormalizowany Zdyskontowany Zysk Skumulowany (*Normalized Discounted Cumulative Gain, NDCG@K*) oraz Średnią Odwrotność Rangi (*Mean Reciprocal Rank, MRR@K*)⁹⁶.

Niech $\mathcal{U}$ oznacza zbiór użytkowników poddawanych ewaluacji, $\mathcal{R}_u(K)$ uporządkowany zbiór K obiektów rekomendowanych użytkownikowi $u \in \mathcal{U}$ przez analizowany model, natomiast $\mathcal{T}_u$ zbiór obiektów faktycznie zaobserwowanych (relevantnych) w zbiorze testowym dla tego użytkownika. Każda z wymienionych metryk mierzy odmienny aspekt jakości dopasowania listy rekomendacyjnej:

- **Czułość (ang. *Recall at K, Recall@K*):** określa, jaki ułamek wszystkich relevantnych dla użytkownika obiektów ze zbioru testowego znalazł się na wygenerowanej liście rekomendacji, ignorując kolejność ich ułożenia⁹⁷. Obliczany jako iloraz trafnych wskazań algorytmu (wyrażonych jako przecięcie zbioru rekomendacji ze zbiorem testowym) i łącznej liczby pożądaných przez użytkownika elementów:

$$\text{Recall@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{|\mathcal{R}_u(K) \cap \mathcal{T}_u|}{|\mathcal{T}_u|} \quad (14)$$

- **Wskaźnik Trafień (ang. *Hit Rate at K, Hit Rate@K*):** reprezentuje prawdopodobieństwo, że na rekomendowanej liście o długości K znajdzie się co najmniej jeden obiekt poszukiwany przez użytkownika w zbiorze testowym⁹⁸:

$$\text{HR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbb{I}(\mathcal{R}_u(K) \cap \mathcal{T}_u \neq \emptyset) \quad (15)$$

⁹³ G. Shani i A. Gunawardana. Evaluating Recommendation Systems. W: (w:) Recommender Systems Handbook. T. 12. 2011, s. 15–16.

⁹⁴ Steck, dz. cyt., s. 220.

⁹⁵ Shani i Gunawardana, dz. cyt., s. 16–20.

⁹⁶ Zhao i in., dz. cyt., s. zob. s. 6, sekcja 2.3.1.

⁹⁷ Shani i Gunawardana, dz. cyt., s. 264.

⁹⁸ He i in., „Neural Collaborative Filtering”, s. 7, sekcja 4.1.1.

gdzie $\mathbb{I}(\cdot)$ oznacza funkcję wskaźnikową, przyjmującą wartość 1, gdy warunek logiczny jest spełniony, oraz 0 w przeciwnym razie.

- **Znormalizowany Zdyskontowany Zysk Skumulowany (ang. *Normalized Discounted Cumulative Gain, NDCG@K*):** w przeciwieństwie do czułości i wskaźnika trafień, metryka $NDCG@K$ uwzględnia dokładną pozycję (rangę) trafionych obiektów. Odzwierciedla to rzeczywiste zachowanie użytkowników platform streamingowych, których uwaga drastycznie maleje wraz z oddalaniem się od początku zestawienia. Dyskonto pozycyjne nakłada najwyższą wagę na trafienia na najwyższych miejscach (np. pozycje 1–3), stosując logarytmiczne osłabienie wag dla pozycji dalszych, co pozwala na precyzyjną ocenę zdolności modelu do pozycjonowania najlepszych propozycji na samym szczycie listy⁹⁹.

Zysk zdyskontowany ($DCG@K$) dla użytkownika u wyraża się wzorem¹⁰⁰:

$$DCG@K(u) = \sum_{i=1}^K \frac{rel_u(i)}{\log_2(i+1)} \quad (16)$$

gdzie $rel_u(i) \in \{0, 1\}$ oznacza wskaźnik trafienia obiektu znajdującego się na i -tej pozycji rekomendowanej listy $\mathcal{R}_u(K)$ (przyjmując wartość 1, jeśli obiekt należy do zbioru testowego $\mathcal{T}_u$, oraz 0 w przeciwnym razie). Idealny zysk zdyskontowany ($IDCG@K$) odpowiada hipotetycznemu, bezbłędnemu uszeregowaniu, w którym wszystkie rzeczywiste obiekty ze zbioru testowego umieszczono na najwyższych możliwych pozycjach listy rekomendacyjnej¹⁰¹:

$$IDCG@K(u) = \sum_{i=1}^{\min(|\mathcal{T}_u|, K)} \frac{1}{\log_2(i+1)} \quad (17)$$

Znormalizowana wartość $NDCG@K$ stanowi stosunek zysku rzeczywistego do idealnego, a jej uśrednienie po całym zbiorze użytkowników pozwala na uzyskanie syntetycznej oceny jakości rankingu generowanego przez model¹⁰²:

$$NDCG@K(u) = \frac{DCG@K(u)}{IDCG@K(u)} \implies NDCG@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} NDCG@K(u) \quad (18)$$

- **Średnia Odwrotność Rangi (ang. *Mean Reciprocal Rank, MRR@K*):** mierzy zdolność systemu do jak najszybszego dostarczenia pierwszej trafnej rekomendacji. Z punktu widzenia platform VOD wskaźnik ten ma fundamentalne znaczenie

⁹⁹ Krawczuk, dz. cyt., s. 35.

¹⁰⁰ Shani i Gunawardana, dz. cyt., s. 270.

¹⁰¹ Krawczuk, Ibidem.

¹⁰² Shani i Gunawardana, dz. cyt.; Krawczuk, dz. cyt., s. 270–271.

użytkowe, gdyż symuluje scenariusz, w którym widz poszukuje pojedynczego, satysfakcjonującego filmu na dany wieczór, a jego proces interakcji z interfejsem kończy się w momencie odnalezienia pierwszej interesującej pozycji. Jakość systemu ocenia się tu przez pryzmat odwrotności pozycji, na której pojawił się pierwszy obiekt ze zbioru testowego¹⁰³:

$$\text{MRR@K}(u) = \frac{1}{\text{rank}_u^*} \quad (19)$$

gdzie rank_u^* oznacza rangę pierwszej trafnej rekomendacji na liście $\mathcal{R}_u(K)$ (przyjmując $\text{MRR@K}(u) = 0$, jeśli w obrębie K pozycji nie wystąpiło żadne trafienie). Ostateczna wartość MRR@K stanowi średnią arytmetyczną odwrotności rang obliczoną dla wszystkich analizowanych użytkowników¹⁰⁴:

$$\text{MRR@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \text{MRR@K}(u) \quad (20)$$

Wartość NDCG@10 przyjęto w badaniach jako główną metrykę walidacyjną (*target metric*), decydującą o zatrzymaniu procesu trenowania (procedura *early stopping*) oraz wyznaczaniu optymalnych zestawów hiperparametrów analizowanych modeli. Takie podejście jest w pełni spójne z powszechną praktyką eksperymentalną w dziedzinie głębokich systemów rekomendacyjnych, gdzie to właśnie jakość uporządkowania czołówki listy rekomendacji decyduje o finalnej użyteczności modelu dla widza¹⁰⁵.

¹⁰³Tenże, „Systemy rekomendacyjne”, s. 34.

¹⁰⁴Ibidem, s. 34.

¹⁰⁵He i in., dz. cyt., s. zob. s. 7, sekcja 4.1.1.

4. Porównanie algorytmów rekomendacyjnych

W niniejszym rozdziale przeprowadzono ewaluację i porównanie skuteczności wybranych algorytmów rekomendacyjnych. Głównym celem badań było zestawienie ze sobą modeli reprezentujących trzy różne paradygmaty: klasyczną faktoryzację macierzy (BPR), głębokie sieci neuronowe (NCF) oraz grafowe sieci neuronowe (LightGCN).

Rozdział został podzielony na trzy główne sekcje. W pierwszej z nich szczegółowo opisano proces doboru i optymalizacji hiperparametrów, mający na celu maksymalizację zdolności predykcyjnych każdego z modeli. W kolejnej części zestawiono wyniki eksperymentów przeprowadzonych na zbiorze danych MovieLens i poddano je analizie pod kątem przyjętych metryk oceny (m.in. NDCG oraz Recall). Rozdział kończy dyskusja uzyskanych wyników oraz wnioski dotyczące skuteczności i ograniczeń badanych architektur w zadaniu rekomendacji Top-N.

4.1. Proces strojenia hiperparametrów

W celu uzyskania stosunkowo najlepszych możliwych wyników badanie poprzedzono procesem doboru odpowiednich hiperparametrów. Przyjęto następującą metodologię. W pierwszej kolejności zbadano poziom wrażliwości algorytmów na zmiany wartości określonych parametrów. Następnie bazując na wynikach zdefiniowano okrojoną siatkę hiperparametrów dla każdej z metod i przy pomocy metody Grid Search polegającej na zbadaniu wszystkich możliwych kombinacji określonych wcześniej wartości wyłoniono najlepsze zestawy parametrów będące podstawą późniejszej analizy porównawczej.


Dobór parametrów poddanych analizie wrażliwości wynikał z ich kluczowego wpływu na zdolności predykcyjne oraz charakterystyki architektonicznej każdego z badanych algorytmów:

- W modelu **ItemKNN** wybrano rozmiar sąsiedztwa (k) oraz współczynnik wygładzania (shrinkage). Parametr k determinuje, na ilu najbardziej podobnych elementach bazuje predykcja, co jest kluczowe w filtrowaniu opartym na sąsiedztwie. Współczynnik wygładzania pozwala z kolei na redukcję szumu statystycznego przy obliczaniu podobieństwa dla rzadko ocenianych przedmiotów.
- Dla modelu **BPR** skupiono się na współczynniku uczenia (learning rate) oraz rozmiarze wektora cech ukrytych (embedding size). Współczynnik uczenia determinuje zbieżność optymalizacji. Z kolei złożoność faktoryzacji macierzy rośnie wraz z wymiarem przestrzeni latentnej, dlatego optymalizacja tego parametru jest kluczowa dla balansu pomiędzy niedouczeniem a przeuczeniem.

- W głębokim modelu **NeuMF** analizie poddano współczynnik uczenia oraz prawdopodobieństwo odrzucenia neuronów (dropout probability). Głębokie sieci neuronowe są wysoce podatne na zapamiętywanie danych treningowych (overfitting), dlatego właściwy dobór parametru dropout jest niezbędny do uzyskania dobrej zdolności do generalizacji.
- W przypadku grafowego modelu **LightGCN** wytypowano wagę regularyzacji (regularization weight) oraz liczbę warstw propagacji (number of layers). Regularyzacja L2 kontroluje wielkość wag wektorów zapobiegając nadmiernemu dopasowaniu, podczas gdy liczba warstw odpowiada za eksplorację sygnałów wyższego rzędu w grafie (np. odległości 2-skokowe).


4.1.1. Analiza wrażliwości

Poniżej przedstawiono graficzne zestawienie wpływu badanych hiperparametrów na metrykę NDCG@10 dla każdego z algorytmów. W przypadku modelu ItemKNN (Rysunek




Rysunek 7: Wpływ hiperparametrów k oraz *shrinkage* na trafność modelu ItemKNN

7) można zaobserwować, że zwiększanie liczby uwzględnianych sąsiadów (k) konsekwentnie poprawia wyniki metryki NDCG@10 aż do wartości $k = 200$, po czym przyrost ten naturalnie zwalnia. Regularyzacja *shrinkage* z kolei nie przynosi w tym przypadku znaczących korzyści na zbiorze MovieLens 100K – najwyższy wynik odnotowano dla braku wygładzania (wartość 0.0), a dalsze zwiększanie tego parametru skutkuje delikatnym i marginalnym spadkiem trafności. Dla modelu faktoryzacji BPR (Rysunek 8) analiza ujawnia klasyczną zależność optymalizacyjną. Współczynnik uczenia osiąga jednoznaczne optimum na poziomie 0.0005, zapewniając najwyższą trafność na poziomie NDCG@10 ≈ 0.2867 . Większe wartości prowadzą do spadku trafności w wyniku niestabilności numerycznej. Z kolei rozmiar wektora cech (*embedding size*) wskazuje, że wartość 128 oferuje optymalną celność (niewielka przewaga nad 64), podczas gdy dalsze zwiększanie do




Rysunek 8: Wpływ współczynnika uczenia oraz rozmiaru wektora zanurzeń na trafność modelu BPR

wymiaru 256 skutkuje spadkiem skuteczności spowodowanym powolnym przeuczeniem się algorytmu na treningowej części zbioru. Ocena parametrów hybrydowego modelu



Rysunek 9: Wpływ współczynnika uczenia oraz parametru dropout na trafność modelu NeuMF

NeuMF (Rysunek 9) potwierdza specyfikę głębokich sieci neuronowych. Widać jednoznacznie, że model zbiega do globalnego optimum przy *learning rate* na poziomie 0.0001 ($NDCG \approx 0.2810$). Parametr *dropout* wykazuje z kolei wysoce czytelny punkt optymalny dla wartości 0.5. Pozwala to na odpowiednią, restrykcyjną regularyzację gęstych warstw, skutecznie hamując overfitting i zwiększając zdolność uogólniania wniosków. Ostatnim etapem analizy była ocena grafowego modelu LightGCN (Rysunek 10). Architektura ta bazuje na propagacji informacji wzdłuż krawędzi, co ma swoje odzwierciedlenie na wykresie: zastosowanie dwóch warstw propagacji ($n_layers = 2$) okazało się optymalne. Zwiększanie liczby warstw do 3 lub 4 nieznacznie pogarsza wyniki, co jest klasycznym objawem problemu nadmiernego wygładzenia sygnałów (over-smoothing). Zastosowa-



Rysunek 10: Wpływ wagi regularyzacji oraz liczby warstw propagacji na trafność modelu LightGCN

nie odpowiedniej siły kary za wielkość wag również posiada ostry szczyt użyteczności: $reg_weight = 0.10$ maksymalizuje końcową precyzję predykcji tego algorytmu.

4.1.2. Przeszukiwanie siatki parametrów — Grid Search

Proces strojenia hiperparametrów zwieńczono zastosowaniem metody wyczerpującego przeszukiwania siatki (ang. *Grid Search*). Jest to deterministyczne podejście do optymalizacji modelu, polegające na zdefiniowaniu dyskretnego zbioru dopuszczalnych wartości dla każdego z badanych parametrów, a następnie przetestowaniu wszystkich możliwych ich kombinacji, stanowiących iloczyn kartezjański zdefiniowanych zbiorów. Choć w ogólnym przypadku metoda ta jest wysoce kosztowna obliczeniowo i jej złożoność rośnie wykładniczo wraz z dodawaniem kolejnych wymiarów (zjawisko znane jako klątwa wymiarowości), jej zastosowanie w niniejszym badaniu było w pełni zoptymalizowane i uzasadnione.

Dzięki przeprowadzonej wcześniej, szczegółowej analizie wrażliwości (Sekcja 3.1.1) udało się odrzucić nieperspektywiczne przedziały wartości i drastycznie zawęzić ostateczną przestrzeń poszukiwań. Pozwoliło to na bezpieczne wykorzystanie metody *Grid Search*, która w przeciwieństwie do podejść stochastycznych (takich jak *Random Search*) gwarantuje bezwzględne odnalezienie globalnego optimum w obrębie zadanej siatki. Opierając się na wytycznych z analizy, dla każdego algorytmu zdefiniowano okrojona przestrzeń hiperparametrów, którą zestawiono w Tabeli 2. Zgodnie z metodologią badawczą, dla każdej możliwej konfiguracji zdefiniowanej w siatce inicjowano całkowicie niezależny proces uczenia od podstaw. Ewaluacja poszczególnych wariantów odbywała się na wyodrębnionym zbiorze walidacyjnym (ang. *validation set*), co zapobiegało zjawisku „wycieku danych” (ang. *data leakage*) i gwarantowało obiektywną ocenę zdolności do generali-

zacji. Za ostateczne kryterium wyboru najlepszego zestawu hiperparametrów przyjęto maksymalizację metryki NDCG@10.

Warto w tym miejscu zaznaczyć, że współczesne algorytmy rekomendacyjne – w szczególności te oparte na sieciach neuronowych – charakteryzują się rozbudowaną przestrzenią konfiguracyjną. Jednoczesna optymalizacja wszystkich dostępnych hiperparametrów przy użyciu metody *Grid Search* była niemożliwa ze względu na wykładniczy wzrost czasu trwania obliczeń. Z tego powodu proces strojenia świadomie ograniczono wyłącznie do kluczowych parametrów, zidentyfikowanych w analizie wrażliwości jako najbardziej wpływowe dla poszczególnych architektur.

Wszelkie pozostałe ustawienia procesu uczenia, niewyszczególnione w Tabeli 2, zostały ustandaryzowane i zachowane na stałym, odgórnie narzuconym poziomie dla wszystkich algorytmów. Do aktualizacji wag wykorzystano optymalizator Adam, będący domyślnym i powszechnie uznanym standardem w środowisku RecBole. Rozmiar partii danych (ang. *batch size*) ustalono na 4096, co zapewniło odpowiednią stabilność numeryczną gradientu. Maksymalną liczbę iteracji ograniczono do 100 epok, jednak w celu zapobiegania przeuczeniu (*overfitting*) zastosowano mechanizm wczesnego zatrzymywania (ang. *early stopping*). Trening modelu był automatycznie przerywany w przypadku, gdy metryka NDCG@10 na zbiorze walidacyjnym nie uległa poprawie przez 10 kolejnych epok. Proces uczenia przeprowadzono również ze stałą strategią negatywnego próbkowania (ang. *negative sampling*), gdzie dla każdej pozytywnej interakcji losowano jednostajnie 4 interakcje negatywne. Zachowanie tych parametrów na jednakowym poziomie dla każdego algorytmu gwarantuje, że końcowa ewaluacja jest miarodajna i sprawiedliwa.

Tabela 2: Zestawienie przestrzeni hiperparametrów (siatki) dla poszczególnych algorytmów

Model	Parametr	Przestrzeń poszukiwań (Grid)
ItemKNN	k	{ 100, 150, 200 }
	$shrink$	{ 0.0, 2.5, 5.0, 7.5, 10.0 }
BPR	$learning_rate$	{ 0.001, 0.0005, 0.0001 }
	$embedding_size$	{ 64, 128 }
NeuMF	$learning_rate$	{ 0.0005, 0.0001, 0.00005 }
	$dropout_prob$	{ 0.4, 0.5, 0.6 }
LightGCN	reg_weight	{ 0.01, 0.05, 0.1 }
	n_layers	{ 2, 4 }

Wyniki procesu optymalizacji pozwoliły na wyłonienie ostatecznych architektur, które posłużą do finalnego porównania skuteczności algorytmów w kolejnym podrozdziale.

Zestawienie zwycięskich parametrów prezentuje się następująco:

- **ItemKNN**: Najlepszą celność uzyskano dla sąsiedztwa $k = 100$ oraz wygładzania $shrinkage = 7.5$ ($NDCG@10 = 0.2734$).
- **BPR**: Wariant z optymalizacją bayesowską najlepiej operował w przestrzeni latentnej o rozmiarze 128 przy kroku uczenia równym 0.001 ($NDCG@10 = 0.2837$).
- **NeuMF**: Algorytm oparty na głębokich sieciach neuronowych osiągnął globalne optimum dla współczynnika odrzucenia (dropout) rzędu 0.5 oraz współczynnika uczenia 0.0005 ($NDCG@10 = 0.2895$). Pozostałe, stałe parametry architektoniczne (w tym rozmiary warstw ukrytych) zostały zachowane na podstawie wcześniejszej analizy.
- **LightGCN**: Model grafowy zdominował zestawienie testowe, uzyskując najwyższą bezwzględną trafność ($NDCG@10 = 0.3021$) dla 2 warstw propagacji wzdłuż krawędzi oraz wagi regularyzacji L2 na poziomie 0.1.

Powyższe zestawy parametrów gwarantują, że każdy z modeli podczas ostatecznej ewaluacji będzie operował na granicy swoich maksymalnych, teoretycznych możliwości, co zapewni miarodajność końcowego porównania.

Tabela 3: Wyselekcjonowane, optymalne wartości hiperparametrów dla badanych modeli

Model	Parametr	Optymalna wartość
ItemKNN	k	100
	$shrink$	7.5
BPR	$learning_rate$	0.001
	$embedding_size$	128
NeuMF	$learning_rate$	0.0005
	$dropout_prob$	0.5
LightGCN	reg_weight	0.1
	n_layers	2

4.2. Wyniki badań

W niniejszym podrozdziale zaprezentowano ostateczne zestawienie skuteczności badanych algorytmów. Ocenę przeprowadzono na odseparowanym zbiorze testowym, gwarantując tym samym obiektywną miarę zdolności modeli do generalizacji. Zgodnie z

wcześniej przyjętą metodologią, predykcje poszczególnych architektur oceniono z wykorzystaniem metryk NDCG@10, Recall@10, Hit@10 oraz MRR@10. Pełne zestawienie wyników zaprezentowano w Tabeli 4.

Tabela 4: Porównanie wyników metryk oceny dla testowanych algorytmów rekomendacyjnych na zbiorze MovieLens 100K.

Model	NDCG@10	Recall@10	Hit@10	MRR@10
ItemKNN	0.2734	0.2336	0.7497	0.4392
BPR	0.2837	<u>0.2437</u>	0.7603	0.4525
NeuMF	<u>0.2895</u>	0.2435	0.7720	<u>0.4744</u>
LightGCN	0.3021	0.2529	<u>0.7678</u>	0.4835


Analiza powyższej tabeli pozwala na wyciągnięcie kilku kluczowych wniosków, które wpisują się w historyczną ewolucję systemów rekomendacyjnych. Punktem odniesienia (ang. *baseline*) w eksperymencie był najprostszy algorytm oparty na sąsiedztwie – ItemKNN, który uzyskał najniższe, bazowe wyniki. Wprowadzenie klasycznej faktoryzacji macierzy (BPR) znacząco poprawiło jakość rekomendacji (wzrost NDCG z 0.2734 na 0.2837), co dowodzi wyższości uczenia się cech ukrytych nad prostymi heurystykami podobieństwa.

Wykorzystanie głębokich sieci neuronowych w modelu NeuMF przyniosło dalszą poprawę w większości metryk, jednak na szczególną uwagę zasługuje relacja między wskaźnikami Hit@10 a NDCG@10. Choć NeuMF wygrał w kategorii Hit@10 (0.7720), co oznacza, że skuteczniej umieszczał przynajmniej jeden trafny element w pierwszej dziesiątce, to ustąpił w rankingu NDCG. Dowodzi to, że bezapelacyjny zwycięzca zestawienia – grafowy model LightGCN – znacznie lepiej radzi sobie z precyzyjnym pozycjonowaniem trafnych rekomendacji na samym szczycie listy. Architektura grafowa, dzięki jawnej propagacji sygnałów między użytkownikami a przedmiotami, uzyskała najwyższe wartości NDCG@10 (0.3021) oraz MRR@10 (0.4835).

4.2.1. Krzywe zbieżności i stabilność procesu uczenia

Zestawienie końcowych wyników uzupełniono o analizę dynamiki procesu uczenia poszczególnych architektur. Na Rysunku 11 zaprezentowano krzywe zbieżności (ang. *learning curves*) rejestrujące zmianę metryki NDCG@10 na zbiorze walidacyjnym w trakcie trwania optymalizacji, aż do momentu aktywacji mechanizmu wczesnego zatrzymywania (ang. *early stopping*).

Analiza krzywych ujawnia interesujące różnice w sposobie optymalizacji. Klasyczny model faktoryzacji macierzy (BPR) wykazuje najszybsze tempo zbieżności – jego trafność



Rysunek 11: Krzywe zbieżności metryki NDCG@10 na zbiorze walidacyjnym dla algorytmów BPR, NeuMF oraz LightGCN.


drastycznie rośnie już w pierwszych iteracjach, osiągając lokalne optimum w okolicach 20. epoki. Następnie można zaobserwować delikatny spadek jakości, co świadczy o podatności na przeuczenie (ang. *overfitting*) na zbiorze treningowym. Z kolei model grafowy (LightGCN) startuje z niższego poziomu i uczy się znacznie wolniej, jednak jego krzywa jest wysoce stabilna. Ostatecznie, proces powolnego propagowania sygnałów w grafie pozwala na przekroczenie pułapu wyznaczonego przez BPR i NeuMF, a optymalna zbieżność osiągana jest znacznie później.

4.2.2. Koszty obliczeniowe a skuteczność algorytmów

Ostatnim elementem ewaluacji jest analiza relacji nakładów obliczeniowych (czasu optymalizacji modelu) do uzyskiwanej trafności predykcji. Jest to kluczowy wskaźnik inżynierski w środowiskach produkcyjnych, w których systemy rekomendacyjne muszą być regularnie i szybko dotrenowywane nowymi danymi. Zależność tę zilustrowano na Rysunku 12.

Wykres punktowy obnaża bardzo wyraźny kompromis (ang. *trade-off*) pomiędzy kosztem a jakością. Model bazowy ItemKNN, nie wymagający iteracyjnej optymalizacji stochastycznej, zapewnia niemal błyskawiczny czas odpowiedzi przy relatywnie najniższej skuteczności. Klasyczny wariant BPR jawi się jako algorytm niezwykle efektywny kosztowo – czas jego uczenia zamyka się w kilkudziesięciu sekundach, dostarczając bardzo zadowalające rezultaty.

Najważniejszym wnioskiem jest jednak ewaluacja grafowych sieci neuronowych. Choć LightGCN deklaruje rywali pod kątem metryki NDCG, to odbywa się to potężnym



Rysunek 12: Zestawienie czasu uczenia względem ostatecznej skuteczności (NDCG@10) dla badanych modeli.

kosztem sprzętowym. Czas jego pełnego treningu okazał się niemal 10-krotnie wyższy niż w przypadku głębokiej sieci neuronowej (NeuMF) oraz rzędy wielkości wyższy w porównaniu do klasycznej faktoryzacji macierzy. Wynik ten zmusza do refleksji nad opłacalnością wdrożenia tego typu algorytmu w czasie rzeczywistym. W przypadkach biznesowych, w których priorytetem jest częste odświeżanie modelu pod wpływem ogromnego wolumenu nowych danych lub gdy zasoby obliczeniowe są mocno ograniczone, architektura hybrydowa NeuMF lub nawet klasyczny BPR mogą okazać się znacznie lepszym i bezpieczniejszym balansem pomiędzy trafnością a wydajnością niż bezwzględny faworyt testów laboratoryjnych.

4.3. Dyskusja wyników i wnioski

Podsumowanie

Należy nawiązać do problemu badawczego, tezy i celu pracy. Trzeba krótko podsumować najważniejsze wnioski z badań – nie w punktach; ma to być tekst ciągły. W oparciu o przywołane najważniejsze spostrzeżenia należy stwierdzić, czy tezę pracy można przyjąć, czy należy ją odrzucić. Na tej podstawie należy stwierdzić, czy cel pracy został zrealizowany. W przypadku prac opartych na konkretnych problemach przedsiębiorstw można ocenić znaczenie przeprowadzonych badań dla firmy w kontekście budowania przewagi konkurencyjnej na rynku (niższe koszty, większa prędkość produkcji, większa elastyczność produkcji itp.).

Bibliografia

- G. Adomavicius i A. Tuzhilin. Toward the next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions. W: „IEEE Transactions on Knowledge and Data Engineering” 17 (2005), s. 734–749.
- V. W. Anelli i in. *Top-N Recommendation Algorithms: A Quest for the State-of-the-Art*. 2022.
- M. Bałchanowski. „Ewolucyjna Agregacja Rang w Systemach Rekomendacyjnych”. Rozprawa doktorska. 2023.
- M. Bernardelli. Wpływ Algorytmów Rekomendacyjnych Na Stopień Usieciowienia Platform Cyfrowych. W: (w:) Platformy Cyfrowe. Model Biznesu, Zastosowania, Użytkownicy. 2024.
- R. Burke. Hybrid Recommender Systems: Survey and Experiments. W: „User Modeling and User-Adapted Interaction” 12 (2002).
- O. Celma. *Music Recommendation and Discovery: The Long Tail, Long Fail, and Long Play in the Digital Music Space*. 2010.
- K. Chęciński i R. Wawrzusiak. Systemy rekomendacji. Remedium w cyfrowej kłęsce urodzaju. W: „Przegląd Telekomunikacyjny + Wiadomości Telekomunikacyjne” nr 2 (2023).
- D. Goldberg i in. Using Collaborative Filtering to Weave an Information TAPESTRY. W: „Commun. ACM” 35 (1992), s. 61–70.
- C. Gómez-Urbe i N. Hunt. The Netflix Recommender System. W: „ACM Transactions on Management Information Systems” 6 (2015), s. 1–19.
- B. Hallinan i T. Striplas. Recommended for You: The Netflix Prize and the Production of Algorithmic Culture. W: „New Media & Society” 18 (2016), s. 117–137.
- F. M. Harper i J. A. Konstan. The MovieLens Datasets: History and Context. W: „ACM Transactions on Interactive Intelligent Systems” 5.Nr 4 (2016), s. 1–19.
- X. He i in. „Neural Collaborative Filtering”. W: *Proceedings of the 26th International Conference on World Wide Web*. WWW '17. Republic i Canton of Geneva, CHE: International World Wide Web Conferences Steering Committee, 2017, s. 173–182.
- X. He i in. LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. W: (2020).
- Y. Koren, R. Bell i C. Volinsky. Matrix Factorization Techniques for Recommender Systems. W: „Computer” 42 (2009), s. 30–37.
- J. Krawczuk. Systemy rekomendacyjne. W: (w:) Wybrane zagadnienia symulacji komputerowej. 2024, s. 24–38.

- M. Malinowski. Zastosowanie Grafów i Sieci w Systemach Rekomendacji. W: 2021, s. 77–96.
- „Algorytm Rekomendacji Bazujący Na Sesjach Rekomendacji Działający Na Podstawie Zachowań Użytkowników Oraz Atrybutów Obiektów w Systemie E-Commerce”. Rozprawa doktorska. Warszawa: Wojskowa Akademia Techniczna im. Jarosława Dąbrowskiego, 2022.
- J. McAuley i J. Leskovec. „Hidden Factors and Hidden Topics: Understanding Rating Dimensions with Review Text”. W: *Proceedings of the 7th ACM Conference on Recommender Systems*. RecSys ’13. New York, NY, USA: Association for Computing Machinery, 2013, s. 165–172.
- S. Raza i in. *A Comprehensive Review of Recommender Systems: Transitioning from Theory to Practice*. 2024.
- S. Rendle i in. „BPR: Bayesian Personalized Ranking from Implicit Feedback.” W: 2009, s. 461.
- P. Resnick i H. R. Varian. Recommender Systems. W: „Communications of The ACM” 40.Nr 3 (1997), s. 56–58.
- F. Ricci, L. Rokach i B. Shapira. Recommender Systems Handbook. W: (w:) Recommender Systems Handbook. T. 1–35. 2010, s. 1–35.
- B. Sarwar i in. Item-Based Collaborative Filtering Recommendation Algorithms. W: „Proceedings of ACM World Wide Web Conference” 1 (2001).
- B. Schwartz. The Paradox of Choice: Why More Is Less. W: 82 (2005), s. 605–610.
- G. Shani i A. Gunawardana. Evaluating Recommendation Systems. W: (w:) Recommender Systems Handbook. T. 12. 2011, s. 257–297.
- H. Steck. *Evaluation of Recommendations: Rating-prediction and Ranking*. 2013, s. 220.
- X. Su i T. Khoshgoftaar. A Survey of Collaborative Filtering Techniques. W: „Adv. Artificial Intelligence” 2009 (2009).
- Z. Sun i in. „Are We Evaluating Rigorously? Benchmarking Recommendation for Reproducible Evaluation and Fair Comparison”. W: *Proceedings of the 14th ACM Conference on Recommender Systems*. RecSys ’20. New York, NY, USA: Association for Computing Machinery, 2020, s. 23–32.
- S. Zhang i in. Deep Learning Based Recommender System: A Survey and New Perspectives. W: „ACM Computing Surveys” 52.Nr 1 (2020), s. 1–38.
- W. X. Zhao i in. „RecBole: Towards a Unified, Comprehensive and Efficient Framework for Recommendation Algorithms”. W: *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*. CIKM ’21. New York, NY, USA: Association for Computing Machinery, 2021, s. 4653–4664.

Źródła internetowe

<https://www.bookbeat.com/pl/about> (dostęp 13.07.2026).

<https://www.imdb.com/pressroom/stats/> (dostęp 13.07.2026).

<https://newsroom.spotify.com/company-info/> (dostęp 13.07.2026).

Spis tabel

1	Podsumowanie statystyczne zbioru danych MovieLens 100K wykorzystanego w eksperymentach	29
2	Zestawienie przestrzeni hiperparametrów (siatki) dla poszczególnych algorytmów	47
3	Wyselekcjonowane, optymalne wartości hiperparametrów dla badanych modeli	48
4	Porównanie wyników metryk oceny dla testowanych algorytmów rekomendacyjnych na zbiorze MovieLens 100K.	49

Spis rysunków

1	Taksonomia i historyczny podział algorytmów rekomendacyjnych uwzględnionych w badaniach.	10
2	Rozkład popularności filmów w zbiorze MovieLens 100K przedstawiający zjawisko długiego ogona (<i>Long-Tail Distribution</i>).	24
3	Rozkład ocen jawnych w zbiorze MovieLens 100K obrazujący efekt zjawiska <i>positivity bias</i>	25
4	Rozkład liczby wystawionych ocen per użytkownik w zbiorze MovieLens 100K	28
5	Architektura hybrydowego modelu Neural Matrix Factorization (NeuMF)	37
6	Architektura algorytmu LightGCN z uwzględnieniem propagacji warstwowej	39
7	Wpływ hiperparametrów k oraz <i>shrinkage</i> na trafność modelu ItemKNN .	44
8	Wpływ współczynnika uczenia oraz rozmiaru wektora zanurzeń na trafność modelu BPR	45
9	Wpływ współczynnika uczenia oraz parametru dropout na trafność modelu NeuMF	45
10	Wpływ wagi regularyzacji oraz liczby warstw propagacji na trafność modelu LightGCN	46
11	Krzywe zbieżności metryki NDCG@10 na zbiorze walidacyjnym dla algorytmów BPR, NeuMF oraz LightGCN.	50
12	Zestawienie czasu uczenia względem ostatecznej skuteczności dla badanych modeli.	51